

分类号 TP391

密级 公开

UDC

编号

雲南大學

碩士研究生學位論文

題 目 基于U-Net的天文圖像复原方法研究

Title Research on Restoration Method
of Astronomical Image Based on
U-Net

學院（所、中心） 信息學院

專業名稱 電子與通信工程

研究方向 天文圖像處理

研究生姓名 黃鑫龍 學號 12019202174

導師姓名 周 浩 職稱 副教授

2022 年 5 月

摘要

天文研究对望远镜拍摄到的天文图像要求日益增高，然而在天文图像的拍摄过程中，受到望远镜自带噪声和外界环境等因素的干扰，天文图像的质量大多不尽人意，因此必须提高天文图像的质量，有效的天文图像处理方法能够加快天文研究的进展。传统的图像处理方法虽然在一定程度上解决了此问题，但其方法简单，且速度慢，效率不高，并且模型简单，复原效果在 PSNR 和 SSIM 的表现上不够好。传统方法不足以应对目前科学研究的发展，因此，本文采用深度学习的方法来对天文图像进行处理。

本文首先介绍了天文图像噪声产生的原因以及特性，并在此基础上阐述了不同退化模型对天文图像的影响。其次对传统图像算法与基于深度学习的复原算法进行了分析，指出了各个方法的优势与缺点。

其次，本文针对天文望远镜在拍摄过程中耗时长和受到噪声等问题的干扰，在此基础上构建了图像生成的数学模型。提出使用 U-Net 来进行地曝光天文图像的复原，并在 U-Net 基础之上添加注意力机制对网络进行改进，低曝光图像作为网络的输入，采用多种损失函数与激活函数来优化网络。实验结果表明，最终的神经网络能够很好的对天文图像进行复原，在 PSNR 指标提高了近 5%，SSIM 指标上提高了 0.5 左右。

最后，针对天文图像存在不同种离焦退化的问题，考虑了退化模式的种类和分布，采用基于深度学习的盲复原的方式，构建了四种用于图像复原复原的点扩散函数。并提出 ResNet 与 U-Net 构建深度学习模型 ResUNet。实验证明，本文所提出的点扩散函数能够有效的复原大部分天文离焦图像，与传统复原算法和部分经典深度学习复原算法相比，基于 ResUNet 的天文图像复原网络有着更优越的性能。

关键词：天文图像处理；深度学习；U-Net；图像复原；点扩散函数

Abstract

Astronomical research has increasingly higher requirements for astronomical images captured by telescopes. However, in the process of shooting astronomical images, due to the interference of the telescope's own noise and external environment, the quality of astronomical images is mostly unsatisfactory. Therefore, it is necessary to improve the quality of astronomical images. Effective astronomical image processing methods can accelerate the progress of astronomical research. Although the traditional image processing method solves this problem to a certain extent, the method is simple, slow, inefficient, and the model is simple, and the restoration effect is not good enough in the performance of PSNR and SSIM. Traditional methods are not enough to deal with the development of current scientific research. Therefore, this paper adopts deep learning method to process astronomical images.

This paper firstly introduces the causes and characteristics of astronomical image noise, and on this basis, expounds the influence of different degradation models on astronomical images. Secondly, the traditional image algorithms and the restoration algorithms based on deep learning are analyzed, and the advantages and disadvantages of each method are pointed out.

Secondly, this paper builds a mathematical model of image generation based on the problem that the astronomical telescope takes a long time and is disturbed by noise during the shooting process. It is proposed to use U-Net to restore ground-exposure astronomical images, and add an attention mechanism to improve the network on the basis of U-Net. The low-exposure image is used as the input of the network, and various loss functions and activation functions are used to optimize the network. The experimental results show that the final network can restore astronomical images well, and the PSNR index is improved by nearly 5%, and the SSIM index is improved by about 0.5.

Finally, in view of the problem of different kinds of defocusing degradation in

astronomical images, considering the types and distribution of degradation modes, four kinds of point spread functions for image restoration and restoration are constructed by means of blind restoration based on deep learning. And proposed ResNet and U-Net to build a deep learning model ResUNet. Experiments show that the point spread function proposed in this paper can effectively restore most astronomical defocused images. Compared with traditional restoration algorithms and some classical deep learning restoration algorithms, the ResUNet-based astronomical image restoration network has better performance.

Keywords: Astronomical Image Processing; Deep Learning; U-Net; Image Restoration; Point Spread Function

目 录

第一章 绪论.....	1
1.1 图像复原.....	1
1.2 课题研究背景及意义.....	2
1.3 国内外研究现状.....	3
1.4 天文图像处理存在的问题	5
1.5 图像复原效果的评价.....	6
1.5.1 有参考型的图像质量评价.....	6
1.5.2 无参考型图像质量评价.....	7
1.6 本文结构和主要工作.....	8
1.7 本章小结.....	9
第二章 图像的预处理及典型复原算法分析	11
2.1 噪声的分类及去噪方法的性能分析	11
2.2 模糊分类和退化模型分析	13
2.2.1 模糊分类.....	13
2.2.2 退化模型分析.....	14
2.3 经典图像复原方法分析和比较	16
2.3.1 维纳滤波复原法.....	16
2.3.2 LR(Lucy-Richardson)复原算法	17
2.4 基于机器学习的图像复原算法	19
2.5 本章小结.....	19
第三章 基于改进 U-Net 的低曝光天文图像复原研究	21
3.1 研究背景.....	21
3.2 U-Net 理论基础.....	22
3.2.1 下采样层	22
3.2.2 上采样层	23
3.2.3 网络细节	24
3.2.4 本文所使用激活函数与损失函数介绍	24
3.3 U-Net 神经网络的改进.....	26
3.3.1 注意力机制.....	26
3.3.2 Attention-UNet 网络结构.....	27
3.4 数据处理与实验设置.....	28
3.4.1 数据集.....	28
3.4.2 实验过程.....	29
3.5 实验结果与分析.....	30

3.5.1 不同实验设置结果及分析.....	30
3.5.2 Attention-UNet 与 U-Net 的对比.....	31
3.5.3 实验结果分析.....	32
3.6 本章小结.....	35
第四章 基于 U-Net 的离焦天文图像复原	37
4.1 研究背景.....	37
4.2 图像复原原理.....	38
4.3 退化模型的设计.....	39
4.4 Res-UNet 网络架构.....	40
4.4.1 ResNet 模块	40
4.4.2 Res-UNet 神经网络	41
4.5 数据处理与实验设置.....	42
4.5.1 数据集介绍.....	42
4.5.2 实验设置.....	43
4.6 实验结果与分析.....	44
4.6.1 实验结果.....	44
4.6.2 结果分析.....	48
4.7 本章小节.....	50
第五章 总结与展望	51
5.1 工作总结.....	51
5.2 展望未来.....	51
参考文献.....	53

第一章 绪论

从古至今，天文学的研究从未间断。在人类历史的初期，人们就会通过天上的太阳，月亮，以及星象来确定时间的推移和季节的变换。无论如何，人类观测天体方法都和天体的运动有关，特定的天体会具有一定的运行规律，能够从中观测出来。

因此，天文学主要靠观测来得出结论，它是一门以观测为主的学科，从事天文研究都必须要进行天文观测。

望远镜的发明使得天文观测更加方便和精准，现阶段，人们了解无穷宇宙的主要方法都是通过天文望远镜来观测。通过望远镜的观测，可以得到特定的天体的天文图像，再对天文图像进行分析与研究，以此来获得相应天体的一些基本物理属性，天体的尺寸、天体的质量以及天体的运行规律等都可以被计算出来，而高质量的天文图像也是精准观测的基础，也是关键所在，这也是天文研究领域的热门话题。

从上个世纪六十年代开始，计算机技术不断发展，这使得图像处理技术也逐渐发展壮大起来。在九十年代，电脑越来越流行，数字图像处理技术也慢慢扩展起来，开始应用到天文领域。因为天文观察不同于寻常的摄影任务，所以望远镜的拍摄时间受到限制，而且对一定范围的观测也不能长期保持，所以，通过拍摄到的天文图像曝光时间大多不够长，并且在天文望远镜进行天文拍摄时，容易受到大气湍流和天空背景等因素的影响，这导致天文图像发生不同层级的退化，而CCD曝光时间较短，因此在每一个观测时间段内都会采集到数以万计的天文图像，因此，天文观测的结果分析中用到了大量的图像处理技术，天文观测领域的图像处理技术逐渐发展起来。

1.1 图像复原

图片在收集、传播与保存的过程中，由于受各种原因的影响，最后所得的图片难免会产生一定程度的降质。为减少或去除图像的降质，对降质图像进行一系

列的处理，以便恢复图像的原始特征，这一步骤称为图像恢复。

图像复原理论首先要利用数理计算与演绎的方式形成退化模式，再进而运用衰退模式对原来图像做出合理的预测。所以，人们也可将图像复原理论看作是人为的图像模糊的可逆过程。所以，退化模型的构建是图像复原中最主要也是最重要的一步。在实际科学研究与实验的处理过程中，单纯地依靠退化模型通过推演计算，进而还原全真的原版图像是相当困难的。但是，人们可以选择相应的准则作为对图像复原有效性的评判准则，以便使对原版图像的评估误差在人们可以承受的范围。

为了退化模型的构建，我们必须通过实际的退化原因来完成数理统计和算法推理工作，而由于退化原因的多样化又直接决定着模型的复杂度，并在不同拍摄过程中的退化过程也不尽相同。因此，图像复原的处理过程十分困难。

但一般而言，对质量比较差的降质图像的恢复，能从以下两个方面入手。一个方向是在对质量较低的图像的信息内容完全掌握的情形下，基于掌握的信息内容对退化模型加以描述、推导和构建，进而使用最优的恢复方案对降质图像实施恢复。而另一种方向则是在对降质的图像的信息内容了解不足的情形下，基于特定场合中出现的退化因素对退化模型加以预测和构建，进而依据该模式具体情况选用最适当的图像恢复方案，对图像实施恢复。

1.2 课题研究背景及意义

本文研究的天文图像为地面观测的图像与空间中观察图像，地面观测是一个比空间观察更加灵活的观察方法，不但在价格上有很大优势，同时其比较灵活，可以更久的支持长期的观察，所以地面观察是目前天文学观察的主要方法之一。地面观察必须通过整个大气层来收集信息，所以观察到的图像质量较低，观察到的图像会出现各种情况的退化，退化图像产生的主要因素就是图像系统的光学特性。地面望远镜是地面观察的主要工具，其主要具备下列特性^[1]：(1)集光能力较强，即使天体光亮较弱，也能够被望远镜探测到；(2)分辨力较强，在拍摄的图像中，能够更加轻易地分辨出天体的边缘等细节。通常情形下，地面望远镜的口径越大，则代表其集光力越强，而在同样情形下，口径也越大的地面望远镜可以比较明显的检测到更远处更黑暗的天体。最小分辨角和孔径大小呈负相关，望远镜的孔径

越大，则其最小分辨角就越小，从而可以分辨更为详尽的信息。这也表明，如果想要获取更高精度的观察资料，就必须耗费更多的成本在望远镜的制造上。空间观测则更加复杂，除了需要建造望远镜之外，优化图像中的信息增益也是一个较大的挑战，并且拍摄过程受到噪声的干扰，去除噪声并非易事，但可以增加曝光时间来获得更好的成像和更高的信号，然而，这也会叠加噪声，因此，天文图像的增强和去噪方法能够在一定程度上解决这类问题。

观测到的数据都不是完美的，或多或少都有一定的偏差，通过后期的图像处理技术能观测数据进行复原、去噪和增强，可以在一定程度上降低观测的成本，较粗糙的观测数据也能产生较大的价值。

标准理想的天文图像与点扩散函数进行卷积之后得到退化之后的天文图像。一般情形下，将图像还原为此过程的反演，如果存在一定的先验信息，则能够在一定程度上还原出标准图像的相似图像。在缺少相应先验信息的情况下，PSF 的建模是非常复杂的，不同环境下对应有不同的 PSF，建模难度大，因此对此类星象复原方法的研究具有前瞻性的意义。

1.3 国内外研究现状

在天文观测研究领域，天文图像复原技术一直以来都是一项非常关键的科学研究领域，为了使得望远镜拍摄到的天文图像能够进行更好的使用，在最近的几十年内，越来越多的天文学者开始使用图像处理的方式来对天文图像进行相应的处理。在 1998 年，Courbin 等^[1]在研究引力的过程中，采用了反卷积的方式，并取得了很好的效果。1999 年，Zavagno 等^[2]则对天文图像进行了重构，并使得重构后的天文图像具有更高的分辨率，从而探测到了存在于恒星内部的一些构造。2000 年，Marchis 等^[3]对一些低分辨率的木卫一图像进行复原，通过对结果的观察发现了木卫一上内部火山的活动。

早期的天文图像恢复方案大多是 A.Labeyri 等^[4]提出的图像重建方案，不过该方案存在一定的局限，必须提前知道波前信号，所以可以对图像进行离线处理，实时性达不到要求。传统的逆滤波方式首先将图像进行傅里叶转换后，将频率域下的数据进行反卷积方式运算，此方式虽然在速度上占有很大的优势，不过在效率上却还并非非常优秀，此过程假设图像都是相对标准的，所以不会引起噪音的

污染，不过由于实际状况下的图像都有相应的噪声污染，所以在反卷积方式的处理过程中也会同时放大图像中相关的噪音，因此采用逆滤波来对天文图像进行复原显得捉襟见肘。到了 1974 年，Hogbom 提出 CLEAN 算法^[5]，此方案能够将图像进行分解，最后在结合其他方案将图像进行一定程度的还原。但是此方法也存在一定的不足，在面对大尺寸的天文图像时，其表现出来的效果不是很好。到了 1987 年，Tikhonov 等^[6]通过加入正则项的方式来对模型进行调优，从而使得反卷积的过程更加完善，在此基础上，其他一些更加优化的方法如维纳滤波法也被提出，这些方法都存在一些问题，无法解决吉布斯效应，使得更多的高频信息被丢失掉，并且在先验信息不够充分的情况下效果也十分不理想。为了能够在图像处理中利用更多的先验信息，Lucy 等^[7]给出了基于贝叶斯定理的反卷积方法，该方法首先假定图像中的所有信息都是以泊松分布的形态存在的，然后再使用最大似然函数进行计算，经过不断迭代，进而获得复原的图像。此方案比较适合于图像中信噪比较高的情况下，但信噪比较低时很容易加大图像中的噪音。

传统的反卷积算法假设天文观测图像中各部分的点扩散函数都是相同的，但是在实际情况中，一张天文图像可能有好几种点扩散函数，因此使用单个的 PSF 不太适用于较为复杂的情况。2011 年，焦继超等^[8]提出了一个局部天文图像修复算法，通过构建初始的光点扩散函数模型，然后再对图像的不同地方进行切割，最后在进行盲反卷积，虽然此方法在一定程度上也可以控制天光背景以及大气湍流等对噪声的影响。2016 年，刘国梁等^[9]给出了一个可以自动停止迭代的新算法，该算法采用盲反卷积原理，并经过实践证明，该算法在实际的应用过程中也具有相当良好的效果。

随着计算机硬件的快速发展以及深度学习理论的突破，深度学习方法开始应用到图像领域，神经网络具有强大的拟合能力，实验证明，在理想的情况下，可以拟合任何函数，随着技术的发展，神经网络也得到了飞速的发展与创新，以及更加完善的训练方式，深度学习在计算机视觉上取得了巨大成功。其在图像识别、目标检测、图像超分等任务中得到了广泛的应用，计算机硬件的发展加速了神经网络的进步，同时也为神经网络推理提供了有力的保障。近年来，通过研究人员的不断实验，产生了众多的深度学习框架，并逐渐应用到各个领域。2012 年，Alex 提出了 AlexNet，拿下了当时比赛的冠军，网络的创新在于加入了 ReLU 激活函数

来对网络进行非线性映射，并在在一定程度上降低了网络的计算量和复杂度。在 2014 年，Christian 等人设计并宣布了 GoogleNet^[10]，该网络引入了 Inception Module 部分，极大地减少了参数量，参数量为 4M，同时也能优秀的解决问题。同年，Visual Geometry Group 使用 3x3 的卷积核堆叠构建了经典的 VGGNet^[11]，节省了计算开销。2016 年，何凯明等^[12]提出了 ResNet，引入了残差模块(Residual Block)，通过跳跃连接的方式，将上层的信息传送到下一层，减小了梯度消失等问题的产生，即使网络层数很深，网络仍然能够表现出很好的性能。

在图像处理领域，深度学习的应用颇为广泛，目标检测跟踪、目标分类以及图像复原等都有涉及。2016 年，Chao 等^[13]在图像复原领域采用了深度学习算法，提出了一种 SRCNN 网络模型，这种模型的基础是卷积神经网络，优势在于隐藏层就进行了图像的预处理，进而大大缩减了工作量，并在评价结果好坏时用到了 PSNR(峰值信噪比)和 SSIM(结构相似性)。随后，他们对模型进行了一系列改进，最终提出了 FSRCNN 模型^[15]，进一步加快了模型的训练。2017 年，Sainandan 等^[14]首次采用 GAN(生成对抗网络)来对真实情况下的模糊图像进行复原，通过 VGG 计算特征图像的损失，对图像的细节部分做到了很好的处理。

1.4 天文图像处理存在的问题

天文望远镜拍摄到的照片不同于平时生活中我们拍摄到的照片，在天文拍摄任务中，或多或少都会存在一定的干扰，目前主要有两种方法来对天文拍摄到的图像进行复原，MAP 和基于贝叶斯的方案，通过对两种方法进行分析与对比，发现在有的时候 MAP 具有更好的效果，但是在另外的一些情况下，贝叶斯则具有更好的效果，且实验论证，贝叶斯方法具有在图像处理时更加稳定，在一些关于图像超分辨率的相关论文中，也得到了证实^[15-17]。

在离焦模糊图像的复原方面，存在一系列的退化模型，主要存在两种比较常见的退化模型，一种是圆盘模型，另一种则是高斯模型，圆盘模型偏向推理，是根据光学知识推理得到的^[18]。但是在现实拍摄任务中，光并不会像理论知识所描述的那样传播，光在传播的过程中会遇到各种情况，甚至会发生一系列的折射，这样一来，圆盘模型就不太适应于真正情况下的退化模式了^[19]，所以圆盘模型实用价值并不高，也不常用。高斯模型则不仅考虑了光学传播特性，并且也考虑了

一些其他的综合因此而得出，因此，在实际的使用时，通常采用高斯模型来解决相应的问题。

在上文的描述中，图像处理技术在不断的发展之中，图像复原方法千差万别，不同的处理方法都有其优点和不足。因此在进行图像的处理时，我们需要针对不同的场景选择比较适合的处理方法，这是目前天文图像处理领域一个亟待解决的问题。

1.5 图像复原效果的评价

在进行图像复原之后需要采用一定的指标来衡量图像复原的效果。评价方法主要有基于个人的主观评价和基于函数的客观评价，具体分类如下文。

1.5.1 有参考型的图像质量评价

所谓有参考型的图像质量评价就是要提供一幅标准的图像作为参考图像，然后通过一些客观的评价函数的值来说明复原图像与标准图像之间的差距，这些常见的评价函数的值有：均方误差(MSE)、峰值信噪比(PSNR)等。

(1) 均方误差

均方误差作为一种有参考型的图像质量评价函数，广泛应用于各种图像评价体系，求得预测复原图像与标准理想的清晰图像之间每个像素灰度值得绝对和。有定义可以知道，均方误差越小，则图像的复原程度越高，离标准图像的差距越小。假设标准理想清晰图像为 $f(x, y)$ ，其长和宽分别为 M 和 N ， $f(m, n)$ 代表了预测的复原图像和标准理想的清晰图像中对应点 (m, n) 的灰度值的大小，则均方误差可以用下面的式子进行描述：

$$MSE = \frac{1}{MN} \sum_{m=1}^M \sum_{n=1}^N (f(m, n) - f'(m, n))^2 \quad (1-1)$$

(2) 峰值信噪比

峰值信噪比衡量了图像的恢复程度，其计算公式需要用到上文所描述的均方误差，具体的表达式如下所示：

$$PSNR = 10 \log \frac{L \times L}{MSE} \quad (1-2)$$

在 PSNR 的描述中，代表了 L 图像的灰度值的取值范围，且最终 PSNR 的值越大，则说明图像的复原效果越好，值越小，则复原效果越差。

(3) 结构相似度

结构相似度(Structural Similarity Index, SSIM)作为图像恢复的另一种评价指标，它能够从亮度、对比度和结构三个方面来对图像进行综合评价，SSIM 的取值范围为[0, 1]，值越大，则说明复原之后的图像的失真度越小，相反则大，计算公式可表示如下：

$$\left\{ \begin{array}{l} SSIM(x, y) = L(x, y)^a C(x, y)^b S(x, y)^c \\ L(x, y) = \frac{2\mu_x \mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_2} \\ C(x, y) = \frac{2\sigma_x \sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2} \\ S(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x \sigma_y + C_3} \end{array} \right. \quad (1-3)$$

$$c_1 = (k_1 L)^2 \quad (1-4)$$

$$c_2 = (k_2 L)^2 \quad (1-5)$$

$$c_3 = \frac{c_2}{2} \quad (1-6)$$

在上面的式中， μ 为图像像素的均值， σ 为标准差， σ_{xy} 表示协方差， abc 代表对应数据的权重系数， $C_1 C_2 C_3$ 可以取较小的值。

1.5.2 无参考型图像质量评价

与有参考型的评价指标有所不同，无参考型的评价指标则不提供标准理想的清晰图像，而通过使用一些函数来衡量复原出的图像的效果。常用的评价函数如下：

(1) 灰度的平均梯度法

梯度法将相邻的像素进行横向和纵向作差，然后作差之后结果的平方和，值越大，则说明其效果越好，可以用如下的公式表示：

$$GMG = \frac{1}{(M-1)(N-1)} \sum_{m=1}^{M-1} \sum_{n=1}^{N-1} \sqrt{\frac{[f(m,n+1) - f(m,n)]^2 + [f(m+1,n) - f(m,n)]^2}{2}} \quad (1-7)$$

在上面的式子中， $F(m,n)$ 代表了所预测图像的 m 行和 n 列的值， M 和 N 则分别代表了预测图的长和宽。

(2) 信噪比

即信号和噪声的功率之比，公式表示如下：

$$SNR = 10 \log \frac{\text{退化图像的方差}}{\text{噪声的方差}} \quad (1-8)$$

1.6 本文结构和主要工作

本文研究主要基于天文望远镜观测得到的离焦天文图像和低曝光时间的图像，致力于提出一种基于深度学习的天文图像增强与去噪算法和一种天文图像离焦星象复原算法。本文的具体内容安排如下：

第一章介绍了本文所研究课题的背景以及意义，对比了基于传统图像复原算法和基于深度学习的图像复原各自的优缺点。并阐述了不同阶段图像复原的发展历程，分析了天文观测需要高质量天文图像的原因，为下文的算法设计提供了方向。

第二章主要介绍了天文图像退化的过程、天文图像的噪声来源以及分类、以及经典天文图像复原算法的比较分析和一些前沿的深度学习复原算法理论。

第三章基于 U-Net 提出了一种低曝光天文图像的复原算法，介绍了网络的各个架构，并采用注意力模块来对网络进行改进。并在多组实验对比的情况下，证实了本文所提出算法的有效性。

第四章主要介绍了 ResNet 和 UNet 等相关算法原理。针对天文望远镜拍摄到的离焦天文图像存在不同程度退化和带有噪声等问题，本章根据离焦天文图像的特点，本文通过对离焦模型进行分析选出了四个常用的离焦模型，并提出了一种基于 ResNet 与 U-Net 相结合的天文图像复原算法，提高了离焦天文图像的复原效果。

第五章为整篇论文的总结与展望，首先对本文所研究的重点内容进行了总结，

随后分析了本文所改进和提出的算法存在的不足之处，对未来模型的改进方向提出了建议。

1.7 本章小结

本章首先介绍了本文的研究意义和研究背景，阐明了天文图像增强与去噪和离焦天文图像的复原的研究价值。随后介绍了图像复原的发展历程以及图像处理技术在天文图像复原领域的应用，然后介绍了具有代表性意义的基于深度学习的图像复原算法。阐述了天文图像处理的难点与离焦天文图像复原的研究现状与在现阶段遇到的问题和局限性，最后总结了本文的总体安排。

第二章 图像的预处理及典型复原算法分析

在我们的日常生活中，我们所拍摄获取到的图像大多数都是收到了有一定程度的噪声污染，特别是在高精度的拍摄任务中，清晰理想的图像显得十分重要，为了使得图像发挥出更大的价值，需要对其进行一定程度的处理，然后再进行相关的分析流程。本章首先分析说明了在拍摄过程中产生各种噪声的原理，然后对噪声的一些处理方法进行了对比和说明。针对文章的研究方向，对不同的退化模型和方式进行了必要的阐述，最后讨论了基于深度学习的图像复原算法的优势。

2.1 噪声的分类及去噪方法的性能分析

在拍摄图像时，无论何种情况下，所拍摄到的图像都会携带一定程度的噪声，我们所拍摄到的图像实际上是噪声与原始图像叠加之后的结果，因此其内部包含了噪声与原始图像的相关信息。在对图像中使图像质量下降的噪声进行处理的过程中，有多种方式，我们可以选择对其进行不同批次的处理去噪，也可以把最后产生的噪声之后放在最后步骤进行消除。噪声在产生的过程中也可以通过相关原理分为不同的种类，不同种类的噪声需要采取不同的去噪方法来进行去噪。因此，在图像复原的过程中，了解噪声的来源以及噪声产生的原理显得十分必要。

（1）按产生的原因分类

在任何拍摄任务中，噪声都可能被分为两大类，一类是外部噪声，顾名思义，外部噪声即为外界环境所产生的噪声，如天空背景，大气湍流等都会造成天文图像的退化。另一类则是内部噪声，同理，内部噪声是由于机器内部相关电子元件所产生的噪声。

上述噪声分类的方式虽然在一定程度上能够获取到相关源头，但最终也只能在原理上提供一些参考而已，不能够在根本上解决噪声的问题。

（2）按噪声的频谱分类

主要分为白噪声、三角噪声以及 $1/f$ 噪声等。 $1/f$ 噪声是频率和频谱成反比的，每个系统中或多或少都会存在一定 $1/f$ 噪声；白噪声则比较特殊，它均匀分

布在拍摄出的图像的各个角落。

（3）按噪声与信号的关系分类

噪声可以被分为以下几个类别：

a)乘性噪声:该噪声与我们拍摄到的图像的信号的强度存在正相关的关系，如果拍摄到的图像的信号越强，则相对而言，图像中含有更多的乘性噪声。

b)加性噪声:与乘性噪声不同的是，加性噪声不会随着图像信号的强度增加而增加，该噪声与图像的强度之间没有必然关系，信道噪声则是加性噪声的一种类别。

（4）按概率密度函数分类

噪声在有的时候会以一定的数学模型来呈现，因此可以在适合的情况下采用一定的数学模型来进行去噪处理，主要有以下几类：

a)高斯噪声:顾名思义，高斯噪声服从高斯分布或者是正态分布。包含了经常出现在天文图像中的宇宙射线和一些热噪声等。高斯噪声有两个比较重要的参数，一个是噪声的均值，另一个则是噪声的方差，噪声的均值和方差决定了高斯噪声的大小，方差较小则说明噪声较小，如果方差变大，则图像质量也会急剧下降。

b)瑞利噪声:噪声可以看做是一个随机产生的二维向量，组成这个二维向量的分量不存在相关关系，分别都是独立分布，如果当这两个二维分量有相同的方差且分布都表现为正态分布，此时，此二维向量即是瑞利分布的形式。

c)指数函数噪声

d)伽马噪声

e)均匀分布噪声

f)椒盐噪声:在离散系统中，会产生部分的脉冲噪声，此种噪声又称为椒盐噪声，有点像胡椒和盐的点状分布，这些噪声都是又脉冲产生，胡椒形状的噪声大多是由系统中的正脉冲产生，与此对应，盐状的噪声大多数情况下都是由系统中的负脉冲产生。脉冲噪声的影响受到系统环境的影响，系统电路或者是通信环境存在缺陷和一些电磁干扰都会产生或多或少的脉冲噪声。

噪声的产生也伴随着噪声消除方法的提出，中值滤波、均值滤波和最大/最小值滤波等相继被提出。中值滤波可以很轻松的去掉椒盐噪声，在对椒盐噪声进行滤波时大多数情况都采用中值滤波，中值滤波速度快，能够快速的对椒盐噪声污

染的图像进行滤波。均值滤波和最大/最小值滤波也有其对应的适用环境。

上段提到的滤波方法经过时间的检验，都是比较经典的滤波方法，但是除了上述的一些方法之外，还有一些其他的滤波方案，比如小波滤波方法^[20-21]，在图像复原时，虽然此类方法在对天文图像进行复原时能够对图像的边界进行很好的保护，但是其速度慢计算效率低是一个比较严重的问题，因此结合不同滤波器的优点能够对效率和速度做到均衡^[22]。

2.2 模糊分类和退化模型分析

2.2.1 模糊分类

(1) 运动模糊

在摄像机的拍摄过程中，难免会发生摄像机的运动，此时可能产生图像的模糊，以此类方式产生的模糊通常被称为运动模糊。运动模糊遵循一定的规律，如果说以匀速直线运动来模拟运动模糊，可以假设摄像机的拍摄水平方向与被拍摄的物体之间存在一个 θ 的夹角，且此时的物体以一种匀速状态运动，不仅如此，在拍摄过程中，相机与物体之间还会产生一个 d 像素的位移，则此类退化模式可以表示如下：

$$h(x, y) = \begin{cases} 1/d, & 0 \leq x \leq d \cos \theta, y = x \tan \theta \\ 0 & \text{其他} \end{cases} \quad (2-1)$$

(2) 离焦模糊

离焦，即为对焦不准，大多数离焦天文图像出现都是对焦不准造成的，此时。由常用的光学知识可以得出，焦距没有调试好的时候，图像的退化模型可以看成是一个光斑，此类光斑一般成均匀分布的形式，数学模型可以表示为：

$$h(x, y) = \begin{cases} \frac{1}{\pi R^2}, & \sqrt{x^2 + y^2} \leq R \\ 0, & \sqrt{x^2 + y^2} > R \end{cases} \quad (2-2)$$

其中 R 是离焦斑半径。

(3) Gauss(高斯)模糊

高斯模糊与之前描述的模糊模式的重大不同点在于高斯模型不仅考虑了基本

模糊类型，更是整合了图像的拍摄过程中的各种情况而得出的结论，公式如下：

$$h(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \quad (2-3)$$

前文已经描述，高斯模型有一个重要的参数，一个是 σ ，代表了高斯模型的方差， σ 的值决定了高斯模糊的程度， σ 越大，则说明图像越模糊， σ 越小，则说明图像更加清晰。

2.2.2 退化模型分析

在图像进行拍摄的过程中，拍摄环境可能存在很大的不同，且不同摄像机拍摄出来的图像中间也会存在很大的差距，因此，拍摄到的图像会存在千差万别的退化模式，甚至不同图像都会存在不同的退化函数。对退化模式的分析至关重要，关系到了图像复原的质量，本节对退化模型的相关理论进行深入的分析和推导。

(1) 连续函数退化模型

通常情况下，标准的理想图像 $f(x, y)$ 作用与相机拍摄时的退化系统 $H(x, y)$ ，此时产生模糊的离焦图像，但是退化过程中不仅受到 $H(x, y)$ 的干扰，还存在额外的一些加性噪声 $n(x, y)$ ，因此在模型经过系统之后，还应该添加相应的噪声才能正确的模拟退化模式，此时，添加加性噪声之后的图像表示为 $g(x, y)$ ，可以用如下式子表示：

$$g(x, y) = H \cdot [f(x, y)] + n(x, y) \quad (2-4)$$

所以，图像退化的一般模型可表示如图 2.1:




图 2.1 图像退化模型

定义 $\delta(x, y)$ 为二维冲激函数，则 $\delta(x - \alpha, y - \beta)$ 可以表述为前面所述冲击函数

的一个延迟, 在信号系统的相关理论可以知道, $f(x, y)$ 能够表示为如下所示的式子:

$$f(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(\alpha, \beta) \delta(x - \alpha, y - \beta) d\alpha d\beta \quad (2-5)$$

由 $g(x, y) = H \cdot [f(x, y)] + n(x, y)$ 可知, 令 $n(x, y) = 0$, 则可得出下式:

$$g(x, y) = H \cdot [f(x, y)] = H \cdot \left[\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(\alpha, \beta) \delta(x - \alpha, y - \beta) d\alpha d\beta \right] \quad (2-6)$$

由于系统是线性的, 所以系统函数 H 可以理解为一种线性算子, 所以:

$$g(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(\alpha, \beta) H \cdot \delta(x - \alpha, y - \beta) d\alpha d\beta \quad (2-7)$$

设 $h(x, \alpha, y, \beta) = H \cdot \delta(x - \alpha, y - \beta)$, 则有:

$$g(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(\alpha, \beta) h(x, \alpha, y, \beta) d\alpha d\beta \quad (2-8)$$

在上面所示的几个式子中, $h(x, \alpha, y, \beta)$ 为系统的退化函数。即 $h(x, \alpha, y, \beta)$ 是相机系统函数 H 在坐标点为 (α, β) 处函数 $\delta(x - \alpha, y - \beta)$ 的响应。

如果拍摄系统的空间位置不曾改变, $H \cdot \delta(x - \alpha, y - \beta) = h(x - \alpha, y - \beta)$, 则上式可以写成如下所示:

$$g(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(\alpha, \beta) h(x - \alpha, y - \beta) d\alpha d\beta \quad (2-9)$$

如果存在加性噪声 $n(x, y)$, 则上式可表示为:

$$g(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(\alpha, \beta) h(x - \alpha, y - \beta) d\alpha d\beta + n(x, y) \quad (2-10)$$

式 2-10 表示了一种连续系统的退化方式。

(2) 离散函数退化模型

从式 2-8 和式 2-9 可以很明确的看出, $f(x, y)$ 和 $h(x, y)$ 在系统的运作过程中需进行了卷积操作。从以上的推导可以得出离散退化模式的相关表达式。

假设图像的长和宽分别为 A 和 B , PSF 的大小分别为 C 和 D , 可以得出:

$$g(x, y) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f(m, n) h(x - m, y - n) \quad (2-11)$$

$$g_e(x, y) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f_e(m, n) h_e(x-m, y-n) \quad (2-12)$$

在上面的式子中， $f_e(x, y)$ 和 $h_e(x, y)$ 是由 $f(x, y)$ 和 $h(x, y)$ 进行延拓之后得到的，延拓周期的大小分别为 M 和 N ，且规则可以表示为如下式子：

$$f_e(x, y) = \begin{cases} f(x, y) & 0 \leq x \leq A-1 \\ f(x, y) & 0 \leq x \leq B-1 \\ 0 & A \leq x \leq M-1 \\ 0 & B \leq x \leq N-1 \end{cases} \quad (2-13)$$

$$h_e(x, y) = \begin{cases} h(x, y) & 0 \leq x \leq C-1 \\ h(x, y) & 0 \leq x \leq D-1 \\ 0 & C \leq x \leq M-1 \\ 0 & D \leq x \leq N-1 \end{cases} \quad (2-14)$$

在延拓的过程中需要避免重叠，因此对参数要求做了一定的限制，其中 $M \geq A+C-1$ ， $N \geq B+D-1$ ，可以得到如下式子：

$$[g] = [H][f] \quad (2-15)$$

其中 $[H]$ 和 $[f]$ 分别是经 $h_e(x, y)$ 和 $f_e(x, y)$ 拓展之后的矩阵。

在前文的对于退化模型的描述中，所假设的情况比较理想，因此在我们的拍摄任务中，系统的退化模型 $h(x, y)$ 通常是不可知的，因此对于清晰理想图像的估计难以实现，所以说处理实际拍摄的退化图像的过程是相当复杂的。

2.3 经典图像复原方法分析和比较

2.3.1 维纳滤波复原法

前文所述逆滤波在处理不可知 $H(u, v)$ 的情况下存在很大的局限性，在此基础上，维纳滤波复原法^[23,24]被提出，维纳滤波在处理图像的效率上有非常明显的优势，速度快，计算复杂度也不高，并且对于图像的复原也相当优秀，因此其被广泛的使用。

维纳滤波和最小二乘比较类似，都是寻找一个对应的估计值 $\hat{f}$ 使得损失函数

$e^2 = E\{(f - \hat{f})^2\}$ 能够达到最小。在前面的描述中, E 是我们期望的操作, f 为我们拍摄到的降质图像, $\hat{f}$ 则是我们经过维纳滤波算法复原之后的预测图像, 可以表示为:

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v) |H(u, v)|^2 + S_f(u, v) / S_n(u, v)} \right] H(u, v) \quad (2-16)$$

在式 2-16 中, $H(u, v)$ 代表了系统函数, $|H(u, v)|^2 = H^*(u, v)H(u, v)$, $H^*(u, v)$ 代表了 $H(u, v)$ 的复共轭函数, $S_n(u, v) = |N(u, v)|^2$ 代表了噪声功率谱的大小, $S_f(u, v) = |F(u, v)|^2$ 代表了原始标准图像的功率谱, $S_f(u, v) / S_n(u, v)$ 表示信噪功率比。

通过 2-16 可以很明显的知道, 我们只要得到了 $H(u, v)$, 再求出信号和噪声功率比, 最后在进一步进行傅里叶逆变换, 就可以很快的求得复原之后的图像。维纳滤波虽在在速度和复原效果上存在一定的优势, 但是维纳滤波依旧需要知道我们需要进行复原的退化图像的相关先验知识, 因此其适用性也比较低。

2.3.2 LR(Lucy-Richardson)复原算法

LR 复原算法实在最小二乘滤波法^[25-28]的基础上进行改进而来。最小二乘滤波法是一种比较先进的滤波方法, 它是一种线性滤波器。

假设 g 为摄像机拍摄到的退化的图像, H 表示为系统的退化模式, f 表示为标准理想的清晰原始图像, n 表示为外部环境等因素产生的加性噪声, 则可以表示为:

$$g = Hf + n \quad (2-17)$$

$$Qf = d \quad (2-18)$$

加入用 2-16 表示标准的原始图像, 则最小二乘就是在 2-19 的限制下求式 2-20 的最小值。

$$\left| Q\hat{f} \right| = d^2 \quad (2-19)$$

$$\tau = \left| g - H \hat{f} \right|^2 \quad (2-20)$$

在上面的式子中， $\hat{f}$ 为式子所估计出来的复原图，则有：

$$L(\hat{f}) = \left| g - H \hat{f} \right|^2 + \mu \left(\left| Q \hat{f} \right|^2 - d^2 \right) \quad (2-21)$$

在 2-21 中， μ 为模型的系数，通过对 f 求导数，则有以下式子：

$$\hat{f} = (\mu Q'Q + H'H)^{-1} H'g \quad (2-22)$$

在上面的式子中， H' 是 H 的转置。

在频域下表示上面的式子则有：

$$\hat{F}(u, v) = \frac{H^*(u, v)}{|H(u, v)|^2 + \mu |Q(u, v)|^2} G(u, v) \quad (2-23)$$

我们可以通过在一定范围内调整 μ 从而使得约束条件满足时，通过选取不同的 Q ，以此适当的改变最小二乘复原法的效果。

L-R 通过最大似然推导而来，公式如下：

$$P(g/f) = \prod_n \frac{a_n g_n \cdot e^{-a_n}}{g_n!} \quad (2-24)$$

在上面的 2-24 中， $g_n = \sum h_{n-1} f_n + n_n$ ， $a_n = \sum h_{n-1} f_n$ ， f_n ， g_n ， n_n 分别表示标准理想的清晰图像 f 、摄像机所拍摄到图像 g 、某些加性噪声 n ， $P(g/f)$ 表示已知标准原始清晰图像 f 条件下，原始图像降质为拍摄图像 g 的概率，由此可以得到：

$$\sum_n g_n \frac{h_{n-k}}{\sum_i h_{n-1}^2 f_i} - 1 = 0 \quad (2-25)$$

通过迭代算法进行计算，可以得到 $\hat{f}$ ，如下式所示：

$$f_{k+1} = f_k \left(\sum_n g_n \frac{h_{n-k}}{\sum_i h_{n-1}^2 \hat{f}_i} \right) \quad (k = 0, 1, \dots, N-1) \quad (2-26)$$

可以知道，L-R 复原算法需要经过大量的迭代来获取更好的结果，虽然可能会在一定程度上优于前面所提到的几种算法，但是需要消耗较大的计算资源，时间复杂度比较高。

2.4 基于机器学习的图像复原算法

近年来，机器学习尤其是深度学习在计算机视觉领域大放异彩，在大量样本的训练下，深度网络在图像复原上表现出了优越的效果。

基于深度学习网络的图像复原算法具有很强的针对性，单个网络大部分都是针对具体的复原任务而言的（比如去噪、去模糊等）。早期 Jain 等人^[32]提出了一种简单的深度网络消除图像中的噪声，取得了与小波变换相当的效果；2016 年，DnCNN 模型^[33]引入批量正则化，同时复原多个噪声图像；19 年 Valsesia 等人^[34]提出通过图神经网络的方式来消除图像中的噪声，也取得了不错的效果。在去模糊方面，Nah 等^[35]利用生成对抗网络来实现模糊图像的复原；2018 年，Xintao 等^[36]人提出利用循环神经网络的 ConvLSTM 模块实现图像去模糊。当然，也有学者在综合复原领域进行了尝试，来复原包含多种退化的图像。Mao 等人^[37]利用对称跳跃连接，提出了一种用于图像去噪和超分的深度卷积自编码网络；MemNet^[38]中利用持久性记忆网络来完成噪声、分辨率和压缩伪影块的修复。

但就当前的情况而言，基于深度学习的复原模型仍然存在一些感受野不够宽阔、端到端方案不成熟等问题，所以基于深度学习的图像复原技术仍有待发展。

2.5 本章小结

本章主要对天文图像噪声产生的原因，退化模型的分类进行了分析，并对基于机器学习的图像复原算法进行了相关的阐述和原理分析，为论文后续方案的实施做好了基础知识的铺垫。

第三章 基于改进 U-Net 的低曝光天文图像复原研究

3.1 研究背景

在天文研究领域，除了建造和开发最先进的望远镜和相机的挑战外，在天文图像处理过程中优化图像中的信息增益也是一个极大的挑战，高质量的天文图像能够对天文数据研究与分析起到推进作用。然而，噪声影响了我们提取我们感兴趣信号的能力，给我们的科学研究增加了限制。仪器噪声，如暗电流和读出噪声可以通过冷却相机和通过减去暗场和平场的图像来降低。然而，从检测到的信号中完全去除噪声并非易事。PSNR(峰值信噪比)是天文观测的一个重要度量指标，它代表了复原天文观测数据信息的优劣程度。

虽然可以通过增加曝光时间来获得更高的信号，以此获得更好的成像，然而，这是以更高的噪声为代价的。也可以叠加多个短曝光的图像来提高信噪比。这个方法增加了图像的深度，减少了噪声，并减少了宇宙射线的数量，然而，这种方法需要长时间的观察和处理来挑选出高质量的天文图像，然后组合起来。

在过去的十年中，已经引入了机器学习方法，包括稀疏、去噪自动编码器、使用字典学习和神经网络去噪，以此来增强图像质量。最近几年，CNN 在图像处理领域大展拳脚，例如去噪、图像风格的转换、图像的重建和图像分割。对于图像到图像的映射，网络通常由卷积层和反卷积层组成。为此，可以使用全卷积网络、生成对抗网络^[39] (GAN)、多尺度上下文聚合网络^[40] (CAN)或 U-Net^[41]。随着许多即将进行的大型天文研究，找到一些更省时的数据分析方法至关重要。神经网络已被应用于天文学中的许多不同任务，包括宇宙网络模拟、检索系外行星大气和图像重建。2017 年，Schawinski 等人使用 GAN 来恢复人工退化图像的特征，而 Chen^[42]提出了用于图像增强 U-Net 用于增强较暗环境中拍摄的图像，能通过暗图像恢复更加明亮的图像，且 U-Net 输入图像格式和大小十分灵活。受此启发，本文提出一种用于天文图像处理的 Attention-UNet，其主要目标是减少观测时间并减少用于科学分析的天文图像中的噪声。

其中最大池化最为常见，最大池化操作过程中，每一个池化框中选择一个最大值保留下来，生成新的特征图。

3.2.2 上采样层

U-Net 的右半部分是一个上采样层。上采样时，输入的空间大小增大，可以使用最近邻、双线性插值算法或转置卷积等技术实现。插值方法使用已知数据来估计未知缺失的数据，最近邻插值是一种非常快速且易于实现的算法，它取最近像素的值，然后将这个最近像素的值进行复制操作，复制到未知的像素的位置。双线性插值与其有点不同，双线性差值能够在一定程度上跨越图像的高度和宽度，然后再对像素进行插值，它使用四周 4 个像素的加权平均值来近似未知像素值，其权重取决于已知像素到缺失像素的距离。与插值方法相比，转置卷积的卷积核的参数都是可以通过网络训练得到，能够根据网络的训练情况进行调整，因此此种方法比较灵活。和卷积层一样，它需要对滤波器的数量、大小和步幅进行设置。过滤器中的所有值都是可训练参数，在网络训练时更新。

在网络的训练阶段，需要找到使得网络损失函数最小的权重，因此，本文采用梯度下降的训练方式。其中梯度被定义为每个输入变量的偏导数。在训练网络之前，网络需要指定损失函数，优化器的类型，并选择对应的数据集。本文所示用的学习方式为主监督学习，因此每一个数据样本都带有标签。所有的权重都随机初始化为小的非零数。在训练过程中，本章希望找到一组使损失函数最小化的权重，损失函数依赖于网络中的所有权重。因此，本文采用梯度下降，其中梯度被定义为每个输入变量的偏导数。它是一个指向函数最大增量的向量，为了使损失函数最小化，取损失函数相对于权值的梯度的相反方向。梯度是根据每个权重计算的，并通过网络反向传播^[43]，权重更新公式如下：

$$\mathbf{w}^t = \mathbf{w}^{t-1} - \alpha \nabla L(\mathbf{w}) \quad (3-2)$$

其中 $\mathbf{w}$ 为当前时刻 t 的权重， $\mathbf{w}^{t-1}$ 为前一次迭代的权重矩阵， L 为损失函数， α 为学习率。学习率不存在与网络内部，它是一个外部的超参数，它决定了权值变化的步长。神经网络的训练是一个迭代的过程，训练方式可总结如下：

- (1) 前相传播：训练数据进入网络计算输出；
- (2) 损失函数：将网络输出与真实图像做比较，计算损失；
- (3) 反向传播：通过式 3-2 进行梯度更新。

3.2.3 网络细节

顾名思义，U-Net 即为一个形状像 U 的网络结构组成，其中左侧为卷积部分，每进行一轮卷积特征图大小都减小，因此称为下采样层，右侧则为转置卷积部分，转置卷积可以使特征图变大，因此称为上采样层。下采样部分由两个卷积层的四个块组成，在每个块中，都有一定数量的卷积核，每个卷积核大小为 3×3 ，在进行完每轮卷积之后经过一个激活函数，此处激活函数选择使用 ReLU，最后在通过一个最大池化层，因此，特征图的大小减半。每下采样一层之后，特征图的数量就会增加一倍。在网络的底部是两个卷积层，网络的右半部分由四个上采样块组成。上采样块是一个 2×2 的转置卷积层，其输出与具有相同形状的子采样层连接，然后接两个具有 ReLU 激活的 3×3 卷积层。在最后一层，没有设置任何激活函数，而采用 1×1 的卷积。在 Chen 的论文中，在输入图像通过网络之前，将图像乘以输入图像与真实图像之间的曝光时间比率。在本文的网络架构中，将特征图与包含曝光时间比值的矩阵连接到转置卷积的第一层(即 U-Net 的底部)。

每张 FITS 图像太大，GPU 资源无法满足要求，而 FCN 具有输入图像大小灵活的优点，因此本文选择 FCN(全连接神经网络)来进行训练。在验证阶段，使用与训练阶段相同的输入大小。在图像重建阶段，将裁剪之后尺寸为 256×256 的图像输入训练好的网络中运行，得到相应输出大小的重建图像。

3.2.4 本文所使用激活函数与损失函数介绍

图像进入神经网络经过一次前相传播能够获得当前的预测图像，预测图像与真实图像之间计算残差，作为网络的损失。在本文所提出的网络模型中，，使用了 L1 loss、L2 loss、perceptual loss^[44]（感知损失）和 KL divergence loss（相对熵）来对网络进行优化，并测试了 ReLU、PReLU 和 SWISH 激活函数对网络性能的影响。说明如下：

(1) L2 loss(平方损失)

L2 loss 称为平方误差, 也即每个像素点之间的大小作差然后取一个平方作为损失, 公式如下:

$$L(Y, f(x)) = (Y - f(x))^2 \quad (3-3)$$

通常情况下, 该损失函数长用于回归问题之中。

(2) L1 loss(绝对损失)

L1 loss 也称为绝对损失, L1 loss 的意义和 L2 loss 比较相近, L1 loss 取像素之间相差的绝对值来当做损失值, 公式如下:

$$L(Y, f(x)) = |Y - f(x)| \quad (3-4)$$

(3) KL divergence loss(相对熵)

KL 公式如下:

$$KL(p \parallel q) = \sum_{i=1}^N p_i \log \left(\frac{p_i}{q_i} \right) \quad (3-5)$$

其中 p 和 q 分别为真是分布和预测分布, KL 能够在一定程度上度量分布所损失的信息量。如果被比较的图像的分布是相同的, 那么 KL 将为 0。

(4) ReLU (Rectified Linear Unit)

ReLU 激活函数描述如下式:

$$f(x) = \max(0, x) \quad (3-6)$$

该函数定义了神经网络中的神经元在经过线性变换之后的输出, 能够将输出映射到一定的范围内, 且其不容易发生过拟合现象。

(4) PReLU (Parametric Rectified Linear Unit)

PReLU 激活函数描述如下式:

$$\text{PReLU}(x) = \begin{cases} x & \text{if } x > 0 \\ ax & \text{if } x \leq 0 \end{cases} \quad (3-7)$$

该函数在小于零的部分不为零, 而是为一个带有比较小的斜率的值。

(5) SWISH (Parametric Rectified Linear Unit)

SWISH 激活函数描述如下式:

$$f(x) = x \cdot \text{sigmoid}(\beta x) \quad (3-8)$$

式中 β 为一个可训练的参数，可根据神经网络训练的过程逐步调整。

3.3 U-Net 神经网络的改进

U-Net 的卷积层在提取特征时会将不重要的特征也一并提取，因此，为了抑制网络提取到的不重要特征，使其在捕捉到更重要的特征，本节提出使用注意力机制来提升网络的性能，本节使用了两种注意力模块，分别是 SE^[45]和 SSE^[46]，其中 Encoder 部分采用 SE 模块，SE 模块能够有效的加强对重要特征的提取，Decoder 部分采用 SSE 模块，SSE 模块是 SE 模块的改进版本。SE 用于给网络添加通道注意力，SSE 则用于给网络添加空间注意力，将其命名为 Attention-UNet。

3.3.1 注意力机制

本文总共添加了两种注意力机制模块来进行网络的优化。

(1) SE(Squeeze-and-Excitation)模块

SENet 在 2017 年 ImageNet 的比赛中被提出，其结构简单，易于嵌入到各种网络之中。其主要思路为学习不同通道之间的相关性，因此有可能提取到更加重要的特征，在只稍微增加了一点计算量的同时，达到很好的效果。

网络结构如图 3.2 所示：




图 3.2 SE 模块

由图可知，SE 模块的思路即是对卷积操作之后得到的特征图进行额外的处理，得到每个通道的评价分数，此分数被添加到了对应的通道中，最终得到输出的结果。

(2) sSE(Channel Squeeze Squeeze-and-Excitation)模块

sSE 是 SE 的改进版，其结构如图 3.3 所示：




图 3.3 sSE 模块

由上图可以看出 sSE 模块直接对特征图进行处理，此模块主要对网络添加空间注意力，易于实现，能够比较容易嵌入到 U-Net 网络中。

3.3.2 Attention-UNet 网络结构

本章所提出的网络结构如图 3.4 所示：




图 3.4 Attention-UNet 网络架构

当天文图像进入模型训练时，输入进入网络的天文图像的长和宽都有 256 像素，在网络的左侧编码部分，数据经过卷积之后进入设置好的注意力机制模块，在编码模块使用 3×3 的卷积核来提取图像的特征。编码部分一共分五层，在每一层的末端都接一个 2×2 的最大池化块，进行一次下采样，能够使得特征图的长和宽都减半，并且特征图的数量加倍。当走到解码部分的最下部分时，再进入反卷积部分，反卷积部分采用 2×2 的反卷积模块，每进行一次反卷积，特征图的大小加倍经过四轮反卷积最终生成的图像与原图像大小一致，并在存在注意力机制模块，因此网络有可能捕捉到更加有用的信息。

3.4 数据处理与实验设置

3.4.1 数据集

数据集为自己构建，数据集包含了 200 幅天文图像。训练集设置 160 张，测试集和验证集的数量都为 20 张。训练集和测试集都为多通道图像，图像由广域相

机 WFC3 上的 UVIS 探测器捕获, WFC3 是两个 CCD(每个 2051 x 4096)的~4000 x 4000 像素探测器, 它们之间有 31 像素的间隙。选择两个宽的滤光片, 可以覆盖更广范围的可见光谱。图像大小明显大于网络, 尽管图像数量很少, 但输入和过拟合也不是一个大问题。把这些图像称为真实数据。在训练网络时, 对于网络的输入, 我们使用的是基于真实数据生成数据, 添加了额外的噪声。网络的输入是 FITS 图像, 没有对图像进行归一化。

3.4.2 实验过程

天文图像会受到各种因素的干扰而发生退化。为了为网络输入创建数据, 实验数据来自 WFC3 的 UVIS 仪器所拍摄的 200 张天文图像, 本文考虑光子散粒噪声、暗噪声和读出噪声。这从远处探测到的光子数量具有固有的统计变化^[47], 相关公式如下:

$$N_{\text{photon}} = \text{Pois}(S) \quad (3-9)$$

其中 S 为天文相机捕获的总信号, $\text{Pois}(S)$ 为 S 的泊松分布。暗噪声来自探测器的热激发电子。它强烈依赖于 CCD 的温度, 而不依赖于落在探测器上的光子, 因此即使在完全黑暗的情况下, 这种噪声也会持续存在。噪声也是泊松分布的, 本文使用的是由暗电流计算出的高斯分布, 公式如下:

$$N_{\text{dark}} = N(0, \sqrt{DK \cdot t}) \quad (3-10)$$

其中 t 代表天文图像的曝光时间。

读出噪声(RON)是由 CCD 电子器件引起的所有像素的均匀噪声。本文使用 WFC3 仪器手册中的读出噪声和暗电流值, 在加入噪声之前, 先把真实图像除以曝光时间比, 由于天文图像拍摄使用 CCD 相机中的线性单元, 因此一张天文图像可以看成多张短曝光图的叠加^[47], 因此, 合成短曝光图像:

$$I_{\text{short}} = I_{\text{long}} / r \quad (3-11)$$

其中 I_{short} 为合成的短曝光图像, I_{long} 为真实长曝光图像, r 为曝光时间比。

曝光时间比是真实图像的曝光时间与合成图像曝光时间的比值, 最终网络合

成的输入数据为:

$$\begin{aligned} I_{\text{input}} &= N_{\text{photon}} + N_{\text{dark}} + N_{\text{RON}} \\ &= \text{Pois}(I_{\text{short}}) + N(0, \sqrt{\text{DK} \cdot t}) + N(0, \text{RON}) \end{aligned} \quad (3-12)$$

其中 I_{input} 为网络的带噪输入, 由于图像的大小较大, 在每次迭代中只将大小为 256×256 的裁剪图像随机输入进网络。

3.5 实验结果与分析

为了寻找不同变量对网络性能的影响, 本文总共设置了八组对照实验, 分别使用了 L1 loss、L2 loss、L1 + perceptual loss、L1 + KL divergence loss、ReLU 激活函数、PReLU 激活函数、SWISH 激活函数。

作为对照, 本文基于 U-Net 进行改进设计了对照实验, 对照组分别为 U-Net+SE 模块与 U-Net+SE 模块+SSE 模块, 其中 SE 代表网络添加了通道注意力模块, SSE 代表网络添加了空间注意力模块。

选择 Adam 优化器来对网络进行优化。初始学习速率是 0.0001, 1500 次迭代后后下降到 0.00001。每个 epoch 迭代 160 次, 在每次迭代中, 网络从一个训练图像中随机抽取 256×256 的局部图像来进行训练。

本文采用 PSNR、SSIM 和 KL 散度作为评价指标, 另外, 另一个评价模型重要的指标是恒星的检测, 本文统一采用 DAOFIND 算法^[48]作为恒星探测算法。在低曝光图像中未探测到的恒星可能在高曝光图像中被探测到, 同理, 在高曝光图像中也可能探测不到低曝光图像中探测到的恒星。因此, 引入额外的评价指标, 真正类率, 定义如下:

$$TPR = \frac{TP}{TP + FN} \quad (3-13)$$

式 3-13 为真正类率的计算公式, TP 表示正确预测恒星的数目, FN 代表没有正确找到恒星的数目。

3.5.1 不同实验设置结果及分析

实验结果如表 3-1 所示:

表 3-1 不同参数设置下网络性能的比较

实验序号	实验描述	TPR[%]	PSNR[dB]	SSIM	KL
1	L1 loss	95.7	13.4	0.63	0.0074
2	L2 loss	94.5	4.6	0.59	0.0130
3	L1 + PLoss	96.0	11.6	0.64	0.0069
4	L1 + KL	95.9	14.0	0.64	0.0070
5	ReLU	96.0	13.3	0.63	0.0072
6	PReLU	95.9	13.7	0.63	0.0070
7	SWISH	95.7	11.6	0.63	0.0073
8	Random r	95.8	13.2	0.63	0.0071

从结果可以得出：L2 loss 不适合本章所研究的问题，且 L2 loss 不符合人类视觉系统的特征。在 zhao 等^[49]人的研究中，L2 loss 更有可能陷入局部最小值，且 L2 loss 对损失更加敏感，在分布有离群值的情况下，L1 loss 更加稳健，能够更有效的达到极小值。

3.5.2 Attention-UNet 与 U-Net 的对比

U-Net 与添加了注意力机制的 U-Net 性能对比，其中 U-Net+SE 代表了网络只添加了 SE 模块，U-Net+SE+SSE 代表了网络不仅添加了 SE 模块，还添加了 SSE 模块。

表 3-2 U-Net 与添加注意力机制的 U-Net 性能比较

网络模型	PSNR	SSIM	KL
U-Net	13.4	0.63	0.0074
U-Net+SE	14.3	0.65	0.0069
U-Net+SE+SSE	12.8	0.62	0.0078

实验结果表明, U-Net+SE 模块能够达到很好的效果, 在 PSNR、SSIM 和 KL 指标上都领先其余两组对比实验。

三种网络训练的损失函数如图 3.5 所示:




图 3.5 三种不同网络模型损失函数变化图

图中蓝色曲线为 U-Net 训练损失曲线, 绿色曲线为 U-Net+SE 模块训练损失曲线, 橙色曲线为 U-Net+SE 模块+sSE 模块训练损失曲线, 从图中可以看到, 经过 5000epoch 的训练, U-Net 和 U-Net+SE 实验组已经收敛, U-Net+SE+SSE 实验组在训练时损失函数收敛更慢, 且中途发生了跳变, 可能是网络结构或者其他技术原因导致。

3.5.3 实验结果分析

部分测试数据实验结果如图 3.6 所示:




图 3.6 网络的输入与重建后的图像

上图中左侧图像为低曝光时间的图像，图为网络生成的高曝光时间的图像，其中曝光时间比设置为 2。

通过肉眼可以很明显的看出，低曝光天文图像模糊不清，不易于进行科学研究，经过本章网络所增强之后的图像具有更多的信号，能够易于天文研究人员的进一步处理。为了证明网络的合理性，对 F555W 拍摄的天文图像进行分析，结果如下图所示：



图 3.7 天文图像构建的网络输入数据




图 3.8 本文网络增强后的天文图像及恒星探测

图 3.7 为网络构建的输入数据，额外添加了噪声，在图 3.8 中，青色的圆圈包围了在输出图像上检测到但在真实图像上没有检测到的恒星，红色的圆圈包围了在地面真像上检测到但在输出图像上没有检测到的恒星，蓝色的圆圈包围了两张图像都检测到的恒星。

经过实验对比分析，本章提出的 Attention-UNet 能够对图像进行一定程度的降噪处理，并能够进行信号的增强，提高 PSNR，在真实图像的恒星检测中能够

检测到更多的真实恒星，对天文研究的发展具有一定的推进作用。

3.6 本章小结

为了对低曝光天文图像进行复原，本文提出使用 U-Net 来对天文图像进行基础架构的设计。目前天文研究主要采用多幅图进行叠加的方式来减小图像中的噪声，因此会消耗大量的时间，在本文的方法中，耗时更少，且能产生质量相等的结果。本文网络可以处理不同尺度的图像，只需要曝光时间比作为输入就可以输出对应复原后的天文图像，并且在 PSNR 和 SSIM 都取得了很好的结果。在本文的网络中，天文图像在输入进网络之前会附带一些人为的噪声，因此网络的输出也会携带一定的噪声，同时，宇宙射线可能会以恒星的形式被恢复出来，因此在图像输入进网络之前可以适当消除宇宙射线。尽管存在这些限制，本文所提出的网络仍然能够用于科学研究。

第四章 基于 U-Net 的离焦天文图像复原

4.1 研究背景

天文观测过程中会受到各种干扰,造成观测图像退化,其中最常见的是离焦退化与噪声退化,离焦退化使天文图像变得模糊,噪声退化则影响图像的质量和分折。每天望远镜都会拍摄大量的天文图像,因此离焦天文图像数量也非常庞大,为了能够对这些退化后的图像加以利用,因此需要对此类图像进行处理而得到质量更好的图像,以推动天文研究的进展。

CCD 图像是恒星观测中常使用的数据形式,像素点的数值越大,反映了其在相同条件下接受到的光流量越大。然而由于大气湍流等复杂的外界干扰(如高空的薄气卷云,大气透明度的变化等)会使得天文 CCD 相机拍摄到的星象出现模糊、离焦等问题,从而使星象的质量下降,影响到恒星定位的精确性。此前已经提出过多种用于图像修复的方法。早在上个世纪 90 年代,Ayers 等人^[50]提出了迭代盲反卷积算法,该算法在空间域和频率域交替运算,算法性能受到初始值和约束条件的影响,在边界容易出现振铃效应。随后 Liang 等人提出一种改进梯度平滑边界算法^[51],改善了边界修复的振铃效应,但仍会残留不少振铃效应。Sun 将维纳滤波算法用于模糊星象的修复^[52],该算法是一种基于图像频域的方法,该算法在图像不连续处易受吉布斯效应的影响。Li 等人^[53]提出了一种迭代残差图像反卷积的方法来复原图像。该方法在图像复原中能够获得较好的效果,可以恢复出更加直观的纹理和细节,但是在图像的修补方面存在明显的不存。Zhang 等人^[54]提出了一种快速、灵活、鲁棒性高的快速灵活去噪神经网络(FFDNet)。使用了 depth-to-space 层来提高速度,中间层采用去噪神经网络(DnCNN)模型^[55]。但是本方法不适合天文离焦图像的修复。Zhang 等人提出一种端到端的图像修复网络 USRNet^[56],它也是首个采用单个端到端模型解决经典降质问题的方法。在图像修复上具有一定的效果。

目前大多数天文图像修复算法都是建立在传统复原算法之上,此类算法缺乏灵活性与高效性,且复原效果不太理想。因此,本文以解决传统方法的不足作为

出发点来进行研究，提出使用 ResNet 与 U-Net 相结合来对天文图像进行复原，来对天文观测提供可靠的数据。

4.2 图像复原原理

传统的天文图像的复原方法存在点扩散函数难以估计和算法灵活性不够等问题，大多数方法都存在。

论文针对天文 CCD 图像的离焦修复展开研究，针对盲复原点扩散函数难以提取的问题，本章进行了点扩散函数的估计，并采用深度学习的方法对天文 CCD 离焦图像进行复原。实验结果表明：相较于传统的星图复原算法，论文提出的基于 ResNet 与 U-Net 相结合的方法能够很有效的复原离焦星象，并且在速度上具有很大优势。

在第二章中对相关天文图像退化原理进行的介绍，天文图像的退化可以看作是标准理想的天文图像 f 与相关模式的点扩散函数的卷积结果，外部的一些噪声也会对图像产生影响，因此还要添加一定的噪声进行训练，在不知道具体 PSF 的情况下的复原其实可以看作是一种复原模型，如图 4.1 所示：




图 4.1 图像复原模型

由图可知，天文图像的复原即是找一个相关的逆变换，从而使离焦模糊之后的天文图像 g 经过转换之后能够输出比较清晰标准的天文图像 F ，但是由于每张天文图像的点扩散函数都不可知，因此理论上有无穷多个点扩散函数，具有不适性，然后由于外界噪声的干扰，进而使得这种不适性进一步加剧。

目前，现有的图像复原方法都依赖于图像的先验知识，然后再天文图像拍摄的过程中，图像的先验知识不可知，因此现有的方法不适应于天文图像的复原工

作。针对现有天文图像复原方法存在的不足之处，本文提出了一种基于神经网络的天文图像处理方法，能够实现天文图像端到端的映射，解决天文图像离焦的问题。

4.3 退化模型的设计

每张天文图像对应的退化模型都不一样，因此无法单独对每一张天文图像进行模型提取和训练相关网络，提出一些近似的退化模型能够在保证计算效率的同时兼顾复原效果。

现有的图像修复方法主要针对双三次降解模型设计，研究表明，如果实际退化模型偏离假设的退化模型，采用这类方法会严重恶化。同时，在本文第二章中，经过对离焦图像的分析研究，望远镜对焦不准会造成拍摄到的天文图像发生离焦模糊，但是离焦模糊不足以解决天空复杂的背景问题，因此，可以知道：大部分离焦星象的 PSF 都是以高斯核函数为主体的函数形式。本文所修复的星象大多数离焦情况并不严重，大多数情况下只发生了比较轻微的离焦模糊。由于发生离焦的星象并不知道其原始图像。根据文献^[57]所述，拍摄过程多摄像机往往产生非常轻微的离焦，且模糊核的半径通常在一定范围波动，因此本文考虑高斯模糊，模糊核半径范围为 $[0.5, 2]$ ，且步长设置为 0.5，退化模型的数学表达式如：

$$y(x, y) = f(x, y)h(x, y) + n(x, y) \quad (4-1)$$

其中 y 为观测到的图像， f 为标准理想星象， f 为假设的退化模型，对应于相应的点扩散函数如下：

$$h(x, y) = \frac{1}{2\pi\sigma} e^{-\frac{x^2+y^2}{\sigma^2}} \quad (4-2)$$

其中 σ 表示点扩散函数的半径， x 和 y 表示点扩散函数上对应的 x 坐标和 y 的坐标，点光源离焦程度越大，则点扩散函数的半径越大。

原始星象都是接近理想状态下的星象，通过对这些星象进行离焦处理，对星象进行不同层次的离焦化，通过上式中的 σ 设置不同的值来模拟星象离焦的程度，由于本论文处理的离焦星象离焦程度较小，实验论证，前文所述的四种模糊核满足本文实验数据的要求，模糊半径分别为 0.5, 1.0, 1.5, 2.0，这四种点扩散函数

足以应对大部分离焦情况。四种离焦模型如图 4.2 所示。




图 4.2 四种离焦模型

4.4 Res-UNet 网络架构

U-Net 是一种 FCN 结构，在实现形式上与 CNN 稍有不同，FCN 将 CNN 最后的全连接层用卷积层作为替换，因此使得 FCN 可以接受任意输入尺寸大小的图像，使得图像在训练过程中变得十分灵活。CNN 对于输入图片的处理不够灵活，不能支持任意图片大小的输入，因此本章采用 U-Net 作为基本架构。

U-Net 对于图像的转换十分高效，但是其网络层数浅，不能够很好地对特征进行计算和提取，因此需要加深网络深度以便更好的提取特征，本章采用 ResNet 结合 U-Net 的思想来进行模型搭建。

4.4.1 ResNet 模块

2015 年，ResNet 在 ImageNet 的比赛中被提出，简单且实用是 ResNet 的主要特点。面对复杂的问题，直观上，越深的网络往往有更好的性能，然而，实际发现，网络层数加深之后，训练集的准确率却呈现下降的趋势。尽管如此，ResNet 在实验中很好的解决了此类问题。ResNet 可以是使网络在输入层基础上学习新的特征。U-Net 作为一种典型的 AutoEncode 模型，具有强大的图像复原功能，即使只有少部分特征图，也能够很好的恢复出原图像。ResNet 与 U-Net 的结合能够更加充分的提取特征，增加网络的鲁棒性。

ResNet 残差单元结构如图 4.3 所示：




图 4.3 残差单元

传统网络在 l 层的输出为:

$$x_l = H_l(x_{l-1}) \quad (4-3)$$

在上图中, x , $H(x)+x$ 代表了第 l 个残差单元的输入和输出。从上式可以看出, 短路连接(shortcut)没有引入额外的参数, 也没有改变网络的复杂度。因此在 shortcuts 映射中, 第 l 层的输出可以用如下公式表示:

$$x_l = H_l(x_{l-1}) + x_{l-1} \quad (4-4)$$

恒等映射和非线性变换输出的叠加方式是相加, 每一层的输出都用了上一层的输出, 使得网络能够提取到更多的特征, 提高了网络的性能。

4.4.2 Res-UNet 神经网络

本章提出的采用 ResNet 与 U-Net 结合的方式来进行天文图像的复原, 本文所搭建的网络结构如图 4.4 所示:




图 4.4 Res-UNet 网络架构

网络的输入退化之后的图像，和上一章网络结构类似，ResUNet 左侧为编码模块，五个卷积层和一个池化层构成了残差模块，最终能够将输入进网络的 256×256 的天文图像转换成 16×16 的特征图。在图像进行卷积的过程中，步幅设置成 1，卷积核的大小设置为 3×3 ，在天文图像经过本文网络的残差模块时，能够保证天文图像特征信息的更多获取。同样的，在网络结构的右侧为解码部分，每一层都含有一个转置卷积模块，和五个卷积层，最终能够将左侧获取到的 16×16 的特征图恢复成 256×256 的正常图像。在本文的 ResUNet 中，左侧编码之后得到的特征图能够融合解码部分的特征图，进而能够更好的保留天文图像的特征。

4.5 数据处理与实验设置

4.5.1 数据集介绍

数据包含了 3475 张真实的星系图像，数据来自于 Smith 等人在文献^[59]所构造的数据集，其坐标取自斯隆数字巡天 DR7 和 Brinchmann+2003 和 Wilman+2010 的修改目录，数据大小为 512 像素 $\times$ 512 像素。该体积完整样本的 r 波段绝对星等极限为 $M_r < -20$ ，红移范围为 $z < 0.08$ 。这个目录涵盖了从集群和现场系统的广泛环境。这些星系图像是由暗能量光谱仪器拍摄的，包含 g、r 和 z 波段，部分数据如图所

示:



图 4.5 部分天文数据

4.5.2 实验设置

在全部的数据中，80%用于模型的训练，10%用于模型的验证，10%用于模型的测试。

本文实验使用的激活函数为线性修正函数(ReLU)，将非线性特征引入到网络中，并且在训练上速度更快，优化器选择 Adam，动量因子为 0.9，0.99。集合了根值均方(RMSProp)和动量(Momentum)的优点，在动态调整学习率的同时调整收敛方向，进而加快训练速度。基于第三章的实验结论，L1 loss 对于图像的转换更加稳健与高效，本文采用 L1 作为网络训练的损失函数，公式如下：

$$L_{\text{cont}} = \frac{1}{K} \sum_{i=1}^K \frac{1}{C_i w_i h_i} \| L_i - S \|_p \quad (4-5)$$

在上面的式子中， L_i 代表了 ResUNet 复原出来的天文图像， S_i 代表了清晰的标准原始天文图像， K 代表了 epoch 的次数， C_i 代表了输出图像的通道数， w_i 代表了网络输出天文图像的宽， h_i 代表了网络输出天文图像的高。

为了证明本章所提出的基于 ResNet 与 U-Net 方法的有效性，作为对比，本章

选择传统维纳滤波复原算法和 LR 复原算法^[60], 基于深度学习的经典图像复原算法 IRCNN+^[61]、FFDNet^[62]与 USRNet^[63]作为对照组进行实验。

复原效果采用 PSNR 和 SSIM 进行评价, PSNR 和 SSIM 原理已在上文介绍, 这里不在赘述。

4.6 实验结果与分析

4.6.1 实验结果

如表 4-1 所示, 表中模型维纳滤波与 LR 为传统复原方法, IRCNN+、FFDNet、USRNet、PSFNet 与本文方法为深度学习图像复原算法, 可以看出, 基于深度学习的复原算法在数据集的表现更加良好, PSNR 指标提升了 4dB, SSIM 指标提升了 0.5 左右, 相比于传统算法, 在 PSNR 指标上, 本文提出的基于 ResUNet 的天文复原算法提高了 6dB。

表 4-1 对比实验 PSNR 与 SSIM 指标对比

实验序号	实验方法	PSNR[dB]	SSIM
1	维纳滤波	25.2	0.834
2	LR	24.3	0.816
3	IRCNN+	27.5	0.892
4	FFDNet	30.1	0.943
5	USRNET	28.7	0.927
6	PSFNet	29.3	0.934
7	本文方法	31.9	0.958

复原效果图如图 4.6 所示:




图 4.6 ResUNet 复原效果图

上图中,左侧两张图为带噪声的离焦星象图,右图则为本文网络恢复出的图像,从图像中明显可以看到,本文方法能够有效的从带噪声的离焦星象中恢复出质量较高的图像,且本文模型参数量较少,并在在实验数据的基础上,本文额外选取了云南天文台的部分数据来进行实验,比较理想的 CCD 星象如图 4.7 所示,离焦星图如图 4.8 所示,图 4.7 和图 4.8 都是同一天文望远镜拍摄下来同一区域的星象,拍摄时间不同。原始图像中有不少恒星,选取其中最亮的 4 颗星进行分析。



图 4.7 标准原始天文图像




图 4.8 离焦天文图像

从理想天文可以看出,标准的天文图像只存在很少的噪点,天体的亮度分布十分均匀。图 4.8 的天文图像则是望远镜失焦之后拍摄到的星象。可以看出,望远镜失焦之后星图变得更加模糊,并且目标星象的质心也发生了偏移,并且星图的形状不再服从严格的高斯分布,这会影响天文学者后续对天文图像的分析。根据寻星算法^[48](DAOStarFind),从离焦星图和正常星图中一共找到了 4 颗恒星,正常星图的质心位置分别为(336.02, 136.05), (74.17, 143.73), (250.61, 251.25), (228.83, 409.57), 其中数值的大小代表在此星图中的像素坐标。

为了验证本文提出的 ResUNet 对于天文图像复原的有效性,作为对比,本文不仅考虑了传统复原算法中较为领先维纳滤波算法,并且也考虑了目前一种较为领先的深度学习图像修复算法 USRNet,在上述多种算法进行复原后,挑选了比较亮的四颗恒星进行分析,四颗恒星在星象中的位置如图 4.9 所示,下图为天文图像的截取部分。




图 4.9 四颗恒星

恒星质心提取结果参见表 4-2、表 4-3、表 4-4 和表 4-5。四个表中的星点代表

DAOStarFind 算法探测到的恒星的标号,质心坐标代表的是星点在横轴和纵轴的位置,单位为像素,总偏差代表不同算法的复原效果与标准星象质心偏差的比较,其值为复原星图与标准星图横轴和纵轴坐标的绝对误差之和。

表 4-2 离焦星图星点坐标

星点	1	2	3	4
质心(x, y)	335.87, 136.3	74.2, 143.97	25.67, 143.97	74.2, 143.97
总偏差	0.43	0.27	0.23	0.16

表 4-3 维纳滤复原星图星点坐标

星点	1	2	3	4
质心(x, y)	336.04, 136.13	74.11, 143.77	250.48, 251.33	228.77, 409.65
总偏差	0.11	0.13	0.21	0.14

表 4-4 USRNet 复原星图星点坐标

星点	1	2	3	4
质心(x, y)	336.08, 136.08	74.15, 143.82	250.62, 251.34	228.71, 409.53
总偏差	0.09	0.11	0.11	0.16

表 4-5 本文方法复原星图星点坐标

星点	1	2	3	4
质心(x, y)	336.11, 136.07	74.13, 143.64	250.75, 251.25	228.72, 409.59
总偏差	0.10	0.10	0.14	0.11

4.6.2 结果分析

通过对比表 4-2、表 4-3、表 4-4 和表 4-5 中星点坐标的偏差可以看出,对于离焦星象的修复,传统的基于维纳滤波的修复算法在星象的修复上有一定的效果,基于图像重建网络(USRNet)的修复方法在星象的质心修复上不太理想。本文所提

出的基于 ResUNet 网络结构的改进复原算法的准确度要高于传统复原算法和基于深度学习算法 USRNet 的修复效果。复原后的星点质心坐标得到了较好的恢复，偏差更小，能够为天文观测提供有意义的参考。实验结果表明：本文提出的基于 ResNet 和 U-Net 的图像复原算法能够对星象进行更好的复原，复原效果如图 4.10 所示。



图 4.10 本文方法复原的天文图像

为了验证 ResUNet 对于恒星的复原程度，在上述所挑选出的天文图像中选取了 $(-524, 55)$ 处的恒星进行放大，如图 4.11 所示。




图 4.11 复原星图星点放大示意图 a. 离焦星象 b. 维纳滤波方法 c. USRNet 方法 d. 本文方法

通过对比图 4.11 中局部星点放大图可以看出：本文所使用的网络结构对离焦星图形状的修复效果更好，修复之后星象的形成更接近接近理想状态下的星象。

基于维纳滤波的复原算法在星象形状的修复上不够理想，并且在修复星象质心定位上不能达到很好的效果。综合以上分析，在星点提取的偏差和星象修复之后的形状可以得知，本文提出的基于改进 ResNet 和 U-Net 的复原算法在星象的离焦修复上要优于传统的维纳滤波复原算法和基于深度学习的 USRNet 图像复原算法，并且在灵活性和高效性上占据优势，能够修复离焦星象。

4.7 本章小节

由于离焦天文图像离焦情况较多，无法采用单一的点扩散函数来进行处理。本章采用多种点扩散函数来模拟天文图像的离焦程度，所采用的点扩散函数涵盖大部分地基天文望远镜拍摄到的天文图像离焦情况，在计算复杂度与计算精度上达到了平衡，整个过程致力于增强卷积层特征提取的效果与计算点扩散函数的复杂性，提高了模型的泛化能力和学习能力，在一定程度上提高了天文图像复原效率与效果，相比于传统算法，本章提出的基于 ResUNet 的复原模型在 PSNR 和 SSIM 等指标上达到了很好的效果。

第五章 总结与展望

5.1 工作总结

本文所研究的方向是天文图像的处理方法。天文相机在拍摄的过程中会受到各种因素的干扰而产生退化，并且天文观测的时间十分宝贵，寻求可靠的图像增强与复原算法能够在减少天文观测时间的同时提高天文图像的质量，但是人如果没有标准理想的天文图像，天文图像模糊核难以估计。当下综合情况比较适合的解决方案是采用深度学习，训练出能够满足当下天文研究需求的网络。本文的主要内容与研究成果如下：

在第二章中，介绍了天文图像的背景知识以及噪声的来源和分类，并对不同种类的退化模型和复原算法进行了深入的分析，对各种天文图像复原算法进行了比较，最后介绍了神经网络在图像复原方面的应用。

在第三章中，文章针对天文图像在拍摄过程中受到噪声干扰和拍摄时间等的限制，对天文图像增强和去噪方法进行了研究。首先对噪声进行了建模，将天文相机的拍摄时间作为输入传入网络。接着对 U-Net 框架进行了分析，并用注意力模块 SE 和 SSE 对网络进行改进。实验结果表明：U-Net 结合 SE 模块的方式能够发挥出更好的性能，对低曝光天文图像的恢复更好，恢复之后的天文图像恒星探测效果更佳。

在第四章中，针对天文望远镜在地面拍摄时产生的退化图像进行了研究，分析了产生退化的综合原因。采用高斯核函数来进行建模，设计了四种能够代表大多数离焦情况的模糊核，并结合 ResNet 和 U-Net 来进行网络的搭建。实验结果验证了 ResUNet 在天文图像的复原方面的有效性。

5.2 展望未来

本文主要针对天文望远镜拍摄的天文图像进行研究分析，由于实验数据的却反和相关研究成果的不足，以下几个方面还值得继续深入：

- (1) 本文所提出的 Attention-UNet 算法在性能上比 U-Net 算法更加优越，并且

计算复杂度较低，尽管能很好的对低曝光天文图像进行复原，但也会将部分宇宙射线恢复成恒星，应该结合一些其他方法，在网络进行训练时先去掉部分宇宙射线，以此尽可能来提升网络的精度。

- (2) 本文假定天文图像的退化遵循一定的规律，退化模型接近文章所提出的四种模型，但是部分天文图像存在很复杂的退化模式，并不能够很好的进行复原，据此，可以考虑针对特定的小部分图像采用与其适配的模糊核来进行复原。

参考文献

- [1] BONTEKOE T, KOPER E, KESTER D. Pyramid maximum entropy images of IRAS survey data[J]. Astronomy and astrophysics, EDP Sciences, 1994, 284(3): 1037–1053.
- [2] ZAVAGNO A, LAGAGE P, CABRIT S. Extended mid-infrared emission around the outflow source and the compact H II region in AFGL 4029[J]. Astronomy and Astrophysics, 1999, 344: 499–504.
- [3] MARCHIS F, PRANGÉ R, FUSCO T. A survey of Io's volcanism by adaptive optics observations in the 3.8- μ m thermal band (1996–1999)[J]. Journal of Geophysical Research: Planets, Wiley Online Library, 2001, 106(E12): 33141–33159.
- [4] FOY R, LABEYRIE A. Feasibility of adaptive telescope with laser probe[J]. Astronomy and Astrophysics, 1985, 152: L29–L31.
- [5] HOGBOM J. CLEAN as a pattern recognition procedure[J]. Indirect Imaging. Measurement and Processing for Indirect Imaging, 1984: 247.
- [6] TIKHONOV A, GONCHARSKII A, STEPANOV V, et al. Ill-posed image processing problems[C]//1987, 32: 456.
- [7] LUCY L B. An iterative technique for the rectification of observed distributions[J]. The astronomical journal, 1974, 79: 745.
- [8] 焦继超, 赵保军, 陶芬芳, 等. 一种基于局部图像复原的天文图像增强算法[J]. 仪器仪表学报, 2011, 32(07): 1455–1461.
- [9] 刘国良, 邵云龙. 基于伸缩梯度投影的天文图像复原改进算法[J]. 传感器与微系统, 2016, 35(04): 134-136+140.
- [10] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]//2015: 1–9.
- [11] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [12] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//2016: 770–778.
- [13] DONG C, LOY C C, TANG X. Accelerating the super-resolution convolutional neural network[C]//Springer, 2016: 391–407.
- [14] RAMAKRISHNAN S, PACHORI S, GANGOPADHYAY A, et al. Deep generative filter for motion deblurring[C]//2017: 2993–3000.
- [15] 邸慧, 于起峰. 基于自相关的匀速运动模糊尺度参数识别[J]. 国防科技大学学报, 2006, (05): 123–125.
- [16] LEVIN A, WEISS Y. User assisted separation of reflections from a single image using a sparsity prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, IEEE, 2007, 29(9): 1647–1654.
- [17] DAI S, WU Y. Motion from blur[C]//IEEE, 2008: 1–8.
- [18] DAI S, WU Y. Estimating space-variant motion blur without deblurring[C]//IEEE,

- 2008: 661–664.
- [19] LEVIN A, RAV-ACHA A, LISCHINSKI D. Spectral matting[J]. IEEE transactions on pattern analysis and machine intelligence, IEEE, 2008, 30(10): 1699–1712.
 - [20] 王新楼. 小波去噪方法分析与 Matlab 仿真[J]. 工业控制计算机, 2008, (06): 55–56.
 - [21] 基于提升小波的运动模糊图像恢复 — 中国知网 [EB/OL]. [2022-03-22] .https://kns.cnki.net/kcms/detail/detail.aspx?dbcode=CJFD&dbname=CJFD2010&filename=JSJZ201005049&uniplatform=NZKPT&v=c7Bq38coLPg3kYKNN6548Ffij_spBl-WpYfFYxXS0lysPUPZ8brwxAJIc32Ga2QD.
 - [22] 一种改进的混合滤波的算法 — 中国知网 [EB/OL]. [2022-03-22] .<https://kns.cnki.net/kcms/detail/detail.aspx?dbcode=CJFD&dbname=CJFD2011&filename=DNZS201101069&uniplatform=NZKPT&v=MXFFVQ-INonZTKq221eUrXlUjVhDLGm4c3faqQYi5ICt-ZkS59QYRLd2Glfzap>.
 - [23] HELSTROM C W. Image restoration by the method of least squares[J]. Josa, Optical Society of America, 1967, 57(3): 297–303.
 - [24] RICHARDSON W H. Bayesian-based iterative method of image restoration[J]. JoSA, Optical Society of America, 1972, 62(1): 55–59.
 - [25] TIKHONOV A N, ARSENIN V I, ARSENIN V. Solutions of ill-posed problems[M]. Vh Winston, 1977.
 - [26] BANHAM M R, KATSAGGELOS A K. Digital image restoration[J]. IEEE signal processing magazine, IEEE, 1997, 14(2): 24–41.
 - [27] HUNT B. A matrix theory proof of the discrete convolution theorem[J]. IEEE Transactions on Audio and Electroacoustics, IEEE, 1971, 19(4): 285–288.
 - [28] HUNT B R. The application of constrained least squares estimation to image restoration by digital computer[J]. IEEE Transactions on Computers, IEEE, 1973, 100(9): 805–812.
 - [29] KUNDUR D, HATZINAKOS D. Blind image deconvolution[J]. IEEE signal processing magazine, IEEE, 1996, 13(3): 43–64.
 - [30] LAM E Y. Image restoration in digital photography[J]. IEEE Transactions on Consumer Electronics, IEEE, 2003, 49(2): 269–274.
 - [31] 张航, 罗大庸. 图像盲复原算法研究现状及其展望[J]. 中国图象图形学报, 2004, (10): 1–8.
 - [32] JAIN V, SEUNG S. Natural image denoising with convolutional networks[J]. Advances in neural information processing systems, 2008, 21.
 - [33] ZHANG K, ZUO W, CHEN Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. IEEE transactions on image processing, IEEE, 2017, 26(7): 3142–3155.
 - [34] VALSESIA D, FRACASTORO G, MAGLI E. Image denoising with graph-convolutional neural networks[C]//IEEE, 2019: 2399–2403.
 - [35] NAH S, HYUN KIM T, MU LEE K. Deep multi-scale convolutional neural network for dynamic scene deblurring[C]//2017: 3883–3891.
 - [36] TAO X, GAO H, SHEN X, et al. Scale-recurrent network for deep image deblurring[C]//2018: 8174–8182.

- [37] MAO X, SHEN C, YANG Y-B. Image restoration using very deep convolutional encoder-decoder networks with symmetric skip connections[J]. Advances in neural information processing systems, 2016, 29.
- [38] TAI Y, YANG J, LIU X, et al. Memnet: A persistent memory network for image restoration[C]//2017: 4539–4547.
- [39] SONG S, MUKERJI T, HOU J. Geological facies modeling based on progressive growing of generative adversarial networks (GANs)[J]. Computational Geosciences, Springer, 2021, 25(3): 1251–1273.
- [40] HU M, ZHAO S, ZHANG L, et al. Can: Constrained attention networks for multi-aspect sentiment analysis[J]. arXiv preprint arXiv:1812.10735, 2018.
- [41] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//Springer, 2015: 234–241.
- [42] CHEN C, CHEN Q, XU J, et al. Learning to see in the dark[C]//2018: 3291–3300.
- [43] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. nature, Nature Publishing Group, 1986, 323(6088): 533–536.
- [44] JOHNSON J, ALAHI A, FEI-FEI L. Perceptual losses for real-time style transfer and super-resolution[C]//Springer, 2016: 694–711.
- [45] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//2018: 7132–7141.
- [46] ROY A G, NAVAB N, WACHINGER C. Concurrent spatial and channel ‘squeeze & excitation’ in fully convolutional networks[C]//Springer, 2018: 421–429.
- [47] 刘娟. 基于线阵相机的目标探测性能研究[D]. 西安工业大学, 2014.
- [48] STETSON P B. DAOPHOT: A computer program for crowded-field stellar photometry[J]. Publications of the Astronomical Society of the Pacific, IOP Publishing, 1987, 99(613): 191.
- [49] ZHAO H, GALLO O, FROSIO I, et al. Loss functions for image restoration with neural networks[J]. IEEE Transactions on computational imaging, IEEE, 2016, 3(1): 47–57.
- [50] G., R., AYERS, 等. Iterative blind deconvolution method and its applications[J]. Optics Letters, 1988, 13(7): 547–549.
- [51] 梁英, 于洵, 陶禹, 等. 散焦图像边缘振铃抑制算法[J]. 电子测量技术, 2019, 42(04): 84–89.
- [52] 孙辉, 张葆, 刘晶红, 等. 离焦模糊图像的维纳滤波恢复[J]. 光学技术, 2009, 35(02): 295–298.
- [53] SI-YAO L, REN D, ZHAO F, 等. Iterative Residual Image Deconvolution[J]. 2018.
- [54] ZHANG K, ZUO W, ZHANG L. FFDNet: Toward a Fast and Flexible Solution for CNN based Image Denoising[J]. IEEE Transactions on Image Processing, 2017: 1–1.
- [55] ZHANG K, ZUO W, CHEN Y, 等. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising[J]. IEEE Transactions on Image Processing, 2017.
- [56] ZHANG K, GOOL L V, _R_ TIMOFTE. Deep Unfolding Network for Image

- Super-Resolution[J]. IEEE, 2020.
- [57] ZHANG K, ZUO W, ZHANG L. Learning a Single Convolutional Super-Resolution Network for Multiple Degradations[J]. IEEE, 2018.
- [58] ZHANG K, ZUO W, ZHANG L. Learning a single convolutional super-resolution network for multiple degradations[C]//2018: 3262–3271.
- [59] SMITH M J, GEACH J E, JACKSON R A, et al. Realistic galaxy image simulation via score-based generative models[J]. Monthly Notices of the Royal Astronomical Society, Oxford University Press, 2022, 511(2): 1808–1818.
- [60] FISH D, BRINICOMBE A, PIKE E, et al. Blind deconvolution by means of the Richardson–Lucy algorithm[J]. JOSAA, Optical Society of America, 1995, 12(1): 58–65.
- [61] ZHANG K, ZUO W, GU S, et al. Learning deep CNN denoiser prior for image restoration[C]//2017: 3929–3938.
- [62] ZHANG K, ZUO W, ZHANG L. FFDNet: Toward a fast and flexible solution for CNN-based image denoising[J]. IEEE Transactions on Image Processing, IEEE, 2018, 27(9): 4608–4622.
- [63] ZHANG K, GOOL L V, TIMOFTE R. Deep unfolding network for image super-resolution[C]//2020: 3217–3226.