

分类号

密 级

太原理工大学

硕 士 学 位 论 文

题 目 基于机器学习的天文图像复原研究

英文并列题目 Astronomical Image Restoration Based on Machine Learning

研究生姓名: 蔡博君

学 号: 2016510935

专 业: 测试计量技术及仪器

研 究 方 向: 计算机视觉与图像处理

导 师 姓 名: 贾 鹏

职 称: 副教授

论文提交日期 2019/06

学位授予单位: 太原理工大学

地 址: 山西·太原

太 原 理 工 大 学

基于机器学习的天文图像复原研究

摘 要

天文图像在成像过程中受大气湍流、CCD 电噪声等因素影响, 最终观测图像发生退化, 造成观测信息的丢失, 影响观测效果。通过数字图像处理的方法对退化图像进行复原, 可以提高图像的像质。目前, 大部分研究都采用反卷积的方法对图像进行复原, 在复原过程中认为图像视场内的 PSF 是不变的。实际上, 在大视场短曝光成像系统中, 图像 PSF 随时间变化, 且同一图像中各个视场位置的 PSF 都不一致, 因此使用一致 PSF 的反卷积复原方法都不能达到较好的复原效果。基于上述原因, 本文提出了一种基于图像 PSF 特点的大视场分区反卷积算法和基于深度学习的图像复原神经网络。

在分区反卷积算法中, 首先估计图像的天光背景, 提取出星点在图像中的坐标位置, 再提取出星点的 PSF, 进一步对 PSF 数据进行降维, 去除噪声提取特征。然后对降维后的数据进行聚类分析, 根据指定的评价指标选取具有 PSF 分布特征的聚类结果。将聚类结果结合星点坐标对图像进行分割, 使分割结果包含 PSF 在视场中的分布特征。最后, 利用对应类别的 PSF 与分区后的子图进行反卷积复原, 再将复原结果进行拼接, 得到分区反卷积复原图像。与传统的分区复原方法相比较, 本文的复原结果在信噪比提升方面更为稳定, 验证了本文算法对大视场天文图像复原的有效性。将本文的复原算法应用到多通道望远镜的图像叠加工作中, 使像质得到提高。

在基于深度学习的图像复原网络中, 首先根据维纳滤波的数学模型讨

论了图像复原过程，再结合 PSF 的可分解性解释了卷积神经网络的图像复原原理。然后，搭建网络框架，利用模拟的数据对模型进行训练，最后根据峰值信噪比(Peak Signal-to-Noise ratio, PSNR)与结构相似度(Structural Similarity, SSIM)对复原效果进行评价，证实了本文的深度反卷积神经网络的可行性。

关键词：天文图像复原，大视场，反卷积，图像分割，深度学习

ASTRONOMICAL IMAGE RESTORATION BASED ON MACHINE LEARNING

ABSTRACT

The astronomical image is affected by the atmospheric turbulence and the electric noise of CCD in the process of during observations. The quality of observation images degraded, which results to the loss of observation information and affects the observation efficiency. The image quality can be improved by restoration. Most of researches on image degradation adopts deconvolution method. PSFs in the whole field of view is considered to be uniform. In fact, for the wide field of view short exposure imaging system, the PSF of the image changes with time, field of view. The deconvolution method with uniform PSF can not achieve good restoration result. Based on the above situation, we propose to use partition image restoration method for the wide field astronomical images, based on the statistical properties of PSFs and an image deconvolution neural network based on deep learning in this dissertation.

In segment deconvolution algorithm, skylight background of image is estimated firstly. Then coordinate positions of stars in the image are extracted, and the PSFs of the stars are extracted. In order to eliminate the noise and reduce the computational load, we use the principal component analysis method and self-organized map to cluster images. The clustering results are labelled by selected

evaluation indexes. The clustering results are combined with star coordinates to segment images, so that the segmentation results include the distribution characteristics of PSFs in the field of view. Finally, the PSFs of clustering are used to restore the sub-images after segmentation, and then the restoration results are spliced to get the segmentation deconvolution restored images. Compared with the traditional zonal restoration method, the restoration results in this paper are more stable in terms of signal-to-noise enhancement ratio, which verifies the effectiveness of the proposed algorithm in restoring wide field of view astronomical images. Applied restoration method in this dissertation to Quad-channel telescope image co-adding, the quality of results improved.

For the deconvolutional neural network algorithm, image restoration is discussed according to the mathematical model of Wiener filter. And the principle of the convolutional neural network is explained by the decomposability of PSFs. Then, the network framework is built, and the model is trained with simulated data. Finally, the restoration effect is evaluated based on PSNR and SSIM, which proves the feasibility of the deep deconvolutional neural network in this dissertation.

KEY WORDS: astronomical image restoration, wide field of view, deconvolution, image segmentation, deep learning

目 录

基于机器学习的天文图像复原研究	I
摘要	I
ABSTRACT	III
目录	V
第一章 绪论	1
1.1 引言	1
1.2 研究背景与研究意义	2
1.3 国内外研究现状	2
1.4 大视场天文图像复原研究存在的问题	5
1.5 本文主要研究内容及章节安排	5
第二章 基于大视场地基望远镜的图像复原算法	7
2.1 图像退化与复原	7
2.2 大视场天文图像的图像复原研究	8
2.3 PSF 位置计算	9
2.3.1 背景估计	9
2.3.2 连通域分析	9
2.4 数据降维	11
2.5 PSF 聚类	12
2.5.1 SOM 神经网络	13
2.5.2 聚类结果评价	14
2.6 图像分割	15
2.7 图像分区反卷积复原	16
2.8 本章小结	17
第三章 基于图像分区复原的多通道望远镜数据处理方法	19
3.1 实验过程	19
3.1.1 数据介绍	19
3.1.2 实验分析	19

3.2 实验结果	23
3.2.1 星象信噪比	23
3.2.1 数据分析	23
3.3 基于多通道望远镜的图像叠加方法	24
3.3.1 几何偏差分析	25
3.3.2 图像配准	26
3.3.3 图像叠加结果分析	27
3.4 本章小结	28
第四章 基于深度学习的天文图像复原研究.....	29
4.1 卷积神经网络简介	29
4.2 卷积神经网络结构	29
4.3 基于深度卷积神经网络的天文图像复原研究	30
4.4 网络结构	31
4.5 训练过程	34
4.5.1 数据准备	34
4.5.2 Batch Normalization.....	37
4.5.3 损失函数和优化方法	38
4.6 数据分析	40
4.7 本章小结	44
第五章 总结与展望.....	45
5.1 研究成果	45
5.2 未来工作展望	46
参考文献	47
致谢	53
攻读硕士学位期间发表的学术论文	55

第一章 绪论

1.1 引言

亘古以来,天文学都一直伴随着人类的文化发展,是最古老的自然学科之一。在人类文明起始的早期,人们就能通过天空中太阳、月亮以及星星的方位来确定时间、方向以及季节的更替。在很大程度上,人们目前所使用的历法都和天体的运行规律有着密切关联:公元前四千年,埃及人根据太阳、天狼星的起落以及尼罗河河水的涨落,确定一年约为 365 天;在以农耕为主的古代中国,人们按照太阳的位置变化与地面的气候演化将一年分成 二十四个节气,从中又诞生了农历;人们根据白天不同时刻太阳位置对物体影子的影响规律发明了日晷和圭表用于计时。

天文学的本质是一门以观测为主的科学,和天文学相关的一切研究都离不开观测工具。从李波尔赛发明望远镜到伽利略制成第一架天文望远镜,再到牛顿发明折反式望远镜,人们逐渐摆脱了只能用肉眼观察天空的困境,随着十八世纪西方分光学和拍摄技术的快速发展与应用,人们可以通过天文望远镜观测到天体的结构,继而开始研究天体的演化。

通过天文望远镜观测遥远天体,成为人们了解浩瀚宇宙的主要途径。对望远镜观测到的图像进行分析研究,可以对观测天体的大小、质量以及运行轨道以及天体间的距离加以估计,而高分辨天文图像的获取成为高精度天体测量的关键,也成为众多天文学家不断探讨的话题。

二十世纪六十年代,随着信息技术发展的不断突破,数字图像处理技术也开始得到发展。1964 年,由美国发射的“旅行者 7 号”探测器通过数字图像技术对拍摄的上千张月球表面图像进行处理,使图像质量得到了提升,并通过计算机成功绘制出月球表面地图,而后又将该技术应用到后续的空间探测器的图像信息处理中。随着九十年代计算机的开始普及,数字图像处理技术开始应用到航空航天、通讯、医学、多媒体以及工业生产等各个领域^[1]。天文观测的成像过程中受大气湍流等因素影响图像发生退化,由于曝光时间短,每个观测时间段 CCD 都可采集到数以千计的海量数据,使得天文观测成为数字图像技术的主要应用领域。

1.2 研究背景与研究意义

与空间观测相比,地基观测具有观测时间长、造价相对低廉和观测灵活等优点,成为目前天文观测的主要方式之一。地基天文望远镜在观测的过程中,由于成像系统固有的缺陷,观测到的图像发生退化,导致图像中的暗弱目标难以分辨。图像退化的原因主要为成像系统的光学性质,如大气湍流、光电系统的低通特性以及望远镜的像差等^[2]。作为地基观测的主要工具,地基天文望远镜的性能主要体现在^[3]:(1)集光能力,即探测暗弱天体的本领;(2)分辨能力,即分辨天体细节的本领。一般来说,望远镜的集光能力则与口径的平方成正比,望远镜的口径越大,集光能力越强,就能探测到更远更暗的天体。而最小分辨角与望远镜口径成反比,最小分辨角越小,能分辨的细节就更细微。这就意味着要想获得更好的观测数据就需要花费更多的成本在望远镜的建造上,而在后期运用数字图像处理技术对天文图像进行复原、增强,可降低天文观测的成本,提高观测数据的研究价值。

将天文图像是退化过程看作是原始的清晰图像与表示图像退化的点扩散函数(Point spread function, PSF)卷积,图像复原算法通常是对退化过程的反演,利用退化过程的先验知识恢复退化图像的本来面目,所以常采用反卷积的方法对图像进行复原,需要对图像的 PSF 进行准确建模。由于大气层在不同海拔处的温度、风速及方向各不相同,大气湍流在空间中的分布并不是均匀的,视场区域的 PSF 是随空间位置变化的,在缺少先验信息的情况下很难对这类图像的 PSF 进行精确建模。

除此以外,对于太阳观测的全日面、星系星云观测等图像,其 PSF 并非能同星象目标一样能够很好地从图像中提取出来,并且此类图像的观测视场较大,所以很难对此类图像的 PSF 进行精确建模,因此对这类图像复原方法的研究具有前瞻性的意义。

1.3 国内外研究现状

天文图像复原是高精度天文观测的一个重要研究领域,为了能更加全面地利用望远镜数据,近年来,大批研究人员利用图像复原的手段对天文观测图像进行复原。1994 年, Bontekoe 等^[4]利用金字塔最大熵算法对 IRAS 图像进行了有效的重构。1998 年, Courbin 等^[5]将图像反卷积应用于对引力透镜的研究。1999 年, Zavagno 等^[6]通过对中红外线图像重构得到的高分辨图像,揭示了年轻恒星目标的内部构造。2000 年, Marchis 等^[7]对

低分辨率图像进行复原，并在复原结果中展现了木卫一的内部火山活动。同年，Rigopoulou 等^[8]对 20 μm 波长的中红外线图像进行复原，并揭示了受高消光的影响隐藏在低波段中的 NGC 1068 活跃星系核内部结构。

早期的天文图像复原方法主要为 A.Labeyri 等^[9]提出的斑点图像重建，由于该方法需要将波前信息作为先验条件，所以无法对图像进行实时的处理。传统的逆滤波方法将图像通过傅里叶变换后在频域下进行反卷积操作，这样处理的速度非常快，但是在考虑复原问题时该方法假设图像未受到噪声污染，实际图像中的噪声会被放大，所以逆滤波方法并不适用于真实图像的反卷积。1974 年 Hogbom 提出 CLEAN 算法^[10]，该方法假设目标是由多个点源构成，将图像分解成一系列峰值标度不同的 δ 方程，再将 δ 方程与理想 PSF 进行卷积，其结果叠加残差即得到复原图像。但是，在对具有大尺度结构的图像上，该算法的表现并不好。1987 年，Tikhonov 等^[11]提出了在求反卷积的过程中加入正则化项，使反卷积能得到稳定唯一的解，并进而衍生出维纳滤波等利用线性正则化的复原方法。但是该方法在图像不连续处易受吉布斯效应影响，图像高频信息会进一步丢失，并且维纳滤波需要利用噪声功率谱作为先验信息，在噪声分布未知的情况下表现并不好，而且如何有效的计算正则化项又成为一个新的问题。为了能更好地利用图像的信息，从信号统计概率的方面考虑，Lucy 等^[12]提出了基于贝叶斯定理的反卷积算法，考虑信号在图像中以泊松分布的形式体现，通过最大似然估计多次迭代得到复原图像。当图像信噪比较高或迭代次数足够多时，该方法具有稳定唯一的解，而对于低信噪比的图像而言，还存在复原图像中噪声被放大的缺陷。

传统的反卷积算法假设成像过程中整个视场受到的退化是完全一致的，即整幅图像中各点的 PSF 不存在差异。事实上视场中各个位置收到的退化是随空间变化的，由于 PSF 随视场位置变化，使用同样的 PSF 对此类图像反卷积的效果不佳。1965 年，Lohmann 等^[13]对这一现象进行了研究，并总结了空间变化点扩散函数(Space-variant point sparse function, SVPSF)成像系统的特点。1990 年，Lee 等^[14]通过对光学成像系统的研究，对成像系统像差和物体运动对 SVPSF 造成的影响进行了总结，当前对 SVPSF 图像的复原方法大致分为三类，分别是：空间坐标转换、分区复原和全局复原。空间坐标转换的方法需要得到可以解析的退化过程，往往不适合处理图像盲复原的问题；分区复原就是将图像分割成若干块，并将每一块图像的 PSF 都看成是近似的，该方法存在的问题在于如何对图像进行合理有效的分割；全局复原从全局的角度上考虑退化过程，需要运

用到大量的退化先验信息,造成复原过程计算量庞大。2007年,Bar等^[15]利用分段非盲反卷积方法得到了较好的复原结果。2011年,焦继超等^[16]提出了一种局部天文图像复原算法,该算法通过观测设备参数与图像建立初始PSF模型,对图像进行分割,然后分割图像进行盲反卷积,经结果分析该算法有效的抑制了大气湍流和噪声的影响,提高了图像的分辨率和空间目标背景的对比度。2016年,刘国良等^[17]在已有的伸缩梯度投影算法的基础上结合图像无参考质量度量,提出了一种基于盲反卷积可自动停止迭代的改进算法,并通过仿真实验证实算法可应用与实际天文图像处理。2017年,白鹏等^[18]针对天文图像的稀疏性,通过基于边界测度的PSF尺寸预估计算法对稀疏测度PSF估计算法进行改进,得到更为精确的PSF估计值,并通过仿真验证了算法能够改善天文图像的复原效果。

随着计算机硬件的发展以及神经网络理论研究的不断突破,神经网络强大的拟合能力被应用到图像处理领域。随着模型结构的优化、参数的调整以及训练模式的转变,深度学习在图像超分辨、模式识别任务中都有了广泛的应用,处理速度和效果也随着计算机硬件的更新迭代不断加快、提高。近年来,随着研究人员的不断实验,大量优秀的深度学习框架被提出并开始应用到诸多领域:2012年Hinton等在ImageNet图像分类任务中提出了AlexNet,AlexNet使用ReLU函数进行非线性映射,降低了计算量,同时引入dropout防止过拟合的发生,池化层使用max-pooling,并使用双GPU训练模型,降低了训练过程花费的时间,即便如此,AlexNet的网络参数仍达到了60.96M。2014年,Christian提出GoogleNet,引入了Inception Module的结构,在解决问题的同时将网络参数削减到了4M。同年,牛津大学Visual Geometry Group通过不断使用 3×3 的卷积核组合构建了VGGNet,并提出使用小卷积核代替大卷积核可以节省运算开销。2016年,何铠明等^[16]对深层网络的准确率下降进行研究,提出了ResNet,引入Residual block结构,在网络不断加深的情况下保证了模型的准确率。

在图像领域,深度学习的应用主要包括目标分类、目标跟踪、图像超分辨重构以及图像复原等方面。2016年,Chao等^[20]将深度学习应用到图像的超分辨复原中,提出了一种基于卷积神经网络的SRCNN模型,他们认为神经网络复原图像的过程在原理上和稀疏编码有着密不可分的关系,在隐藏层中完成图像的预处理工作缩减了大量的预处理与后期工作,通过复原图像的PSNR和SSIM进行评价,得到了比经典插值方法更好的效果。2016年,Chao等^[21]对SRCNN进行优化提出FSRCNN,优化后模型通过卷积层对输出图像进行上采样、使用更小的卷积核、增加映射数量,并使映射之间的参数共享,

提高了模型的训练速度。Kim 等^[22]结合 ResNet 的思路提出基于图像残差学习超分辨重建的 VDSR, 他们认为低分辨率图像和高分辨图像的低频部分很大程度上是相似的, 将这部分信息从训练过程中剔除可以减少训练耗费的时间, 通过对高、低分辨率图像之间的高频残差学习即可完成超分辨任务。VDSR 深化了网络的架构, 使得深层卷积核具有更大感受野, 在训练过程使用不同尺度的图像数据, 使模型可以实现多尺度的图像超分辨任务。2017 年, Sainandan 等^[23]利用生成对抗模型对真实的运动模糊图像进行复原, 提出用 VGGNet 模型的特征图计算图像感知损失, 解决了图像结构细节的复原问题。

1.4 大视场天文图像复原研究存在的问题

大视场天文图像的复原研究与传统的天文图像复原有所区别, 其研究工作不仅包含对图像复原工作的研究, 还包含了 PSF 与视场分布的关系以及对图像复原的影响的研究。根据对国内外图像复原算法与大视场处理方法的整理和归纳, 目前大视场天文图像复原研究面临的问题有以下几点:

- (1) 图像的盲反卷积复原是一个病态问题, 目前大部分研究对图像的质量都有要求, 如何在低信噪比图像中得到较好的复原结果是一个问题。
- (2) 在大视场观测条件下, PSF 随视场空间变化。如何有效地对不同 PSF 视场区域进行分块成为大视场图像复原的另一个需要解决问题。
- (3) 对于太阳全日面等天文图像, 由于 PSF 难以建模, 造成很难利用传统的图像反卷积方法对这类图像进行复原, 如何对此类图像进行盲复原是一个亟待解决的问题。

1.5 本文主要研究内容及章节安排

由于大视场天文图像自身的特点, 其复原工作不能像传统复原方法一样认为 PSF 在全视场区域都是不变的。本文旨在对大视场天文图像视场区域分割进行研究, 在对各个视场区域的 PSF 进行精确建模, 并将结果应用到此类图像的盲反卷积复原工作中。

本文对天文图像中星象的定位、PSF 的分类及图像分区反卷积复原等进行了深入的分析研究, 并且对最终的复原结果进行了定量分析。本文的主要研究分以下几个部分:

- (1) 研究了图像预处理的方法以及星象提取的方法;
- (2) 研究了如何基于 PSF 的聚类分析结果对图像视场进行分割, 使分割结果更符合 PSF 的视场分布;

(3) 研究了基于天文图像的迭代盲反卷积算法, 并结合图像分割方法将算法应用到
大视场天文图像的分区复原与叠加;

(4) 研究了基于深度学习的天文图像复原算法, 对算法模型进行搭建、训练。

本文各章节的内容安排如下:

第一章介绍本课题的研究背景、意义以及国内外研究现状与当前面临的问题。

第二章介绍了天文图像的退化过程, 研究并提出了基于空间变化 PSF 图像的反卷积
算法, 提出了基于大视场天文图像的分区反卷积算法。

第三章对第二章提到的分区反卷积算法进行实验, 分析实验数据, 并将算法应用到
多通道望远镜的数据处理中。

第四章介绍了深度学习在图像复原方面的应用, 研究了基于深度学习的天文图像复
原, 阐明了深度学习方法的复原原理。

第五章对本文的工作进行了归纳总结, 并对后续的工作进行展望。

第二章 基于大视场地基望远镜的图像复原算法

在大视场地基天文观测活动中,由于大气层中大气湍流的存在造成的天文图像发生退化、模糊,需要对图像进行复原。但是由于缺少精准的 PSF 信息,加上图像盲复原过程的病态性,天文图像的盲反卷积复原一直是一个亟待解决的难题。根据大视场下天文图像的 PSF 随视场位置变化的特性,本文所总结的大视场天文图像复原算法可以精确地得到图像视场位置下的 PSF。算法首先根据星象位置提取出图像中所有星象的 PSF,对 PSF 进行降维、聚类分析,再通过生长算法将聚类结果根据其位置对图像进行分割,分割后的子图与对应的 PSF 进行反卷积,再将反卷积的子图进行拼接,得到复原图像。经实验结果表明,应用该方法复原的天文图像信噪比得到提升,且可以消除望远镜像差对图像造成的影响,为其他的图像增强方法提供了更好的处理对象。

2.1 图像退化与复原

受大气湍流和成像系统固有误差等因素,天文图像在观测的过程中会发生退化^{[24][25]}。图像的退化过程如图 2-1 所示。




图 2-1 图像退化过程

Fig.2-1 Image connectivity

图像的退化过程往往被看成是清晰图像与退化算子的卷积或者模糊图像与噪声作用的形式,退化过程的数学模型通常可以表示成公式(2-1):

$$g(x,y) = f(x,y) * h(x,y) + n(x,y) \tag{2-1}$$

其中 (x,y) 为二维图像的坐标, $f(x,y)$ 为清晰图像, $h(x,y)$ 为成像系统的 PSF, $n(x,y)$ 为加性噪声, $g(x,y)$ 为退化图像, “*”表示卷积操作。在频域下,该过程被表示为公式(2-2):

$$G(u,v) = F(u,v) \times H(u,v) + N(u,v) \tag{2-2}$$

$F(u, v)$ 、 $G(u, v)$ 、 $H(u, v)$ 和 $N(u, v)$ 分别为清晰图像、退化图像、PSF 以及加性噪声的傅里叶变换。因此，在不考虑噪声的情况下，图像复原的过程可以看成是卷积的逆过程，如公式(2-3)所示：

$$F(u, v) = \frac{G(u, v)}{H(u, v)} = G(u, v) \times H^{-1}(u, v) \quad (2-3)$$

其中 $H^{-1}(u, v)$ 为反卷积过程，通过图像的 PSF 求解得到。在理想情况下，望远镜的 PSF 为一个艾里斑，然而由于大气湍流和望远镜像差的存在，实际的 PSF 会与理想中有一定差异，使 PSF 成为一个未知量。本文通过图像中星点的坐标提取出图像的 PSF，再利用盲反卷积算法对图像进行复原。盲反卷积的本质是一个约束下的最优化问题，在迭代过程中，正则化会不断增加 PSF 信息，使 PSF 更加精确^[25]。

2.2 大视场天文图像的图像复原研究

根据本文 2.1 节的讨论，PSF 的精确度会影响图像复原结果。在传统的天文图像复原工作中，为了简化问题的复杂性，退化过程被看成是一个单一的线性过程，并认为整个视场的 PSF 唯一^{[27][28]}。实际上，在地基天文观测过程中，大气湍流作为传播介质随时间在不同空间位置下发生的变化不同，光学系统在不同视场下的像差也存在差异^[28]，所以大视场望远镜观测图像的 PSF 是随空间和时间变化的。因此，针对大视场图像复原的研究需要考虑退化过程会随视场空间变化的特性。1978 年，Trussell 等^[29]提出了图像分块复原算法，该方法首先对图像区域进行分割，得到若干子图，并认为子图视场内的 PSF 是近似不变的，然后利用子图的 PSF 对对应的子图区域进行图像复原，并按照对应的位置将复原后的子图拼接，得到最终的复原图像。理论上，该方法可以处理任何空间变化 PSF 图像的复原工作，但是算法精确度仍受图像分割结果的影响。分割子图像区域过大，PSF 在子图仍是变化的，影响图像复原效果，子图区域过小，会带来过大的计算量，并引入图像边缘的“振铃”效应。而 PSF 的变化体现在 PSF 的分布上，因此根据 PSF 的分布对图像分割。进行聚类，再根据聚类结果对图像进行分割可得到空间变化 PSF 图像的分割结果。

基于以上分析，本文提出的大视场天文图像复原算法主要包括五个部分，分别是：PSF 位置计算，数据降维，PSF 聚类，图像分割与图像分区反卷积。


2.3 PSF 位置计算

2.3.1 背景估计

图像的 PSF 信息来自于星点的光度分布，所以需要提取星点的位置。在地基望远镜所观测到的图像中，像素灰度值为背景与星象目标的灰度值叠加。在传统的天文目标提取方法中，背景阈值 $threshold$ 由图像灰度的标准差 std 和中值 $median$ 以及系数 k 确定^[30]，小于等于 $threshold$ 的区域被认为是背景，大于 $threshold$ 的区域被认为是星点目标，如公式(2-4)所示。

$$\begin{aligned} threshold &= median + k \times std, \\ region &= \begin{cases} star, & gray\ value > threshold \\ background, & gray\ value \leq threshold \end{cases} \end{aligned} \quad (2-4)$$

实际图像的背景往往比较复杂，且暗星易被亮星遮挡掩盖，按照这种方法所估计的背景往往会与实际图像有较大出入，造成大量暗星不能被检测到。



(a)原始图像
(a)Raw image

(b)估计背景
(b) Predicted background

图 2-2 背景估计

Fig.2-2 Background prediction

本文中先将图像分成 32×32 的子图，然后对每个子图的局部背景进行估计，得到 32×32 的局部背景矩阵，通过图像插值法对局部背景矩阵进行填充，生成图像的背景，提高背景估计的准确度。如图 2-2 所示。

2.3.2 连通域分析

阈值分割的方法可以将星点目标从图像中提取出，即通过原始图像减去背景，得到粗提取的星点。这样粗提取的星点会包含大量噪声。图像中的星点和噪声如图 2-3 所示。






图 2-3 星点与噪声

Fig.2-3 Star removal

由于噪声在图像中往往是跳变孤立的^[31]，通过对图像连通域分析，设置星点连通域面积的最小阈值，筛除粗提取结果中的噪声，得到星点目标。本文按 8-邻域搜索模式提取粗提取结果中大于 5 个像素点的连通域，结果如图 2-4 所示。





(c)星点提取结果
(c)Stars extraction result
图 2-4 噪声滤除结果
Fig.2-4 Noises removal result

2.4 数据降维

通过图像中提取的星点坐标，用于提取出星点目标的 PSF，PSF 的提取如公式(2-5)所示^[32]。

$$PSF(i,j) = \frac{s(i,j)-b}{f} \tag{2-5}$$

其中， $s(i,j)$ 为星点在 (i,j) 坐标下的灰度值， b 为所估计的天光背景， f 为星点目标的光通量。从星点中提取的 PSF 分布如图 2-5 所示。




图 2-5 PSF 三维分布图
Fig.2-5 3-dimensional distribution of PSF

星点的 PSF 反映了光源在成像过程中所受到的退化影响。图像在观测过程中会受到随机噪声的干扰，对于暗星而言，其边缘易被噪声以及亮星淹没，造成暗星的光度分布信息被破坏，导致提取的 PSF 信息缺失，影响后续图像复原的结果。

考虑到暗星 PSF 信息缺失的问题，在选择提取 PSF 的参考星时，根据图像中星点的灰度值,在图像不同位置的星象中选取最大灰度值前 85%的星点作为亮星，从这些亮星提取 PSF 数据。此外，为了剔除冗余信息及噪声带来的干扰，提高下一步聚类过程的效率，需要对提取 PSF 数据的进行 PCA (Principal Component Analysis)降维处理。PCA 算法由 Karl 于 1901 年提出^[33]，该算法通过对数据使用正交变换将数据转换成一组线性不相关的向量，这些向量被称为数据主成分。这些向量在原始数据中的信息占比决定了主成分的特征值的大小，相对的，特征值越大则意味着对应的向量所包含的数据信息也越多。其实现基本流程表 2-1 所示^[34]。

表 2-1 PCA 算法
Table 2-1 PCA algorithm

算法：PCA 算法
输入： 具有 n 个特征大小为 $n \times m$ 的 PSF 数据 $P = \{p_1, p_2, \dots, p_m\}$ ；降维目标 $k(k < n)$
输出： 降维结果 $D = \{d_1, d_2, \dots, d_m\}$
伪代码：
1、计算均值 $\mu = \frac{1}{m} \sum_{i=1}^m p_i$ ；
2、更新 $P, P = \{p_i p_i = p_i - \mu, i = 1, 2, \dots, m\}$ ；
3、计算特征值序列 $E = (e_1, e_2, \dots, e_m)$ ；计算协方差矩阵 C ，并按照特征值从 4、大到小的顺序排布 C 中的元素， $C' = \{c_1, c_2, \dots, c_m\}$ ， C 的大小为 $m \times m$ ；
5、选取 C 中前 k 个元素，组成新的的特征矩阵 $C' = \{c_1, c_2, \dots, c_k\}$ ；
6、计算降维结果 D ， $D = C' \times P$ ，大小为 $k \times m$ ，返回 D 。

PCA 降维的实质是一个将高维数据向低维空间映射的过程，通过该方法将数据的维度压缩、综合，在保证信息损失尽可能少的前提下降低数据维度^[35]。

2.5 PSF 聚类

为了将星点 PSF 的分布信息应用到天文图像视场分割的工作上，需要对星点的 PSF 进行聚类。聚类是指通过对数据属性的考察，对一系列无类别的对象进行分组，

以揭示数据内部存在的规律^[36]。每一组数据都称为“簇”，聚类的目的就是要使同一簇的簇内成员之间相似度高，不同簇的成员之间相似度低。与分类相比，聚类通常没有明确的分类数，也没有明确的分类准则，属于无监督学习的范畴。聚类常常被描述成一个多目标优化问题，除了算法的设计以外还要考虑参数设置，包括距离评价函数、预期聚类数和阈值的选择。目前，聚类算法主要应用于数据分析的工作中。本文的 PSF 聚类工作主要分成以两步：①通过 SOM（Self-organizing Maps）神经网络对 PCA 降维后的 PSF 数据进行多个聚类数的聚类；②计算聚类结果的 DB 指数（Davies-Bouldin index）评价出最合理的聚类结果。

2.5.1 SOM 神经网络

1981 年，Kohonen^[37]通过模拟人脑处理信号的过程提出了 SOM 神经网络，它由输入层和输出层组成，可以将训练样本进行低维离散映射，并保持输入数据的拓扑性质，网络结构如图 2-6 所示。




图 2-6 SOM 网络结构

Fig.2-6 SOM network structure

SOM 神经网络是一种无监督学习的聚类方法，于其他神经网络相比，SOM 的学习过程利用的是 Winner Takes All 竞争机制，即获胜的神经元获得权重更新的资源。本文中 SOM 网络对 PSF 降维数据的聚类流程如下表所示。

表 2-2 SOM 算法

Table 2-2 SOM cluster algorithm

算法：SOM 聚类算法

输入：降维后的 PSF 数据 $D_0 = \{d_1, d_2, \dots, d_m\}$, 迭代上限 λ ;

输出：聚类结果 D_λ

伪代码：

- 1、初始化映射的节点权重向量 W_0 , $i = 1$; SOM 映射过程表示成 $F(\cdot)$,
- 2、进行第 i 次迭代: $D_i = F(D_{i-1})$ 。计算所有 PSF 数据于节点权重向量间的欧式距离, 距离最小的节点为获胜节点 W_c ;
- 3、更新权重向量, 以 W_c 为中心, 按以下规则更新 W_c 及其邻域内的其他节点:
- 4、 $W_i = W_{i-1} + \theta \cdot \alpha \cdot (D_i) - W_{i-1}$, 其中 θ 表示节点距离限制, $0 < \theta < 1$, α 表示学习率限制;
- 5、更新迭代次数, $i = i + 1$;
- 6、当 $i < \lambda$, 重复步骤 2、3、4、5, 否则返回聚类结果 D_λ

2.5.2 聚类结果评价

在机器学习领域中, 对聚类算法的表现性能具有一系列的评价标准, 主要是通过聚类结果的簇内信息来进行评价的。①凝聚度: 评价一个簇内成员之间紧密性的指标, 通常可由簇成员到中心的平均欧式距离或者是方差等表征。②分离度: 评价簇中的某一个成员到其他簇的距离远近的指标, 通常通过计算各个簇中心之间的距离来表示。在聚类问题中, 某个聚类结果的簇内成员越紧凑, 簇间距离越大, 则表明聚类效果越好^[38]。

1979 年, Davies 等^[39]提出 DB 指数作为一种衡量聚类算法的指标。DB 指数计算所有簇的簇内距离以及簇间距离来评价聚类结果的凝聚度和分离度, 如公式(2-6)所示:

$$DB index \equiv \frac{1}{N} \sum_{i=1}^N \max_{i \neq j} \left(\frac{\bar{C}_i + \bar{C}_j}{\|M_i - M_j\|_2} \right) \quad (2-6)$$

其中, $DB index$ 是聚类结果的 DB 指数, N 是聚类数, $\bar{C}_i$ 和 $\bar{C}_j$ 分别是第 i 个和第 j 个簇的簇内距离, M_i 和 M_j 分别是第 i 个和第 j 个簇的簇间距离。 $\|M_i - M_j\|_2$ 越大, 则簇间

距离越大，数据的分离度越好， $\bar{C}_i + \bar{C}_j$ 越小，簇内距离就越小，数据的凝聚度就越好，因此，DB 指数越小，说明聚类结果的簇间距离越大，簇内距离越小，聚类结果越合理。

在本文 2.5.1 节中，根据 SOM 神经网络对 PCA 降维后的 PSF 数据集进行一系列聚类。实际上，PSF 的聚类数是未知的，通过 DB 指数对聚类结果分析，在 DB 指数最小情况下的聚类结果就是 SOM 最合理的聚类结果。

2.6 图像分割

PSF 的聚类结果反映了星点光度分布的相互关系，也反映了星点所在视场的内在联系。根据 PSF 聚类结果对图像的视场区域进行分割，可以保证视场区域类的 PSF 是相似的。PSF 的位置信息来自于星点的位置，仅凭借星点是无法填充整个视场区域的，要借此完成对图像视场的分割需要应用到区域生长算法。

区域生长是一种简单的基于区域的图像分割方法。该方法涉及到初始种子点的选择，检查初始种子点的相邻像素，并确定是否应将像素相邻添加到区域中^[40]，因此也被归类为基于像素的图像分割方法。根据事先设定好的生长规则以及所设置的初始种子点，区域生长算法遍历图像中所有像素点，并按照生长规则将像素种子周围像素邻域中与种子具有相似性质的像素合并到种子所在的区域中，使同一区域内的像素具有相同的属性特征，直到图像中没有像素可以被并入区域中，算法终止。

表 2-3 区域生长算法

Table 2-1 Region growing algorithm

算法：区域生长算法
输入：图像的宽 width、高 height，初始种子；
输出：图像分割结果
伪代码：
1、根据 width、height 建立全零矩阵 mask；
2、初始化种子点，按种子坐标将 mask 中对应像素点的灰度以种子的聚类标签进行填充；
3、以 mask 中的种子点为起点，遍历 mask 中所有像素点，将种子点 8-邻域内未被标记的像素点填充种子的标签；
4、更新 mask 中的种子；

5、重复步骤 3、4，直到 mask 中所有像素点都被标注。

输出 mask

本文将 PSF 的位置选取为初始种子点，把 PSF 聚类标签作为种子初始值，利用区域生长算法对图像进行分割。区域生长算法的流程如表 2-3 所示。

区域生长算法输出的矩阵被标签填充，按照标签对 mask 进行分割可得到若干个子图像，由于算法利用 PSF 聚类的结果作为初始种子，所以可以保证同簇的 PSF 被分割在同一个子图像中，这样就将 PSF 数据的内在联系运用到了图像的分割中，与其他图像分割算法相比，本算法对图像视场的分割更具有合理性。

2.7 图像分区反卷积复原

图像复原的数学本质就是通过反卷积去除成像退化过程对图像造成的影响。本文采用盲反卷积的复原方法，从图像中提取星点的 PSF 作为先验 PSF，为了提高 PSF 的一致性，通过区域生长算法对相似的视场区域分割，再利用 SOM 聚类后的 PSF 与对应图像区域反卷积、拼接，得到最终的复原图像。

使用伸缩梯度投影法（Scaled Gradient Projection Method, SGP method）算法对退化子图像反卷积，2009 年，Bonettini 等^[41]提出将 SGP 应用于天文图像的盲复原，算法在迭代过程中加入约束项以限制噪声在图像复原过程中的影响，该方法具有复原精度高、响应速度快、稳健性好等优点。

SGP 算法将图像复原过程归纳为一个特殊约束下的最优化问题，如公式(2-7)所示。

$$\begin{aligned} \min J(x), \\ \text{sub. to } x \geq 0, \end{aligned} \quad (2-7)$$

x 为图像复原的结果，是清晰图像的近似估计。 $J(x)$ 为退化过程与真实退化过程的 KL(Kullback-Leible)散度，反应两者之间的差异，其定义如公式(2-8)所描述^[42]：

$$\begin{aligned} J(x) &= D_{KL}(Ax + yg, y) \\ &= \sum_{i=1}^N \left(\sum_{j=1}^N A_{ij}x_j + yg - y_i - y_i \lg \frac{\sum_{j=1}^N A_{ij}x_j + yg}{y_i} \right) \end{aligned} \quad (2-8)$$

A 为 PSF 在频域下的向量展开形式， y 为真实退化图像的频域向量展开形式，对于大小为 $m \times n$ 的图像， y 的维度为 $N(N=m \times n)$ ， g 为不考虑噪声情况下退化图像的频域

向量展开。SGP 算法通过迭代反卷积进行图像复原，每次迭代过程都需要计算梯度投影 $P_{\Omega, D_k^{-1}}(x^{(k)} - \alpha^k D_k \nabla f(x^{(k)}))$ 。 Ω 表示空间中的一个凸集， f 为定义在凸集上的函数， k 表示当前迭代数， α 表示迭代步长， D_k^{-1} 为 D_k 的逆矩阵， D_k 为在 Barzilai 等^[43]提出的迭代更新策略下的投影过程的缩放矩阵，定义如公式(2-9)所示：

$$D_k = \text{diag}(d_1^{(k)}, d_2^{(k)}, \dots, d_N^{(k)}),$$

$$d_i^{(k)} = \min \left(L, \max \left\{ \frac{1}{L}, \left[\frac{\partial^2 J(x^{(k)})}{(\partial x_i)^2} \right]^{-1} \right\} \right), i = 1, 2, \dots, N \quad (2-9)$$

缩放矩阵 D_k 中的元素 $d_i^{(k)}$ 为 $\nabla^2 J(x)$ 的海森矩阵求逆所得。但在实际的求解过程中，为了优化迭代过程的效率，选择阈值 L 按照公式(2-9)进行更新迭代 $d_i^{(k)}$ 的值。

SGP 算法在迭代的过程中，计算频域下估计的清晰图像与退化过程 A 的乘积，与实际退化图像的 y 的散度作为迭代复原的评价函数，将复原问题转化为数学上的最优化问题。本文将 PSF 聚类后同簇均值 PSF 作为迭代反卷积的先验 PSF，利用 SGP 算法结合先验 PSF 对图像分割后的每一类退化图像进行复原，再将分区复原的图像拼接，得到分区反卷积图像。

2.8 本章小结

本章主要讨论了大视场空间变化 PSF 图像的复原问题，并提出了一种基于视场图像分割的图像分区复原方法，从原理的角度上探讨其可靠性。讨论了图像退化过程与反卷积复原过程的数学模型，详细叙述了图像分割反卷积方法的步骤，包括：星点坐标提取、PCA 降维、PSF 聚类、图像分割以及分区反卷积复原，实现了一套完整的图像复原体系。

第三章 基于图像分区复原的多通道望远镜数据处理方法

在进行图像叠加工作中，叠加效果会受像质最差的图像限制，为了改善这一问题，在本章的工作中，首先根据第二章提出的天文图像分区复原方法对多通道望远镜获取的图像进行了处理，以提高图像像质，然后结合图像配准算法矫正复原图像之间存在的几何偏差，再将配准后的复原图像进行叠加，并对最终的叠加结果加以分析。

3.1 实验过程

3.1.1 数据介绍

本章所用到的数据来自多通道望远镜拍摄于 2012 年 9 月 8 日至 9 月 10 日观测的 4×537 张图像。图像及相关参数如表 3-1 所示。

表 3-1 图像与成像参数

Table 3-1 Parameters of image and imaging process

Parameter	Value	Parameter	Value
Focal Ratio	f/1.18	CCD Pixel Size	$13\mu\text{m} \times 13\mu\text{m}$
Exposure Time	100ms	FOV	$2^\circ \times 2^\circ$
Image Size	1024pixel $\times$ 1024pixel		

3.1.2 实验分析

按照第二章的流程，对天文图像进行处理，处理流程如图 3-1 所示：




图 3-1 数据处理过程

Fig.3-1 Processes of data

在星点提取的过程中，一共提取到 61779 个星点坐标，按照亮度保留前 85% 的亮星，并提取星点的 PSF，获取总计 52511 个大小为 11×11 的 PSF 数据。从退化图像中提取的 PSF 如图 3-2 所示。




图 3-2 退化图像的 PSF

Fig.3-2 PSF of degrade image

对 PSF 进行 PCA 降维，保留前 9 项主成分，得到降维结果。再通过 SOM 聚类算法对降维 PSF 进行聚类，聚类数为 2~20 类，并计算各个分类结果的 DB 指数，选择 DB 指数最小的聚类方案。DB 指数计算结果如图 3-3 所示。




图 3-3 退化图像的 PSF

Fig.3-3 PSF of degrade image


由图 3-3 可知当聚类数为 2 类时，数据的 DB 指数是最小的，因此可确定将数据分成 2 类的分类方案是最合理的。

为了验证 PCA 降维数据聚类结果的合理性，本文利用 PCA 降维后得到的特征值矩阵和特征向量对 PSF 进行了重构，再比较重构后的 PSF 数据和聚类后的 PSF 数据是否具有相同的分布特征，如表 3-2 所示。


表 3-2 PSF 质心对比
Table 3-2 The comparison of PSFs' centroid

	聚类 1	聚类 2	重构 1	重构 2
均值	(5.007,5.024)	(5.057,4.745)	(5.013,5.030)	(5.052,4.735)
标准差	(0.303,0.290)	(0.414,0.456)	(0.283,0.267)	(0.273,0.367)


表 3-2 展示的是原始 PSF 的 SOM 聚类结果和 PCA 降维重构结果的质心统计数据。对于低采样率下的 PSF，质心能够粗略反映出 PSF 的形态差异。通过比较聚类 1 和重构 1、聚类 2 和重构 2，可发现二者的质心分布基本一致，且 PCA 降维可以剔除冗余噪声，所以重构结果具有更小的标准差。因此可得知 PSF 经 PCA 降维后数据中仍包含原始 PSF 的形态特征，SOM 实际上也是根据 PSF 的形态分布进行聚类的。




(a)退化图像
(a)Degrade image




(b)聚类结果
(b)Cluster result



(c)图像分割掩膜
(c)Mask of image segment



(d)分割区域 1
(d)Part 1 segment region




(e)分割区域 2
(e)Part 2 of segment region


图 3-4 图像分割结果
Fig.3-4 Result of image segment

将 PSF 聚类后标签结合 PSF 在图像中的坐标作为区域生长算法的初始种子，对退化图像进行分割。结果如图 3-4 所示。

将聚类结果的均值作为图像反卷积的先验 PSF，使用 SGP 算法对退化图像进行分区反卷积，再将得到的复原区域进行拼接，得到最终的复原图像。如图 3-5 所示。



(a)退化图像
(a)Degrade image



(b)复原图像
(b)Restore image

图 3-5 图像复原结果
Fig.3-5 Result of image restoration

3.2 实验结果

根据图 3-4 的结果对比,在经过 SGP 反卷积后,复原图像的星象轮廓在视觉效果上比退化图像更为显著。为了客观评价本文算法处理后的图像复原质量,采用星象信噪比分别对退化图像和复原图像进行评估。

3.2.1 星象信噪比

本文的星象信噪比定义如下所述:以星点坐标为中心,在星点周围划分 20×20 像元的区域,求该区域的信噪比即为星象信噪比,信噪比计算如公式(3-1)所示^[44]。

$$SNR = \frac{F - (N_{photo} \times b)}{\sqrt{N_{photo} \times \sigma^2}} \quad (3-1)$$

F为星象区域中像素光通量的总和,b为背景的灰度均值, σ^2 为背景的方差, N_{photo} 为星象区域中像元的数量。在一定程度上,星象信噪比的高低可以体现出图像的品质,其值越大,说明星象受噪声影响越小,观测质量越好。

3.2.2 数据分析

多通道望远镜由四个小口径望远镜同轴安装构成,四个通道下原始图像与复原图像的星象信噪比统计结果如表 3-3 所示。

表 3-3 星象信噪比统计
Table 3-3 The statistics of stars' SNR

	C1	C2	C3	C4	D1	D2	D3	D4
均值	10.61	9.47	10.51	9.48	13.01	13.30	11.87	11.94
标准差	10.13	9.00	9.88	9.12	9.54	12.10	13.46	11.94

表 3-3 中 C1/C2/C3/C4 表示四个通道下原始图像的星象信噪比,D1/D2/D3/D4 表示四个通道下复原图像的星象信噪比,可发现复原图像的星象信噪比都比原始图像的要高。

表 3-4 不同分区反卷积方法的星象信噪比倍率统计
Table 3-4 The statistics of deconvolution' s SNR ratio in different section method

	CR1	CR2	CR3	CR4	SR1	SR2	SR3	SR4
均值	12.973	9.045	12.202	11.015	13.799	9.256	12.634	11.371
方差	106.65	50.05	91.37	75.90	151.37	56.43	110.98	91.18

为比较本文的分区反卷积方法和传统的 2×2 分块反卷积方法的结果,分别统计四个通道下 94 组图像按两种方法复原后的星象信噪比提升倍率,如表 3-4 所示。

表 3-4 中 CR1/CR2/CR3/CR4 分别表示本文的聚类分区反卷积算法下四个通道图像对应的复原结果星象信噪比提升率, SR1/SR2/SR3/SR4 分别表示 2×2 分区反卷积算法的复原结果星象信噪比提升率。相比较而言,两种算法都可以提高 SNR,改善观测效果。为了更加直观的比较,将 94×4 组数据以折线图的形式展现,如图 3-6 所示。




图 3-6 不同分区方法的平均星象信噪比倍率对比

Fig.3-6 The comparison of averaged star SNR ratio in different section methods

从图 3-6 中可以较直观的发现, 2×2 分区方法在部分通道的复原结果中出现了信噪比下降的现象,再结合表 3-4,在 2×2 分区方法的统计数据中方差较大,说明信噪比提升率的波动较大。因此,本文所提出的聚类分区复原算法相比传统的分区方法而言,对图像质量的提升更为稳定。

3.3 基于多通道望远镜的图像叠加方法

多通道望远镜由 4 个构造相同的小口径折反式望远镜同轴安装组成,四个镜筒指向同一天区,可观测同一时刻下同一视场位置的天文目标,多通道望远镜如图 3-7 所示。



图 3-7 多通道望远镜

Fig.3-7 Quad-channel Telescope

2002 年, Fruchter 等^[45]提出, 通过图像配准和灰度值叠加的方法可以提升图像的质量。将多通道望远镜同时刻下的观测图像进行叠加可达到与大口径望远镜详尽的灵敏度。2017 年, Ping 等^[46]通过对多通道望远镜的指向模型分析, 指出望远镜之间存在指向差异, 导致多个望远镜的观测图像间存在几何偏差, 并通过对未安装滤光片的观测图像进行配准矫正和叠加, 使星象信噪比和星象探测能力得到提高。但是直接配准图像进行叠加, 其结果会受多个望远镜中分辨效果最差的望远镜限制, 将本文的大视场图像反卷积复原方法应用到多通道望远镜图像的叠加中可以提高观测灵敏度。

3.3.1 几何偏差分析

理论上, 多通道望远镜的 4 个镜筒指向一致, 但由于跟踪观测和 CCD 安装过程的偏差, 图像无法直接按对应坐标进行叠加。通过对不同镜筒观测到图像间的几何偏差进行分析, 利用几何变换的方法对偏差进行矫正, 就可以将反卷积复原的图像应用到图像叠加中。




图 3-8 正方形图像通过不同变换模型的变换结果

Fig.3-8 The results of a square image transformed by different transform models

常见的图像几何变换模型包括：平移变换、欧几里得变换、仿射变换以及透射变换，如图 3-8 所示。图 3-8 中任意几何变换之间的转换都可以通过一个单应性矩阵来实现，单应性矩阵 M 的数学定义如公式(3-1)所示。

$$\begin{pmatrix} \tilde{x} \\ \tilde{y} \\ \tilde{z} \end{pmatrix} = M \cdot \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} m_{11} & m_{12} & m_{13} \\ m_{21} & m_{22} & m_{23} \\ m_{31} & m_{32} & m_{33} \end{pmatrix} \cdot \begin{pmatrix} x \\ y \\ z \end{pmatrix} \quad (3-1)$$

公式(3-1)中，对于平面中的任意一点坐标 $d = (x, y)^T$ 都可通过矩阵 M 变换得到另一平面下的点 $\tilde{d} = (\tilde{x}, \tilde{y})^T$ ，公式中的 z 、 $\tilde{z}$ 为方程的齐次项，始终为 1。 M 中的 9 个元素之间相互独立，通过不同的组合可以实现不同的变换用途： m_{13} 和 m_{23} 实现对 x 和 y 方向的平移，对这两个值进行设定可以实现平移变换； m_{11} 和 m_{22} 控制 x 和 y 方向上的尺度缩放，结合 m_{12} 和 m_{21} 可以实现欧几里得变换；将上述 6 个参数结合可实现仿射变换； m_{31} 和 m_{32} 分别为 x 和 y 方向上的视角参数， m_{33} 为比例参数，通常为取固定值 1，结合 9 个参数可以实现三维空间的物体在二维平面上的投影，即透射变换。透射变换的单应性矩阵包含所有几何变换参数，其他几何变换都是特殊情况下的透射变换，都可以通过透射变换实现。

多通道望远镜中，镜筒之间的偏差包括望远镜安装带来的平移和旋转偏差、望远镜调试过程引入的尺度偏差以及 CCD 轴面倾斜造成的视角偏差，CCD 上观测图像的实际中心偏离预期中心，因此需要使用透射变换对图像进行矫正。

3.3.2 图像配准

作为图像配准过程的重要一环，单应性矩阵的准确度会直接影响到图像叠加的效果，如果单应性矩阵中元素与实际值偏差过大，将造成叠加结果中出现“重影”现象。为保证图像配准精度能够达到预期要求，将图像的增强相关系数(Enhanced Correlation Coefficient, E_{ECC})作为评价配准精确程度的标准， E_{ECC} 反映了两个图像之间的相关关系程度， E_{ECC} 值越大，图像之间的差异越大^[47]。 E_{ECC} 计算公式如(3-2)所示。

$$E_{ECC} = \left\| \frac{\vec{F}_0}{\|\vec{F}_0\|} - \frac{\vec{F}_i}{\|\vec{F}_i\|} \right\|^2 \quad (3-2)$$

$\vec{F}_0$ 为基准图像的向量化结果， $\vec{F}_i$ 为图像 i 的向量化结果。配准过程可描述如下：选取同一时刻观测图像中信噪比最高的图像作为基准图像，计算其他图像与基准图像间几何变换的单应性矩阵，通过单应性矩阵得到配准图像，并计算配准图像和基准图像的 E_{ECC} ，当 E_{ECC} 大于预设阈值时，矩阵中元素按预设定的步长变化，继续迭代计算 E_{ECC} ，直到满

足配准精度，停止迭代，返回单应性矩阵变换后的配准图像。通过对算法中 E_{ECC} 阈值的设定，配准精度可达到亚像素级，保证了图像叠加结果的准确性。

3.3.3 图像叠加结果分析

将 3.2 节中反卷积处理后得到的 94 组复原图像进行配准叠加，结果如图 3-9 所示。




图 3-9 图像叠加结果

Fig.3-9 The results of co-adding

从图 3-9 中可观察到反卷积复原后星点的轮廓更加清晰，将复原图像配准叠加后星点在图像中更加明显。




图 3-10 星象信噪比倍率均值比较

Fig.3-10 The comparison of stars' averaged SNR ratio

为了客观评价图像反卷积对图像叠加的影响,分析直接叠加结果与反卷积后叠加结果的星象信噪比提升倍率统计,如图 3-10 所示。从图 3-10 中可发现,反卷积复原后的叠加图像,其星象信噪比的提升倍率比直接将退化图像进行叠加的结果更高,即表明反卷积后的复原图像能够进一步提高图像叠加结果的质量。

为了验证图像叠加对星点探测能力的影响,应用 2.4 节提取星点坐标的方法对退化图像、直接叠加图像与反卷积复原叠加图像的星点提取结果进行统计,如图 3-11 所示。




图 3-11 星点提取统计结果

Fig.3-11 The statistics of star extraction

从图 3-11 中可观察到,经图像叠加后,图像中可以检测到更多星点目标的存在,而应用反卷积复原方法后,对星点的探测能力得到进一步提升。

3.4 本章小结

本章主要对分区反卷积复原算法进行了实验,并客观的分析了其结果。首先对 PCA 降维数据的可靠性进行了验证,对复原结果的信噪比数据进行分析,验证了算法的有效性。然后将本文的复原算法与传统的分区复原算法的结果进行比对,验证了算法的稳定性。最后,将本文算法应用到多通道望远镜的图像叠加工作中,并从信噪比倍率和星点探测能力两个方面验证了反卷积算法可以进一步提高图像叠加结果的质量。

第四章 基于深度学习的天文图像复原研究

通过从星点中提取先验 PSF，使反卷积方法在星象图像的复原工作中得到了很好的应用。但是针对星系、全日面等非点状结构的图像，并不能很好的将 PSF 从图像中解析出来，目前应用较广泛的斑点重建法需要使用上百帧图像的数据才能复原出一帧清晰的图像，这样造成了大量观测图像的浪费。在本章中，借鉴深度学习算法在图像去模糊方面的应用，提出了基于深度学习的天文图像复原算法，算法的本质仍在于通过神经网络精确构建图像的 PSF，从而提高算法的复原效果，旨在为此类图像 PSF 的提取和建模提供思路。

4.1 卷积神经网络简介

卷积网络起源于神经科学，早在上世纪 60 年代，Wiesel 等^[48]在研究猫的大脑皮层的过程中观察到神经元构成的网络结构，提出了 CNN(Convolutional neural network)的概念。卷积神经网络在功能上模拟了生物神经元轴突和树突间的信号传递、神经元的激活过程和神经元对信号的处理过程，如图 4-1 所示。




图 4-1 生物神经元数学模型

Fig.4-1 Neural unit architecture

4.2 卷积神经网络结构

卷积神经网络是一种专门用来处理类似网格结构数据的神经网络，比如时间序列数据或图像数据。典型的卷积神经网络主要包含卷积层、池化层、激活函数以及全连接层等结构，网络之中层层之间相互组合实现复杂的任务。1988 年，Lang 等^[49]在对时间序列的分析工作中提出利用反向传播对时延神经网络进行训练。1998 年，Lecun 等^[50]提出

了基于 CNN 结构的 LeNet5，并将其应用到手写字符的识别。以 LeNet5 为例，CNN 的结构如图 4-2 所示。




图 4-2 LeNet5 网络结构

Fig.4-2 LeNet5 network architecture

卷积核是组成卷积层最基本的单元，卷积核的大小决定了感受野的大小。感受野是指神经网络中某一层的输出像素对应其输入层像素区域的大小，在网络中表示卷积核可以从图像中提取特征的范围，卷积核越大，该层特征图对应的感受野也就越大。

卷积层由若干卷积核组成，卷积层的作用就是提取输入数据中的特征，输入图像通过卷积层得到特征图，卷积神经网络具有权值共享的特点，保证了在同一特征图内的区域具有相近的特征，并且减少模型训练过程需要优化的参数数量。浅层卷积层能够提取图像的边缘轮廓等简单特征，深层卷积层能够提取复杂的特征。

在神经网络中，线性模型并不能解决所有问题，卷积过程代表的是线性拟合能力，还需要通过激活函数弥补模型的非线性拟合能力。激活函数通过非线性映射将图像特征从一个向量空间转换到另一个向量空间，使特征更加具体。此外，激活函数还起到对数据归一化的作用，如 $\tanh$ 函数，可以将数据压缩到 $[-1,1]$ 区间范围内。

池化层主要起到压缩数据减小模型计算量和提取特征图中主要特征的作用。全连接层的本质是一个多层感知器，其目的是将所有特征图结合在一起，再将结果输出。

4.3 基于深度卷积神经网络的天文图像复原研究

在计算机视觉领域的研究当中，图像复原一直是一个值得探究的问题。基于深度学习的图像复原已经大量运用到动态场景图像的去模糊问题上。2014 年，Xu 等^[51]通过深度卷积神经网络对模糊图像进行复原，模糊图像和清晰图像之间实现端对端映射，不需要对图像进行额外的处理，同时证实了深度学习可以在图像复原工作上得到很好的结果。2017 年，Remi^[52]将卷积神经网络应用到天文图像的复原研究中，利用哈勃空间望远镜

观测的原始图像与生成的艾里斑卷积得到模拟的模糊图像，再利用一个 3 层卷积神经网络对图像进行复原，与维纳滤波相比，得到了较好的复原结果。

根据本文 2.2 节的介绍，图像反卷积可以认为是频域下 $H^{-1}(u, v)$ 与图像的乘积，即一个反卷积算子与图像在时域下的卷积。在 Tikhonov 正则化下，维纳滤波可以表达成公式(4-1)所示。

$$f(x, y) = F^{-1} \left(\frac{1}{F(h(x, y))} \left\{ \frac{|F(h(x, y))|^2}{|F(h(x, y))|^2 + \frac{1}{SNR}} \right\} \right) * g(x, y) = h^{-1}(x, y) * g(x, y) \quad (4-1)$$

SNR 为图像的信噪比， F 、 F^{-1} 分别表示傅里叶、傅里叶逆变换， $h^{-1}(x, y)$ 表示反卷积核。在数学上可通过奇异值(SVD)分解等手段对反卷积核进行分解，所以退化图像与反卷积核的卷积可被分解成退化图像和一系列向量的运算结果，如公式 4-2 所示。

$$h^{-1}(x, y) * g(x, y) = \sum_{j=1}^m s_j \cdot u_j (v_j^T * y) \quad (4-2)$$

经 SVD 分解， $h^{-1}(x, y) = USV^T$ ，反卷积核被分解成矩阵 U 、 V 和一个对角阵 S 的形式。成公式 3-2 中的 u_j 和 v_j 项分别为 U 和 V 的第 j 个列向量， s_j 为 $h^{-1}(x, y)$ 的第 j 个特征值。因此，二维矩阵之间的卷积可以看成矩阵与一维向量卷积的加权和。

在第二章中提到了基于传统盲反卷积方法的大视场天文图像复原，PSF 可以从星点、空间碎片等点状目标中提取，但是对于星云、星系以及全日面等不具有点、线结构的天文图像，很难得到其 PSF，这一类图像的盲复原成为一个问题。通过深度学习进行图像反卷积可以被归纳为利用卷积神经网络拟合反卷积核与退化图像作用的复原过程。反卷积核的可分离性可通过多层卷积核之间的相互堆叠来实现。这一过程不涉及卷积核的提取，信息都来源于退化图像，因此属于图像盲复原的范畴。本文对此类图像应用深度卷积神经网络，设计了一个“端对端”的 CNN 模型，先通过模拟生成清晰——模糊图像对用于模型的训练，然后再将训练好的模型应用到真实的模糊图像复原工作中。

4.4 网络结构

PSFNET 总共包含三种结构，分别是卷积层、Res Block 结构和反卷积层。

基于 4.3 节的分析，本文设计的天文图像 PSFNET 思路来源于卷积核的可分解性，网络结构可解释为如公式(4-3)所示：

$$c_i = \sigma(h_{i-1} * w_i + b_i), \quad h_0 = x, \quad i = 0, 1, 2, 3 \quad (4-3)$$

c_i 表示卷积层, 当 $i=0$ 时 h_0 表示输入层。 w_i 为第 $i-1$ 层到第 i 层的映射权重, b_i 为偏置向量, $\sigma(\cdot)$ 表示非线性激活函数。本文中选择了 Leaky ReLU 函数作为激活函数。ReLU 函数的数学模型如图 4-3(a)所示, 在负数端斜率为 0, 正数端斜率为 1。本文采用的 Leaky ReLU 函数在负数端不为 0, 而是通过斜率 α 来控制, 当网络层数较多时可以比 ReLU 函数更有效地克服梯度消失, 提高模型的收敛速度。




图 4-3 激活函数 Leaky ReLU 和 ReLU

Fig.4-3 Activity function Leaky ReLU and ReLU

Res Block 结构如图 4-4 所示, Num 为卷积核的数目, 其结构中独有的 skip connection 可以有效解决深层网络中的梯度弥散问题, 提高梯度在网络中传递的效率。




图 4-4 Res Block 结构

Fig.4-4 Res Block architecture

在卷积层和 Res Block 中, 卷积核的步长会缩减图像的大小, 输出图像与原始图像大小不一致。PSFNET 在图像输出网络前通过反卷积层将图像填充至原始大小, 该过程类似图像的上采样过程, 保证了图像的大小不会改变。

网络结构如图 4-5 所示，网络详细参数如图 4-6 所示。




图 4-5 PSFNET 结构

Fig.4-5 PSFNET architecture




图 4-6 PSFNET 网络参数

Fig.4-6 Parameters of PSFNET

4.5 训练过程

4.5.1 数据准备

PSFNET 进行训练时需要输入清晰-模糊图像对作为训练集，其中清晰图像在模型中作为模糊图像的训练标签。本文的数据来源于云南抚仙湖太阳观测站 NVST 的 $H\alpha$ 波段散斑重建图像和真实的模糊图像，如图 4-7 所示。数据的参数如表 4-1 所示。




图 4-7 观测图像

Fig.4-7 Observation images

表 4-1 原始图像参数

Table 4-1 Parameters of raw images



















Parameter	Value	Parameter	Value
Exposure Time	20ms	观测波段	$H\alpha$
Image Size	1024pixel $\times$ 1024pixel	FOV	139.264 $\times$ 139.264 arcsec ²

要精确的描述大气湍流的状态需要用到尽可能全面的成像系统参数，但是大多数观测系统都难以提供足够的测量参数，因此本文应用 ESO 35(European Southern Observatory) 湍流剖面参数作为经验参数，并假设湍流剖面稳定，然后通过 Monte Carlo 模拟结合大气湍流相位屏生成方法，生成大量不同视宁度下短曝光成像系统 PSF。为了提供足够的 PSF 作为训练集，本文在每个视宁度下都生成了 1000 个大小为 128 $\times$ 128 的短曝光 PSF。

在同一观测系统中，视宁度根据 d/r_0 来衡量。望远镜口径 d 保持不变，大气相干长度 r_0 越大， d/r_0 越小，观测效果越好。本文模拟的不同 d/r_0 下的 PSF 表 4-2 所示。

表 4-2 Monte Carlo 模拟生成不同视宁度的 PSF

Table. 4-2 PSFs generated by Monte Carlo simulation in different seeing condition

d/r_0	PSF			
1~4				
5~8				
9~12				
13~16				
17~20				

从表 4-2 可以观察到随着 d/r_0 的增大, PSF 的形态也越来越复杂, 那么对应生成的模拟模糊图像也会越来越模糊。图像复原算法对 PSF 的精度要求较高, 为了得到接近真实模糊数据的 PSF, 先利用插值法将 d/r_0 为 5~19 的模拟 PSF 重采样至与清晰的散斑重建图像的分辨率, 然后与散斑重建图像卷积, 使得到的模糊图像在观测分辨率上与真实数据保持一致。然后计算不同 d/r_0 下模拟模糊图像与真实模糊图像的余弦距离, 计算公式如公式(4-4)所示。

$$\begin{cases} D = \sum_{l \in L} (1 - \frac{Gram(VGG(a)) \cdot Gram(VGG(b))}{\|Gram(VGG(a))\| \cdot \|Gram(VGG(b))\|}) \\ Gram(a) = a \cdot a^T \end{cases} \quad (4-4)$$









其中, $VGG(\cdot)$ 为经一个冻结的 VGG19 输出的特征图, $Gram(\cdot)$ 为对图像向量求 Gram 矩阵, $\|\cdot\|$ 为求一范数。Gram 矩阵是图像各特征之间的偏心协方差矩阵, 可以反映各个

特征与并体现和其他特征间的关系，所以可以反映整个图像的大体风格。将图像 a 、 b 送入 VGG19，得到 VGG19 输出的图像特征图， L 为指定的特征图集合， $L=\{\text{Conv2-2}, \text{Conv3-2}, \text{Conv4-2}, \text{Conv5-2}\}$ 。 D 为 1 与图像 a 、 b 的余弦距离的差值，取值在 0~1 之间。余弦距离越大，两幅图像间的模糊差异就越小， D 就越小。

对于如图 4-7(a)所示的清晰图像，VGG19 提取的高维特征图如表 4-3 所示。

表 4-3 VGG19 特征图

Table 4-3 Featuremaps of VGG19

卷积层（图像尺寸）	特征图			
Conv1(512×512)				
Conv2(256×256)				
Conv3(128×128)				
Conv4(64×64)				
Conv5(32×32)				

计算不同视宁度下的 PSF 生成的模拟图像与真实模糊图像的余弦距离统计结果如图 4-8 所示。






图 4-8 不同视宁度模拟图像与真实图像的余弦距离统计

Fig.4-8 The statistics of different seeing simulation images and real images' cosine distance

结合上述分析与图 4-8 的结果,可以确定 d/r_0 为 16 的模拟数据与真实数据之间的模糊程度最接近,因此选取 d/r_0 为 16 的模拟数据与清晰图像组成清晰——模糊图像对作为模型的训练集数据,如图 4-9 所示。



(a)



(b)

图 4-9 清晰--模糊图像对

Fig. 4-9 Image pairs of the distincts and the blurs

4.5.2 Batch Normalization

在模型的训练过程中,数据的初始值分布会对训练结果产生影响。初始值过大或过小都会导致数据在经过激活函数映射后饱和,造成反向传播时不能正确的将梯度进行反馈。2015 年 Sergey 等^[53]提出了 Batch Normalization(BN)的方法。该算法在数据进行前向传递的过程中,在激活函数处理前,对数据进行标准化处理,在数据反向传播的过程中,对数据进行反标准化处理。算法如表 4-1 所示。

表 4-1 Batch Normalization 算法
Table 4-1 Batch Normalization algorithm

算法：Batch Normalization

输入：批数据 $B=\{x_1, x_2, \dots, x_m\}$;待学习参数 γ, β ;

输出： $\{y_i = BN_{\gamma, \beta}(x_i)\}$;

伪代码：

- 1、计算批数据均值 $\mu_B = \frac{1}{m} \sum_{i=1}^m x_i$;
- 2、计算批数据方差 $\sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$;
- 3、对数据进行标准化，更新数据 $\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$;
- 4、反向传播过程进行反标准化 $y_i = \gamma \hat{x}_i + \beta \equiv BN_{\gamma, \beta}(x_i)$

算法的前三步发生于前向传播，第四步发生于反向传播，整个过程实现了对数据的扩展和平移，并且模型对扩展参数 γ 和平移参数 β 进行学习，模型能根据数据的梯度变化调节 γ 和 β 。

本文在反卷积网络的激活函数前布置了 BN 处理，以达到增强模型表达能力、加速模型收敛的目的。

4.5.3 损失函数和优化方法

(1) 损失函数

目前大多数基于深度学习的图像复原方法都将复原图像与清晰图像的 MSE 作为损失函数，如公式(4-4)所示。

$$MSE = \frac{1}{N} \sum_{i=1}^N (\hat{x} - x)^2 \quad (4-4)$$

$\hat{x}$ 为复原图像， x 为清晰图像， N 为图像的像素点总数。MSE 反映的是预测值与真实值之间距离的平方和，在距离 $|e|>1$ 时，计算 MSE 可以放大预测值与真实值之间的差距，使差距更加显著，但是当 $|e|<1$ 时，MSE 的值会比 $|e|$ 的实际值更小，所以并不能很好的反映出两者的差异。

考虑到 MSE 作为损失函数不足以完全表现出图像的差异，在计算损失函数的工作中应用了孪生神经网络的策略。孪生神经网络最早于 1993 年由 Lecun 等^[54]提出，应用于支票签名图像的匹配工作中。孪生神经网络由两个权值完全相同的神经网络构成^[55]，

目前广泛应用于识别、认证以及目标跟踪等任务当中。本文使用两个权值相同的 VGG19 构成一个孪生神经网络，用于损失函数的计算，网络结构如图 4-10 所示。




图 4-10 孪生神经网络结构

Fig. 4-10 Siamese network architecture

在孪生神经网络中，使用了两个完全一致的 VGG19，VGG19 的实际作用相当于特征提取器，将图像映射到新的特征空间。VGG19 的网络结构较深，能够提取更为抽象复杂的图像特征。在结构上，VGG19 包含 16 个卷积层，使用多个 3×3 的卷积核串联减少参数数量，且保证了底层卷积核的感受野不变。使用 1×1 的卷积核提高了非线性映射能力。图像通过 VGG19 处理后被映射到更高的维度，图像的特征也更加明显。

为了保证 VGG19 的权值不变，将在 ImageNet 数据集上预训练的 VGG19 模型参数冻结，使 VGG19 的参数不参与反向传播的参数更新，再将反卷积网络的输出和原始清晰图像同时作为孪生神经网络的两个输入，得到复原图像的特征图和原始清晰图像的特征图用于计算模型的损失，损失函数如公式(4-5)所示：

$$Loss = \frac{1}{N} \sum_{i=1}^N (\hat{x} - x)^2 + \frac{\lambda}{L} \sum_{l \in L} \left(1 - \frac{Gram(VGG(a)) \cdot Gram(VGG(b))}{\|Gram(VGG(a))\| \cdot \|Gram(VGG(b))\|} \right) \quad (4-5)$$

公式中 x 表示原始的清晰图像， $\hat{x}$ 表示反卷积网络输出的复原图像。损失函数为两项相加的形式，其中前一项 $\frac{1}{N} \sum_{i=1}^N (\hat{x} - x)^2$ 为复原图像与清晰图像的 MSE，后一项为 VGG19 特征图的余弦距离， L 同公式(4-4)， λ 为正则项系数，本文中 $\lambda = 10^3$ 。

(2) 优化方法

深度学习模型的训练过程需要应用到优化算法，优化过程通常是一个非常困难的任务。在优化过程中，经常会遇到非凸优化问题，即优化问题的局部最优解不是全局最优

解。即使是凸优化问题，也存在局部最小值等情况，因此，优化算法的选择也是训练过程中的重要环节。

基本的优化算法包括随机梯度下降算法、动量算法以及 Nesterov 动量算法。随机梯度下降算法计算样本的梯度，再根据设定的学习率更新步长，使样本不断向学习任务靠近，这个过程一般会非常漫长。动量算法的提出加快了模型学习的过程，该方法通过累计梯度在指数衰减下的平均变化，继续朝变化方向移动，针对高曲率或一致梯度的参数样本具有非常好的效果^[56]。2013 年，Sutskever 等^[57]提出了结合 Nesterov 加速梯度算法的 Nesterov 动量算法，该方法在标准的动量算法中添加了校正因子，减小了模型训练的额外误差收敛率。这些基本的算法都存在学习率调整的问题，导致很难设定合适的初始学习率。2014 年，Kingma 等^[58]在前人的算法的基础上总结，提出了结合自适应梯度和遗忘因子思想的 Adam 优化算法，该算法根据参数的一阶梯度矩估计和二阶矩估计调整每个参数的学习率，使迭代过程中学习率可以有一个明确的更新范围，参数能够连续稳定变化。

为了使模型能够快速收敛，并合理更新内部参数，在模型训练时需要部署合适的优化算法。综合以上分析，本文在部署网络框架时应用了 Adam 优化器，根据经验将初始学习率设定为 0.01，激活函数 Leaky ReLU 的斜率参数 α 设定为 0.2。

4.6 数据分析

模型训练过程所使用计算机 CPU 型号为 Intel CORE i5 7300HQ，核心频率为 2.5GHz，GPU 型号为 NVIDIA Tesla T4，计算机内存大小为 12GB，显存大小为 16GB。算法通过 Python3.6 语言部署在 TensorFlow 1.3 框架上。由于计算机显存大小的限制，本文将分辨率为 1024×1024 的原始图像裁剪成 200×200 的大小，使用训练集包含 220 组模拟的清晰-模糊图像对，验证集包含 28 组图像对，迭代 epoch 次数为 350 次，共耗时约为 13h。训练过程的损失曲线如图 4-11 所示。





图 4-11 训练数据损失曲线


Fig. 4-11 Loss curve of training data

从图 4-11 中可观察到，在训练迭代次数达到 300 之后，损失曲线不再有较大波动，可认为模型基本拟合。


如图 4-9(b)所示的验证集图像，在迭代次数分别为 10、50、100、150、200、250、300 次时的复原效果如图 4-12 中的(a)~(f)所示，随着迭代次数的增加，验证集图像越来越接近原始图像图 4-9(a)。




(a)Epoch 10




(b)Epoch 50




(c)Epoch 100



(d)Epoch 150



(e)Epoch 200



(f)Epoch 250

图 4-12 不同迭代次数下验证集数据复原结果

Fig. 4-12 Restoration of validation images in different epochs

为了客观衡量复原效果, 本文采用 PSNR(Peak signal-to-noise ratio)和 SSIM(structural similarity index)对验证集图像进行评价。PSNR 为图像的峰值信噪比, 是一种衡量图像失真程度的客观标准, PSNR 越大则说明两幅图像越相似, PSNR 的计算公式如公式(4-6)所示。

$$PSNR(a, b) = 20 \times \log_{10} \left(\frac{MAX(a, b)}{\sqrt{MSE(a, b)}} \right) \quad (4-6)$$

MAX 为图像 a, b 中的最大像素值, 也即图像的峰值, $MSE(\cdot)$, 为图像 a, b 的均方根误差。从公式(4-6)中可发现 PSNR 越大, MSE 越小, 图像间的距离越小, 则表示图像失真越少。

SSIM 为图像的结构相似性，用于衡量图像之间相似程度。SSIM 为基于人眼特性结构相似性指标，结合了图像的灰度、对比度以及结构信息，SSIM 取值范围为 0~1，SSIM 越接近 1 则两幅图像越相似。SSIM 的计算公式如式(4-7)所示。

$$\begin{cases} L(a, b) = \frac{2u_a u_b + C_1}{u_a^2 + u_b^2 + C_1}, \\ C(a, b) = \frac{2\sigma_a \sigma_b + C_2}{\sigma_a^2 + \sigma_b^2 + C_2}, \\ S(a, b) = \frac{\sigma_{ab} + C_3}{\sigma_a \sigma_b + C_3}, \end{cases}$$

$$SSIM(a, b) = L(a, b) \times C(a, b) \times S(a, b) \quad (4-7)$$

其中 u 为图像的均值， σ 为图像的标准差， C_1 、 C_2 、 C_3 为三个常数， $L(\cdot)$ 、 $C(\cdot)$ 、 $S(\cdot)$ 分别表征两图像在高度、对比度以及轮廓结构之间的相似性。


对 760 组测试集数据复原结果的 PSNR 和 SSIM 进行统计，如表 4-3 所示。

表 4-3 测试集复原图像数据统计
Table 4-3 The statistics of test data restoration images

	模糊图像	神经网络复原图像
PSNR	62.291	85.715
SSIM	0.682	0.894

从表 4-3 中的数据可对比出，PSFNET 处理后的复原图像 SSIM 更接近 1，PSNR 值也更高，因此本文的模型在图像复原方面起到了一定的作用。

为了衡量模型对真实模糊数据的复原效果，利用本文训练的反卷积神经网络模型对 150 组真实模糊图像进行复原，并使用 d/r_0 为 16 的平均 PSF 作为先验 PSF 维纳滤波的方法对测试集图像复原作为对比。复原的对比结果如图 4-13 所示。






图 4-13 复原结果

Fig. 4-13 Result of restoration

从图 4-13 的对比结果来看，本文的方法对退化图像的复原起到了一定的作用，和原始模糊图像比较，反卷积神经网络的复原结果的细节更丰富，但 d/r_0 为 16 的训练集模糊图像与真实模糊图像在模糊程度上仍存在差异，模拟 PSF 与真实模糊图像也存在差异，因此真实模糊图像的复原结果中还引入了噪声。此外，维纳滤波在复原过程对 PSF 的精度要求较高，因此用均值 PSF 进行维纳滤波效果与原始图像相差较大，维纳滤波很难达到较好的效果。

综上，本文使用反卷积神经网络的复原结果在视觉效果上比维纳滤波的结果更加接近原始图像。

4.7 本章小结

本章首先介绍了深度学习的发展过程以及卷积神经网络的基础理论知识，从卷积神经网络的结构和图像复原问题的原理上展开了分析和研究，简述了通过深度学习的方法对图像进行盲复原的主要原理及过程。提出了基于深度学习的天文图像反卷积网络，介绍了网络的结构、参数，对训练方式等细节问题进行了讨论，并对模型进行训练，通过模拟数据对模型进行实验和分析。经分析，本文提出的基于深度卷积神经网络的天文图像复原方法对模拟的短曝光模糊图像起到了一定的复原作用。

第五章 总结与展望

本章主要对论文全文内容进行综合归纳,总结本文的主要内容以及科研成果,讨论现阶段研究中存在的问题并展望将来的后续工作。

5.1 研究成果

天文图像复原研究对天文观测具有重要意义,现阶段的主要方法就是图像反卷积算法。在图像反卷积的过程中,算法对先验 PSF 的精度提出了要求。目前的复原算法很少会考虑到视场对 PSF 的影响,造成图像复原结果不佳,因此,对大视场空间变化 PSF 图像复原的研究具有非常重要的意义。通过对国内外大量文献的查阅与研究,本文对天文图像盲复原算法的当前现状进行分析,提出了一套针对大视场空间变化 PSF 的图像复原方法。该部分的主要内容和成果如下:

1) 在星点位置提取的过程,为了拟合出较精确的天光背景,将图像进行分割,先估计图像的局部天光背景,使图像中大部分亮星能够被检测到。

2) 对 PSF 数据进行降维,降低了聚类过程的计算复杂度,采用机器学习方法对降维数据聚类,并通过对 PCA 降维数据重构,验证聚类算法的可靠性,得出 SOM 神经网络聚类的依据是 PSF 的分布特征的结论。因此,根据这样的聚类结果对图像分割可使分割结果与实际的 PSF 视场分布更接近,为大视场天文图像的分割方法提供了一个良好的思路。

3) 将本文的图像复原方法结合图像配准方法应用到多通道望远镜的图像叠加工作中,根据星象信噪比的提升和星点探测能力的评估结果验证了本文的处理结果在像质上得到了提高。

4) 在深度学习方面,本文对基于卷积神经网络的图像复原方法的原理进行阐释,并通过实验验证了通过神经网络对大视场图像进行复原的可行性,为神经网络解析图像 PSF 的后续研究提供了一个基础。

5.2 未来工作展望

本文主要对天文图像复原方法进行了讨论，并针对图像的特性分别对传统的反卷积算法和基于深度学习的图像复原算法展开了收入的研究。目前仍存在一些尚未解决的问题，对于未来的研究安排，总结如下：

(1)本文对多通道望远镜观测图像的复原工作进行了一定的研究，根据图像 PSF 的特性对视场区域进行分割，再利用 SGP 算法进行分区反卷积，并将结果结合亚像素配准方法应用到多通道望远镜的图像叠加工作中。该过程可进一步引伸到多通道望远镜的多帧图像超分辨复原工作中，如何结合图像的特征来提高图像的空间分辨率是一个值得探究的问题。

(2)目前的反卷积神经网络处理的图像与原始图像还具有一定的差距，复原过程仍不够精准，因此还需要大量实验进一步调整网络参数提高模型的复原效果。

(3)卷积神经网络具有强大的拟合函数的能力，通过深度卷积神经网络复原对H α 波段全日面图像进行盲复原的本质就是在拟合图像的复原过程，图像复原是一个对退化过程 PSF 解卷积的过程，如何通过卷积神经网络对图像的 PSF 进行解析也是一个非常有意义的课题，神经网络解析的 PSF 可以进行到进一步的应用，比如真实的全日面图像的复原研究。所以，下一步研究的方向会放在神经网络模型参数解析上，从参数中解析出表示复原过程的反卷积 PSF，将 PSF 应用到后续的研究工作中。

参考文献

- [1] 翟磊, 董守平, 马红莲. 数字图像处理技术的发展现状与展望[C]. 全国第 19 届计算机技术与应用 (CACIS) 学术会议论文集 (上册). 2008.
- [2] 唐正宏. 图像复原技术在天体测量学中的应用暨河外射电源的精确光学定位[D]. 中国科学院上海天文台, 2001.
- [3] 周超, 杨洪波, 吴小霞, et al. 地基大口径望远镜结构的性能分析[J]. 光学精密工程, 2011, 19(1):138-145.
- [4] Bontekoe T R , Koper E , Kester D J M . Pyramid maximum entropy images of IRAS survey data[J]. Astronomy & Astrophysics, 1994, 284(3):1037-1053.
- [5] Benitez N , Broadhurst T , Rosati P , et al. Deep Imaging of AXJ2019+112: The Luminosity of a “Dark Cluster” [J]. Astrophysical Journal, 1998, 527(1):31-41.
- [6] Zavagno A , Lagage P O , Cabrit S . Extended mid-infrared emission around the outflow source and the compact H II region in AFGL 4029[J]. Astronomy and Astrophysics, 1999, 344(2):499-504.
- [7] Marchis F , Renée Prangé, Fusco T . A survey of Io's volcanism by adaptive optics observations in the 3.8- μm thermal band (1996–1999)[J]. Journal of Geophysical Research: Planets, 2001, 106(E12).
- [8] Rigopoulou D , Spoon H W W , Genzel R , et al. A large mid-infrared spectroscopic and near-IR imaging survey of ULIRGs: their nature and evolution[J]. Astronomical Journal, 1999, 118(6):1009-1038.
- [9] Foy R , Labeyrie A . Feasibility of adaptive telescope with laser probe[J]. Astronomy and Astrophysics, 1985, 152:L29-L31.
- [10] Hogbom J A . Clean as a Pattern Recognition Procedure[C]. Indirect Imaging Measurement & Processing for Indirect Imaging. Indirect Imaging. Measurement and Processing for Indirect Imaging, 1984.
- [11] Tikhonov A N , Goncharskii A V , Stepanov V V , et al. Ill-posed image processing problems[J]. Soviet Physics Doklady, 1987, 32:456.

- [12] Lucy L B. An iterative technique for the rectification of observed distributions[J]. J of Astronomy, 1974, 79(6):745.
- [13] Lohmann A W , Paris D P . Space-Variant Image Formation[J]. Journal of the Optical Society of America (1917-1983), 1965, 55(8):1007-1013.
- [14] Lee H C. Review of image-blur models in a photographic system using the principles of optics[J]. Optical Engineering, 1990, 29(5):405-421.
- [15] Bar L, Sochen N, Kiryati N. Restoration of Images with Piecewise Space-Variant Blur[C]. International Conference on Scale Space & Variational Methods in Computer Vision. 2007.
- [16] 焦继超, 赵保军, 陶芬芳, et al. 一种基于局部图像复原的天文图像增强算法[J]. 仪器仪表学报, 2011, 32(7):1455-1461.
- [17] 刘国良, 邵云龙. 基于伸缩梯度投影的天文图像复原改进算法[J]. 传感器与微系统, 2016, 35(4):134-136.
- [18] 白鹏, 魏延恒, 安涛. 基于 PSF 尺寸预估计的天文图像复原优化算法[J]. 计算机工程与应用, 2017(16).
- [19] He K, Zhang X, Ren S, et al. Identity Mappings in Deep Residual Networks[M]. Computer Vision – ECCV. 2016.
- [20] Dong C, Loy C C, He K, et al. Image Super-Resolution Using Deep Convolutional Networks[J]. IEEE Trans Pattern Anal Mach Intell, 2016, 38(2):295-307.
- [21] Dong C , Loy C C , Tang X . Accelerating the Super-Resolution Convolutional Neural Network[J]. Computer Vision – ECCV. 2016.
- [22] Kim J , Lee J K , Lee K M . Accurate Image Super-Resolution Using Very Deep Convolutional Networks[J]. Computer Vision – ECCV. 2015.
- [23] Ramakrishnan S , Gangopadhyay S P A , Raman S . Deep Generative Filter for Motion Deblurring[J]. Computer Vision and Pattern Recognition, 2017.
- [24] 李庆菲, 朱志超, 方帅. 大气湍流退化图像的复原研究[J]. 合肥工业大学学报(自然科学版), 2011, 34(1):80-82.
- [25] 退化图像复原技术在天文图片处理中的应用[J]. 红外, 2005(3):6-10.
- [26] 陈亮. 图像复原技术中的关键问题研究[D]. 中国科学院研究生院 中国科学院大学, 2012.
- [27] 周峰, 叶然, 李光伟,等. 大视场波前编码成像系统中的图像复原[J]. 光学学报, 2010, 30(2):388-393.

- [28] Nagy J G , O'Leary D P . Fast iterative image restoration with a spatially varying PSF[C]. Advanced Signal Processing: Algorithms, Architectures, and Implementations VII. International Society for Optics and Photonics, 1997.
- [29] Trussell H, Hunt B. Image restoration of space-variant blurs by sectioned methods[J]. IEEE Transactions on Acoustics Speech & Signal Processing, 1978, 26(6):608-609.
- [30] Bertin E, Arnouts S. SExtractor: Software for source extraction[J]. Astronomy & Astrophysics, 1996, 117(2):393-404.
- [31] 吴君钦, 叶彬浔. 对弱信号 CCD 图像噪声的最佳化处理[J]. 天文研究与技术, 1991(2):46-51.
- [32] 王婷婷, 苏成悦, 王娴,等. 基于多幅图像的有效点扩散函数的高精度测量[J]. 广东工业大学学报, 2010, 27(3):51-55.
- [33] Gorban A N, Kgl B, Wunsch D C, et al. Principal Manifolds for Data Visualization and Dimension Reduction[M]. Principal Manifolds for Data Visualisation and Dimension Reduction. 2008.
- [34] Gupta V, Singh R, Singh G, et al. An Introduction to Principal Component Analysis and Its Importance in Biomedical Signal Processing[C]. International Conference on Life Science & Technology. 2011.
- [35] Mika S, Smola A, Scholz M. Kernel PCA and de-noising in feature spaces[C]. Conference on Advances in Neural Information Processing Systems II. 1999.
- [36] 贺玲, 吴玲达, 蔡益朝. 数据挖掘中的聚类算法综述[J]. 计算机应用研究, 2007, 24(1):10-13.
- [37] Kohonen T . Self-Organization and Associative Memory[M]. Self-organization and associative memory. Springer-Verlag, 1984.
- [38] Everitt, Brian S, Landau, et al. Cluster Analysis[J]. Quality & Quantity, 1980, 14(1):75-100.
- [39] Davies, David L.; Bouldin, Donald W. (1979). A Cluster Separation Measure[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. PAMI-1 (2): 224–227.
- [40] 刘喜英, 吴淑泉, 徐向民. 基于区域生长法的医学图像分割研究[J]. 电视技术, 2003(9):24-25.

- [41] Bonettini S, Zanella R, Zanni L. A scaled gradient projection method for constrained image deblurring[J]. Inverse Problems, 2009, 25(1):711-723.
- [42] 聚类分析中的相似性度量及其应用研究[D]. 北京交通大学, 2012.
- [43] Barzilai, Jonathan, Borwein, et al. Two-Point Step Size Gradient Methods[J]. Ima J.numer.anal, 1988, 8(1):141-148.
- [44] Mackay C, Staley T D, King D, et al. High-resolution imaging and spectroscopy in the visible from large ground-based telescopes with natural guide stars[J]. Proceedings of SPIE - The International Society for Optical Engineering, 2010, 7735.
- [45] A. S. Fruchter, R. N. Hook. Drizzle: A Method for the Linear Reconstruction of Undersampled Images[J]. Publications of the Astronomical Society of the Pacific, 2002, 114(792):144-152.
- [46] Ping Y, Chen Z. The fast co-adding algorithm of QCT[J]. Advances in Space Research, 2017, 60(5):907-914.
- [47] Evangelidis G D, Psarakis E Z. Parametric image alignment using enhanced correlation coefficient maximization.[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2008, 30(10):1858-1865.
- [48] Wiesel T N, Hubel D H. Extent of Recovery from the Effects of Visual Deprivation in Kitens[C]. 1965:1060-1072.
- [49] Lang K J, Waibel A H, Hinton G E. A time-delay neural network architecture for isolated word recognition.[J]. Neural Networks, 1990, 3(1):23-43.
- [50] Lecun Y L , Bottou L , Bengio Y , et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [51] Xu L, Ren J S J, Liu C, et al. Deep convolutional neural network for image deconvolution[C]. International Conference on Neural Information Processing Systems. 2014:1790-1798.
- [52] Rémi Flamary. Astronomical image reconstruction with convolutional neural networks[C]. Signal Processing Conference. IEEE, 2017.

- [53] Ioffe S , Szegedy C . Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C].International Conference on International Conference on Machine Learning. 2015.
- [54] Bromley J , Guyon I , Lecun Y , et al. Signature Verification Using a Siamese Time Delay Neural Network[C]. Advances in Neural Information Processing Systems 6, 7th NIPS Conference. 1993.
- [55] Chopra S, Hadsell R, Lecun Y. Learning a similarity metric discriminatively, with application to face verification[C]. IEEE Computer Society Conference on Computer Vision & Pattern Recognition. 2005.
- [56] Polyak B T . Some methods of speeding up the convergence of iteration methods[J]. USSR Computational Mathematics and Mathematical Physics, 1964, 4(5):1-17.
- [57] Sutskever I, Martens J, Dahl G, et al. On the importance of initialization and momentum in deep learning[C]. International Conference on International Conference on Machine Learning. 2013.
- [58] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[J]. Computer Science, 2014.

致 谢

光阴荏苒，转眼研究生生涯即将划上圆满的句号。回顾往昔时光，不禁令人心生感慨。三载的寒来暑往，教会我如何积累沉淀，通过脚踏实地亲身躬耕换一个充实有意义的人生。三年是人生岁月的匆匆一瞥，我要感谢在这三年时光中一直引导我、激励我不断朝前迈进的人。

感谢我的导师贾鹏副教授。贾老师是一位非常有责任心的老师，他严以律己的态度使我意识到科研工作丝毫不可马虎。在课题研究的过程中，每当有新问题发现，老师总强调我要从多个不同的角度思考，用严谨批判的态度对待问题，多注意问题的细节和根源。在个人未来发展的问题上，老师总是会引导、培养我自己的想法，并时刻告诫我要想在人生中取得长远发展就要严格要求自己，不断提升自己的综合能力。

感谢课题组的蔡冬梅副教授和韦宏艳副教授，两位老师亲切热忱又富有耐心，在我的学习和科研工作上给予了莫大的鼓励和支持，平日里的嘘寒问暖都包含着老师们的关怀，无论是学术上还是生活上都给了我许多宝贵建议。

感谢中国科学院南京紫金山天文台的孙荣煜老师和中国科学院云南天文台的向永源老师以及云南抚仙湖太阳观测站 NVST 全组老师对我提供的实验数据和技术指导。

感谢实验室已毕业的王伟男、王利文、刘正、刘丹枫以及张智露、赵欢欢和李振军这几位师兄，在我开展课题以及日常生活中不断地帮助我、指引我。在我初入课题组期间，师兄们营造了一个充满学术氛围的科研环境，使我在进行课题研究的过程中能够坚实自己的脚步。

感谢实验室同期毕业的赵逸飞、李灿、李娟娟和毛宁这四位同学，三年来一路相互帮助，共同进步，在我失望气馁的时候激励我，在我成功的时候和我一起分享喜悦。

感谢实验室的师弟师妹们在平日生活中给我的帮助，我也很荣幸能见证你们的成长。最后，衷心感谢参与论文审阅工作的各位评审专家！

攻读硕士学位期间发表的学术论文

- [1] 蔡博君,贾鹏,孙荣煜,王伟男.基于大视场反卷积的天文图像叠加方法[J].天文学报,2019,60(01):42-56.