

分类号: TP391
学校代码: 10638

密级:
学号: 212020085400033

西華師範大學
硕士学位论文

基于深度学习的射电天文图像去噪的方法研究

论文作者 唐艳
指导教师 潘伟 副教授
学科专业 电子信息
申请学科门类 电子信息
所在学院 电子信息工程学院
论文提交日期 2023 年 4 月
论文答辩日期 2023 年 5 月

西华师范大学学位评定委员会
四川·南充
2023 年 5 月

Research on the method of radio astronomical image denoising based on depth learning

A Dissertation

Submitted to the Graduate Faculty

In Partial Fulfillment of the Requirement

For the Degree of Master of Engineering

By

Tang Yan

Supervised by

Associate Professor Pan Wei

Major in

Electronic information

In

School of Electronic Information Engineering

China West Normal University

Nanchong, Sichuan Province, China

May, 2023

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.1.1 研究背景.....	1
1.1.2 研究意义.....	2
1.2 国内外研究现状.....	3
1.2.1 深度学习研究现状.....	3
1.2.2 天文图像去噪研究现状.....	4
1.3 论文的主要工作和创新.....	5
1.4 本文的组织结构.....	6
第 2 章 基础知识	8
2.1 SKA 基础知识.....	8
2.1.1 SKA 的基本介绍.....	8
2.1.2 SKA1low	9
2.1.3 SKA 的成像软件及模拟过程.....	11
2.2 图像去噪基础知识.....	12
2.2.1 图像噪声	12
2.2.2 评价指标.....	13
2.3 本章小结.....	15
第 3 章 基于 DnCNN 的射电天文图像去噪.....	16
3.1 DnCNN 相关知识	16
3.1.1 网络结构.....	16
3.1.2 残差结构.....	17
3.1.3 批量归一化.....	17
3.2 改进的基础.....	18
3.3 改进后的网络结构.....	20
3.4 实验与讨论.....	21
3.4.1 数据预处理.....	21
3.4.2 参数设置.....	22
3.4.3 实验分析.....	23
3.5 本章小结.....	27
第 4 章 基于多尺度残差网络的射电天文图像去噪	28
4.1 融合注意力机制的天文图像去噪	28
4.1.1 SA 的原理.....	28
4.1.2 融化注意力机制的网络结构.....	29

4.1.3 实验与分析.....	30
4.2 基于多尺度残差网络的深度学习天文图像去噪	34
4.2.1 多尺度特征提取模块.....	35
4.2.2 多尺度残差网络深度学习网络模型.....	35
4.2.3 实验与分析.....	36
4.3 本章小结.....	41
第5章 图像去噪系统的设计与实现	42
5.1 系统的设计与实现.....	42
5.1.1 总体设计.....	42
5.1.2 设计思路.....	42
5.2 天文图像去噪系统.....	44
5.3 本章小结.....	47
第6章 总结和展望	48
6.1 总结.....	48
6.2 展望.....	49
参考文献.....	50

摘要

随着人们对宇宙的深入探索,对天文望远镜的需求也在进一步提高,迫切的需要一个更大的、观测更细致的天文望远镜,平方公里阵列(Square Kilometer Array, SKA)计划由此展开。它作为世界联合的科学项目,将会是世界上最大的射电天文望远镜,它的观测灵敏度相比于现在的射电天文望远镜提升了 50 倍。SKA1 是 SKA 的第一个科学目标阶段,它的目的是探索宇宙的黎明。由于深空环境的干扰、传输过程中辐射的干扰以及地面接收设备的热噪声等因素的影响,导致最终观测到的 SKA 射电天文图像存在一定的噪声,对后面的研究造成了一定影响。为了解决上述问题,本文针对 SKA 射电天文图像进行去噪研究。

本文首先将 DnCNN 去噪网络应用于 SKA 射电天文图像上,并针对 DnCNN 网络存在的对图像边缘恢复能力较差的问题,提出使用联合损失函数的方法。由于 MS-SSIM 损失函数能够保留图像的边缘,但是会损失图像的亮度,而 L1 损失函数可以保留图像的亮度和色彩,因此将两个损失函数组合起来,解决 DnCNN 存在的问题。经过实验证明,所提的网络能够很好的保留图像的边缘。在噪声强度为 $\sigma=25$ 的时候,本文所提的联合损失函数网络模型比传统的小波算法提高了 13.49dB,比 BM3D 算法提升了 5%。

虽然所提的联合损失函数的方法解决了 DnCNN 存在的对图像边缘恢复不够的问题,但是它和 DnCNN 依旧存在两个问题,第一就是它们将不同注意力的权重视为相同。第二就是它们都对特征的提取只使用一个尺寸的卷积核,对特征的提取度不够。为了解决这两个问题,本文首先引入融合注意力机制 Shuffle Attention 模块提出 SACNN 网络,解决了对不同注意力权重同等看待的问题。经过实验证明所提的 SACNN 网络能够很好的恢复图像,去除噪声的干扰。无论在噪声强度强还是弱的时候, SACNN 算法去噪之后的平均 PSNR 均在 39.9dB 之上。在噪声强度为 $\sigma=25$ 的时候, SACNN 比传统的 NLM 去噪算法提升了 12.3%,是传统的小波算法的 1.1 倍。

为了解决特征提取度不够的问题,在融合了注意力机制的基础上提出基于多尺度残差网络的射电天文图像去噪方法,对比之前的网络只使用 3×3 的卷积核,基于多尺度残差网络的射电天文图像去噪方法使用 4 个尺寸分别为 1×1 、 3×3 、 5×5 和 7×7 的卷积核进行特征提取。经过实验证实,无论在噪声强度强还是弱的时候,所提的多尺度残差网络去噪的平均 PSNR 值均在 40dB 之上,去噪之后的平均 SSIM 均在 0.97dB 之上。

为了给后续的研究提供一个高效快速的对比实验,根据所提的三种深度学习去噪模型,实现在线系统的编写。

关键字: 平方公里阵列; 深度学习; 联合损失函数; SACNN; 多尺度残差网络

Abstract

With the in-depth exploration of the universe, the demand for astronomical telescopes is also further increasing, and there is an urgent need for larger, more detailed astronomical telescopes, and the Square Kilometer Array (SKA) plan has begun. As a joint science project of the world, it will be the world's largest radio astronomy telescope, and its observation sensitivity is 50 times higher than that of current radio astronomy telescopes. SKA1 is SKA's first science-targeted phase, which aims to explore the dawn of the universe. Due to the interference of the deep space environment, the interference of radiation during transmission, and the thermal noise of ground receiving equipment, there is a certain noise in the final observed SKA radio astronomy image, which has a certain impact on the subsequent research. In order to solve the above problems, this paper conducts a denoising study on SKA radio astronomy images.

In this paper, the DnCNN denoising network is first applied to SKA radio astronomy images, and a method using the joint loss function is proposed to solve the problem of poor image edge recovery ability of DnCNN network. Since the MS-SSIM loss function can preserve the edges of the image, but will lose the brightness of the image, while the L1 loss function can preserve the brightness and color of the image, the two loss functions are combined to solve the problem of DnCNN. Experiments have proved that the proposed network can retain the edges of the image well. When the noise intensity is $\sigma=25$, the joint loss function network model proposed in this paper is 13.49dB higher than the traditional wavelet algorithm and 5% higher than the BM3D algorithm.

Although the proposed method of joint loss function solves the problem of insufficient image edge recovery in DnCNN, it still has two problems with DnCNN, the first is that they treat the weight of different attention as the same. The second is that they all use only one size convolution kernel for the extraction of features, and the extraction degree of features is not enough. In order to solve these two problems, this paper first introduces the fusion attention mechanism Shuffle Attention module to propose the SACNN network, which solves the problem of equal treatment of different attention weights. Experiments have proved that the proposed SACNN network can restore images well and remove noise interference. Whether the noise intensity is strong or weak, the average PSNR after denoising by the SACNN algorithm is above 39.9dB. When the noise intensity is $\sigma=25$, SACNN is 12.3% higher than the traditional NLM denoising algorithm, which is 1.1 times that of the traditional wavelet algorithm.

In order to solve the problem of insufficient feature extraction, a radio astronomy image denoising method based on multi-scale residual network was proposed on the basis of integrating attention mechanism, compared with the previous network that only used 3×3 convolution kernels, and the radio astronomy image denoising method based on multi-scale residual network used four convolution kernels with sizes of 1×1 , 3×3 , 5×5 and 7×7 respectively for feature extraction. Experiments show that the average PSNR value of the proposed multi-scale residual network denoising is above 40dB and the average SSIM after denoising is above 0.97dB regardless of the noise intensity when the noise intensity is strong or weak.

In order to provide an efficient and rapid comparative experiment for subsequent research, the online system is written according to the three proposed deep learning denoising models.

Key Words: Square Kilometer Array; deep learning; joint loss function; SACNN; Multiscale residual network

第1章 绪论

1.1 研究背景及意义

1.1.1 研究背景

探索宇宙的起源和发展,一直以来都是全人类孜孜以求的目标,与其相关的课题一直以来都占据着重要的地位。经过多年的探索和研究,终于形成了一套被大众广泛所接受的理论——宇宙大爆炸理论。该理论认为,大约在138亿年前,一次大爆炸创造了宇宙。从此以后,宇宙空间开始膨胀,从一个微小的点扩散至今。随着空间的膨胀,宇宙中的物质逐渐冷却,经历了一系列的变化和演化,最终形成了我们所熟知的宇宙。

在宇宙大爆炸之后,宇宙进入了一个被称为“黑暗时代”的时期,随着“第一缕曙光”的出现,宇宙迎来了它的黎明^[1]。之后随着时间的推移演化出更多的恒星和星系,宇宙进入辉煌、璀璨的时代。在宇宙黑暗时代到黎明的演变过程中,最重要的一个阶段是再电离时期阶段^[1],这个阶段大约开始于宇宙大爆炸后的4亿年。这个阶段是本文研究的重点背景知识,也是基于平方公里射电阵(Square Kilometre Array, SKA)的第一科学目标^[2]。再电离是宇宙中气体经历的第二次重要相变,其主要作用是将宇宙中大部分的重子物质转变为氢原子的形式。具体来说,再电离是指氢气体中的电子与质子重新结合形成氢原子的过程。这个过程是宇宙演化早期的重要事件,因为它在宇宙学中扮演了关键的角色。

由于再电离过程是宇宙中气体的第二次主要相变,是主要的重子物质成为氢的形式,因此这个过程也叫氢气体的电离。宇宙中星系的形成与演化的关键阶段就是宇宙再电离阶段,但是我们也仅仅只了解这个阶段演变的结论,演变过程中的详细步骤我们还不了解,需要进一步的研究。因此宇宙再电离的研究成为了目前宇宙学和天文学的一个热门的研究方向。

为了获取更多的天文数据,得到更多的宇宙视野,我们对天文望远镜的需求也在一步步提高,随着技术的进步,望远镜由伽利略发明的折射望远镜到反射的哈勃望远镜、海尔望远镜再到后面的施密特式望远镜以及马克苏托夫-卡塞格林式折返镜等等,直至现在的射电天文望远镜。射电天文望远镜能够测量天体射电的强度、频谱和偏振等等数据。目前,世界各地的射电天文望远镜都在不断发展和完善。其中,代表性的射电天文望远镜包括中国的天眼望远镜(FAST, Five-hundred-meter Aperture Spherical radio Telescope)、美国的阿雷西博天文台(Arecibo Observatory)、德国的埃菲尔斯伯格射电望远镜(Effelsberg)以及智利的阿塔卡玛大型毫米波天线阵(ALMA, Atacama Large Millimeter Array),但是这些射电天文望远镜都是进行数据分析的望远镜。而SKA则是能够直接成像的射电天文望远镜。

平方公里射电阵计划始于 1993 年,是一个由中国、澳大利亚、意大利、荷兰、葡萄牙、南非、英国七个创始成员国牵头,10 多个国家共同参与建设的国际大科学工程,是世界上最大的射电望远镜阵列^[4]。平方公里射电阵将由数千个蝶形天线组成(每个蝶形天线的表面积是 1 平方公里),它的直径是 1900 英里(3057.75 公里),其频率的覆盖范围为 50 兆赫—20 吉赫,因此它具有超高的分辨率和灵敏度、超大视场、超快巡天速度。目前 SKA1-low (SKA 第一阶段低频阵)已经完成了部分建设,并且开始了观测。位于南非境内的部分 SKA 如图 1-1 所示。

随着 SKA 的建设完成,将会产生海量的观测数据,面对这些数据,如何快速高效的获取有用的信息进行研究是一个重要的问题,为了解决这个问题,本文提出将深度学习应用于 SKA 射电天文上,进行数据处理,避免浪费资源。



图 1-1 南非境内的部分 SKA 望远镜蝶形天线^①

Fig 1-1 Some SKA telescope butterfly antennas in South Africa

1.1.2 研究意义

SKA 作为世界上最大的射电望远镜,其灵敏度提升约为世界目前最大的望远镜的 50 倍^[4]。与目前的射电孔径天文望远镜的观测结果不同,SKA 的观测结果是图像而不是数据^[6]。由于 SKA 射电天文望远镜在成像过程中受到的来自各种自然或者人为因素的干扰,导致最终观测的 SKA 射电天文图像存在噪声,甚至 SKA 天文图像的有效信息会被噪声覆盖,严重的影响后续的识别判断工作。虽然 SKA 在建设的过程中会考虑噪声的问题,建设的地点选择在南部非洲和澳大利亚的无线电静默区域^[7]。但是由于深空环境中的辐射干扰、传输过程中的电离层干扰、射频干扰、到达地面接收设备时的热噪声干扰,这些干扰会严重降低观测到的 SKA 射电天文图像的质量。因此,对观测到的 SKA 射电天文图进行噪声的去除工作,具有非常重要的现实意义。

SKA 射电天文望远镜作为目前世界上最大最精密的天文望远镜,其在天文学领域的地位是非常重要的,目前虽然该望远镜并未建设成功,但是其先导望远镜已经开始工作,如南非的 MeerKAT、澳大利亚的 SKA 探路者(ASKAP)等。SKA

^① <https://www.skao.int/>

射电天文图像去噪作为其图像预处理工作，为后续研究人员等观测提供非常重要的数据支持，是天文图像处理上不可避免的工作。

为了提高天文图像的信噪比，去除各种噪声的干扰，研究人员提出了多种多样的去噪方法，但在实际运用过程中都是针对具体的不同类型的天文图像，因此这些算法对 SKA 射电天文图像去噪不一定有效果。对 SKA 射电天文图像进行去噪研究有一定的必要性。

得益于神经网络的强大特征提取能力，它在面对海量的数据时能更快速高效的对其进行提取，并且已在各个领域都得到了广泛的研究与应用。因此将深度学习图像去噪应用于 SKA 射电天文图像领域将会是未来不可避免的发展趋势。

1.2 国内外研究现状

1.2.1 深度学习研究现状

深度学习 (Deep Learning) 是近几年来的一个研究热点和重点，它依靠建立、模拟人脑的分层结构来实现对输入内容的特征从低级到高级的提取^[8]。深度学习允许多个处理层组合成学习模型来学习具有多个层的数据，广泛的应用于各个领域^[8]。早在 1943 年，神经网络就被 Mcculloch 和 Pitts 首次提出^[9]。他们提出了第一个脑神经元模型，M-P 模型 (MCP)。由此开启了神经网络的新时代。在 1958 年，Frank Rosenblatt^[10]基于 MCP 提出了第一个感知器网络，此时，我们已经可以通过训练模型来获取参数了。但是在 1969 年，Minsky, Marvin 和 Papert^{错误!未找到引用源。}阐述了感知机的缺点，即单层太弱，双层算力达不到。至此的 10 年内深度学习的研究陷入低谷。直至 1986 年，Rumelhart、Hinton 和 Williams 等人^[11]提出了一种适用于多层感知机的反向传播算法 (Back Propagation, BP)，解决了 10 年来的困境，使深度学习爆发第二次热潮。研究发现可以利用 BP 算法从海量的数据中训练得到规律，完成预测，但是 BP 算法在网络层数过多时容易过拟合，导致局部最优。

20 世纪 90 年代，支持向量机 (Support Vector Machines, SVM) 模型被提出^[13]，但是由于当时的神经网络训练不够成熟，方法经验不够，针对 SVM 的研究相对低迷。这种情况在 2006 年被打破，Hinton 和 Salakhutdinov^[14]提出深度学习概念。这篇文章主要介绍了两个方面：

(1) 重建输入：可以通过训练中间层神经网络，将高维数据 (high-dimensional data) 转换为低维编码 (low-dimensional codes)，来重建高维输入。

(2) 权重最优：使用“预训练”方法，找到较好的初始权重。再使用梯度下降，来微调自编码器上的权值，有效避免局部最优的情况出现。

这篇文章一经发表，就引起各个领域深度学习的研究热潮，并且取得了较大的成果。到目前为止，深度学习依旧是各个领域的研究重点，各大互联网大厂依旧投入大量的人力、物力资源继续进行深度学习的研究。近几年深度学习的研究和发展趋势可以概括为以下几个方面：

(1) 发展趋势: 深度学习算法可以从输入的无规律数据中学习到数据的隐藏特征, 其高效的特征提取性能能够很好的代替人工标记。其发展势头欣欣向荣。

(2) 应用趋势: 深度学习的一些基础研究依旧有很高的热度, 由于深度学习良好的泛化能力、快速高效的收敛性等能力, 导致其应用领域广泛, 应用范围不断拓展, 并且取得了长足的进步。如文本分类的 TextCNN^{错误!未找到引用源。}、RCNN^[15]、HAN^[17]等, 语义分割的 FCN^[18]、PSPNet^[19]、Mask R-CNN^{错误!未找到引用源。}等, 目标检测的 OverFeat^[20]、R-CNN^[22]、YOLO v1-4^[24-27]等。

(3) 研究趋势: 深度学习在文本、图像、语音等领域的研究是目前研究的热点领域。如语音识别、实时翻译、无人驾驶等。

本文将深度学习图像去噪方法应用于 SKA 射电天文图像上, 并根据 SKA 射电天文图像的特征进行模型的优化, 拟更好的完成图像去噪任务, 为后续的天文图像观测打好基础铺垫工作, 为后续研究人员的研究做出基础贡献, 来推动 SKA 射电天文的发展。

1.2.2 天文图像去噪研究现状

图像去噪, 一直以来都是学者们在图像预处理过程中重点关注的研究方向。随着研究的不断深入以及时代的更新, 图像去噪由传统的空间域和变换域不断变换到基于模型的去噪再到如今的基于深度学习去噪, 应用领域也逐步扩展到医疗、地理、天文等等领域。下面将对天文图像去噪算法的研究现状做一个总结归纳。

早在 90 年代初期就有学者针对天文图像去噪进行研究, 早期大量运用小波方法进行去噪的研究, 研究者利用小波成功的排除了观测到的射电图像中的干扰线, 该方法在去噪的过程中能够尽可能多的保留有用信息^[28]。Fligge 和 Solanki^[29] 提出了一种新的基于小波的降噪方法, 并且在太阳的强度和圆偏振光谱上进行了测试, 验证了该方法能够清楚地将信号与噪声分离, 尤其是在噪声主导的最高频率下。Egiazarian 和 Astola 等人^[30], 提出了一种新的去噪方法, 基于脉冲去除和变换域局部自适应滤波相结合的图像混合噪声去除算法。该算法在被白色(高斯、拉普拉斯、指数)噪声脉冲噪声及其混合物破坏的图像去噪中效果良好。Willett 和 Nowak 等人^[31]提出了一种非参数多尺度算法, 该算法在光子受限信号和图像去噪和重建上表现优异, 并且改算法在处理柏松数据上十分具有优势, 并且能够保留图像的边缘特征。2013 年, Beckouche 和 Starck 等人^[32]将中心字典学习(CDL)方法应用于天文图像上, 进行去噪测试, 实验证明, 该算法优于之前的小波去噪算法和金典字典去噪算法。Liu Qianshun 很 Bai Jian 等人^[33]提出了一种新的稀疏编码算法, 称为基于回溯的改进自适应 OMP(ABOMP)。通过将 IABOMP 算法与最先进的字典学习算法 K-SVD 相结合, 该算法对天文图像实现了更好的去噪效果。2016 年, Torres-Forné 和 Marquina 等人^[34]将字典学习算法应用于引力波去噪上, 对算法参

数进行修改并将其应用与真实信号 GW150914 上, 并且从噪声中获得了有用的信号。

随着技术的发展, 深度学习凭借其运算能力强、速度快、消耗成本小等优点渐渐被人们应用于天文图像上。在 2017 年, Remez 和 Litany 等人^[34], 利用深度卷积神经网络的强大框架进行泊松去噪。该方法在视觉和定量上都大大优于以前的最先进技术。Lucas 和 Calef 等人^[36]将神经网络深度学习去噪应用于双谱来提神图像的质量, 实验证明该方法十分有效。Park 和 Moon 等人^[37]将深度学习去噪方法应用于太阳磁图上, 模型成功地去除了 SDO/HMI 磁图的噪声, 并且从我们的模型中去除的噪声磁图与目标磁图基本一致。同年, Shen 和 George 等人^[38]针对引力波信号提出了一种新的去噪方法基于序列到序列双向长短期记忆递归神经网络的阶梯式多时间步去噪自动编码器 SMTDAE, 并且经过实验证明该方法针对引力波信号去噪有明显的效果。之后深度学习在天文图像去噪领域的研究得到了有效的发展。2019 年, Baso 等人^[39]针对太阳天文图像, 使用深度学习技术, 利用观测的空间相干性来降低噪声, 设计了一个神经网络, 它能够在复杂的噪声破坏(包括仪器伪影和非线性后处理)下恢复微弱信号, 实验证明无论使用什么样的谱线或谱采样, 所提出的方法都能很好地恢复微弱信号。它特别适用于波长采样不足的情况。2020 年, Park 和 Moon 等人^[40]将深度学习去噪模型应用于去噪太阳磁图上, 模型基于深度卷积生成对抗网络, 具有从单个磁图(输入)到堆叠磁图(目标)的图像到图像转换的条件损失, 经过实验验证, 该模型能够很好的恢复图像。2021 年, Vojtekova 和 Lieu 等人^[41]基于 U-net 提出了一种新的模型 ASTRO U-NET, 一种用于图像去噪和增强的卷积神经网络, 并进行实验, 实验证明该网络能够恢复 95.9% 的恒星, 平均通量误差为 2.26%。2022 年, Zhang 和 Nord 等人^[42]将神经网络去噪应用于天文图像上, 采用基于 CNN 的自监督学习算法(Noise2Noise^[43]), 进行实验, 证明能够很好的去除天文图像上的泊松噪声。随着技术的进步, 以及时代的发展, 越来越多的学者开始基于深度学习研究天文图像去噪了。随着 SKA 射电望远镜即将投入使用, 本文作者将研究视野投入到 SKA 射电天文图像上, 基于深度学习开展了一系列的研究。

深度学习在天文图像领域开始占据着重要的地位, 越来越多的学者们, 开始研究深度学习在天文领域的应用以及发展, 这也让深度学习在天文图像领域开始披荆斩棘, 取得越来越多的研究成果。

1.3 论文的主要工作和创新

本文的主要工作包括一下 5 点:

(1) 由于 SKA 射电天文望远镜还在建设过程中, 因此没有实际的观测图像, 需要针对其低频阵列进行模拟图像, 在查阅了大量的关于 SKA 射电天文图像的成

像文章,认真学习和分析了其成像的原理,最终选择使用李维天等人提出的成像方法。为研究的可行性搭建了基础的图像条件。

(2) 查阅大量的相关深度学习的研究资料,认真学习和分析了传统的图像去噪算法以及深度学习去噪算法的优劣,以及其在射电天文领域的应用情况,掌握的国内外的射电天文图像去噪的研究的发展现状和基础,为研究的方向做好了基础知识的铺垫。

(3) 针对 DnCNN 算法存在的对图像边缘恢复能力不足的问题,提出使用联合损失函数的方法。由于 MS-SSIM 损失函数能够保留图像的边缘,但是会损失图像的亮度,但是 L1 损失函数可以保留图像的亮度和色彩,因此将两个损失函数组合起来,提出联合损失函数的去噪方法,进行实验分析,该算法可以有效的弥补 DnCNN 存在的对图像边缘恢复能力不足的问题。

(4) 针对所提的联合损失函数和 DnCNN 网络同时存在的两个问题,进行改进。第一问题就是它们都对不同注意力视为相同的权重。第二,就是它们都对特征的提取使用同一个大小的卷积核,对特征的提取度不够。为了解决第一个问题本文首先融合注意力机制 Shuffle Attention 模块,提出 SACNN 网络。之后在融合注意力机制的前提下为了解决第二个问题,提出多尺度残差网络。经过对比实验证实,所提的 SACNN 和多尺度残差网络,在一定程度上,弥补了存在的两个问题,去噪的能力得到有效的提升。

(5) 完成深度学习图像去噪在线系统的设计与实现。基于本文所提出的三种深度学习的模型,设计制作一个在线系统,这个在线系统的目的是为后续的研究提供一个快捷高效的对比实验。在后续的研究过程中,提供一个快速的对比实验,无须对代码进行再次编写。

1.4 本文的组织结构

本文主要分为 6 个章节,总结构如图 1-2 所示




图 1-2 本文总结构图

Fig 1-2 General structure of this paper

第一章 绪论。在本章节首先说明了本文的研究背景和研究意义,阐述并分析了深度学习以及天文图像去噪的国内外研究现状。引出本文的研究的可行性。

第二章 相关知识。在本章首先介绍了 SKA 的相关知识, 包括 SKA1_low 的基本内容以及 SKA 的成像软件和成像模拟过程。然后介绍了图像去噪的基本内容, 主要是图像噪声以及图像去噪的评价指标。

第三章 基于 DnCNN 的天文图像去噪。本章首先介绍了选择的深度学习模型 DnCNN 的相关知识, 包括模型的网络结构、所采用的残差结构以及批量归一化等内容。之后针对 DnCNN 存在的对图像边缘恢复能力不足的问题, 提出使用联合损失函数的深度学习方法。由于 MS-SSIM 损失函数能够保留图像的边缘, 但是会损失图像的亮度, 但是 L1 损失函数可以保留图像的亮度和色彩, 因此将两个损失函数组合起来, 解决 DnCNN 存在的问题。经过实验证明, 所提的网络能够很好的保留图像的边缘。

第四章 基于多尺度残差网络的深度学习天文图像去噪。本章针对所提的联合损失函数和 DnCNN 存在两个问题, 第一就是它们对不同注意力视为相同的权重。第二, 就是它们都对特征的提取使用一个大小的卷积核, 对特征的提取度不够, 进行优化。本文首先引入融合注意力机制 Shuffle Attention 模块的 SACNN 网络, 解决了对不同注意力权重同等看待的问题。经过实验证明所提的 SACNN 网络能够很好的恢复图像, 去除噪声的干扰。之后为了解决特征提取度不够的问题, 在融合了注意力机制的基础上提出多尺度残差网络, 对比之前的网络只使用 3×3 的卷积核, 多尺度残差网络使用 4 个不同尺寸的卷积核进行特征提取, 4 个尺寸分别为 1×1 、 3×3 、 5×5 和 7×7 的卷积核。经过实验证实, 多尺度残差网络能够很好的恢复图像。

第五章 在线系统的设计与实现。本章节主要针对研究的内容做出一个实际的 demo, 将研究成果进行落地实现, 设计编写一个 SKA 天文图像去噪的系统, 并且实现系统。

第六章 总结和展望。在本章首先总结了本文的研究内容, 主要包括模拟数据、将传统算法应用于 SKA 射电天文图像上以及提出改进的三种深度学习模型。然后对深度学习图像去噪算法应用于 SKA 射电天文图像领域的研究进行一个展望。

第2章 基础知识

2.1 SKA 基础知识

2.1.1 SKA 的基本介绍

SKA 最开始目的是为了了解决射电天文学研究所需要的厘米波长无法被光学望远镜观测到的问题。SKA 不仅仅是一座射电望远镜，它还承担着诸多科学疑问的探索任务，例如探究第一代天体的形成、研究星系演化、揭示宇宙磁场的本质、解开引力之谜、寻找地外生命和地外文明、探索暗物质和暗能量等。这些疑问都是人类对宇宙本质和演化认知的重大挑战，SKA 的运行和观测数据将为解决这些难题提供重要的科学支持。

SKA 计划始于 1993 年的国际无线电科联会上，由全球十多个国家共同出资建造、运行、维护和管理，是一部超越国界的全球大科学装置^[44]。SKA 是一个由数千个小型碟形天线组成的巨型射电望远镜阵列，其命名中的“平方公里”体现了其覆盖面积之广。相比于直径达到 1 公里的射电碟形天线，SKA 的设计方式可以提供更高的信号采集面，因此 SKA 能够实现超高的观测能力，包括超高灵敏度、超大视场、超快的巡天速度和超高的分辨率。它的灵敏度是地球上所有射电望远镜阵列中最高的，是其他阵列的 50 倍。而它的分辨率也是其他阵列的 100 倍。为了实现更好的观测结果，SKA 的天线将分布在多个地区，通过汇总不同天线的探测结果来获得观测图像^[44]。SKA 的科学目标涉及众多领域，如星系演化、宇宙学、暗物质和暗能量等，其将在未来为我们提供更为深入的宇宙研究数据。

SKA 作为多国共同参与建设的射电望远镜，将建立在南非（包括南部非洲 8 个国家）和澳大利亚的无线电宁静区。因此 SKA 的建设范围非常大，最大的覆盖范围是 3000 公里，频率覆盖范围为 50MHz 至 20GHz。SKA 将分为两个阶段进行，第一阶段（SKA1）是 2021 年-2028 年，将建设约 10% 的 SKA。第二阶段（SKA2）将建设其余部分的 SKA。整个项目的建设计划于 2030 年后完成。

虽然 SKA 尚未建成，但是 SKA 相关的部分算法以及实验已经在一些相关的先驱设备上进行了验证，并且取得了一定的成果，如位于澳大利亚西部的默奇森射电天文台（MRO）的先导望远镜“默奇森宽场阵列”（Murchison Widefield Array, MWA）^②、澳大利亚的平方公里阵列探路者 ASKAP^③以及南非的 MeerKAT^④望远镜等。2018 年，Camilo^[46]等人，通过射电望远镜 MeerKAT 和 Parkes、X 射线望远镜 XMM-Newton、Swift、Chandra 和 NuSTAR 的观测，发现了一颗名为 PSR J1622-4950 的磁星于 2017 年再度活跃。Sett 等人^[47]在 MWA-VCS 的图像

② <https://baijiahao.baidu.com/s?id=1723104622082489679&wfr=spider&for=pc>

③ <https://3g.163.com/dy/article/H7NII16E0552AWS7.html>

④ <https://finance.sina.cn/2022-12-06/detail-imqqsmrp8793565.d.html>

上, 基于脉冲星的特性, 如光谱指数、极化和可变性等, 开发并测试了基于图像的方法来寻找脉冲星的候选者。Gupta 和 Huynh 等人^[48]我们提出了一组使用无监督机器学习方法检测到的特殊无线电源。并且在 ASKAP 的数据中发现了两个新的奇数无线电图 (ORC) 候选者和其他五种特殊的形态。2022 年中科院上海天文台张翔助理研究员和 Hurley-Walker 博士等人^[49]通过分析 SKA 先导望远镜 MWA 的观测数据, 发现了一个超长周期的磁星, 它是一个具有异常缓慢周期性辐射的射电暂现源。

这些大量的观测结果以及实验, 为后续分析 SKA 做出了很好的铺垫, 涉及到各种到干涉阵列技术问题, 目前甚至未来 30 年都只有 SKA 能够对再电离时期各个成分信号的直接观测成像。

2.1.2 SKA1_low

表 2-1 SKA1 最终建设实施方案主要参数

Table 2-1 Main parameters of SKA1 final construction implementation plan

	SKA1-Low	SKA1-Mid
Location	Australia	South Africa
Frequency range	50 MHz-350 MHz	350 MHz-15.3 GHz
Antenna type	Log Periodic Dipole Antenna	15m Offset Gregorian Dish
Quantity	131,072 organised into 512 stations, each with 256 antennas	133 SKA dishes, equipped with Band 1, Band 2, and Band 5 Feeds (plus 64 MeerKAT dishes with L- and UHF Bands)
Maximum baseline (km)	65	150
Pulsar Search	167 nodes	500 nodes
Compute Power (Common to both)	260 PFlops	

SKA1 是 SKA 的第一个科学与工程, 其主要完成 SKA1-low 和 SKA1-mid 的建设, 并且开展基于这两个探测设备的科学实验^[49]。随着 SKA 项目关键系统验证阶段 (CDR) 的完成, SKA 董事会听取了理事会筹备工作组 (Council Preparatory

Task Force, CPTF)、科学与工程咨询委员会 (Scientific and Engineering Advisory Committee, SEAC), 以及科学工作小组 (Science Working Groups) 的意见, 于 2020 年 2 月 28 日的董事会议上讨论通过了 SKA 第一阶段 (SKA1) 的最终建设实施方案。最终方案与原设计方案一致。这标志着 SKA 即将进入建设阶段。最终建设实施中的方案主要参数如表 2-1 所示^⑤。

SKA1 的科学目标主要由 SKAO 的科学评审委员会 (SRP) 和工程咨询委员会 (SEAC) 进行科学评估确定。SKA 的第一阶段主要有 13 个科学目标, 如表 2-2 所示。

表 2-2 国际 SKA 组织确定的 SKA1 的 13 个最优先科学目标 (来源: 国际 SKA 组织)

Table 2-2 The 13 top scientific objectives of SKA1 determined by the International SKA Organization (source: International SKA Organization)

科学工作组	科学目标	SKA1 阵列
宇宙再电离	早期宇宙再电离成像观测	SKA1_Low
脉冲星	高精度计时-引力波探测	SKA1_Low, SKA1_Mid
脉冲星	脉冲搜寻-引力理论检验	SKA1_Low, SKA1_Mid
宇宙再电离	宇宙再电离功率谱	SKA1_Low
中性氢	红移 0.8 内对中性氢宇宙	SKA1_Mid
宇宙磁场	可分辨的全天星际和星系际 磁场特征	SKA1_Mid
暂现源	快速射电暴等变源	SKA_Mid, SKA1_Low
宇宙学	限制初期非高斯性和超视距 尺度引力检验	SKA1_Mid
中性氢	近邻宇宙中性氢星系	SKA1_Mid
地外生命	100pc 距离类地行星形成区 内微小尘粒生长成图像	SKA1_Mid
连续谱	测量宇宙的恒星形成历史-非 热+热过程	SKA1_Mid
中性氢	银河系星际介质的多分辨成 图研究	SKA1_Mid
宇宙学	角相关函数-探测非高斯性和 物质偶极分布	SKA1_Mid

由表 2-2 可知, SKA1 的第一科学目标是早期宇宙再电离成像观测, 该研究基于 21cm 的中性氢进行。该目标也是本文所研究的内容的基础背景, 本文基于 SKA 的第一科学目标进行, 该目标所涉及的 SKA1 阵列为 SKA1_Low 阵列, 其目的是利用中性 21cm 氢进行宇宙早期再电离研究。

SKA1-Low 是位于西澳大利亚的望远镜, 将观测到更低的从 50 兆赫到 350 兆赫的频率, 并且在 74 公里长的内陆地区分布着 512 个无线电天线站^[51]。

⑤ http://www.shao.ac.cn/skazdyf/news1/202007/t20200722_5639216.html

SKA1_low 包含大约 13.1 万个偶极天线，每个天线都类似于两米高的电线圣诞树。由 256 根天线组成的 512 个阵列将点缀在场地的红沙滩上。每个站天线发出的信号将被电子组合，指向天空的不同部分，形成单一的视图。其中 512 个站点的分布分为核心区域和核心区域之外两种情况^[51]，核心区域是在半径小于等于 500 米的区域随机分布 224 个站点。余下的 288 个站点构成 48 个站点团（每个团由 6 个站点组成）分布在 3 跳半径达到 35 千米的螺旋线上，形成长达 65 千米的基线就说核心区域之外，如图 2-1 所示。




图 2-1 SKA1_low 的站点分布图

Fig 2-1 Distribution of sites SKA1_low

2.1.3 SKA 的成像软件及模拟过程

本文基于宇宙再电离时期的 SKA1_low 干涉阵列模拟了 SKA 射电晕天文图像，用于构建深度学习模型的数据集。实验的数据集模拟了再电离时期的 6 个成分的天图。首先模拟各个成分的天图，之后使用成像软件模拟每张天图的可见度数据，积分时间为 6h（输入天图的中心的天角的范围为 $[-3h, 3h]$ ）。模拟过程使用 FG21sim^[51]、OSKER^[53]、WSClean^[54]等 3 个专业成像软件进行数据集的模拟。

首先使用 FG21sim 模拟各个成分的数据天图。FG21sim 是由徐海光团队提出的前景模拟软件，它是一种低频模拟软件，目的在于模拟阻碍 21cm 再电离信号检测的常见前景干扰。本文选取数据频段在 150MHz-166MHz（以 3.2MHz 为频率间隔）模拟，模拟出 6 个不同频率的天图（sky map）。

然后，使用 OSKER 软件进行可见度数据模拟。OSKER 是由牛津大学团队开发用来匹配 SKA 的阵列信息并生成可见度数据的软件。在本文中首先将 6 个 FIT 文件转换为天空模型（sky model），转换过程中最新的 SKA 阵列信息添加进去，为后续使用 OSKER 软件进行可见度数据模拟做准备。最后使用 OSKER 软件进行数据可见度的模拟。

最后使用 WSClean 生成相应的 SKA 射电天文图。WSClean 是由 Offringa 等人在 2014 年提出的一种快速的通用宽场成像仪，该软件使用 w-stacking 算法，并且可以利用 w-snapshot 算法。它比 CASA 的 w 投影速度快 2-12 倍。它支持全天候成像和针对同质偶极子阵列（例如 MWA）的适当光束校正。WSClean 可以进行 Hogbom 和 Cotton-Schwab 清洁。在本文中，将经过 OSKER 生成可见度数据的 6 个天文 FIT 图经过该软件堆叠成像，最终得到模拟的 FITS 天文图像。具体的 SKA 射电天文图像的模拟过程如图 2-2 所示。




图 2-2 SKA 射电天文图像的模拟过程

Fig 2-2 Simulation process of SKA radio astronomy image

2.2 图像去噪基础知识

2.2.1 图像噪声

图像噪声是指存在于图像中的不必要或冗余的干扰信息，其能够影响图像的质量，导致图像存在不同程度的失真，并且可能淹没图像中的重要信息，干扰图像处理后续的工作。因此图像去噪是很多图像处理工作如图像分类、图像增强等等的预处理工作，往往是图像处理的第一步工作。

图像噪声可以分为内部噪声和外部噪声两类^[54]。外部噪声是由系统外部因素引起的干扰，如来自外部天体的干扰和环境因素的干扰等。内部噪声是系统内部干扰，主要来源于系统的物质性质、材料、电路和设备机械运动等。其中最为普遍的是热噪声，它由不同条件下物质分子的热运动而产生。

在图像处理中，噪声是一个非常重要的问题，因为它会干扰到图像的质量和清晰度。因此，准确地分析和处理噪声是提高图像处理效果的关键之一。

对于一张带有噪声的图像我们可以将其简单的用数学模型来表示，可以表示为公式（2-1）。

$$y = u + v \quad (2-1)$$

其中， y 表示为噪声图像， u 表示为原始图像， v 表示为噪声量。因此图像去噪就可以简单的理解为从噪声图像 y 中分离噪声量 v 得到干净有用的图像 u 。

2.2.2 评价指标

一、主观评价

图像去噪的主观评价主要靠人眼直接观察来区分图像质量的好坏,对图像的质量好坏做一个分类评价。这是一种定性的评价方法,很容易受到观察者的情绪和直觉经验等不受控制的情绪所影响,导致观察的结果具有很强的不确定性^[56]。常用的主观评价方法是將一组需要评价的图像展示给一定基数的观察者看,并且让观察者根据自己的观察结果对这组待评价的图片进行打分,打分的标准如表 2-3 所示。最后将所有观察者的打分情况汇总,去掉其中离谱的打分,求平均得分值。

表 2-3 图像质量主观评价标准

Table 2-3 Subjective evaluation criteria of image quality

评价结果	评价标准	得分
优秀	能够明显辨认图像内容,图像质量很好,很清晰,无杂质。	5
好	能够辨认图像内容,图像质量清晰,几乎没有杂质。	4
一般	能够辨认图像内容,图像质量正常,带有一点点杂质。	3
差	能够模糊辨认图像内容,杂质较多。	2
很差	无法辨认图像内容,杂质非常多。	1

二、客观评价

图像质量的客观评价是一种定量的评价方法,下面将介绍几种常见点图像质量的评价指标。

1. 均方误差 (MSE)

均方误差 (mean-square error, MSE), 它的计算原理为真实值与预测值之间的差值的平方的平均。若 MSE 的计算值越小, 则说明去噪之后的图像与原图像越相似, 因此去噪之后的图像质量也越好。其计算公式如公式 (2-2) 所示。

$$MSE = \frac{1}{M \cdot N} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} [I(i, j) - K(i, j)]^2 \quad (2-2)$$

其中, $M \cdot N$ 为图像的大小, $I(i, j)$ 为原始图像, $K(i, j)$ 为去噪之后的图像。

2. 信噪比 (SNR)

信噪比 (Signal-to-noise ratio, SNR), 是有用信号功率(Power of Signal)与噪声信号功率(Power of Noise)的比, 也就是幅度(Amplitude)平方的比。SNR 的值越大说明, 有用信号越多, 则图像的质量就越好。其计算公式如公式 (2-3) 所示。

$$SNR = 10 \log_{10} \left(\frac{P_{signal}}{P_{noise}} \right) = 10 \log_{10} \left(\frac{A_{signal}^2}{A_{noise}^2} \right) = 20 \log_{10} \left(\frac{A_{signal}}{A_{noise}} \right) \quad (2-3)$$

3. 峰值信噪比 (PSNR)

峰值信噪比（Peak signal-to-noise ratio, PSNR），即信号最大可能功率与噪声功率之间的比率。其值越大则表明图像的质量越好。其计算公式如公式（2-4）所示。

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \quad (2-4)$$

其中， MAX_I 代表的是图像点颜色的最大值。

4. 结构相似性（SSIM）

结构相似性（Structural Similarity, SSIM），SSIM 是一种用来衡量两张图片相似度的评价指标，其目的是评估压缩之后图片的质量。该方法是模仿人类感知图像边缘的纹理和相似性的评价指标，是最接近人眼主观的评价指标。

SSIM 从三个维度进行对比评价，分别为亮度、对比度和结构，其计算公式分别如公式（2-5、2-6、2-7）所示。

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1} \quad (2-5)$$

$$c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2} \quad (2-6)$$

$$s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3} \quad (2-7)$$

以上三个维度结合构成的 SSIM 的计算公式如公式（2-8）所示。

$$SSIM(x, y) = f(l(x, y), c(x, y), s(x, y)) = [l(x, y)]^\alpha [c(x, y)]^\beta [s(x, y)]^\gamma \quad (2-8)$$

其中， $\alpha, \beta, \gamma > 0$ ，用来调整三个模块，假设 $\alpha, \beta, \gamma = 1$ ， $C_3 = \frac{C_2}{2}$ ，则 SSIM 表达式如公式（2-9）所示。

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2-9)$$

因此 SSIM 结果值的范围为[0,1]，其值越接近 1 则说明图片失真越不严重，两张图片越相似。

5. 特征相似性（feature similarity index measure, FSIM）

FSIM 利用特征相似性来评价图像质量。FSIM 利用相位一致性特征(phase congruency, PC)和梯度特征 (gradient magnitude, GM) 两个互为补充的特征进行图像质量评价。尽管 PC 可以很好地捕捉图像的局部细节，并对图像变化具有不变性，这可以稳定地提取图像的特征，但某些图像变化确实会对人的视觉产生影响。因此，GM 被设计用来补偿这一缺点。其中 PC 和 GM 的计算公式分别如公式（2-10）、（2-11）所示。

$$S_{pc}(x) = \frac{2PC_1(x)PC_2(x) + T_1}{PC_1^2(x) + PC_2^2(x) + T_1} \quad (2-10)$$

$$S_G(x) = \frac{2G_1(x)G_2(x) + T_2}{G_1(x)^2 + G_2(x)^2 + T_2} \quad (2-11)$$

将 PC 和 GM 进行融合相似度，表达式如公式（2-12）所示。

$$S_L(x) = [S_{pc}(x)]^\alpha [S_G(x)]^\beta \quad (2-12)$$

设 $\alpha, \beta = 1$, 则 FSIM 计算公式如（2-13）。

$$FSIM = \frac{\sum_{x \in \Omega} S_L(x) PC_m(x)}{\sum_{x \in \Omega} PC_m(x)} \quad (2-13)$$

2.3 本章小结

本章首先对低频 SKA 的基础知识进行了简单的介绍，并且介绍了 SKA 的相关科学目标以及本文针对研究的 SKA1_low 的相关基础知识。并且介绍了数据集的详细模拟过程，具体描述了模拟成像所使用的软件以及每个步骤的软件使用过程。为后续章节进行实验做好基础的数据集的准备。具体的各个成分的天图的模拟观测结果将在后续的 3.4.1 节中进行详细的展示。之后本章节介绍了图像去噪点基础知识，包括图像的噪声，以及图像质量的评价指标的几个常见方法。

第3章 基于 DnCNN 的射电天文图像去噪

3.1 DnCNN 相关知识

DnCNN 网络最早由张凯^[55]等人在 2017 年提出的, 该网络主要引入了两个关键技术第一个是批量归一化第二个是残差结构, 对于第二章提到的噪声模型采用残差学习公式训练残差映射得到带噪图像的残差图像如公式 (3-1) 所示, 然后使用带噪图像减去残差图像得到最后的输出为噪声图像如公式 (3-2) 所示, 将图像中的干净图像去除获得噪声图像。

$$R(y) \approx u \quad (3-1)$$

$$v = y - R(y) \quad (3-2)$$

3.1.1 网络结构

DnCNN 网络由 17 层网络组成, 分为三种不同的类型。

1) 第一层, *Conv + ReLU* 层: 在这一层中, 首先将噪声图像进行零填充, 用来确保之后的中间层的每一层的输入图像和特征图像的大小一样, 然后送入 64 个 $3 \times 3 \times c$ (本文选定 $c = 1$) 的卷积层进行卷积操作, 以生成 64 个特征图, 我们提取第一层的底层特征, 通过非线性函数 ReLU 进行激活输出。

2) 第 2-16 层, *Conv + BN + ReLU* 层: 在这些中间层当中, 我们把经过第一层处理输出的图像同样首先进行零填充, 之后按照顺序经过中间这 15 层进行来学习更加抽象的图像特征。由于要保证中间层的输入和特征图像的大小的一致性, 因此采用的是 64 个 $3 \times 3 \times 64$ 大小的滤波器, 并且在非线性函数 ReLU 和卷积核的中间引入批量归一化来加速网络的训练和收敛。

3) 第十七层, *Conv* 层: 首先还是把从上一层获得的输出图像进行零填充, 然后使用 $3 \times 3 \times 64$ 的 c (本文 $c = 1$) 滤波器进行网络的重构输出图像。

整个网络从第一层到最后一层整体构成一个残差结构, 网络采用残差结构来预测残差图像, 最后使用输入图像减去残差图像就得到了噪声图像, 整个结构如图 3-1 所示。




图 3-1 DnCNN 网络结构图

Fig 3-1 DnCNN network structure diagram

3.1.2 残差结构

深度学习的网络层数理论上来说是越多越好，但是实际上，由于网络层数的增加，其优化算法就越难以计算，训练的误差也就会越来越多，特别是网络层数 10 层以上的网络。为了解决这些问题 2016 年，He 等人^[58]提出了残差网络，其中的残差结构如公式(3-3)所示，能够很好的解决“退化”问题。残差结构一经提出，在图像去噪、目标检测和图像分割领域得到广泛的应用，DRN^[59]、CBDNet^{错误!未找到引用源。}、YOLOv3^[26]等大量深度学习的模型都采用了残差结构，尤其在图像去噪领域的引用更为广泛，之后的深度学习模型都引入了残差结构来防止梯度爆炸和梯度消失的问题。

$$y = F(x, \{W_i\}) + x \quad (3-3)$$

其中 x 为上一层输出到这一层的值， $\{W_i\}$ 为 x 传到该层经过的权重， y 为 x 在某一层由激活函数，求得多输出值。残差模块如图 3-2 所示。




图 3-2 残差结构图

Fig 3-2 Residual structure diagram

3.1.3 批量归一化

对于深层网络（10 层以上）来说，因为当前层的输入是上一层的输出，虽然在每一层都进行了据标准化处理，但是当前面几层的参数发生变化会导致最后的输出产生剧烈的变化，为了解决上述问题 Ioffe 和 Szegedy^[60]在 2015 年提出批量归一化（Batch normalization, BN）。利用 BN 在网络的每一层输入进行归一化操作，归一化之后的输入分布被强制拉到均值为 0 和方差为 1 的分布上来。这样数据就会更加的稳定。由于们最后的模型是基于训练集的，因此需要对归一化的数据进行重构替换操作，恢复基于数据集的特征分布。批量归一化的主要计算公式如公式（3-4 到 3-7 所示）。

$$\mu_B = \frac{1}{m} \sum_{i=1}^m X_i \quad (3-4)$$

$$\sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_b)^2 \quad (3-5)$$

$$\overline{X_i} = \frac{X_i - \mu_b}{\sqrt{\sigma_b^2 + \epsilon}} \quad (3-6)$$

$$y_i = \gamma \overline{X_i} + \beta \quad (3-7)$$

其中，公式（3-4）是用来计算批量的均值的， X_i 表示第*i*个输入数据， m 是批量的大小。公式（3-5）用来计算批量的方差。公式（3-6）是对数据进行归一化的，其中 ϵ 是一个常数用来防止分母为 0。公式（3-7）是对数据的重构替换，其中 γ 和 β 是神经网络学习得出的参数，用来对数据进行重新缩放和移位， $\overline{X_i}$ 是第*i*个数据的输出。

3.2 改进的基础

对比传统的图像去噪算法在恢复图像的同时会丢失大量的图像内容等问题，以 DnCNN 算法为代表的图像去噪算法已经能够弥补绝大部分的缺点，恢复的图像和原图无法用肉眼进行明显分辨，但是 DnCNN 算法依旧存在对部分图像边缘丢失的问题，本节针对这个问题，提出了联合损失函数的图像去噪算法。

联合损失函数去噪算法的目的是为了解决图像边缘丢失的问题，因此使用 MS-SSIM 损失函数来更好的保留图像的边缘，但是 MS-SSIM 损失函数又会导致图像的亮度发生改变，为了解决这个问题使用 L1 损失函数来保留图像的亮度和色彩，因为在 L1 损失函数是平均绝对误差，因此不管局部结构如何，误差都会被平均。因此将两个损失函数联合在一起进行图像去噪。

损失函数是神经网络不可缺少的部分，它的主要作用是神经网络的反向传播提供阶梯误差，是神经网络中不可或缺的一部分。2017 年，Hang, Zhao 等人^[61]针对图像复原的损失函数进行了一个总结，总结了 L1 损失函数、L2 损失函数、SSIM 损失函数、MS-SSIM 损失函数，并且提出了 MS-SSIM Loss 与 L1 Loss 的组合是最佳选择。因为 SSIM 和 MS-SSIM 都对均匀的偏差非常不敏感，这就导致了使用它们作为损失函数必然会带来颜色的平移或亮度的改变，导致结果会变得阴暗。但是 MS-SSIM 可以保留高频区域的对比，因此选用 MS-SSIM 损失函数。由于 L1 可以保留颜色和亮度，能够有效弥补 MS-SSIM 损失函数带来的问题，但是它会忽略局部结构。因此我们将两个损失函数进行联合，联合损失函数的定义公式如公式（3-8）所示。

$$L^{Mix} = \alpha \cdot L^{MS-SSIM} + (1 - \alpha) \cdot G_{\sigma_G^M} \cdot L^{l_1} \quad (3-8)$$

其中 α 是一个范围在[0,1]的参数，其目的为用来平衡两个函数， $G_{\sigma_G^M}$ 是计算 MS-SSIM 中的第 M 个尺度的高斯核，它与 L1 的逐点乘法是因为 MS-SSIM 基于

像素点 q 对中心像素点 p 的 MS-SSIM 的贡献来反向传播，而这个贡献用高斯权重来确定。

下面对 MS-SSIM 损失函数和 L1 损失函数分别进行具体介绍。

1. MS-SSIM 损失函数 $L^{MS-SSIM}$

为了解决 SSIM 损失函数高斯核的选择调整所消耗的巨大成本问题，Wang 和 Simoncelli^[72]等人提出了使用多尺度的 SSIM (multi-scale SSIM, 简称为 MS-SSIM)，它是一种基于多层的 SSIM 损失函数，多尺度的实质就是对生成图像和真实图像不断地以 2 为因子进行下采样，从而得到具有多个分辨率的图像，并使用 SSIM 对这些不同图像进行评估，最后将这些 SSIM 融合成一个值，就是 MS-SSIM。MS-SSIM 能够很好的模拟人的眼睛对图像质量的感知，因为他考虑的图像的结构、纹理和分辨率。MS-SSIM 的值越大则两张图片就越相似，因此 MS-SSIM 的损失函数可以表达为公式 (3-9)。

$$L^{MS-SSIM} = \frac{1}{N} \sum_{q \in Q} (1 - MSSIM(q)) \quad (3-9)$$

其中， N 表示图像块中像素的数量， q 表示像素点， Q 表示图像块。

由于损失函数基本使用在神经网络当中，因此在计算损失函数的时候，可以用图像块中间像素的损失函数来代替图像块的损失函数，因此损失函数可以表达为公式 (3-10)。

$$L^{MS-SSIM} = 1 - MSSIM(\tilde{q}) \quad (3-10)$$

其中， $\tilde{q}$ 表示中间像素。

2. L1 损失函数 L^1

L1 损失函数的本质就是平均绝对误差 (MAE)，也就是基于图像的像素之差绝对值的和。其公示如公式(3-11)所示。

$$L^1 = \frac{1}{N} \sum_{i=1}^N |y_i - x_i| \quad (3-11)$$

其中 N 是训练样本的总数量。

L1 损失函数的分布如图 3-3 所示。由此我们可以推断，在面对不同的输入内容时，该损失函数的梯度都是稳定的，不会因为输入的不同而导致梯度爆炸。并且它能过保留图像的色彩和亮度，可以很好的弥补 MS-SSIM 的缺点。




图 3-3 L1 损失函数分布图

Fig 3-3 L1 loss function distribution

3.3 改进后的网络结构

对 DnCNN 模型进行改进，将 MS-SSIM 和 L1 联合损失函数应用到 DnCNN 模型中。由于 DnCNN 网络输出的值为去除的噪声点图像，但是我们需要的是去噪之后的图像，因此对模型进行改进得到输出结果为去噪后的图像。改进之后的网络结构如图 3-4 所示。




图 3-4 联合损失 CNN 网络模型
Fig 3-4 Joint loss CNN network model

在该网络结构中，首先将噪声图像随机裁剪截取成 40×40 大小的图像块，对裁剪的图像块进行零填充，然后输入到第一个卷积层当中去（卷积核大小设置为 3×3 ，卷积的步长设置为 1），提取第一层的底层特征，然后将结果经过 ReLU 函数进行激活输出作为下一层的网络输入。为了保证图像特征的大小，在每一次进行输入之前都要对上一层的输出结果进行零填充，并且在中间训练过程中引入批量归一化来加速训练，之后再次使用 ReLU 激活函数进行结果输出。直到最后一层进行特征提取输出。经过一系列的训练之后得到的是噪声的残差图像，然后使用噪声图像减去残差图像可以获得复原的去噪图像。通过优化损失函数来使网络性能达到最佳。图 3-5 比较了原始 DnCNN 和改进损失函数之后的网络在噪声水平为 50 时的训练损失函数曲线。从训练曲线对比来看，本章所提的网络的损失函数收敛更快。




图 3-5 训练损失函数对比曲线图
Fig 3-5 Training loss function comparison graph

3.4 实验与讨论

3.4.1 数据预处理

本次数据来源于模拟的射电晕图像，其模拟范围在 150-166MHz。数据集使用的是第二章的具体步骤模拟出来的数据集。第二章中模拟的数据集是一个个的 FITS 文件，并非能够直接进行图像处理的图片，因此需要对数据集进行预处理工作。第一个工作就是数据转换，将模拟出来的 FITS 文件转换为目标的图像文件。

要对 FITS 文件进行格式转换，首先需要了解 FITS 文件。知道其具体的文件格式才能进行文件转换。FITS 是一种天文学界广泛使用的数据格式，全称为 Flexible Image Transport System。它的设计初衷是为了方便在不同的计算机系统之间交换天文数据。FITS 最初由 NRAO 的 Don Wells 和 Eric Greisen 于 1979 年设计开发提出，并且在 1982^[63]年被确定为世界各天文台之间用于数据传输、交换的统一标准格式。规定了一个 FITS 文件的逻辑总长度为 2880 字节，文件命名规则，其后缀为.fits。一般情况下一个 FITS 文件包含一个或者多个基础单元，这个基础单元被命名为 HDU^[65]（Header + DataUnit），每个 HDU 都包含两个部分分别为文件头 Header 和数据单元 DataUnit，其中头文件 Header 用来保存基本信息如望远镜参数、观察参数、光谱仪参数、天气条件、文件信息等等关键字信息，用 ASCII 码编辑而成，每一个关键字信息都用一个 8 字符的关键词（keyword）定义 80 字符的信息类型。数据单元则用来存储详细的图像信息，其中包含所有的图像像素信息。其文件格式如图 3-6 所示。在本文的实验中，由于我们针对的是图像信息的处理，因此只提取 FITS 文件中的数据单元进行实验。后续的实验结果都直接通过图片格式进行展示。




图 3-6 FIT 文件信息图

Fig 3-6 FIT file infographic

将模拟的 FITS 文件进行数据读取，并且将其保存为图片格式，保存下来的图片大小为 1800x1800。由于本文进行的是图像去噪实验，如果按照常规的射电

晕图像进行实验，会导致关键信息被除去，因此对图像的识别范围进行扩张，扩张在在 10^{-9} - 10^{-10} 大小的范围进行。为了模拟真实观测过程中存在的噪声干扰，对图像添加方差分别为 $\sigma = 10$ 、 $\sigma = 25$ 和 $\sigma = 50$ 的加性噪声。由于模拟的观测点源和致密源的部分像素值差别较大，会导致模拟结果的图像中同时存在像素正值和负值，且差别较大，会造成 FITS 图像数据量过大，最终导致实验进度缓慢，为了解决这个问题，我们对数据进行了归一化处理，将所有对像素数据归一化到[0, 1]上。使用的方法为最大最小值方法，其计算表达式如公式（3-12 所示）。

$$X_{norm} = \frac{X_i - X_{min}}{X_{max} - X_{min}} \tag{3-12}$$

其中 X_{norm} 为归一化之后的像素值， X_i 为原始的像素数据值， X_{max} 和 X_{min} 分别为原始像素中的最大值和最小值。因此通过数据转换、添加噪声和数据归一化处理之后，我们得到了进行实验所需的数据集。


3. 4. 2 参数设置

为了验证 3. 2 所提的联合损失函数是否对恢复图像的边缘有效果，对模型进行实验验证，为了保证实验的准确性我们使用控制变量法，对所有的实验环境进行控制，统一实验环境不变，来探究模型是否有效，并且对实验结果从客观和主观两个方面进行评价。实验环境参数如表 3-1 所示。

表 3-1 实验平台环境参数表

Table 3-1 Environmental parameter table of experimental platform	
实验环境	版本型号
操作系统	Linux
实验平台	Pycharm
处理器	NVIDIA
显卡	3090TI
内存	64G
显存	24G

实验数据集选取 100 张 FITS 图像进行，实验将图像随机裁剪为 40×40 的图像块，训练的三个噪声梯度大小分别为 10、25、50，学习率从 10^{-3} - 10^{-5} 递减。网络的各个参数通过实验进行确定。首先确定训练轮次，选择不同训练轮次进行实验，最终测试集的平均 PSNR 和 SSIM 如图 3-7 所示，根据图 3-7（a）和图 3-7（b）可以看到当 epoch 为 35 时，PSNR 和 SSIM 开始出现转折点，之后随着 epoch 的递增，PSNR 和 SSIM 维持稳定。考虑到网络的稳定性，以及网络的消耗等因素，最终选取训练轮次为 35。进行同样的对比实验来进一步确定网络层数、批量大小和参数 α 的值。最终根据实验确定的各个网络参数如表 3-2 所示。



(a) 不同训练轮次的测试集平均 PSNR (b) 不同训练轮次的测试集平均 SSIM
图 3-7 不同训练轮次实验结果对比

Fig 3-7 Comparison of experimental results of different training rounds

表 3-2 深度学习网络参数
Table 3-2 Deep learning network parameters

网络参数	具体数值
Epoch	35
噪声强度	10、25、50
Learning rate	10-3-10-5
Batch size	128
联合损失函数 α	0.16

3.4.3 实验分析

为了验证本章所提的网络对天文图像的去噪能力，本章首先对模拟出来的 SKA 射电天文图像添加不同程度的噪声进行去噪实验。实验结果如图 3-8 所示，对如图 3-8 (a) 所示的原始图像，添加噪声强度分别为 10、25 和 50 的噪声。其中图 3-8 (b) 是添加了噪声强度为 $\sigma = 10$ 的噪声图像，图 3-8 (c) 为去噪之后的图像，对比图 3-8 (c) 和 3.8 (a)，可以看到两张图片在肉眼上没有区别。图 3-8 (d) 为噪声强度是 $\sigma = 25$ 的噪声图像，图 3-8 (e) 是去噪之后的图像，对比图 3-8 (a) 和 (e) 可以看到，图像并没有什么区别，所提的网络能过很好的恢复图像。图 3-8 (f) 是噪声强度为 $\sigma = 50$ 的噪声图像，图 3-8 (g) 为去噪之后的图像，对比图 3-8 (f) 和 (g)，可以看到在噪声强度高时，本章所提的模型能过很好的恢复图像，并且恢复的图像与原图并没有什么区别。对比图 3-8 (c)、(e) 和 (g) 三张图片，并没有明显区别，因此无论添加的噪声强度是弱还是强，本章所提的深度学习网络都能够很好的去除图像的噪声，恢复图像，可以达到肉眼观测没有很大的区别。




图 3-8 不同噪声强度的噪声图像与原始图像对比图

Fig 3-8 Comparison of noise image with different noise intensity and original image

为了验证深度学习模型比传统模型在 SKA 射电天文图像去噪上的优势，本章将对比传统算法和深度学习网络模型。本章将使用客观评价指标 PSNR 和 SSIM 对比所提的深度学习算法和传统的小波去噪算法^[61]、中值滤波算法^[66]、非局部均值（Non-Local Means, NLM^[68]）算法、三维块匹配（Block Matching 3D, BM3D^[69]）算法、加权核范数最小化（weighted nuclear norm minimization, WNNM^[70]）算法和可训练的非线性反应扩散（Trainable Nonlinear Reaction Diffusion, TNRD^[71]）模型进行去噪效果评价。经过不同模型在不同噪声强度下去噪之后的平均 PSNR 结果对比，如表 3-3 所示。根据表 3-3 中的内容可以看到无论在噪声强度弱还是强

的时候，所提的深度学习网络去噪之后的图像平均 PSNR 最高，去噪后的平均 PSNR 均在 39dB 之上，去噪效果明显比传统的算法强。在噪声强度为 $\sigma = 25$ 的时候，本章所提的深度学习网络模型比传统的小波算法提高了 13.49dB，比 WNNM 算法提高了 4.99%。在噪声强度为 $\sigma = 10$ 的时候，所提的深度学习网络模型去噪之后的平均 PSNR 达 50dB。在噪声强度为 $\sigma = 50$ 的时候，所提的深度学习网络模型比传统的 NLM 算法提高了近 1.6 倍，比 TNRD 提高了 3%。

表 3-3 不同模型去噪的平均 PSNR 对比表

Table 3-3 Comparison of average PSNR of different models

噪声强度	小波	中值滤波	NLM	BM3D	WNNM	TNRD	联合损失函数
$\sigma = 10$	32.157	36.808	37.156	47.310	47.503	47.514	50.001
$\sigma = 25$	30.872	32.637	32.923	42.240	42.312	42.506	44.361
$\sigma = 50$	26.858	26.929	24.897	38.353	38.527	38.714	39.973

对比小波算法、中值滤波算法、NLM 算法和 BM3D 算法等传统算法以及本章所提的深度学习网络去噪之后的平均 SSIM 如表 3-4 所示，根据表 3-4 展示的内容可以看到，本章所提的深度学习模型去噪后的平均 SSIM 均高于传统的算法，平均 SSIM 值均在 0.97 以上，因此本章所提的深度学习模型明显优于传统算法。在噪声强度 $\sigma = 10$ 的时候，本章所提的深度学习模型去噪之后的平均 SSIM 达 0.995dB。在噪声强度为 $\sigma = 25$ 的时候，本章所提的深度学习模型比传统的中值滤波算法提升了约 32%。在噪声强度为 $\sigma = 50$ 的时候，改进之后的网络去噪之后的平均 SSIM 值比 NLM 算法提升了 2 倍。综上，深度学习算法在 SKA 天文图像去噪上的表现明显优于传统算法，深度学习去噪之后的图像的峰值信噪比和结构相似性都比传统算法高。


表 3-4 不同模型去噪的平均 SSIM 对比表

Table 3-4 Comparison of average SSIM of different models

噪声强度	小波	中值滤波	NLM	BM3D	WNNM	TNRD	联合损失函数
$\sigma = 10$	0.92668	0.87663	0.95813	0.99247	0.99312	0.99452	0.99552
$\sigma = 25$	0.91229	0.74534	0.87955	0.98142	0.98231	0.98425	0.98567
$\sigma = 50$	0.85403	0.47907	0.47742	0.96234	0.96314	0.96518	0.97157

为了验证本章所提的改进之后的网络对 SKA 射电天文图像的去噪效果有提升，使用 SKA 射电天文数据集分别在 DnCNN 网络和改进的网络上进行训练、测试。选择 PSNR 和 SSIM 两个客观评价指标进行去噪效果好坏的评价，对比实验之后的平均 PSNR 和 SSIM，结果如图 3-9 所示。其中图 3-9 (a) 是平均 PSNR 的结果对比图，图 3-9 (b) 为平均 SSIM 的结果对比图。根据图 3-9 (a) 可知所提的改进之后的网络比 DnCNN 网络的平均 PSNR 都高，随着噪声强度的提升，去噪效果提升更明显。根据图 3-9 (b) 可知，本章所提的改进网络去噪之后的平

均 SSIM 比 DnCNN 有提升, 并且随着噪声强度的增加, 提升的效果越明显。由此, 根据图 3-9 综合评估可知, 本章所提的深度学习网络去噪之后的平均 PSNR 和平均 SSIM 均比 DnCNN 有提升, 尤其在噪声强度高时, 提升的效果更明显。



(a) 不同模型去噪平均 PSNR 对比图

(b) 不同模型去噪平均 SSIM 对比图

图 3-9 深度学习去噪效果对比

Fig 3-9 Comparison of deep learning denoising effect

除了客观的数据对比之外, 我们还对去噪后的图像进行了主观的评价。在噪声强度 $\sigma = 50$ 的时候, 对同一张图片进行去噪声之后的效果对比, 如图 3-10 (a) 和 3.10 (b), 其中红色方框为图像的放大图, 对比图 3-10 (a) 和 3.10 (b) 的放大图, 可以看到 3.10 (b) 恢复的边缘效果更好, 因此改进之后的网络有效的恢复了图像的边缘。


(a) $\sigma = 50$ DnCNN 去噪后(b) $\sigma = 50$ 改进网络去噪后

图 3-10 不同模型去噪之后的结果

Fig 3-10 Results of different models after denoising

在噪声强度 $\sigma=50$ 的时候,对同一张经过改进之后的深度学习和 DnCNN 网络去噪之后的图像和原始图像进行一个残差操作,得到去噪之后的图像与原始图像的残差图,进行去噪效果对比,若两张图像越相似,则残差图的内容就越少,反之,如若两张图像越不相似,则残差图的内容就越多,就越复杂。残差结果如图 3-11 (a) 和图 3-11 (b) 所示,其中右上角的红色方框内为图中左边部分红色小方框的放大图。对比图 3-11 (a) 和 3.11 (b) 的局部放大图,可以看到 DnCNN 去噪之后的图像与原图的残差图像比改进之后的网络的残差图像更复杂,因此改进之后的网络去噪之后恢复的图像内容更多。综上所有的实验结果表明改进之后的网络去噪效果更好,恢复的图像边缘更好,相比 DnCNN 有明显的提升。



(a) 原始 DnCNN 的残差图

(b) 改进之后的网络的残差图

图 3-11 不同模型去噪之后的图像与原始图像的残差图

Fig 3-11 Residual image between the original image and the de-noised image of different models

3.5 本章小结

天文图像去噪是天文学的基础工作,为天文学的后续研究发展做出铺垫,因此图像去噪在天文学领域是一个非常基础的工作,SKA 射电天文图像在图像去噪领域的研究并不明显,研究的学者很少。本章作者基于 DnCNN 网络在天文图像去噪上不能很好的恢复图像边缘的问题,提出改进网络,并且进行实验分析,证实了改进之后的网络不但明显的优于传统的算法,而且比 DnCNN 算法去噪的效果更好,能够有效的弥补 DnCNN 算法在天文图像去噪上边缘恢复能力弱的缺点。

第4章 基于多尺度残差网络的射电天文图像去噪

第三章所提的联合损失函数的去噪声方法虽然已经取得了一定的进步，获得了比 DnCNN 更好的效果，但是它和 DnCNN 存在两个共同的缺点。第一，它们都对每一个通道平等的看待。但是在图像去噪上来说，不同通道的特征在图像去噪上的权重上不一样的，并且通道的关联性也是非常重要的，关联性强的，在去噪中就越重要。第二，它们都使用单一尺寸的卷积核，会造成对图像特征的提取度不够的问题。本章针对以上两个问题分别提出了两种解决方法，并且进行了对比实验，针对第一个问题，引入注意力机制，进行优化。对第二个问题，进行多尺度的卷积，提取更多的特征。

4.1 融合注意力机制的天文图像去噪

神经网络中的注意力机制^[72]（Attention Mechanism）起源于对人类视觉的研究，人类在观察数据的时候会先观察整体，然后聚焦于重点的局部信息，获取细节内容。因此在神经网络中引入注意力机制可以对重要特征进行提取关注。在本节中引入 Shuffle Attention (SA) 注意力模块进行特征提取，获取更多重要特征，来解决第三章所提改进网络和 DnCNN 都存在的平等看待每一个通道的问题。

4.1.1 SA 的原理

SA_NET 在 2021 年由 Zhang 等人^[74]首次提出，其中重点内容为 SA 模块，它能够更加有效的组合空间注意力和通道注意力两种注意力机制，并且能够高效的解决同时使用这两种注意力机制所产生的计算成本较高的问题。SA 模块将输入的特征映射划为多个组，使用 Shuffle 单元构建空间注意力和通道注意力，并整合到每一个组。之后聚合所有的子特征。SA 模块的架构如图 4-1 所示。




图 4-1 SA 模块架构图
Fig 4-1 SA module architecture diagram

模型对给定的特征映射 X ，沿通道尺寸分成 G 组，对每一组特征通过“Channel Split”处理分为两个分支，通道注意力和空间注意力。对通道注意力，通过使用全局池平均（GAP）来嵌入全局信息，生成通道统计信息 s ，如公式（4-4）所示。还有一个紧凑功能，通过 sigmoid 实现，以达到更加精确和自适应的目的，因此通道的最终输出如公式（4-5）所示。对空间注意力，空间注意力是对通道注意力的补充，通过该注意力上的 Group Norm（GN）获得空间统计信息，然后采用 $\mathcal{F}_c(\cdot)$ 来增强特征的代表性。空间注意力的最终输出如公式（4-6）所示。

之后将这两个分支的特征输出链接起来，保证通道的输入和输出数量一样。最后采用 Channel Shuffle 操作，使得跨组的特征信息能够在不同的通道维度之间流动。

$$s = \mathcal{F}_{gp}(X_{k1}) = \frac{1}{H \times W} \sum_i^H \sum_j^W X_{k1}(i, j) \quad (4-4)$$

其中， H 、 W 分别表示空间的高度和宽度， X_{k1} 表示的是通道注意力分支的特征输入。

$$X'_{k1} = \sigma(\mathcal{F}_c(s)) \cdot X_{k1} = \sigma(W_1 s + b_1) \cdot X_{k1} \quad (4-5)$$

其中 W_1 和 b_1 是两个参数用来移动和缩放 s 。

$$X'_{k2} = \sigma(W_2 \cdot \text{GN}(X_{k2}) + b_2) \cdot X_{k2} \quad (4-6)$$

其中， W_2 和 b_2 为参数， X_{k2} 表示空间注意力分支的特征输入。

4.1.2 融化注意力机制的网络结构

由于 SA 模块的输出和输入大小相同的特性，能够很好的对图像进行各种操作，以及 SA 模块能够对图像细节很好的恢复，并且可以将其很好融合到深度卷积网络上。因此本文提出一种基于 SA 的深度学习模型 SACNN。SACNN 网络模型如图 4-2 所示。




图 4-2 SACNN 网络模型
Fig 4-2 SACNN network model

在该网络结构中，首先将噪声图像随机裁剪为 40×40 的图像块，在网络的第一层对裁剪的图像块进行零填充，然后输入到第一个卷积层去（卷积核大小为 3×3 ，卷积步长设置为 1）提取第一次到底层特征，在初步提取特征的同时进行 SA 注意力机制的特征映射，将提取的特征进行划分，针对不同的特征进行处理，然后经过 ReLU 函数进行激活输出并且作为下一层的输入。为了保证图像特征的小，对每一次的输入都进行零填充，并且在中间层引入批量归一化来加速训练，之后在中间层对深层特征提取，然后依旧采用 SA 模块对特征进行划分，针对划分的特征进行更加高校的处理，得到更好的去噪效果，最后用 ReLU 激活函数进行输出。在最后一层进行网络的重构输出。

4.1.3 实验与分析

4.1.3.1 参数设置

为了验证我们所提 SACNN 网络是否对恢复图像有效果，对模型进行实验验证，为了保证实验的准确性我们使用控制变量法，对所有的实验环境进行控制，统一实验环境不变，来探究模型是否有效，并且对实验结果从客观和主观两个方面进行评价。实验环境参数如表 4-1 所示。网络参数如图 4-2 所示。

表 4-1 实验平台环境参数表

Table 4-1 Environmental parameter table of experimental platform	
实验环境	版本型号
操作系统	Linux
实验平台	Pycharm
处理器	NVIDIA
显卡	3090TI
内存	64G
显存	24G

表 4-2 深度学习网络参数

Table 4-2 Deep learning network parameters	
网络参数	具体数值
Epoch	35
噪声强度	10、25、50
Learning rate	10^{-3} - 10^{-5}
Batch size	128

4.1.3.2 实验分析

为了验证 SACNN 模型对不同噪声图像的去噪效果，对模拟出来的 SKA 射电天文图学添加不同程度的加性噪声进行实验。实验对 SKA 射电天文图如图 4-3（a）所示，添加噪声强度分别为 10、25 和 50 的噪声进行去噪实验。其中图 4-3（b）为添加的噪声强度为 $\sigma = 10$ 的噪声图像，图 4-3（c）为去噪之后的图像，对比图 4-3（a）和图 4-3（c），可以看到，两幅图像并没有明显的区别，因此面对低等强度的噪声，SACNN 可以很好的去除它的干扰。图 4-3（d）是添加噪声

强度为 $\sigma = 25$ 的噪声图像，图 4-3 (e) 为对应的去噪后的图像，对比图 4-3 (a) 和图 4-3 (e) 不能用肉眼区分两张图像的区别在哪里，因此 SACNN 能很好的去除中等强度的噪声。图 4-3 (f) 是噪声强度为 $\sigma = 50$ 的噪声图像，图 4-3 (g) 为对应的去噪之后的图像，可以看到两幅图像差别并不大，因此在噪声强度高时，SACNN 依旧能够很好的去除噪声的干扰。对比图 4-3 (c)、图 4-3 (e) 和图 4-3 (g)，可以看到，三张图片的差别并不明显，不能很快区分出来，无论噪声强度是弱还是强，经过 SACNN 模型之后，噪声都得到了有效的去除，并且很好的保留了图像的细节特征。由此 SACNN 网络不仅能有效的去除 SKA 射电天文图像的噪声，还能很好的恢复图像的细节特征。




图 4-3 不同噪声程度下 SACNN 去噪图

Fig 4-3 SACNN denoising diagram at different noise levels

为了验证 SACNN 网络与传统算法去噪能力的强弱,本章选取客观评价指标 PSNR 和 SSIM 两个指标进行数据分析,以得出结论。表 4-3 为小波算法、中值滤波算法、NLM 算法、BM3D 算法和 SACNN 五个模型针对不同噪声强度 $\sigma=10$ 、25、50 去噪之后图像的测试集平均 PSNR 对比表。根据表 4-3 我们可以得出如下结论:①SACNN 算法明显优于传统算法,无论在噪声强度强还是弱的时候,SACNN 去噪之后的平均 PSNR 均在 39.9dB 之上。②在噪声强度 $\sigma=10$ 的时候,深度学习去噪效果比 TNRD 去噪提高了 18.39dB,比 BM3D 算法提升了 6.8%。③在噪声强为 $\sigma=25$ 的时候,SACNN 比 NLM 算法提升了 34.8%,比 WNNM 提高了近 1.05 倍。④在噪声强度 $\sigma=50$ 的时候,SACNN 比传统的小波算法提升了 48.8%,比中值滤波算法提高了 13dB。

表 4-3 不同去噪方法的平均 PSNR 对比表

Table 4-3 Comparison of average PSNR of different noise removal methods

噪声强度	小波	中值滤波	NLM	BM3D	WNNM	TNRD	SACNN
$\sigma=10$	32.157	36.808	37.156	47.310	47.503	47.514	50.549
$\sigma=25$	30.872	32.637	32.923	42.240	42.312	42.506	44.361
$\sigma=50$	26.858	26.929	24.897	38.353	38.527	38.714	39.973

对比去噪效果的平均 SSIM 如表 4-4 所示,根据表 4-4,可以看到①深度学习去噪效果比传统的去噪效果其细节恢复的更好,无论噪声强度是强还是弱,均在 0.97dB 之上。②在噪声强度 $\sigma=10$ 的时候,SACNN 比传统的中值滤波算法提高了约 0.12dB,比 BM3D 算法提高了 3.4%。③在噪声强度为 $\sigma=25$ 的时候,SACNN 比传统的 NLM 去噪算法提升了 12.3%,是传统的小波算法的 1.1 倍。④在噪声强度为 $\sigma=50$ 的时候,SACNN 网络去噪之后的 SKA 射电天文图像的平均 SSIM 比 WNNM 算法提高了约 1%,比 BM3D 算法提高了 9.3%。综上,SACNN 去噪之后的 SKA 射电天文图像无论在 SSIM 还是 PSNR 上都明显优于传统算法。


表 4-4 不同去噪方法的平均 SSIM 对比表

Table 4-4 Comparison of average SSIM of different noise removal methods

噪声强度	小波	中值滤波	NLM	BM3D	WNNM	TNRD	SACNN
$\sigma=10$	0.92668	0.87663	0.95813	0.99247	0.99312	0.99452	0.99581
$\sigma=25$	0.91229	0.74534	0.87955	0.98142	0.98231	0.98425	0.98707
$\sigma=50$	0.85403	0.47907	0.47742	0.96234	0.96314	0.96518	0.97113

为了验证 SACNN 网络与 DnCNN 网络性能的强弱,对分别经过 SACNN 和 DnCNN 两个模型去噪之后的平均 PSNR 和平均 SSIM 进行对比,结果如图 4-4 所示。其中图 4-4 (a) 是平均 PSNR 对比图,由图可知 SACNN 去噪后的图像的 PSNR 值无论在噪声强还是弱都比 DnCNN 更优。图 4-4 (b) 是平均 SSIM 性能

对比图，由图可知 SACNN 在对图像的结构特征的保留上效果更好，特别是在噪声强的时候其能力远比 DnCNN 强。由此 SACNN 的性能比 DnCNN 好，更适合与 SKA 射电天文图像的去噪。



(a) 不同模型去噪的 PSNR 图

(b) 不同模型去噪的 SSIM 图

图 4-4 不同去噪方法去噪性能对比

Fig 4-4 Comparison of denoising performance of different denoising methods

除了客观的数据对比之外，我们还对去噪后的图像进行了主观的评价。在噪声强度 $\sigma = 25$ 的时候，对同一张图片进行去噪声之后的效果对比，如图 4-5 (a) 和 4.5 (b)，其中红色方框为图像的放大图，对比图 4-5 (a) 和 4.5 (b) 的放大图，可以看到 4.5 (b) 恢复的边缘效果更好，因此改进之后的网络有效的恢复了图像的边缘。


(a) $\sigma = 25$ DnCNN 去噪图(b) $\sigma = 25$ SACNN 去噪图

图 4-5 不同模型去噪之后的结果

Fig 4-5 Results of different models after denoising

在噪声强度 $\sigma=25$ 的时候,对经过 SACNN 和 DnCNN 网络去噪之后的图像和原始图像进行一个残差操作,得到去噪之后的图像与原始图像的残差图,进行去噪效果对比。残差结果如图 4-6 (a) 和图 4-6 (b) 所示,其中右上角的红色方框内为图中左边部分红色小方框的放大图。对比图 4-6 (a) 和 4.6 (b) 的局部放大图,可以看到 DnCNN 去噪之后的残差图像比 SACNN 的残差图像更复杂,因此 SACNN 去噪之后恢复的图像内容更多。综上所有的实验结果表明融合了注意力机制的 SACNN 网络比 DnCNN 网络去噪的效果更明显,保留更多的图像细节。




图 4-6 不同去噪方法去噪残差对比图

Fig 4-6 Comparison of noise removal residuals of different noise removal methods

4.2 基于多尺度残差网络的深度学习天文图像去噪

在上一节中,根据存在的第一个问题引入了注意力机制来进行优化,在本节中,将引入多尺度特征提取模块,来解决单一尺寸卷积核对特征提取度不够的问题。

在深度学习神经网络中,往往会使用卷积核来进行特征提取。常见的卷积核大小有 1×1 、 3×3 、 5×5 、 7×7 和 9×9 等几种大小,卷积核等尺寸越大,代表提取特征的区域就越大,所提取的特征就越多,但是其参数的数量也就越多。因此,目前大多数的深度学习网络都采用的单一尺寸的卷积核。DnCNN 就采取的 3×3 的卷积核,这样会造成提取的特征数量有一定的局限性。为了解决这个问题,本节引入多尺度特征提取模块。

4.2.1 多尺度特征提取模块

本节基于 2015 年，Liao 和 Carneiro 等人^[72]提出的 Competitive Multi-scale Convolution 提出了多尺度特征提取模块，如图 4-7 所示。




图 4-7 多尺度特征提取模块
Fig 4-7 Multiscale Feature Extraction Module

在这个多尺度特征提取模块，设定了 4 个尺度不同的卷积核，分别为 1×1 、 3×3 、 5×5 和 7×7 ，4 个不同的卷积尺寸。多个不同尺寸的卷积核可以学习到多个不同的感受视野下的特征，因此能够提取到多个不同的特征。为了方便计算，输入的特征图，在经过不同的特征尺寸的卷积核卷积之后需要得到相同的输出，但是实际上的输出并不是相同的，为了使输出相同，对结果进行零填充，由于 1×1 的卷积核尺寸最小，因此得到的输出尺寸最大，所以以 1×1 的输出为填充标准，即 1×1 的卷积不需要进行零填充， 3×3 的卷积的 padding 设置为 1， 5×5 的卷积的 padding 设置为 2， 7×7 的卷积的 padding 设置为 3。这样就会使经过不同尺寸卷积核进行特征提取的特征图的输出特征图的尺寸大小相同。然后对输出的不同尺寸的特征图进行拼接，这样能够获得更加饱满的特征，但是同样会导致参数数量的变大，为了控制参数量，只在特征提取层进行多尺度的特征提取，来避免参数量过大的问题。

4.2.2 多尺度残差网络深度学习网络模型

将多尺度特征提取模块与注意力机制一起融合到网络中，形成新的网络结构，基于多尺度残差的深度学习模型。在该模型中第一层为多尺度特征提取层，中间层为卷积残差模块，倒数第二层为 SA 注意力模块。其网络模型如图 4-8 所示。




图 4-8 多尺度残差网络模型

Fig 4-8 Multiscale residual network model

在该网络模型中，首先将图像随机切割为 40x40 大小的图像块。在网络的第一层对裁剪的图像块进行零填充，然后输入到第一层，多尺度特征提取层，在这一层，使用 4 个不同尺寸的卷积核(1×1、3×3、5×5和7×7)进行特征提取，并且进行零填充保证图像尺寸大小相同，然后进行拼接输出，之后将第一层图像的特征输出做为中间下一层的输入，在中间层进行处理之前先进行零填充，在通过滤波核进行进一步过滤。在倒数第二层使用 SA 模块进行特征划分，针对划分的特征进行高效的处理，之后通过 ReLU 函数进行激活输出。最后一层还是将上一层的输出作为输入，依旧进行零填充，滤波器进行网络的重构输出图像。

4. 2. 3 实验与分析

4. 2. 3. 1 参数设置

为了验证我们所提的基于多尺度残差网络是否对恢复图像有提升，对模型进行实验验证，为了保证实验的准确性我们使用控制变量法，对所有的实验环境进行控制，统一实验环境不变，来探究模型是否有效，并且对实验结果从客观和主观两个方面进行评价。实验环境参数不变，网络参数如表 4-5 所示。

表 4.5 深度学习网络参数

Table 4-5 Deep learning network parameters

网络参数	具体数值
Epoch	35
噪声强度	10、25、50
Learning rate	10-3-10-5
Batch size	128
网络层数	18

4. 2. 3. 2 实验分析

为了验证多尺度残差网络模型对不同噪声图像的去噪效果，添加噪声强度分别为 $\sigma = 10$ 、 $\sigma = 25$ 和 $\sigma = 50$ 的噪声进行去噪实验，结果如图 4-9 所示。其中图 4-9 (a) 为原始图像，图 4-9 (b) 为噪声强度 $\sigma = 10$ 的噪声图像，图 4-9 (c) 是去噪之后的图像，对比图 4-9 (a) 和图 4-9 (b) 可以看到在噪声强度较小的时候，所提的网络能够很好的恢复图像，两张图像用肉眼无法区分。图 4-9 (d) 为噪声强度 $\sigma = 25$ 的噪声图像，图 4-9 (e) 是去噪之后的图像，对比图 4-9 (a) 和图 4-

9 (e)，在噪声强度中等的时候，本节所提的网络能够很好的恢复图像的信息，两张图片并没有太大的区别。图 4-9 (f) 为噪声强度 $\sigma = 50$ 的噪声图像，图 4-9 (g) 是去噪之后的图像，对比图 4-9 (a) 和图 4-9 (g)，并没有什么区别，因此在噪声强度高的时候，多尺度残差网络能够很好的恢复图像。对比图 4-9 (c)、图 4-9 (e) 和图 4-9 (g)，可以看到随着噪声强度的增加，多尺度残差网络恢复多图像并没有太大的区别，因此无论噪声是强还是弱，经过多尺度残差网络去噪之后的图像恢复的效果与原图的区别在肉眼上并没有明显的差异。恢复的图像效果受噪声的影响较小。




图 4-9 不同噪声程度下 SPACNN 去噪图

Fig 4-9 SPACNN denoising diagram at different noise levels

选取客观评价指标 PSNR 和 SSIM 两个指标，对多尺度残差网络和传统算法进行去噪分析，以得出多尺度残差网络去噪效果的结论。表 4-6 为不同噪声强度 $\sigma=10$ 、 $\sigma=25$ 、 $\sigma=50$ 去噪之后图像的测试集平均 PSNR 对比表。根据表 4-6 我们可以得出如下结论①多尺度残差网络去噪的平均 PSNR 值明显高于传统算法，其值均在 40dB 之上。②在噪声强度 $\sigma=10$ 的时候，多尺度残差网络比传统的小波算法提神了 58.3%，比 BM3D 算法提高了 3.6dB。③在噪声强度 $\sigma=25$ 的时候，多尺度残差网络是传统的中值滤波算法的 1.36 倍，比 NLM 算法提升了 35%。④在噪声强度 $\sigma=50$ 的时候，对比 WNNM 算法多尺度残差网络多平均 PSNR 至少提升 3.97%，对比 TNRD 提高了 1.4dB。

表 4-6 不同去噪方法的平均 PSNR 对比表

Table 4-6 Comparison of average PSNR of different denoising methods

噪声强度	小波	中值滤波	NLM	BM3D	WNNM	TNRD	多尺度残差
$\sigma=10$	32.157	36.808	37.156	47.310	47.503	47.514	50.918
$\sigma=25$	30.872	32.637	32.923	42.240	42.312	42.506	44.481
$\sigma=50$	26.858	26.929	24.897	38.353	38.527	38.714	40.121


对比去噪效果的平均 SSIM 如表 4-7 所示，根据表 4-7 可以得出如下结论，①深度学习的模型比传统的算法去噪效果明显更好，无论噪声强还是弱，去噪之后的平均 SSIM 均在 0.97dB 之上。②在噪声强度 $\sigma=10$ 的时候，多尺度残差网络去噪之后的平均 SSIM 比传统的小波算法高 0.069dB，比 NLM 算法提升了 4.2%。③在噪声强度 $\sigma=25$ 的时候，多尺度残差网络是传统的中值滤波算法的 1.32 倍，比小波算法提升了 0.075dB。④在噪声强度 $\sigma=50$ 的时候，多尺度残差网络是传统的 NLM 算法的 2 倍多一点，比 WNNM 算法提升了 1%。综上，多尺度残差网络，在天文图像去噪上明显优于传统算法。

表 4-7 不同去噪方法的平均 SSIM 对比表

Table 4-7 Comparison of average SSIM of different noise removal methods

噪声强度	小波	中值滤波	NLM	BM3D	WNNM	TNRD	多尺度残差
$\sigma=10$	0.92668	0.87663	0.95813	0.99247	0.99312	0.99452	0.99576
$\sigma=25$	0.91229	0.74534	0.87955	0.98142	0.98231	0.98425	0.98660
$\sigma=50$	0.85403	0.47907	0.47742	0.96234	0.96314	0.96518	0.97208

图 4-10 为 DnCNN 与多尺度残差网络的去噪性能的对比如，图 4-10（a）是平均 PSNR 对比图，图 4-10（b）是平均 SSIM 性能对比图。根据图 4-10 可以看到，多尺度残差网络去噪之后的平均 PSNR 无论噪声是否强弱其提升较明显，平均 SSIM 则在噪声强度较高的时候提升效果更明显。




(a) 不同模型去噪的 PSNR 对比图

(b) 不同模型去噪的 SSIM 对比图

图 4-10 不同去噪方法去噪性能对比

Fig 4-10 Comparison of denoising performance of different denoising methods

由于多尺度残差网络是在 SACNN 对基础上提出对优化,为了验证多尺度残差网络对比 SACNN 是否有提升。对多尺度残差网络 and SACNN 进行去噪效果对比,图 4-11 为 SACNN 与多尺度残差网络的去噪性能的对比如。其中图 4-11(a) 是平均 PSNR 对比图,图 4-11(b) 是平均 SSIM 性能对比图。根据图 4-11(a) 可以看到,多尺度残差网络去噪之后的图像平均 PSNR 比 SACNN 强。根据图 4-11(b) 可以看到,无论在噪声强还是弱的时候,多尺度残差网络去噪之后的图像的平均 SSIM 均比 SACNN 好。综上,多尺度残差网络去噪之后的平均 PSNR 无论噪声是否强弱其提升较明显,平均 SSIM 则在噪声强度较高的时候提升效果更明显。



(a) 不同模型去噪的 PSNR 对比图

(b) 不同模型去噪的 SSIM 对比图

图 4-11 不同去噪方法去噪性能对比

Fig 4-11 Comparison of denoising performance of different denoising methods

除了客观的数据对比之外,同时还对去噪后的图像进行了主观的评价。在噪声强度 $\sigma=50$ 的时候,对同一张图片进行 DnCNN、SACNN 和多尺度残差网络

去噪声之后的效果对比,如图 4-12 (a)、图 4-12 (b) 和图 4-12 (c), 其中红色方框为图像的放大图。对比图 4-12 (a) 和 4.12 (c) 的放大图,可以看到 4.12 (c) 恢复的边缘效果更好, 因此多尺度残差网络对比 DnCNN 网络能够更加有效的恢复图像。对比图 4-12 (b) 和 4.12 (c) 的放大图,可以看到图 4-12 (c) 的图像更清晰, 恢复的图像质量更好, 因此多尺度残差网络比 SACNN 能够更好的去除噪声的干扰, 恢复图像。




图 4-13 不同去噪方法对比图

Fig 4-13 Comparison of different denoising methods

在噪声强度 $\sigma = 50$ 的时候,对经过 SACNN、DnCNN 和多尺度残差网络去噪之后的图像和原始图像进行一个残差操作。残差结果如图 4-13 (a)、图 4-13 (b) 和图 4-13 (c) 所示, 其中右上角的红色方框内为图中左边部分红色小方框的放大图,由于图片残差之后过于黑,为了便于观察,因此对于放大图进行了亮度的调整,调亮了放大图。对比图 4-13 (a) 和 4.13 (c) 的局部放大图,可以看到 DnCNN 去噪之后的残差图像比多尺度残差网络的残差图像更复杂, 因此多尺度残差网络去噪之后恢复的图像内容更多。对比图 4-13 (b) 和 4.13 (c) 的局部放大图, 可以看到多尺度残差网络也比 SACNN 的内容少, 说明多尺度残差网络比 SACNN 能更好的恢复图像。综上所有的实验结果表明多尺度残差网络比 DnCNN 网络和 SACNN 网络去噪的效果更明显, 能够保留更多的图像细节。




图 4-13 不同去噪方法残差对比图

Fig 4-13 Residual Comparison Diagram of Different Noise Removal Methods

4.3 本章小结

本章针对第三章所提的联合损失函数的去噪算法和 DnCNN 存在的两个共同缺点提出了优化的方法。首先是为了解决它们都对每一个通道平等的看待问题，引入 SA 模块进行注意力机制的融合，提出 SACNN 网络，经过实验证实，该方法能够很好的解决上述问题。之后又根据它们都使用单一尺寸的卷积核，会造成对图像特征的提取度不够的问题。引入多尺度机制，在融合注意力模块的前提下引入多尺度机制，提出基于多尺度残差的网络，经过对比实验分析，得出最终的多尺度残差网络比 DnCNN 网络和 SACNN 网络的去噪效果都更好，能够有效的解决第三章所提的联合损失函数的去噪算法和 DnCNN 存在的缺点。

第5章 图像去噪系统的设计与实现

5.1 系统的设计与实现

5.1.1 总体设计

SKA 射电天文图像去噪在线系统的目的是提供一个在线的深度学习天文图像去噪平台。它的主要目的是为后续的研究提供一个快速高效的对比实验，无须进行代码的重新编写即可得出对比实验结论。为了拓展系统的适用性，将系统改为不只是针对 FITS 文件的系统，拓展到天文图像上去。将系统设计为两个模块：一个是针对天文的 FITS 文件的模块，一个是针对天文图像的模块。针对在线系统的用户提供部分功能如下：

- 1.能够上传文件、或者使用系统提供的文件进行实验。
- 2.能够自主选择对文件添加噪声的强度、去噪的模型。
- 3.对去噪的文件能够进行输出展示、并且能够有数据支撑（如 PSNR、SSIM 等评价指标）。

功能流程图如图 5-1 所示。




图 5-1 用户功能流程图

Fig 5-1 User Function Flow Chart

5.1.2 设计思路

在线图像去噪系统的目的是为了为后续的研究以及学者提供一个快速的对比实验，为了拓展对比实验的广泛性，将该网站扩张为不仅仅可以进行天文图像去噪，也可以进行普通图像去噪两个模块。本系统可以为后面的学者提供一个在线的去噪功能，后续的学者进行对比研究时可以直接使用本系统得出实验结论，无需自己进行代码的复写，能够高效便捷的完成对比实验。

为了能够便捷高效的进行去噪，因此系统的界面设计应该简洁明了，设计的系统分为 3 个模块。第一个为进行实验的文件选择，可以选择系统提供的示例文件也可以上传自己想要去噪的文件，上传的文件可以选择天文图像 FITS 文件、或者普通的图像文件，在这里就需要对上传的文件进行一个判断，判断其是否为

FITS 文件，根据判断结果进行不同的后续的文件读取。该模块功能如图 5-2 所示。




图 5-2 文件选取模块功能

Fig 5-2 File selection module function

第二个模块为去噪的参数选择模块，该模块的主要功能为选择去噪的参数。首先就需要对噪声强度的参数选择，添加的噪声强弱能够被用户进行自行选择，但是选择的范围我们设定在 $[1, 70]$ 之间，设计一个滑动条带单个噪声的加减进行噪声强弱设定，噪声设定如图 5-3 所示，对选取的文件添加用户选定点噪声强度点噪声。然后是对去噪模型点选择，对添加噪声之后对图像进行一个去噪模型的选择，选择的范围为论文所提出的三个深度学习模型，联合损失函数、SACNN 和多尺度残差网络。最后对选择的深度学习网络进行参数设置，包括网络层数、批量大小和训练轮次等三个关键的网络参数进行设置。对去噪实验的所有参数进行设置完毕之后，运行实验。



图 5-3 噪声强弱设定具体实现图

Fig 5-3 Specific implementation of noise intensity setting

最后一个模块为实验结果展示模块，该模块并非一开始就出现在用户界面的，是需要运行之后再出现的界面，运行之后展示的结果分 2 个小的模块，一个为图像模块，一个为数据模块。图像模块展示的图像有四张，分别为原始图像、噪声图像、添加噪声之后的图像以及去噪之后的图像四个。数据模块主要展示的是图像的评价指标，包括，选择的模型、添加的噪声强度以及评价指标 PSNR 和 SSIM 两个客观指标。方便后续的学者之间对结果进行使用。

5.2 SKA 图像的去噪系统

根据上一节的设计思路,对三个模块进行具体的代码实现,并且进行界面的补充完善设计,由于本系统是为了方便后续的学者进行对比实验能够直接使用本系统进行实验结果的输出,因此需要在系统首页进行一个标识,标明如果使用该系统的结果进行研究需要进行引用,并且有一个论文的展示界面,该界面主要提供系列论文的简介与下载,其实现效果如图 5-4 所示。

SKA图像的去噪系统




图 5-4 相关论文效果图

Fig 5-4 Rendering of relevant papers

根据 5.1 的设计思路完成在线系统的代码编写工作,首先进行第一个模块的代码编写。在这个模块中有两个主要的选择功能,第一个就是选择系统展示天文图像进行去噪实验,为了方便展示 FITS 文件的具体内容,我们将提供的 FITS 文件进行了一个转换操作,将其转换为图像展示在系统可选数据中。第二个就是选择自己上传文件进行去噪实验,其中上传文件的具体实现模块如图 5-5 所示。




图 5-5 文件上传模块

Fig 5-5 File Upload Module

编写完成的第一个模块文件选择的模块实现如图 5-6 所示。

SKA图像的去噪系统




图 5-6 文件选择模块实现图

Fig 5-6 Implementation diagram of file selection module

第二个模块去噪参数选择模块的具体实现如图 5-7 所示, 考虑到实验过程可能需要针对一张图片重复进行多次不同操作实验, 因此对具体的实现模块添加了一个重置功能, 其目的就是重置参数选择模块的所有内容, 可以不重新选择图像, 只是重新选择参数进行实验。




图 5.7 去噪模型选择模块实现样例

Fig 5-7 Implementation example of denoising model selection module

第三个模块运行结果模块的具体实现如图 5-8-5.10 所示, 在该模块中, 将展示原始图像、噪声图像、添加噪声之后的图像、去噪之后的图像 4 张图片, 并且在图像下方输出噪声强度大小以及客观评价指标 SSIM 何 PSNR 的值。选择一张天文图像, 添加噪声强度为 $\sigma = 50$ 的噪声图, 并且选择去噪模型为联合损失函数,

网络层数设置为 17 层，批量大小设置为 128，训练轮次设置为 35 轮，运行结果如图 5-8 所示。

运行结果：




客观评价指标结果

选择的去噪模型：联合损失函数 sigma = 50 PSNR = 39.264528 SSIM = 0.974433

图 5-8 联合损失函数运行结果模块实现效果
Fig 5-8 The operation result of joint loss function

选择一张天文图像，添加噪声强度为 $\sigma = 50$ 的噪声图，并且选择去噪模型为 SACNN 网络，网络层数设置为 17 层，批量大小设置为 128，训练轮次设置为 35 轮，运行结果如图 5-9 所示。

运行结果：




客观评价指标结果

选择的去噪模型：联合损失函数 sigma = 50 PSNR = 43.733945 SSIM = 0.983045

图 5-9 SACNN 运行结果
Fig 5-9 The operation results of SACN

选择一张天文图像，添加噪声强度为 $\sigma = 50$ 的噪声图，并且选择去噪模型为多尺度残差网络，网络层数设置为 17 层，批量大小设置为 128，训练轮次设置为 35 轮，运行结果如图 5-10 所示。

运行结果：



客观评价指标结果

```
*****  
选择的去噪模型：联合损失函数 sigma = 50 PSNR = 40.810204 SSIM = 0.975133
```

图 5-9 SPACNN 运行结果模块实现效果

Fig 5-9 The operation results of SPACNN

5.3 本章小结

在本章节，作者主要介绍了天文图像去噪在线系统的实现，首先分析该系统针对的目标群体，之后根据目标群体进行了系统的总体设计，并且做了设计思路的分析，最后根据设计思路进行的在线系统的实现，并且在实际的实现过程中又对系统做了一些优化，最终呈现出展示的在线系统。

第六章 总结和展望

6.1 总结

SKA 做为全球最大的射电天文望远镜，其未来将会为全世界的天文研究领域带来更多重大的发现，其肩负着探索宇宙黎明、黑洞演化、发现新的行星的重任，是未来天文研究领域必然不可忽视的重点研究内容。而 SKA 的第一科学目标——探索宇宙黎明的再电离时期，是目前更多的学者进行研究的领域，但是更多的学者研究的都是针其再电离时期的效应矫正问题如极化效应、带宽涂污效应的矫正等等。本文从 SKA 射电天文图像的预处理方向进行研究，针对图像的噪声进行去噪研究，针对传统算法去噪能力不足的问题进行研究，将深度学习应用于 SKA 射电天文图像去噪上，有效的弥补了传统算法去噪能力不够的问题，下面将本文的具体工作进行如下总结：

1. 为了更好的研究 SKA 射电天文图像去噪，并且由于 SKA 射电天文望远镜并未建成，因此利用现有的软件进行射电晕的成像模拟。在 150-166MHz（以 3.2MHz 为频率间隔）上模拟了星系团射电晕图像，并将 SKA1_low 的阵列信息添加到模拟出来的射电晕图像上，最后进行成像，得到了实验所需的数据集。

2. 针对 DnCNN 网络对 SKA 射电天文图像存在的边缘恢复能力不足的问题，提出联合损失函数去噪方法。由于 MS-SSIM 损失函数能够保留图像的边缘，但是会损失图像的亮度，但是 L1 损失函数可以保留图像的亮度和色彩，因此将两个损失函数组合起来，解决 DnCNN 存在的问题。进行对比实验，证明所提的方法能够有效的弥补 DnCNN 存在的问题。

3. 为了解决所提的联合损失函数去噪方法和 DnCNN 存在的对不同注意力的权重视为平等的问题，本文提出基于融合注意力机制的 SACNN 网络，在该网络中融合了 SA 注意力机制模块，该模块能够高效低成本低将空间注意力和通道注意力组合在一起。经过对比实验证明所提的 SACNN 网络可以有效的弥补所提的联合损失函数深度学习模型和 DnCNN 存在的对不同注意力的权重视为平等的问题。

4. 为了解决所提的联合损失函数深度学习模型和 DnCNN 存在的只使用 3×3 单一尺寸的卷积核的问题，对特征提取度不足的问题，基于融合注意力机制的问题提出了多尺度残差网络，提出使用 1×1 、 3×3 、 5×5 和 7×7 4 个不同尺寸的卷积核进行特征提取。经过对比实验证实，所提的多尺度残差网络的去噪效果更好，回复的图像细节更多。

5. 针对本文的几个深度学习的研究内容，完成了天文图像去噪的在线系统。该系统的目的是为后续的研究提供对比实验，为需要进行深度学习天文图像去噪

研究的实验内容提供一个快速可以进行并且得到结果的对比实验,并且不需要进行大量的模型搭建工作,方便后续进行天文图像去噪研究。

6.2 展望

本文的 SKA 射电天文图像去噪研究是基于 SKA1_low 进行的,SKA 射电天文望远镜的干涉阵列有很多,不同的干涉阵列的研究也各不相同,因此还是需要继续研究的,不能止步于此。由于时间有限,本文所提出的研究内容也还需要继续进行下一步的优化,研究内容也可以继续进行扩展。本文所提的深度学习天文图像去噪还可以进行以下内容的深入研究:

1.本文研究的内容为 SKA 射电天文图像的去噪,研究的内容限定在了 SKA 望远镜观测到的射电天文图像上,并且目前由于 SKA 天文望远镜并未建成,数据来源于模拟多数据,我们可以拓展数据到目前已有的观测数据上,如太阳、黑洞等等已经有大量的观测数据,因此后续的研究可以拓展研究内容,不仅仅局限于 SKA 射电天文图像上。

2.由于本文的数据集来源是根据 SKA1_low 以及目前现有的成像软件模拟的射电晕图像,研究的数据集内容可以进行广泛的拓展,可以研究模拟河外点源、EOR 信号再添加干涉阵列模拟数据集进行拓展实验,能拓展研究的广泛性。模拟的数据频率范围在 150-166MHz,模拟的频率范围也可以进行拓展,模拟更多频率范围的数据,完成更高频和低频数据的研究。

3.本文研究的阵列为 SKA1_low 低频阵列,但是 SKA 射电天文望远镜的成像阵列并非只有 SKA1_low,后续可以研究 SKA1_Mid 阵列的天图,拓展研究的阵列,得到更广的研究结论,提高网络的普适性。

4.本文选择的深度学习模型是一个相对来说使用的很普遍的网络,选取的优化内容也是普遍常见的优化方法,网络适用行很广泛。实验所选取的 FITS 图像的天区也是固定的,后续的研究可以进行自住研究构建针对 SKA 射电天文图像去噪的深度学习网络,研究针对更加广泛的天区的深度学习去噪模型。

参考文献

- [1] Mirabel I F , Dijkstra M , Laurent P , et al. Stellar black holes at the dawn of the universe[J]. Astronomy and Astrophysics, 2011, 528(5):85-87.
- [2] Jonathan, R, Pritchard, et al. Constraining the unexplored period between the dark ages and reionization with observations of the global 21 cm signal[J]. Physical Review D, 2010.
- [3] 赵碧轩, 郑倩, 张泽康,等. 宇宙黎明和再电离时期探测进展[J]. 天文学进展, 2021, 039(004):455-471.
- [4] 唐远志.基于深度学习的低频 SKA 极化效应研究[D].贵州: 贵州大学, 2022.
- [5] 静远. 世界最大 SKA 首台天线在我国诞生[J]. 中国设备工程, 2018, 000(004):3.
- [6] 张唯诚. 为什么我们需要 SKA? [J]. 百科知识, 2012(13):5.
- [7] 李碧莹编译. 平方公里阵列射电望远镜 SKA 启动建设[J]. 物理, 2021, 50(9):1.
- [8] 郭丽丽, 丁世飞. 深度学习研究进展[J]. 计算机科学, 2015, 42(5):6.
- [9] Lecun Y , Bengio Y , Hinton G . Deep Learning[J]. Nature, 2015, 521(7553):436-444.
- [10] Mcculloch W S , Pitts W H . A logical Calculus of Ideas Immanent in Nervous Activity[J]. The Bulletin of Mathematical Biophysics, 1942, 5:115-133.
- [11] Rosenblatt F . Perceptrons and the Theory of Brain Mechanisms[R]. Cornell Aeronautical Laboratory Report No, 1960.
- [12] Minsky, Marvin and Papert, Seymour. Perceptrons : An Introduction to Computational Geometry.[M] 1969.
- [13] Rumelhart D E , Hinton G E , Williams R J . Learning Representations by Back Propagating Errors[J]. Nature, 1986, 323(6088):533-536.
- [14] Platt J C . Sequential Minimal Optimization: A Fast Algorithm for Training Support Vector Machines[J]. Microsoft Research, 1998.
- [15] Hinton, G, E, et al. Reducing the Dimensionality of Data with Neural Networks.[J]. Science, 2006.
- [16] Kim Y . Convolutional Neural Networks for Sentence Classification[J]. Eprint Arxiv, 2014.
- [17] Lai S , Xu L , Liu K , et al. Recurrent Convolutional Neural Networks for Text Classification[C]// National Conference on Artificial Intelligence. AAAI Press, 2015.
- [18] Yang Z , Yang D , Dyer C , et al. Hierarchical Attention Networks for Document Classification[C]// Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2016.

- [19] Long J , Shelhamer E , Darrell T . Fully Convolutional Networks for Semantic Segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(4):640-651.
- [20] Zhao H , Shi J , Qi X , et al. Pyramid Scene Parsing Network[J]. IEEE Computer Society, 2016.
- [21] He K , Gkioxari G , P Dollár, et al. Mask R-CNN[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017.
- [22] Sermanet P , Eigen D , Zhang X , et al. OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks[J]. Eprint Arxiv, 2013.
- [23] Girshick R , Donahue J , Darrell T , et al. Region-Based Convolutional Networks for Accurate Object Detection and Segmentation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2015, 38(1):142-158.
- [24] Redmon J , Divvala S , Girshick R , et al. You Only Look Once: Unified, Real-Time Object Detection[C]// Computer Vision & Pattern Recognition. IEEE, 2016.
- [25] Redmon J , Farhadi A . YOLO9000: Better, Faster, Stronger[C]// IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2017:6517-6525.
- [26] Redmon J , Farhadi A . YOLOv3: An Incremental Improvement[J]. arXiv e-prints, 2018.
- [27] Bochkovskiy A , Wang C Y , Liao H . YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020.
- [28] Chen Pu-chun et al. Application of Debauchies wavelet to the de-noising of radio maps[J]. Chinese Astronomy & Astrophysics, 2001, 25(1):132-137.
- [29] Fligge M, Solanki S K. Noise reduction in astronomical spectra using wavelet packets[J]. Astronomy and Astrophysics Supplement Series, 1997, 124(3): 579-587.
- [30] Egiazarian K O, Astola J T. New algorithm for removing mixed (white and impulsive) noise from images[C]//Nonlinear Image Processing X. SPIE, 1999, 3646: 78-89.
- [31] Willett R M, Nowak R D, Kolaczyk E D. Multiscale Analysis of Photon-Limited Astronomical Signals and Images[C]//American Astronomical Society Meeting Abstracts. 2002, 201: 63.01.
- [32] Beckouche S, Starck J L, Fadili J. Astronomical image denoising using dictionary learning[J]. Astronomy & Astrophysics, 2013, 556: A132.
- [33] Liu Q, Bai J, Yu F. Astronomical image denoising by means of improved adaptive backtracking-based matching pursuit algorithm[J]. Applied Optics, 2014, 53(32): 7796-7803.

- [34] Torres-Forné A, Marquina A, Font J A, et al. Denoising of gravitational wave signals via dictionary learning algorithms[J]. *Physical Review D*, 2016, 94(12): 124040.
- [35] Remez T, Litany O, Giryes R, et al. Deep convolutional denoising of low-light images[J]. *arXiv preprint arXiv:1701.01687*, 2017.
- [36] Lucas J, Calef B, Kyono T. Recovering astronomical images with deep neural network supported bispectrum processing[C]//Advanced Maui Optical and Space Surveillance (AMOS) Technologies Conference. 2018.
- [37] Park E, Moon Y J, Lim D, et al. De-noising SDO/HMI solar magnetograms by image translation method based on deep learning[J]. *The Astrophysical Journal Letters*, 2020, 891(1): L4.
- [38] Shen H , George D , Huerta E A , et al. Denoising Gravitational Waves using Deep Learning with Recurrent Denoising Autoencoders[J]. 2017.
- [39] Baso C J D, de la Cruz Rodriguez J, Danilovic S. Solar image denoising with convolutional neural networks[J]. *Astronomy & Astrophysics*, 2019, 629: A99.
- [40] Park E, Moon Y J, Lim D, et al. De-noising SDO/HMI solar magnetograms by image translation method based on deep learning[J]. *The Astrophysical Journal Letters*, 2020, 891(1): L4.
- [41] Vojtekova A, Lieu M, Valtchanov I, et al. Learning to denoise astronomical images with U-nets[J]. *Monthly Notices of the Royal Astronomical Society*, 2021, 503(3): 3204-3215.
- [42] Zhang Y, Nord B, Pagul A, et al. Noise2Astro: Astronomical Image Denoising with Self-supervised Neural Networks[J]. *Research Notes of the AAS*, 2022, 6(9): 187.
- [43] Lehtinen J , Munkberg J , Hasselgren J , et al. Noise2Noise: Learning Image Restoration without Clean Data[J]. 2018.
- [44] 任沁沁,董瑞丰. 世界最大射电望远镜有望 7 月开建[N]. *新华每日电讯*,2021-03-04(009).
- [45] 张唯诚. 为什么我们需要 SKA? [J]. *百科知识*, 2012(13):5.
- [46] Camilo F, Scholz P, Serylak M, et al. Revival of the magnetar psr j1622–4950: Observations with meerkat, parkes, xmm-newton, swift, chandra, and nustar[J]. *The Astrophysical Journal*, 2018, 856(2): 180.
- [47] Sett S, Bhat N D R, Sokolowski M, et al. Image-based searches for pulsar candidates using MWA VCS data[J]. *arXiv preprint arXiv:2212.06982*, 2022.
- [48] Gupta N, Huynh M, Norris R P, et al. Discovery of peculiar radio morphologies with ASKAP using unsupervised machine learning[J]. *Publications of the Astronomical Society of Australia*, 2022, 39: e051.

- [49] Hurley-Walker N, Zhang X, Bahramian A, et al. A radio transient with unusually slow periodic emission[J]. *Nature*, 2022, 601(7894): 526-530.
- [50] 卫星奇. 基于深度学习的低频 SKA 带宽涂污效应矫正研究[D]. 贵州: 贵州大学, 2022.
- [51] 张佳欣. SKA 尝试回答“人类在宇宙中是否孤独”[N]. *科技日报*, 2022-12-07(012).
- [52] 李维天. SKA EoR 探测实验的射电晕前景建模以及 EoR 信号分离算法的研究[D]. 上海: 上海交通大学, 2019.
- [53] Dulwich F, Mort B J, Salvini S, et al. OSKAR: Simulating digital beamforming for the SKA aperture array[C]// *IEEE International Symposium on Phased Array Systems and Technology*. IEEE, 2010.
- [54] Offringa A R, McKinley B, Hurley-Walker N, et al. WSCLEAN: an implementation of a fast, generic wide-field imager for radio astronomy[J]. *Monthly Notices of the Royal Astronomical Society*, 2014, 444(1): 606-619.
- [55] 丁生荣. 图像斑点噪声判别与参数估计方法研究[D]. 陕西: 陕西师范大学, 2011.
- [56] 徐凤. 图像去噪算法及噪声估计研究[D]. 重庆: 重庆大学, 2020.
- [57] Zhang K, Zuo W, Chen Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. *IEEE transactions on image processing*, 2017, 26(7): 3142-3155.
- [58] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]// *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2016.
- [59] Yu F, Koltun V, Funkhouser T. Dilated Residual Networks[C]// *IEEE Computer Society*. IEEE Computer Society, 2017.
- [60] Shi G, Yan Z, Kai Z, et al. Toward Convolutional Blind Denoising of Real Photographs[J]. 2018.
- [61] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[J]. *JMLR.org*, 2015.
- [62] Hang, Zhao, Orazio, et al. Loss Functions for Image Restoration With Neural Networks[J]. *IEEE Transactions on Computational Imaging*, 2017.
- [63] Wang Z, Simoncelli E P, Bovik A C. Multiscale structural similarity for image quality assessment[J]. 2003.
- [64] Greisen E W, Harten R H. An extension of FITS for groups of small arrays of data[J]. *Astronomy and Astrophysics Supplement Series*, 1981, 44: 371.
- [65] Wells D C, Greisen E W. FITS-a flexible image transport system[C]// *Image processing in astronomy*. 1979: 445.

- [66] Donoho D L . De-noising by soft-thresholding[J]. IEEE Transactions on Information Theory, 1995, 41(3):P.613-627.
- [67] Tukey J W . Exploratory data analysis. Addison W [J][J]. Biometrics, 1977.
- [68] Buades A , Coll B , Morel J M . A non-local algorithm for image denoising[C]// Computer Vision and Pattern Recognition, 2005. CVPR 2005. IEEE Computer Society Conference on. IEEE, 2005.
- [69] Dabov K , Foi A , Katkovnik V , et al. Image Denoising by Sparse 3-D Transform-Domain Collaborative Filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8):2080-2095.
- [70] Gu S , Lei Z , Zuo W , et al. Weighted Nuclear Norm Minimization with Application to Image Denoising[C]// 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2014.
- [71] Chen Y , Pock T . Trainable Nonlinear Reaction Diffusion: A Flexible Framework for Fast and Effective Image Restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017.
- [72] Liao Z , Carneiro G . Competitive Multi-scale Convolution[J]. Computer ence, 2015.
- [73] Adam Kosiorek. 神经网络中的注意力机制[J]. 机器人产业, 2017(6):6.
- [74] Yang Y B . SA-Net: Shuffle Attention for Deep Convolutional Neural Networks[C]// 2021.