

学校代码 10702

密级 公开

中图分类号 TP391

学号 2106310787



西安工业大学
Xi'an Technological University

专业硕士学位论文

大视场天文图像超分辨率重建
的深度学习研究方法研究

学位申请人：杜江斌

校内导师：马龙教授

企业导师：李洪峻 高工

专业领域：计算机技术

学位类别：工程

2024年5月



西安工业大学
Xi'an Technological University

专业硕士学位论文

(学位研究生)

题目：大视场天文图像超分辨率重建
的深度学习研究方法研究

作者 杜江斌

校内导师 马龙 专业技术职务 教授

企业导师 李洪峻 专业技术职务 高工

专业领域 计算机技术

西安工业大学

2024 年 5 月 中国·西安

Research on deep Learning method for Super-resolution Reconstruction of large Field Astronomical Images

by

Du Jiangbin

Dissertation Submitted to the faculty of the Xi'an Technological
University in Partial Fulfillment of
the Requirements for the Degree of

MASTER

in

Computer Technology

Supervisor: Professor

Ma Long

Supervisor: Senior Engineer

Li Hong Jun

Xi'an Technological University

May 2024

Xi'an, Shaanxi, P.R.China

摘 要

受设备口径和传输过程的限制,天文图像的分辨率常常难以满足空间探测的需求。天文图像超分辨率重建是将低分辨率图像重建为具有更多细节的高分辨率图像,从而增强图像的有效视觉信息。传统的图像超分辨率方法在处理大视场天文图像时存在重建效率低下且重建内容不完整的问题。本文采用深度学习方法对大视场天文图像的超分辨率重建问题进行了研究。主要工作如下:

(1) 构建了完备的天文图像超分辨率重建数据集。针对天文图像超分辨率重建样本难以获取的问题,本文采用了有效的模拟天文图像退化过程的数据准备策略。首先,本文通过数据增强技术处理原始天文图像,制作出高清样本。随后,通过应用高斯模糊、下采样,并引入噪声,生成了与这些高清样本相对应的低分辨率图像;最后通过两者的结合构建了一套包含低分辨率和高分辨率图像对的大规模数据集,为深度学习模型的训练提供了必要的数据库。

(2) 构建了基于自编码器结构的渐进生成式大视场天文图像超分辨率重建网络。为克服传统超分辨率重建算法在大视场天文图像上的限制,开发了基于自编码器结构的渐进生成式超分辨率重建网络(Progressive generative super-resolution reconstruction network, PGSRNet),包含特征提取、校正和图像生成三大模块。特征提取模块从低分辨率图像中提取浅层和深层特征,捕捉细节和全局信息。特征校正模块使用移动卷积和层归一化技术优化特征。图像生成阶段,结合深层和校正后的浅层特征,渐进式生成高分辨率图像,显著提升了图像细节丰富度和真实感。

(3) 设计实现了集成 PGSRNet 的嵌入式天文图像超分辨率重建系统。为将本文的重建算法应用于实际,实现与望远镜系统的高效对接,本文设计了一款以 NVIDIA JETSON TX2 AI 控制板为核心的天文图像超分辨率重建系统。该系统融合了 PGSRNet 重建算法、GPS、温湿度采集、WIFI 及二维舵机模块,并提供了高兼容性的望远镜系统专用数据传输接口。配合友好的上位机界面,能实时处理望远镜采集的天文图像,进行精准的图像重建。

(4) 实验验证了所提方法在主观评价和客观指标上的优势,同时也证实了其在不同望远镜图像数据上的泛化能力和局限性。主观评价方面,本文的网络不仅较好的保存了图像内容,而且保证了图像灰度值的正确表达。在客观指标方面,本文网络比其他方法中最优的结果在 SSIM 上提高了 0.077,在 PSNR 上更是提高了 1.969dB。

关键词: 大视场天文图像;超分辨率重建;深度神经网络;自编码器;

Abstract

Due to the limitations of equipment aperture and transmission process, the resolution of astronomical images often fails to meet the requirements of space exploration. Astronomical image super-resolution reconstruction aims to rebuild low-resolution images into high-resolution images with more details, thereby enhancing the effective visual information of the image. Traditional image super-resolution methods face challenges of low reconstruction efficiency and incomplete content when dealing with large-field astronomical images. This paper studies the super-resolution reconstruction of large-field astronomical images using deep learning methods. The main work is as follows:

(1) A comprehensive dataset for astronomical image super-resolution reconstruction has been established. Addressing the issue of obtaining samples for super-resolution reconstruction of astronomical images, we utilized an effective data preparation strategy that simulates the degradation process of astronomical images. Initially, we processed the original astronomical images with data augmentation techniques to create high-definition samples. Subsequently, by applying Gaussian blur, down-sampling, and introducing noise, we produced low-resolution images corresponding to these high-definition samples. Finally, by integrating these elements, we developed a large-scale dataset containing pairs of low-resolution and high-resolution images, thus providing a necessary data foundation for training deep learning models.

(2) A progressive generative super-resolution reconstruction network (PGSRNet) based on autoencoder structure was developed for large-field astronomical image super-resolution reconstruction. To overcome the limitations of traditional super-resolution algorithms on large-field astronomical images, PGSRNet was developed, comprising feature extraction, correction, and image generation modules. The feature extraction module extracts shallow and deep features from low-resolution images, capturing details and global information. The feature correction module uses moving convolution and layer normalization techniques to optimize features. In the image generation stage, high-resolution images are progressively generated by combining deep and corrected shallow features, significantly enhancing image richness and realism.

(3) An embedded astronomical image super-resolution reconstruction system integrating PGSRNet has been designed and implemented. To apply our reconstruction algorithm in practice and achieve efficient integration with telescope systems, we have designed an astronomical image super-resolution reconstruction system centered around the NVIDIA JETSON TX2 AI control board. This system integrates the PGSRNet reconstruction algorithm, GPS, temperature and humidity data acquisition, WIFI, and a two-dimensional servo module, and provides a highly compatible data transmission interface dedicated to telescope systems. Paired with a user-friendly

host computer interface, it can process astronomical images captured by telescopes in real-time, perform precise image reconstruction, and demonstrate its tremendous potential in the field of astronomical observation.

(4) The experiment has verified the advantages of the proposed method in both subjective evaluation and objective metrics, as well as confirmed its generalizability and limitations on different telescope image data. In terms of subjective evaluation, the network in this paper not only preserves the image content well, but also ensures the correct representation of image grayscale values. In terms of objective metrics, the network of this paper outperforms the best results from other methods, achieving a 0.077 increase in SSIM and a 1.969 dB improvement in PSNR.

Key Words: Large-field Astronomical Image; Superresolution Reconstruction; Deep Neural Network; Autoencoder

目 录

1 绪论.....	1
1.1 研究背景.....	1
1.2 研究现状与发展动态分析	2
1.2.1 研究现状.....	2
1.2.2 发展动态分析.....	5
1.3 论文的主要内容及结构安排	5
1.3.1 论文的主要内容.....	5
1.3.2 结构安排.....	7
2 超分辨率重建的理论基础与评价指标	9
2.1 理论基础.....	9
2.1.1 深度学习相关原理.....	9
2.1.2 天文图像的成像特点.....	14
2.1.3 常见的模糊类型.....	15
2.1.4 常见的噪声类型.....	17
2.2 评价指标.....	19
2.2.1 主观评价	19
2.2.2 客观评价	20
2.3 本章小结.....	21
3 基于自编码器结构的渐进生成式天文图像超分辨率重建方法	22
3.1 大视场天文图像数据集建立	22
3.2 网络结构设计.....	23
3.2.1 特征提取模块.....	24
3.2.2 特征校正模块.....	25
3.2.3 图像生成模块.....	26
3.2.4 特征提取模块优化.....	28
3.3 模型训练.....	29
3.3.1 学习率衰减策略.....	30
3.3.2 损失函数设计.....	30
3.3.3 优化器选择.....	34
3.3.4 训练过程分析.....	36
3.4 模型验证.....	37
3.4.1 主观评价	37
3.4.2 客观评价	39
3.4.3 模型泛化能力验证.....	39

3.5 模型局限性分析.....	40
3.6 本章小结.....	41
4 集成 PGSRNet 的嵌入式天文图像超分辨率重建系统	43
4.1 需求分析.....	43
4.1.1 系统功能需求分析.....	43
4.1.2 系统性能需求分析.....	44
4.1.3 系统运行环境分析.....	45
4.1.4 系统可行性分析.....	45
4.2 系统总体设计.....	46
4.2.1 系统逻辑架构设计.....	46
4.2.2 系统功能模块设计.....	47
4.2.3 系统总体流程设计.....	48
4.3 AI 控制板端的设计与实现	49
4.3.1 对接望远镜系统的设计与实现.....	49
4.3.2 位置与环境检测的设计与实现.....	51
4.3.3 重建算法 PGSRNet 集成与远程控制的设计与实现.....	52
4.4 上位机端的设计与实现.....	53
4.4.1 图像采集与信息监控的设计与实现.....	54
4.4.2 重建算法集成与结果展示的设计与实现	55
4.4.3 下发操作指令的设计与实现.....	56
4.5 本章小结.....	57
5 总结与展望.....	58
5.1 总结.....	58
5.2 展望.....	59
参考文献.....	61

1 绪 论

1.1 研究背景

捕捉自天文望远镜等先进设备的天文图像，为我们揭示了外太空众多天体的神秘面貌。这些图像的超分辨率处理对科学研究、宇宙探索以及天文和物理学的进步具有极其重要的影响。然而，在天体观测过程中，由于设备口径和传输过程的限制，使得图像质量受损严重，分辨率也随之下降，严重影响到对观测目标的识别与分析。其中，针对成像设备口径小所导致的天文图像分辨率低问题，可以通过增大望远镜的口径来获得超分辨率的图像，但会带来较高的制造和维护成本。因此，通过图像后处理技术对天文图像进行超分辨率重建显得尤为重要。

超分辨率重建是指从退化后的低分辨率图像中恢复图像所丢失的高频信息，从而重建出更加清晰且分辨率更大的超分辨率图像，所以它不是简单地对图像进行放大或者插值，而是通过整合图像的多尺度表示来处理图像，需要遵循特定模型，综合考虑图像的全局特性进行恢复。其目的使图像具有更丰富的细节信息，提供更好的感知质量，为人们提供更加优质的使用价值。

传统的图像超分辨率重建算法可以大致分为基于样例学习的方法以及基于重构的方法，其主要问题在于普遍难以恢复图像中的高频信息以及因图像分辨率提升而造成的图像模糊问题，且计算复杂、实时性不高。而随着近年来机器学习技术和深度学习技术的迅速发展及广泛应用，越来越多的研究者将其应用到超分辨率重建任务中，相较于传统的图像超分辨率算法，基于深度学习的算法在恢复图像的高频信息、图像去模糊、实现更大放大因子以及多尺寸放大的超分辨率重建任务上具有更好的表现能力，因此受到广大研究者的青睐^[54]。在基于深度学习的图像超分辨率研究领域，我们将其分为单帧图像超分辨率重建和多帧图像超分辨率重建两个主要方向。相比于多帧图像超分辨率技术，单帧图像的超分辨率在天文图像的研究中具有更大的灵活性和实用性，因此在本文的研究中，将主要探究基于单帧图像的超分辨率问题。

综上所述，由于天文望远镜的造价成本、成像能力以及后期图像的传输速度、存储空间等因素的限制，低分辨率图像的产生是不可避免的。因此，从低分辨率的图像中重建其对应的超分辨率图像这一任务具有十分重要的研究意义与应用价值，而由于传统方法所存在的固有缺陷，因此研究如何利用深度学习技术实现大视场天文图像的超分辨率重建是一件非常有意义的课题。

1.2 研究现状与发展动态分析

1.2.1 研究现状

图像超分辨率重建利用图像处理技术，将低分辨率（Low-Resolution, LR）图像转化为超分辨率（Super-Resolution, SR）图像，目的是增加图像的清晰度与细节，从而改善图像的视觉效果和辨识度。目前用于解决 SISR(Single Image Super-resolution)问题的方法大致可以分为基于插值的方法、基于退化模型的方法和基于学习的方法^[1]。

1) 基于插值的方法

基于插值的方法具有简单快速、实时性强和能够保留图像结构等优点，但同时也存在信息丢失、平滑效应和难以处理复杂图像内容等缺点^[2]。常见的基于插值的方法有最近邻插值、双线性插值和双三次插值等。

最近邻插值法又称为零阶插值是一种简单直接的灰度值插值方法。其基本原理是将变换后图像中每个像素的灰度值设置为距离其最近的输入图像像素的灰度值。比如在图像缩放时，最近邻插值会将每个原始像素的值直接复制到目标图像的相应位置。虽然这种方法计算简单且速度快，但由于它缺乏对像素间平滑过渡的处理，可能导致放大后的图像出现锯齿状的边缘。其计算公式为

$$\hat{x} = x * \left(\frac{\hat{w}}{w} \right) \quad (1.1)$$

$$\hat{y} = y * \left(\frac{\hat{h}}{h} \right) \quad (1.2)$$

式中， x, y 为目标图像的某个像素的横纵坐标， w, h 为目标图像的长和宽。 $\hat{w}, \hat{h}$ 为原图像的宽度和高度， $\hat{x}, \hat{y}$ 为目标图像在点 (x, y) 处对应的原图像的坐标。根据以上公式可得到如图 1.1 的生成过程。




图 1.1 最近邻插值法生成过程

双线性插值法是一种常用于图像处理和计算机图形学中的插值方法。用于在已知离散数据点的情况下，估计两个相邻点之间的数值。具体来说，双线性插值是在二维空间中，

通过对四个相邻的离散数据点进行线性插值来估计目标点的数值,而这四个相邻点通常组成一个矩形,目标点的位置落在这个矩形内部。其相较于最近邻插值,可以得到更加平滑和自然的插值效果,有效减轻图像缩放或者变换时出现的锯齿状现象。具体计算过程如下:

- (1) 根据目标点的位置,找到四个最近邻的离散数据点。
- (2) 分别在水平方向和垂直方向上对两个相邻的点进行线性插值,得到两个临界结果。
- (3) 最后,在垂直方向上对这两个临时结果进行线性插值,得到最终的插值结果。

根据以上计算过程可得如图 1.2 的示例图。




图 1.2 双线性插值计算过程示例图

其计算公式为

$$f(x, y) \approx \frac{f(Q_{11})}{(x_2 - x_1)(y_2 - y_1)}(x_2 - x)(y_2 - y) + \frac{f(Q_{21})}{(x_2 - x_1)(y_2 - y_1)}(x - x_1)(y_2 - y) \quad (1.3)$$

式中, $f(x, y)$ 为要求得点 $P(x, y)$ 处的值, $f(Q_{11})$ 、 $f(Q_{12})$ 、 $f(Q_{21})$ 、 $f(Q_{22})$ 分别为已知点 $Q_{11}(x_1, y_1)$ 、 $Q_{12}(x_1, y_2)$ 、 $Q_{21}(x_2, y_1)$ 、 $Q_{22}(x_2, y_2)$ 的值。


双三次插值又称立方卷积插值。与双线性插值类似,它也是在一直离散数据点的情况下,通过对一组相邻的数据点进行插值来估计目标点的数值。具体来说,双三次插值是在二维空间中,通过对一个相对较大的区域内的 16 个相邻离散数据点进行加权平均来估计目标点的数值。这 16 个相邻点通常组成一个 4×4 的矩阵,目标点的位置位于这个矩形内部。双三次插值利用了更多的相邻点信息,因此相对于双线性插值,它能够提供更加平滑和精确的插值效果。常用于图像超分、图像修复等图像处理任务中,可以有效地保留他图像细节和纹理信息,同时减轻缩放或者变幻时可能出现的锯齿状现象。其计算公式为

$$f(x, y) = \sum_{i=0}^3 \sum_{j=0}^3 f(x_i, y_j) \mathcal{W}(x - x_i) \mathcal{W}(y - y_j) \quad (1.4)$$

$$\mathcal{W}(x) = \begin{cases} (a+2)|x|^3 - (a+3)|x|^2 + 1 & |x| \leq 1 \\ a|x|^3 - 5a|x|^2 + 8a|x| - 4a & 1 < |x| < 2 \\ 0 & \text{其他} \end{cases} \quad (1.5)$$

CONCLUSIONS

迭代反投影法是一种基于投影数据的图像重建算法。它通过迭代的方式，将投影数据反向投影回图像空间，并与原始图像进行比较，不断调整以逼近实际图像。在超分辨率重建中，迭代反投影法可通过先将低分辨率图像升采样到高分辨率，然后将其投影模拟成低分辨率投影数据，再通过反投影得到一个初步的高分辨率估计。随后，通过不断迭代，结合先验信息，逐步优化以获得更高质量的超分辨率图像。其基本原理图如图 1.3 所示：



4. 知识的重建计划（特别）

凸集投影法是一种利用先验知识的重建方法，特别适用于超分辨率任务。其基于高分辨率图像集合构成凸集的假设，通过利用数学映射关系，将低分辨率图像转换至高分辨率空间中，进而产生预期的高分辨率图像。这种方法的优点在于，通过巧妙设计先验知识，可以得到符合实际场景的高质量重建结果，避免产生不现实的细节或过拟合现象。然而，需要注意的是，凸集投影法的有效性高度依赖于先验知识的合理设计和选择，同时在处理复杂场景或包含大量细节的图像时可能会表现出局限性。此外，该方法可能需要较长的计算时间，特别是在处理高分辨率图像时，因此在实际应用中需要权衡其适用

性和性能表现。

最大后验概率法利用贝叶斯定理进行图像恢复，视图像重建为在已有观测数据条件下寻求最有可能图像的过程。在超分辨率重建领域，最大后验概率法将待重建的高分辨率图像看作是随机变量，结合先验知识与观测数据，通过贝叶斯定理来估计后验概率。其优点在于能够综合利用先验知识和观测数据来提升图像质量，同时也允许灵活调整先验知识的权重以适应不同的应用场景。但其准确性高度依赖于先验知识的选择，不合适的先验知识可能导致重建结果不准确。此外，解决优化问题可能会带来较高的计算复杂度，尤其在处理大规模图像时。具体来说，它考虑两部分信息：

- (1) 先验概率：这是关于高分辨率图像的先验知识，通常基于统计模型或者其他先验信息来描述。先验概率反应了在没有观测数据的情况下，我们对高分辨率图像的信念。
- (2) 似然函数：这是在给定观测数据的条件下，高分辨率图像出现的概率。它反映了观测数据与高分辨率图像之间的关系。

3) 基于学习的方法

基于学习的方法则由于 SISR 问题的不适宜性而通过学习退化空间到原始空间的映射^[6]，进而求得该不适宜问题的最优解，因此可以保留更多的细节信息，得到更加准确的重建效果，其中深度学习方法由于其对复杂函数超强的建模能力而被广泛用于学习超分辨率重建中的映射关系。例如生成对抗网络（GAN）^{[7][8]}、Transformer^{[9][11]}和自编码器^{[12][13]}等深度神经网络均在图像超分辨率重建中取得了不错的结果。

1.2.2 发展动态分析

现有天文图像超分辨率重建方法在扩展目标等图像上可以取得较好的效果。然而这些方法在处理大视场天文图像时会存在以下问题：1、大视场图像的尺寸一般较大，传统方法的处理效率不高；2、现有深度学习方法在训练阶段需要采用与测试阶段相同大尺寸的图像样本，这将导致训练效率低、资源占用量较大；3、大视场图像场景复杂，一般包括星体，星云等，传统方法的处理效果不佳。针对以上问题本文提出一种基于自编码器结构的渐进生成式天文图像超分辨率重建的网络结构，弥补了当前领域针对大视场天文图像研究的缺陷，进而重建出理想的高分辨率图像。

1.3 论文的主要内容及结构安排

1.3.1 论文的主要内容

本文针对天文图像超分辨率重建任务展开研究，主要内容包括天文图像数据集的建立、基于自编码器结构的渐进生成式天文图像超分辨率重建网络的设计、模型训练方式的设计、模型的验证以及应用与实践。主要内容如图 1.4 所示。




图 1.4 主要内容与组织结构

(1) 大视场天文图像数据集建立。由于图像超分辨率重建对图像的分辨率以及质量要求较高，所以本文选用了目前天文学领域最先进的韦伯望远镜所拍摄的天文图像作为基础数据。通过数据增强的方式得到几十万张高分辨率图像，随后，考虑到天文图像的成像特点以及潜在的干扰因素，本文给得到的高分辨率图像添加相应模糊和噪声模拟其退化过程，最终生成所需的大规模 LR-SR 图像对的仿真数据集。

(2) 基于自编码器结构的渐进生成式天文图像超分辨率重建网络设计。本文根据天文图像超分辨率重建任务的特点，巧妙设计了一个基于自编码器结构的重建网络，主要包括特征提取、特征校正以及图像生成三个关键模块。这套网络结构充分考虑到天文图像的大视场、复杂干扰、背景多样等特征，通过自编码器的灵活性和强大的特征提取能力，以及巧妙的特征校正方式，使得网络能够在保留天文图像细节的同时，高效地抑制噪声和模糊，从而显著提高了重建结果的质量和准确性。并根据模型的特点从学习率的衰减策略、损失函数设计以及优化器选择三部分设计了模型训练方法。

- a) 学习率衰减策略。在本课题中采纳了余弦退火策略来调整学习率，这种方法有助于避免算法陷入局部最优，从而更有效地探索并定位到全局最优解。
- b) 损失函数设计。本文从重建网络训练的收敛速度、稳定性以及生成图像的视觉效果等多个方面出发，采用了将 Charbonnier 损失和结构性损失相结合的策略，同时设计并引入了层次融合损失。通过充分利用 LR-SR 图像对的约束优势以及不同分辨率特征的对应关系，使得网络在训练过程中能够更有效地收敛，并且保证了生成图像在视觉上的高质量表现。这一方法的选择在提升重建网络性能方面起到了关键作用。
- c) 优化器选择。本文采用 Adam 优化器，结合了一阶动量和二阶动量，以共同影响梯度下降速率的方式，有效地控制了梯度更新。

(3) 集成 PGSRNet 的嵌入式天文图像超分辨率重建系统的设计与实现。在本研究中，本文成功研发了一款嵌入式天文图像超分辨率重建系统。该系统以 NVIDIA JETSON TX2 为 AI 控制板，集成了 PGSRNet 重建算法、GPS、温湿度采集、二维舵机和 WIFI 模块，并配备了专用于望远镜的数据传输接口。系统还搭载了友好的上位机界面，能够有效地对望远镜捕获的天文图像进行重建。这一成果不仅展示了算法的实用性，还通过直观的界面设计增强了操作的灵活性，为天文图像处理技术的进步提供了新的动力。

(4) 模型验证。本文的模型验证分为三个主要部分：消融实验、对比实验以及模型的泛化能力和局限性分析。消融实验通过定量对比不同方法，筛选出最适合本研究的方案。对比实验则将本研究方法与该领域近年来的权威方法进行比较，以展示本方法的先进性。最后，通过在不同望远镜数据上测试模型，验证其泛化能力和局限性。

1.3.2 结构安排

第一章：绪论部分。首先，介绍了课题的研究背景，突出了天文学领域对于高质量图像的需求。接着对当前存在的超分辨率重建算法进行了综述，深入分析了它们的优缺点，尤其在天文图像上的局限性。通过这一分析，突显了本课题在天文图像超分辨率重建方面的优势。最后，概述了本研究课题的核心内容，为深入分析和讨论后续章节奠定了基础。

第二章：超分辨率重建的理论基础与评价指标。首先，系统介绍了超分辨率重建的基本原理，凸显了本次研究中所面临的技术难点。其次，简单探讨了图像领域常用的模糊类型和噪声类型，阐述了它们的原理和产生原因，为后续章节的技术分析奠定了清晰的背景。最后，对图像超分辨率重建领域的定量和定性两方面的评价指标及其计算方法进行了详尽的阐述，为后续实验结果的评估提供了全面而系统的评价体系。

第三章：基于自编码器结构的渐进生成式天文图像超分辨率重建方法。首先，详细介绍了网络训练以及验证所需数据集的制作方式，为课题研究提供了充分的数据支持。其次，深入阐述了该网络的总体设计，包括每个模块的设计原因和优势，并通过对每个

部分的消融实验进一步验证了设计的有效性。接着，对模型训练方式中的各个部分进行了仔细的阐述，更加清晰地展示了在训练过程中的技术细节和决策背后的逻辑，并通过消融实验进一步佐证。最后，通过定量和定性的方式对网络结构进行全面验证，为研究结果的可信性提供了多方面的支持。

第四章：集成 PGSRNet 的嵌入式天文图像超分辨率重建系统。本部分将 NVIDIA JETSON TX2 AI 控制板与天文望远镜连接后进行拍摄。同时，使用 PyQt 开发了一款天文图像后处理软件作为上位机。用户可以通过这款后处理软件控制望远镜进行拍摄，并将拍摄图像传输至开发板上位机。随后，通过应用本课题的算法进行处理，最终将处理后的图像展示给用户。这一实践应用过程使得用户能够亲身体验并了解本研究算法在实际天文图像处理中的效果，为算法的实际应用提供了直观的展示。

第五章：总结与展望。总结了本课题研究中关键内容以及创新点，同时对该领域进行了展望。

2 超分辨率重建的理论基础与评价指标

2.1 理论基础

2.1.1 深度学习相关原理

近年来，深度学习已成为各个领域的重要工具，而其在图像超分辨率重建领域也取得了显著的成果。现有深度学习方法大多都是依靠网络输入数据进行特征提取，从而进行学习。对于以提取特征为核心的深度学习，其主要由卷积层、激活函数层、池化层以及归一化层组成，利用这些层的不同组合实现对各类图像特征的提取和学习。本小节主要对本文所使用深度学习的重要组件的功能以及作用进行详细的介绍。

1) 卷积层

(1) 二维卷积 (Conv2d)

卷积神经网络^[14] (CNN) 中最常用的卷积是二维卷积，主要用于处理图像数据。图像通常具有二维结构，其中像素分布在高度和宽度的空间维度上。忽略颜色通道的情况下，输入图像的表示可以用三维矩阵表示，尺寸为 $C_{in} \times H_{in} \times W_{in}$ ，其中 C_{in} 是通道数， H_{in} 和 W_{in} 分别表示图像的高度和宽度。二维卷积通过在输入图像矩阵上滑动一个被称为卷积核的小矩阵，对图像进行逐点的加权求和操作，生成输出特征图。卷积核的尺寸为 $C_{out} \times C_{in} \times k \times k$ ，其中 C_{out} 是输出通道数， k 是卷积核大小。整个卷积操作涉及到空间维度和通道维度的关联性。输出特征图的尺寸为 $C_{out} \times H_{out} \times W_{out}$ ，其中 H_{out} 和 W_{out} 分别是输出特征图的高度和宽度。这种关联性是通过将输出图像的不同空间位置和通道进行加权相加来实现的。卷积的计算公式如下

$$y_{o,i,j} = \sum_{k_c} \sum_{k_i} \sum_{k_j} w(k_o, k_c, k_i, k_j) x(k_c, i + k_i, j + k_j) + b_{k_o} \quad (2.1)$$

其中 $y_{o,i,j}$ 为输出特征图中通道 o 的 (i, j) 位置的值， w 、 x 以及 b 分别表示权重、输入特征图的值和偏置项，而三个求和符分别表示对输入特征图的通道进行求和、对卷积核垂直方向和水平方向维度进行求和。

输入特征与输出特征的尺寸关系如下

$$H_{out} = \left\lfloor \frac{H_{in} + 2 \times padding - kernel_{size}}{stride} + 1 \right\rfloor \quad (2.2)$$

$$W_{out} = \left\lfloor \frac{W_{in} + 2 \times padding - kernel_{size}}{stride} + 1 \right\rfloor \quad (2.3)$$

其 $padding$ 为填充的数量， $kernel_{size}$ 表示卷积核的大小，而 $stride$ 为卷积核移动时的步幅。图 2.1 为二维卷积在空间维度上卷积计算示意图。




图 2.1 卷积计算示意图

在卷积过程中，卷积核对输入图像的每个位置进行卷积运算，生成一个对应位置的输出值。这个过程通过在空间维度上滑动卷积核，同时在通道维度上对不同通道的权重进行加权求和，学习到了图像的抽象表示。这使得卷积神经网络能够有效地捕捉图像中的局部特征，并通过多层卷积层逐渐形成对更高级别特征的抽象。这也是本文网络结构设计中各个模块均有使用该组件的主要原因。

(2) 深度可分离卷积 (Depthwise Separable Convolution)

深度可分离卷积^[15]是对传统卷积方法的优化，目的是在保持模型性能的同时，降低参数数量和计算成本。这种技术通常分为深度卷积 (Depthwise Convolution) 和逐点卷积 (Pointwise Convolution) 两个阶段，对标准卷积过程进行改进和简化。鉴于以上原因，本文在设计网络的特征校正模块时，考虑到降低计算成本的同时不影响效果的目的，采用了该模块。

a、深度卷积 (Depthwise Convolution)

作为深度可分离卷积流程中的初步环节，深度卷积专门针对输入数据的各个独立通道执行卷积处理。与传统卷积不同，深度卷积通过为每个输入通道分配专用的卷积核来实现独立处理，这意味着对于具有多个通道的输入数据，将使用相应数量的卷积核，每个卷积核负责处理一个通道的信息。通过学习卷积核的权重，深度卷积能够捕捉输入数据中每个通道的局部特征，有效提取图像的关键信息，如边缘和纹理。这种独立卷积操作的方式使得深度卷积逐渐建立对输入更为丰富的抽象表示，为神经网络的后续层提供更具信息量的输入。其计算过程可以由以下简化的公式表示。

$$Y_{o,i,j} = \sum_{k_c} W_{k_c} \cdot X_{k_c}(i,j) \quad (2.4)$$

其中 $Y_{o,i,j}$ 为输出， W_{k_c} 是与输入通道 k_c 相关联的卷积核权重， $X_{k_c}(i,j)$ 是输入的通道 k_c 在位置 (i,j) 上的值。深度卷积在空间维度上卷积计算示意图如图 2.2 所示。

b、逐点卷积 (Pointwise Convolution)

深度可分离卷积的第二步是逐点卷积，它对深度卷积的输出进行进一步处理。它采用 1×1 的卷积核在输入数据的每个位置上进行卷积操作。与常规卷积操作不同，逐点卷

积主要针对通道维度进行，它通过线性方式调整每个通道的信息，有利于通道间的信息融合，调节各通道权重，以产生最终输出。这个操作在深度可分离卷积中发挥着重要作用，不仅减少了冗余信息，提升了模型的表达能力，还在计算效率上实现了优化。其计算过程可以表示为

$$Z_{o,i,j} = \sum_{k_c} W_p(k_c) \cdot Y_{o,i,j} \quad (2.5)$$

其中， $Z_{o,i,j}$ 是逐点卷积的输出，表示在输出通道 o 中位置 (i,j) 的值。 $W_p(k_c)$ 是逐点卷积的权重，与输入通道 k_c 相关联。 $Y_{o,i,j}$ 是深度卷积的输出，作为逐点卷积的输入。逐点卷积在空间维度上卷积计算示意图如图 2.3 所示。




图 2.2 深度卷积计算示意图




图 2.3 逐点卷积计算示意图

深度可分离卷积通过分解卷积操作，有效减少了参数数量。深度卷积专注于对输入的每个通道进行卷积操作，捕捉通道内的局部信息。而逐点卷积通过在通道之间执行线性组合操作，合并深层卷积的输出，有效减少了通道间的多余信息。由于两个步骤的完美配合，是的模型具有更少的参数，从而减小了计算和存储开销。

1) 激活函数

(1) ReLU (Rectified Linear Unit)

ReLU^[16]是一种在神经网络中广泛应用的激活函数。其基本概念在于引入非线性特性，通过简单的阈值操作对输入信号进行转换。具体来说，ReLU 函数在输入值大于 0 时直接输出该输入值；当输入值小于或等于 0 时，则输出为 0。非线性特性使得神经网络更能灵活地捕捉和学习数据中的复杂模式。其数学表法是为

$$f(x) = \max(0, x) \quad (2.6)$$

式中, x 表示输入。通过选取输入和 0 之间的最大值, 实现简单而高效的非线性激活。

ReLU 激活函数的优势在于引入非线性, 使得神经网络能够更好地适应复杂的数据模式。它具有计算高效, 稀疏激活的特点, 有助于网络训练和泛化。尽管存在“神经元死亡”问题, 即部分神经元可能不会被激活, 当然这一问题可以通过使用改进型的激活函数(如 Leaky ReLU^[17]或 Parametric ReLU^[18])来缓解。但本课题在设计网络时综合考虑计算效率及激活特性, 仍然采用该激活函数来配合卷积层对网络进行激活。

Leaky ReLU^[17](带泄漏的线性整流单元)是对传统 ReLU 的改进, 通过在输入小于 0 时引入小的斜率, 以解决 ReLU 可能导致的“神经元死亡”问题, 使得在训练过程中能够更好地处理负数输入的梯度, 提高模型的鲁棒性。其数学表达式如下

$$f(x) = \begin{cases} x, & x > 0 \\ ax, & x \leq 0 \end{cases} \quad (2.7)$$

式中, x 表示输入, a 为一个小的正数, 通常取较小的常数如 0.01。

Parametric ReLU^[18](参数化的线性整流单元)与 Leaky ReLU^[17]相比, 其更进一步引入了可学习的参数, 使得模型能够自适应地确定负数范围内的激活程度。它允许神经网络在训练过程中学习适应性的激活函数, 提高模型的灵活性, 可以更好地使用不同数据分布的特点。其数学表达式为

$$f(x) = \begin{cases} x, & x > 0 \\ bx, & x \leq 0 \end{cases} \quad (2.8)$$

式中, b 为一个可学习的参数, 通过反向传播进行调整。与 Leaky ReLU 类似, 这个可学习的斜率使 Parametric ReLU^[18]在负数范围内不是完全平坦有助于缓解“神经元死亡”问题。

(2) GeLU (Gaussian Error Linear Unit^[19])

GeLU^[19]是一种在神经网络中广泛应用的激活函数。它在深度学习中的关键作用体现在引入非线性特性和呈现平滑的 S 形曲线上。这使得神经网络更能够灵活地学习复杂的数据模式。相对于其他激活函数, GeLU^[19]的曲线在整个输入范围内都保持着非零梯度, 为模型的训练提供了更丰富的梯度信息, 有助于避免梯度消失问题。其数学表达式为

$$f(x) = \frac{1}{2} \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} \cdot (x + 0.044715x^3) \right) \right) \quad (2.9)$$

其中, $\tanh$ 是双曲正切函数。这个表达式综合了高斯误差函数和线性单元函数, 以一种平滑的方式引入非线性特性。

2) 池化层

池化层是神经网络中一种关键结构，通过对局部区域的数值进行汇聚，实现减小特征图尺寸的目的。其主要作用包括降低计算复杂度、提取重要特征，以及提高模型对平移变化的适应性。通过最大池化或平均池化等操作，使其有助于提高模型的性能和训练效率，同时避免过拟合问题的发生。在设计中，合理设置池化层窗口大小和步幅，能够更好地满足不同任务的需求，为深度学习模型提供更灵活的特征提取能力。

(1) 最大池化 (Max Pooling)

最大池化^[20]是对每个需要操作的局部区域取最大值，从而凸显显著特征。数学表达式为

$$\text{MaxPooling}(x) = \max_{i,j} x_{i,j} \quad (2.10)$$

式中， $x_{i,j}$ 表示局部区域内的元素。

(2) 平均池化 (Average Pooling)

平均池化^[21]是对每个将要操作的局部区域取平均值，从而保留图像更加平滑的特征。其数学表达式为

$$\text{AveragePooling}(x) = \frac{1}{m \times n} \sum_{i,j} x_{i,j} \quad (2.11)$$

式中， $m \times n$ 为局部区域的大小。

最大池化和平均池化在特征提取和降维方面有不同的侧重点。最大池化突出显著特征，适用于强调局部重要信息的任务；而平均池化更加平滑，适用于一些需要综合考虑局部信息的场景。两种池化正向传播和反向传播示意图如图 2.4 所示。




图 2.4 两种池化操作示意图

3) 归一化层 (Normalization Layer)

归一化层是深度学习中一类用于提高模型训练稳定性和泛化性能的层次结构。它通过对输入进行归一化操作，调整数据的分布，有助于加速训练收敛过程，并提高模型在

不同任务上的泛化能力。考虑到模型训练的收敛速度以及模型的泛化能力，本课题在设计网络结构时均使用了归一化层与卷积层进行配合。其计算公式为

$$N(x) = \frac{x - \mu}{\sigma} \cdot \gamma + \beta \quad (2.12)$$

其中， μ 为均值， σ 为标准差， γ 为缩放因子， β 为平移因子。

(1) 批归一化^[22] (**Batch Normalization, BN**)。在进行每层激活之前，通过对小批量数据执行归一化处理，确保数据的均值为 0 且标准差为 1。

(2) 层归一化^[24] (**Layer Normalization**)。在每个特征图的通道中实施归一化，意味着对每个通道内的数值执行归一化过程。

(3) 组归一化^[23] (**Group Normalization**)。将通道划分为几个组，然后对这些组中的每一个单独进行归一化处理。

(4) 自适应实例归一化^[25] (**Adaptive Instance Normalization, AdaIN**)。其核心概念在于通过输入的条件信息，自适应地调整每一层的实例归一化参数，从而精细控制生成图像的风格。通过调整输入特征图的均值和标准差，使生成器网络能够在不同条件下灵活地调整生成图像的风格。其优势体现在风格控制、多样性和适应性方面，使 AdaIN 成为生成模型中的重要工具，为图像生成任务提供更高程度的灵活性和创造性。本文中为提升生成的超分辨图像的表达多样性和适应性，采用了 AdaIN 归一化方式。这选择旨在优化生成网络性能，提高生成图像质量。AdaIN 通过巧妙调整实例归一化参数，使网络能够在不同条件下自适应调整图像风格，为超分辨图像注入更丰富的特征，从而实现更出色的生成效果。其计算公式为

$$AdaIN(x, y) = \sigma(y) \left(\frac{x - \mu(x)}{\sigma(x)} \right) + \mu(y) \quad (2.13)$$

2.1.2 天文图像的成像特点

在研究天文图像超分辨率重建的过程中，对天文图像的深入理解至关重要。天文图像是通过望远镜和探测器捕捉到的宇宙光学信息，其成像特点对于有效的图像处理和重建提出了独特的挑战。

1) 低分辨率难题

天文图像的低分辨率主要受到光学仪器的限制。大气湍流、望远镜光学系统的限制等因素导致图像细节的失真和模糊。物理上，这意味着我们在观测中受到了波动的折射指数，限制了所能达到的最小角分辨率。在图像重建中，必须克服这些限制，以还原宇宙中微小结构的真实面貌。

2) 噪声干扰与数据质量

天文图像中的噪声主要来源于光学系统的系统性误差、探测器噪声等。从物理角度看，这些噪声是观测仪器自身特性的体现，需要在图像处理中进行恰当处理。提高数据质量，特别是对微弱信号的提取，是一个物理学上的挑战。

3) 大视场的复杂性

大视场天文图像涵盖了广泛的天空区域，覆盖了多个天体和星系。从物理学的角度，这意味着我们在同一图像中观测到了来自不同天体的光，具有不同的光度和光谱特征。因此，图像处理算法需要考虑光度的变化和不同天体的辨识。

4) 不均匀光度的挑战

天文图像中的不均匀光度分布是由天体本身的性质和光度差异引起的。在物理学上，这可能反映了星际介质的密度变化或星体演化的特殊性质。处理这种不均匀性需要对光度的物理意义有深入理解，以更好地还原图像中的天体结构。

5) 多样性的天体组成

天文图像中的多样性主要表现在不同天体类型的存在，如行星、星云、星系等。从物理学的角度，这意味着我们在同一图像中观测到了具有不同发射光谱、反射光谱和吸收光谱的物体。深度学习方法需要在训练阶段考虑这种多样性，以提高对不同类别天体的准确识别和重建能力。

2.1.3 常见的模糊类型

模糊在图像处理中发挥着多重作用，深刻影响着图像的质量和视觉效果。它通过细节抑制和噪声消除，实现对图像的有效平滑，从而提升图像的清晰度和整体质量。在超分辨率重建领域，模糊不仅模拟了低分辨率图像的效果，更直接影响了算法的适应性，对于提高超分辨率算法的稳定性和性能至关重要。在天文学领域，一些常见的模糊方法，如 Gaussian 模糊、Airy Disk 以及 Lorentz 模糊等，为模拟天文图像和处理观测数据提供了重要支持。本课题在构建天文图像超分辨率重建数据集时，为了尽可能的模拟天文图像的退化过程，达到理想的重建效果，分别对以下几种模糊做了相应的对比试验。

1) Gaussian 模糊

高斯模糊^[26]，也称为高斯平滑或高斯滤波，是图像处理中常用的一种方法。该技术通过计算图像中每个像素点及其邻域像素的加权平均值，有效地减少了图像噪声并模糊了图像细节，使得图像展现出一种更加平滑和柔和的效果。这一模糊操作基于高斯函数的权重分布，通过调整标准差，可精细地控制模糊的程度。在图像处理的实践中，高斯模糊被广泛用于降噪、平滑边缘以及模糊背景等任务，成为一种常见而高效的图像优化手段。通常，我们会基于高斯函数生成一个模糊核，然后将其与原始图像进行卷积，以实现图像的高斯模糊处理。这个过程结合了数学原理与工程实践，为图像处理提供了强大而灵活的工具。其二维形式可表达为

$$H(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (2.14)$$

其中， $H(x, y)$ 为高斯核的值， σ 是高斯函数的标准差， x, y 分别为像素的横纵坐标。其函数图像及前后对比图如图 2.5 所示。



图 2.5 高斯模糊对比图

2) Airy Disk

Airy Disk^[27]作为光学系统中常见的现象，源自光波穿过有限孔径或光圈时发生的瑞利散射衍射。这一现象导致图像中央出现明亮的中央斑点，即 Airy Disk^[27]，并形成周围的同心光环，营造出独特的模糊效果。其基本原理依赖于光的波动性和瑞利散射的衍射特性，通过瑞利函数可描述 Airy Disk^[27]的强度分布，其中中央斑点呈现最高亮度。

在图像处理领域，Airy Disk^[27]具有广泛的应用。首先，在天文学观测中，由于大气干扰和望远镜光学系统的限制，Airy Disk^[27]成为影响天体图像清晰度的关键因素。其次，在显微镜学中，由于波长微小和样本结构微小，Airy Disk^[27]是显微成像中常见的挑战。深入了解和有效处理这种模糊现象对于获取更清晰的显微图像至关重要。

Airy Disk^[27]的优点在于它在一定程度上保留了光学系统的信息，反映了光波的衍射特性。同时，它提供了关于光学系统分辨率的关键信息，尤其在特殊应用中表现出明显优势。此外，作为一种物理模拟，Airy Disk^[27]有助于更真实地模拟光学成像过程，为系统设计和图像处理提供了有益的参考。其数学表达式为

$$I(r) = I_0 \left(\frac{2J_1(kr)}{kr} \right)^2 \quad (2.15)$$

其中， $I(r)$ 是 Airy Disk^[27]的强度分布，表示在距离中央斑点 r 处的强度。 I_0 是中央斑点的最大强度， J_1 是贝塞尔函数，是一种特殊函数， k 是与波长核孔径有关的常数。这个公式描述了 Airy Disk^[27]模糊的强度在径向上的分布，其中中央斑点的强度最大，而随着距离中央的增加，强度逐渐减小。贝塞尔函数是用于描述振幅的特殊函数，它在 Airy Disk^[27]的数学表达式中体现了光的波动性和衍射效应。图 2.6 为给图像添加模拟的 Airy Disk^[27]前后对比图。

3) Lorentz 模糊

Lorentz 模糊^[28]作为广泛采用的图像处理模糊技术，基于洛伦兹分布的数学原理，主要用于模拟特定光学系统产生的模糊效果。其主要应用领域包括处理因系统限制或物理因素引起的图像模糊，以提升图像处理的真实性。洛伦兹模糊的数学基础源自洛伦兹分

布函数，该函数在概率论和统计学中被广泛用于描述各种自然现象。在图像处理中，其通过将每个图像像素与洛伦兹函数卷积实现。这种函数的显著特点是其长尾性质，即在远离中心位置仍然存在较大数值，成功模拟了一些光学系统中独特的模糊效果。



图 2.6 Airy Disk 前后对比图

Lorentz 模糊作为一种图像处理技术，被广泛应用于多个领域。首先，它常用于模拟实际摄影中的光学效应，尤其是在相机快门较慢时，形成的运动物体轨迹。这使得图像更贴近实际场景，并为图像赋予一定的艺术效果。其次，在医学影像领域，特别是在核磁共振图像处理中。在这些情境下，Lorentz 模糊有助于模拟仪器与生物组织之间的相互作用，提升图像的逼真度和可解释性。另外，在天文学图像中，Lorentz 模糊同样发挥着重要作用。由于大气扰动等因素，天文学图像可能受到一定程度的模糊影响。Lorentz 模糊可用于模拟这种模糊效应，帮助天文学家更准确地解释观测数据，提高图像的清晰度和质量。

它的优势之一在于其灵活性。通过调整洛伦兹分布的参数，可以精确地控制模糊的程度，使其更符合具体需求。此外，Lorentz 模糊还能够有效处理一些特殊情况，例如在低光条件下捕捉运动物体，为图像提供更真实的表现。这使得 Lorentz 模糊成为一个强大而多功能的图像处理工具。

$$L(x; x_0, \gamma) = \frac{1}{\pi} \frac{\gamma}{(x - x_0)^2 + \gamma^2} \quad (2.16)$$

其中， x 为位置变量， x_0 为分布的中心位置， γ 是分布的半宽度（也成为半峰宽）。这个分布函数的特点是在位置附近有较高的数值，然后随着位置偏离中心而逐渐减小。而对于二维图像，可以将这个一维函数应用于图像的两个方向（通常是水平和垂直），以实现二维的 Lorentz 模糊。这涉及将两个一维函数进行卷积，从而形成一个二维的模糊核，用于对图像进行模糊处理。图 2.7 为加入 Lorentz 模糊前后对比图。

2.1.4 常见的噪声类型

噪声指的是图像中由各种随机因素引起的不规则、随机的干扰，通常表现为图像中

出现不期望的颜色或亮度的随机变化。这些随机因素的来源涵盖了传感器内部元件的不完美性、环境条件的变化以及信号传输过程中的干扰等。噪声在图像处理中产生负面影响，导致图像质量下降，进而影响图像的清晰度和细节，甚至可能导致图像分析任务中错误的特征提取和对象检测。为了应对噪声的挑战，图像处理中采用了一系列有效手段。其中，深度学习方法的引入使得噪声去除更为智能化，通过训练网络学习噪声模式，实现更为精准的噪声去除。这些综合应用的处理手段不仅有助于优化图像质量，提升图像分析的准确性，还更好地满足不同应用领域的需求。在构建天文图像超分辨率重建数据集的过程中，为了更精准地模拟图像在传输过程中受到电流干扰以及拍摄时光子干扰导致的退化现象，本课题采取了高斯噪声和泊松噪声的模拟方法。



图 2.7 Lorentz 模糊前后对比图

1) 高斯噪声

高斯噪声^[29]是一种在自然界和工程系统中广泛存在的随机信号，其特点是其数值分布符合正态分布，也成为高斯分布。正态分布是一种钟形曲线，具有对称性，由均值（ μ ）和标准差（ σ ）两个参数完全描述。高斯噪声的概率密度函数呈现出峰值在均值处，随着离均值的增加或减少而逐渐减小，这使得其在统计学、信号处理以及图像处理领域中具有广泛的应用。在数学上，高斯噪声的概率密度函数表示为

$$P(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (2.17)$$

其中， $P(x)$ 是信号值为 x 的概率密度， μ 是均值决定了分布的中心位置， σ 是标准差表征了分布的离散程度。这一分布特性使得高斯噪声的波动主要集中在均值周围，形成一组对称的随机值。在图像处理中，高斯噪声通常用于模拟真实世界中的随机干扰，如传感器测量误差、电子器件的随机波动和数据传输过程中的电流干扰等。为了进一步模拟复杂环境下的真实图像，我们常通过向仿真数据中添加高斯噪声来训练网络。这样的操作有助于提升网络在真实图像中的处理效果，达到增强网络鲁棒性的目的。通过模拟各种干扰，网络可以更好地适应真实场景的复杂性，从而提高在实际应用中的性能。

2) 泊松噪声

泊松噪声^[30]是在随机过程中常见的一种噪声类型，通常用于模拟光子计数的随机性

或在低光条件下产生的电子信号的随机性。其特点在于其幅度和频率与信号的强度成正比，因此在描述光子计数或电子信号技术时具有实际应用的重要性。它是一种用于描述离散随机事件发生的概率分布。在泊松噪声中，每个事件（比如光子的到达或者电子的计数）被认为是独立的，并且其发生服从泊松分布。泊松分布的概率质量函数为

$$P(k;\lambda) = \frac{\lambda^k e^{-\lambda}}{k!} \tag{2.18}$$

其中， $P(k;\lambda)$ 是发生 k 个事件的概率， λ 是单位时间或空间内平均事件发生率。在图像处理中，数据集的制作常常使用泊松噪声来模拟低光条件下的成像环境，特别是在模拟光子计数的随机性和传感器的随机电子信号。这种做法有助于评估图像处理算法在实际成像系统中的性能，提高算法对低光条件下的鲁棒性。

2.2 评价指标

在图像处理领域，不仅需要设计先进的图像处理算法，而且对生成图像质量的评价也至关重要。主观评价和客观评价是常见的评价方法。主观评价注重人的直观感受，通过肉眼观察图像的整体结构、亮度和对比度等因素来评价生成图像的质量。相对而言，主观评价更能反映人的实际感受，但可能受到个体主观差异的影响。而客观评价则通过业内公认的评估算法，对图像进行定量的技术指标计算。客观评价提供了更为精确的数值衡量，能够量化生成图像与原始图像之间的差异，为算法的设计和改进提供了有力的依据。通过综合运用主观和客观评价方法，可以更全面、准确地了解图像的生成质量，促进图像处理技术的不断创新，确保生成图像在各种应用场景中都能够达到高质量的标准。这种综合评价的方法有助于推动整个图像处理领域的不断发展和优化。

2.2.1 主观评价

1) 绝对评价（Absolute Evaluation）

在绝对评价中，观察者被要求单独评估单个图像的质量，而无需与其他图像进行比较。评估者需要直接给出图像的整体质量分数，通常采用数值或等级进行评分。这种方式适用于在特定场景下对图像质量进行独立评价的情况，例如比较不同算法生成图像或者不同图像处理参数的效果。通常会根据如下评价尺度表对图像进行打分。

表 2.1 绝对评价尺度表

得分	质量尺度	妨碍尺度
5 分	丝毫看不出图像质量变坏	非常好
4 分	能看出图像质量变化但不妨碍观看	好
3 分	清楚看出图像质量变坏，对观看稍有妨碍	一般
2 分	对观看有妨碍	差
1 分	非常严重的妨碍观看	非常差

2) 相对评价 (Relative Evaluation)

相对评价要求观察者在两个或多个图像之间进行比较, 选择哪一个更好或更接近原始图像。这种方式适用于需要确定不同处理方式或算法之间性能差异的场景。其能够提供更详细的图像质量相对关系, 帮助比较不同图像的优劣。其评分制度如下表所示。

表 2.2 相对评价与绝对评价尺度对照表

得分	相对测量尺度	绝对测量尺度
5 分	一群中最好的	非常好
4 分	好于该群体中平均水平	好
3 分	该群中的平均水平	一般
2 分	差于该群体中平均水平	差
1 分	该群体中最差的	非常差

2.2.2 客观评价

1) 峰值信噪比 (Peak Signal to Noise Ratio, PSNR)

峰值信噪比^[31]是图像处理领域常用于衡量图像质量的客观评价指标之一。主要用于比较原始图像和经过处理后图像之间的质量差异, 越高的 PSNR 值通常表示图像质量的损失越小。该过程依据图像的均方误差 (Mean Squared Error, MSE) 进行计算, 如公式 2.19。均方误差衡量的是原图与处理过的图像在每个像素上差异的平方总和的平均值。PSNR 的数学表达式如下公式 2.20 所示。

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2 \quad (2.19)$$

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX^2}{MSE} \right) \quad (2.20)$$

其中, MAX 是图像像素的最大可能取值 (通常为 255, 对应 8 位图像)。PSNR 单位是“分贝”(dB), 类似于声学领域中对信噪比的度量。通常, PSNR 值在 20dB 到 50dB 之间, 越接近 50dB, 表示图像质量越好。

2) 结构相似性 (Structural Similarity, SSIM)

结构性相似性^[32]指数是用于衡量两个图像之间相似度的客观评价指标。与 PSNR 一样, SSIM 被广泛用于图像处理、图像质量评价以及图像压缩等领域。SSIM 不仅考虑亮度, 还包括对比度和结构信息, 使其更符合人眼对图像质量的感知。SSIM 的计算设计三个关键方面: 亮度 $l(x, y)$ 、对比度 $c(x, y)$ 和结构 $s(x, y)$ 。这三方面的综合构成了整体的结构相似性指数。其计算公式如下。

$$SSIM(x, y) = l(x, y) * c(x, y) * s(x, y) \quad (2.21)$$

$$l(x, y) = \frac{2u_x u_y + C_1}{u_x^2 + u_y^2 + C_1} \quad (2.22)$$

$$c(x, y) = \frac{2\sigma_x \sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2} \quad (2.23)$$

$$s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x \sigma_y + C_3} \quad (2.24)$$

其中, u_x 和 u_y 分别是 x 和 y 的均值, σ_x 和 σ_y 分别是 x 和 y 的标准差, σ_{xy} 代表 x 和 y 的协方差。而 C_1, C_2, C_3 为常数。SSIM 的取值范围为 $[0,1]$ 。通常来说, 其值越接近 1, 表示两幅图像的结构相似性越高。

2.3 本章小结

在本章节中, 首先系统介绍了神经网络中常用组件及其原理, 包括卷积层、池化层、激活函数和归一化层等, 为后续网络结构的构建打下了夯实的基础。同时考虑到本课题使用天文图像作为数据集的特殊性, 进而描述了天文图像的特点以及在后续图像处理中可能面临的挑战。紧接着从概念、原理、产生原因以及在图像处理中的作用等方面对常见的模糊类型和噪声类型进行了详细的解释, 为后续制作仿真数据集时模糊和噪声的选择起到了指导性作用。最后从主观和客观两方面描述了图像超分辨率重建领域公认的评价指标, 为后续网络性能的验证提供了有力的数据保障。

3 基于自编码器结构的渐进生成式天文图像超分辨率重建方法

3.1 大视场天文图像数据集建立

数据集在深度学习中具有重要意义，它为模型的训练提供了必要的的支持，有助于模型学习数据的模式、特征和关联性，进而提升模型的泛化能力。对于深度学习模型的训练和优化而言，拥有一个高品质、多元化且实用的数据集是至关重要的。在本课题研究过程中，为了得到更好的重建效果，进而为数据集的建立做了充足的知识储备和实验。实验初在 NASA 官网下载由各个天文望远镜所拍摄的天文图像，来制作网络所需的训练数据集，但是通过实验结果以及查阅资料后发现，不同天文望远镜的波长范围和成像方式均不相同，并且 NASA 官网很多天文图像都是后期合成，所以造成了网络无法学习到其真实且具体的细节信息，导致重建结果不理想。受到以上结论的启发，在后续研究过程中的所有天文图像数据原图均来自韦伯官网，由于课题设计的网络模型需要 LR-SR 图像对来完成训练，所以对天文图像的退化过程也做了相应的模拟实验，具体使用过的模拟方案如图 3.1 所示。




图 3.1 四种模拟方案结果图

图 3.1 中的(a)到(d)分别表示了不同方式的图像退化模拟方案，用于生成对应的低分辨率图像，SR 代表原始高分辨率图像。这些模拟方案包括插值下采样、高斯模糊、噪声添加和 Lorentz 模糊等。通过消融实验得到图 3.2 结果可以用于评估不同退化方式对网络生成的图像质量的影响，并为本课题数据集的选择和优化提供参考。

图 3.2 中编号对应图 3.1 中的退化过程模拟方案，通过消融实验结果，本文发现如果直接将高分辨率图通过双三次插值进行下采样时会由于高频信息严重丢失造成生成的高分辨率图像有较多的伪影和模糊现象，同时会将噪声放大。为了解决以上问题，本文给高分辨率图像加上具有滤波作用的高斯模糊^[33]或者 Lorentz 模糊后再将其进行下采样操

作，由图(b)和图(d)测试结果可以看出，加上 Lorentz 模糊后图像质量变得更差，所以本课题选择加高斯模糊，但尽管该方案可以减少生成图像的伪影和模糊现象，却仍然存在噪声被放大，又鉴于该原因本文给图(b)模拟方案再进一步加上高斯白噪声和泊松噪声得到图(c)的实验结果，根据结果显示，该模拟方案符合课题要求。




图 3.2 退化过程模拟对比实验结果

通过以上实验结论，本文所使用的图像数据均来自于韦伯官网上通过韦伯空间望远镜所拍摄的天文图像共 25 张，挑出 5 张图像作为验证集，其余 20 张图像作为训练集的原始图像。之后通过旋转等数据增强操作扩展训练集图像数量至 80 张，将扩展后的图像裁剪成 256×256 尺寸的图像共 25 万张作为超分任务中的 SR 图像，然后将裁剪得到的 SR 图像通过公式 3.1 随机生成与清晰图像数量相等的高斯模糊核来对拍摄设备所导致的模糊干扰进行模拟建模，并将得到模糊核与清晰图一比一进行卷积得到模糊图像，其中 K 表示模糊核、 I_0 表示峰值幅度、 r 表示模糊核半径、 σ 表示标准差。

$$K = I_0 e^{-\frac{r^2}{2\sigma^2}} \quad (3.1)$$

再对模糊图像利用双三次插值进行下采样得到形同数量 64×64 尺寸的 LR 图像，最后为 LR 图像添加泊松和高斯白噪声以模拟天文望远镜拍摄天文图像时所受到的光子噪声和传输过程中产生的电流噪声。具体数据集的制作过程如图 3.3 所示。




图 3.3 数据集制作过程

3.2 网络结构设计

本课题提出的网络结构由特征提取、特征校正、图像生成三个模块组成。我们将受到外界因素影响而降质的低分辨率图像输入网络后，首先利用特征提取模块得到图像的

浅层和深层特征并将深层特征直接输入给图像生成模块，而后利用校正模块将包含更多高频信息的浅层特征错误部分进行校正，最后由图像生成模块在生成过程中与校正后的特征相融合得到重建后的高分辨率图像。总体网络设计如图 3.4 所示。




图 3.4 PGSRNet 网络结构图

3.2.1 特征提取模块

特征提取模块在 PGSRNet (Progressive generative super-resolution reconstruction network, PGSRNet, 渐进生成式超分辨率重建网络) 中起着重要作用，它主要用于提取低分辨率图像的浅层特征和深层特征。在提取特征的过程中，浅层的特征集中于捕获细节，这是因为它们的感受野相对较小，导致每个像素点的感受区域重叠程度低，从而能够揭示更多细节信息。这样做有助于形成更为精确且详细的特征表示。随着特征提取的层数增加，通过不断的卷积操作和降维操作，得到了更能反映数据本质结构的深层特征。深层特征对整体结构和全局信息的感知能力更强，能够捕捉到更高级别的语义和抽象特征。这些深层特征在后续的图像生成模块中被用来生成高分辨率图像。因此，特征提取模块通过层层卷积和降维操作，逐渐从图像中提取出细节丰富的浅层特征和具有更高级别语义的深层特征，为后续的任务提供了丰富的特征表示。

在本研究中，针对大视场天文图像的独特结构特性，本文设计了一个包含六个 CNNBlock 的编码器网络架构。每个 CNNBlock 均由两个卷积块组成，其中每个卷积块内

部包括卷积层、标准化层以及激活层。在训练过程中，特征提取模块首先接收一张 $64 \times 64 \times 3$ 的大视场天文图像。随后，通过 CNNBlock 中的卷积层逐级执行下采样操作，从而提取不同分辨率层次上的特征信息。特别地，网络将在经过下采样过程的最后三层特征输出送往特征校正模块以进行后续处理。为了有效地弥补图像降采样过程中可能发生的特征信息损失，本架构在每一次卷积降采样后，均将通道数增加一倍。这一设计策略不仅增强了网络在深层次上的特征表示能力，而且通过通道数的增加，进一步丰富了模型对图像细节和结构信息的捕捉能力，从而为大视场天文图像的超分辨率重建提供了更为强大和精细的特征支持。其网络结构设计如图 3.5 所示。




图 3.5 特征提取模块网络结构图

为了更加直观的表达特征提取模块对于不同层次深度的网络所提取的特征以及网络关注的图像区域的差异，我们挑选了两个 CNNBlock 中的特征使用 CAM^[39]进行了可视化，如图 3.6 所示。




图 3.6 CAM 可视化结果

上图 3.6 中 (a) 为原图 (b) 和 (c) 分别为从特征提取模块中的 CNNBlock1 和 CNNBlock4 进行可视化的结果，由以上结果可以看出，刚进入网络时的浅层特征具有更加丰富的细节信息，同时也包含更多输入图像的原有特征表达。而随着网络的不断加深，能够捕捉到更高级别的语义和抽象特征，也更能够将注意力放在对重建结果影响较大的红褐色区域。

3.2.2 特征校正模块

特征校正模块是从 NAFNet^[35]中引入，并根据网络需求进行改进，其没有非线性激活函数。主要由三部分组成：(1) Mobile convolution (MB Conv)，其基于具有通道注意力的 Point-wise 和 Depth wise convolution；(2) 前馈网络模块 (FFN)，其具有两个通过

Point-wise convolution 实现的全连接层；（3）上采样模块（Plex），由亚像素卷积和典型的卷积网络组成，主要用于超分辨率重建中特征分辨率以及通道的调整。整个特征校正模块中采用了 Transformer^[36]中经常被使用到的 LayerNorm，使小批量训练的数据更加稳定。在每一网络层，本文采用了 SimpleGate 激活函数，在保证精度不变的情况下有效减少了计算量。同时，使用 Depth wise convolution^[37]替换了传统的通道注意力，以增强全局信息的聚合，Channel 维信息的交互，同时也减少了网络的计算量。而上采样模块是因为网络在做超分辨率重建工作时，网络的输出维度为输入维度的整数倍，而特征提取模块是以输入图片为基础进行特征提取的，所以在将提取到的浅层特征通过校正模块时需要进行上采样到同样的整数倍才能和图像生成模块中生成的特征进行融合。特征校正模块的网络结构设计如图 3.7 所示。




图 3.7 特征校正模块网络结构

在整体网络结构的设计过程中，本文进行了关于是否需要特征校正模块对图像的浅层特征进行校正的消融实验，以保证网络结构在设计过程中的强逻辑支撑。具体消融实验结果如图 3.8 所示。




图 3.8 特征校正模块消融实验结果

图 3.8 中 LR 表示输入网络的低分辨率图像在经过等比例放大后得到的图像，NO 和 NY 分别表示网络结构中是否使用了校正模块。从消融实验结果中可以看出，如果网络结构中不使用校正模块进行特征校正，可能会因为部分高频信息的丢失导致模糊和伪影现象，以及学习过程中由于部分错误特征的引导造成图像灰度值的错误表达。

3.2.3 图像生成模块

图像生成模块的核心功能是接收特征提取模块所提取的图像特征，并通过渐进式增

长的策略生成高分辨率图像。此模块综合利用了两类关键特征：一类是通过深层卷积处理获得的深层特征，这些特征具备强大的整体结构感知与全局信息处理能力；另一类是经过特征校正模块矫正的浅层特征，这些特征富含高频信息，对于重建图像的细节至关重要。为了实现这一目标，本研究采纳了一个包含 8 个 CNNBlock 的解码器网络架构。解码器首先接收深层特征，并通过逐层递增的方式逐步构建更高分辨率的图像。每一层生成的特征都通过 ToRGB 模块转换为 RGB 图像，并在上采样后与下一层的 RGB 图像融合，以此方式确保了更多原始信息的保留。在最后三个 CNNBlock 进行特征传递之前，每一层都加入了特征校正模块，这样做的目的是将经过特征校正模块矫正的浅层特征与深层特征进行融合。此过程不仅校正了部分错误特征，而且保障了生成的高分辨率图像含有更丰富的高频信息和更真实的纹理细节。

总的来说，图像生成模块通过采用渐进式增长的策略，并结合深层与经过校正的浅层特征，逐步构建出高分辨率的图像。这种特征融合与校正的方法使得模型在保持图像细节丰富性和真实性的同时，显著提升了生成图像的视觉效果，实现了更加逼真和细腻的图像重建。此方法体现了在超分辨率重建中深层特征与浅层特征融合的重要性，为提升生成图像的质量提供了有效途径。图像生成模块的网络结构设计如图 3.9 所示。




图 3.9 图像生成模块网络结构

同样为了更直观的表达图像生成模块所关注的特征区域以及不同深度网络关注区域的差异，本文选取了两个 CNNBlock 来使用 CAM^[39]进行可视化，具体可视化结果如图 3.10 所示。




图 3.10 图像生成模块 CAM 可视化结果

图 3.10 中 (a) 和 (b) 分别代表从图像生成模块中对 CNNBlock1 和 CNNBlock6 进行特征可视化的结果 (c) 为原图。从结果可以看出, 图像生成模块首先接收来自特征提取模块的特征, 所以 CNNBlock1 的特征可视化结果更加抽象, 而随着渐进式的生成, 在接近网络输出的 CNNBlock6 的特征表达更加接近真实图像的结构分布。

3.2.4 特征提取模块优化

在研究过程中, 本课题针对特征提取模块做了进一步的优化, 同样采用了 6 个 CNNBlock 的编码器网络结构, 但不同的是每个 CNNBlock 由典型的卷积网络和 RDB^[34] 模块组成。其中典型的卷积网络与上述 3.2.1 中方案相同, 通过卷积操作对输入图像进行降采样操作, 同时加倍通道弥补特征损失。而 RDB^[35] 模块则用于提取经过卷积网络降采样后图像中的高级特征, 其通过密集连接和多层卷积的设计, 实现了特征的高效重用和梯度的顺畅传递。这种设计能够有效地提取图像的高级特征, 更好地捕捉图像中的细节和纹理信息, 并具有较高的参数效率和表达能力。每个残差块都包含了多个卷积层和跳跃连接, 使得网络可以更加深层地进行特征提取。同时, 通过残差学习机制可以更好地解决梯度消失和梯度爆炸等问题, 有助于提高网络的收敛速度和训练效果。特征提取模块的优化网络结构设计如图 3.11 所示。




图 3.11 特征提取模块优化后网络结构

而在特征提取模块设计过程中, 本文对 CNNBlock 的设计方案也做了相应的实验, 比较了仅两层卷积块和一层卷积块与 RDB^[34] 模块相结合这两种不同的方案。实验结果显示, 使用卷积块和 RDB^[34] 模块相结合的方式在性能上表现最好, 表明 RDB^[34] 模块能够更有效地提取图像特征和捕获图像细节信息。该模块的消融实验结果如图 3.12 和 3.13 所示。




图 3.12 特征提取模块消融实验




图 3.13 不同模块的指标图

上图 3.12 中 LR 表示输入网络的低分辨率图像在经过等比例放大后得到的图像，SR-C 表示特征提取模块中每个 CNNBlock 的两层均由典型的卷积网络模块组成，SR-R 表示特征提取模块中每个 CNNBlock 的两层由典型的卷积网络和 RDB^{[35][34]}模块组成。图 3.13 中绿色曲线代表使用了 RDB^[34]模块，而黑色曲线则相反。由实验结果不难看出，使用 RDB^[34]模块进行特征提取时能够更好的去除因分辨率提升而带来的伪影，使重建结果更加清晰，同时也具有和输入网络的低分辨率图像更加接近的颜色分布和更高的评测指标，使用 RDB^[34]模块后 PSNR 最高为 30.252dB、SSIM 最高为 0.837，而使用典型卷积时 PSNR 最高为 30.10dB、SSIM 最高为 0.833。由此说明使用 RDB 模块有效的实现了高级特征的重叠复用以及梯度的顺畅传递，更好的捕捉到了输入图像中的细节和纹理信息，极大的提升了网络的性能。

3.3 模型训练

本课题综合模型的特点，在模型的训练中主要对学习率衰减策略、损失函数设计以及优化器选择做了详细的设计和研究。通过有效的学习率衰减，本文确保模型在训练中能够平衡收敛速度和稳定性。损失函数的设计旨在最大化模型对特定任务的优化。选择优化器时，本文考虑了其对梯度更新的效率和稳定性的影响。这些设计决策的深入研究有助于确保模型在训练过程中充分发挥潜力，为解决实际问题提供有力的支持。

3.3.1 学习率衰减策略

鉴于研究主题的复杂性，目标优化函数可能呈现多峰性质，导致除了一个全局最优解以外，还会出现若干局部最优解。在训练过程中，使用梯度下降算法可能会陷入局部最优解中。为了解决这个问题，可以通过突然提高学习率的方式跳出局部最优解。因此，在本课题中，本文采用学习率余弦退火衰减策略^[40]来训练模型。这种策略通过在训练过程中逐渐减小学习率，使得模型在训练的不同阶段具有不同的学习率。具体而言，本文使用余弦函数来调整学习率，以在训练的早期阶段设置的学习率偏大，促进模型迅速收敛并避免陷入局部最优，而到了训练的后期阶段逐渐减小学习率，以细调模型参数并寻找更优的解。利用学习率的余弦退火衰减方法，可以有效避免落入局部最优，并增加找到更好的全局最优解的可能性。这种训练策略能够提高模型的性能和泛化能力，使得模型在复杂优化问题中更加稳定和可靠。其计算公式通常为

$$lr = lr_{min} + \frac{1}{2} \times (lr_{max} - lr_{min}) \times \left(1 + \cos\left(\frac{T_{epoch}}{T_{max}}\pi\right)\right) \quad (3.2)$$

其中， lr 为当前学习率， lr_{min} 和 lr_{max} 分别为最小学习率和最大学习率， T_{epoch} 为当前迭代次数， T_{max} 代表最大可迭代次数，也为余弦的周期长度，表示在多少个步骤内学习率从最大值降到最小值。

3.3.2 损失函数设计

损失函数在深度学习中担任着至关重要的角色，通过度量模型的预测值与实际标签之间的差异，指导模型的优化过程，以使其能够生成符合预期的结果。在图像处理领域，多种损失函数被广泛应用，每种损失函数都有其独特的优势和适用场景。常见的损失函数包括均方误差（MSE）、均值绝对误差（MAE）、结构相似性损失（SSIM）、感知损失（Perceptual Loss）^[41]以及 Charbonnier 损失函数等。在本课题中，结合了天文图像视野较大且背景复杂的特点，通过对比各种损失函数的拟合特性，并结合实验的支持，进行了如下选择。

1) Charbonnier 损失函数

MSE 损失函数在图像超分辨率重建中对于高频信息有较好的生成效果，但也会在其他区域中生成许多影响观感的虚影和不规则的像素点。L1 损失函数在重建图像时耗时较多，但它对于图像中的高频细节有着较强的恢复能力，能够有效地消除重建图像里的幽灵效应和不规则像素。对比 L1 和 MSE 损失函数，本课题使用了鲁棒性更好的 Charbonnier^[41]损失函数，兼顾 L1 和 MSE 的优点，既能使模型的训练更加稳定又可以取得较好的重建效果。Charbonnier^[41]损失函数如下公式所示。

$$\mathcal{L}_s(y, \hat{y}; \theta) = \frac{1}{N} \sum_{i=1}^N \sum_{l=1}^L \rho(y_l^{(i)} - \hat{y}_l^{(i)}) \quad (3.3)$$

式中： y_l 表示真实 SR 的图像， $\hat{y}_l$ 表示网络输出的 SR 图像， $\rho = (\sqrt{x^2 + \epsilon^2})$ ， N 为每次训练的样本数， S 为目标上采样的比例因子， L 是该网络中可超分的倍率数。

在上述对 MSE 和 Charbonnier^[43]损失的对比过程中，除了进行一系列理论知识的研究和支撑外，也分别将其应用到本文的网络中进行了充分的实验，并在实验结果的支撑下做出了最终的选择，具体消融实验效果展示如图 3.14 和图 3.15 所示。




图 3.14 不同损失函数指标曲线图




图 3.15 不同损失函数下的实测图测试结果

图 3.14 展示了本课题中不同损失函数对测试集上指标以及训练稳定程度的影响。在图中，MSE 代表网络使用 MSE 损失进行训练，而 Charbonnier^[43]代表网络使用 Charbonnier^[43]损失函数进行训练。由训练得到的曲线结果可知，Charbonnier^[43]损失函数在本研究课题的网络训练中表现出更高的峰值，并且整个训练过程更加稳定，这与超分辨率重建任务中图像的稳生长过程更为契合。在图 3.15 中，展示了不同损失函数对真实图像上的超分结果的影响。LR 表示输入网络的低分辨率图像在经过等比例放大后得到

的图像，SR-M 和 SR-C 分别表示使用 MSE 损失和 Charbonnier^[43]损失进行训练时得到的真实图像在网络中的测试结果。实验结果表明，使用 Charbonnier^[43]损失得到的测试结果相比于 MSE 损失的结果在整体细节上更加更富，而且图像中的亮星以及星云与原图更加接近，整体颜色分布也更加相似。通过以上实验结果，进一步支持了理论研究的结论。所以本课题使用了重建效果较好的 Charbonnier^[43]损失函数。

2) 结构相似性损失 (Structural Similarity, SSIM)

此外，由于考虑到生成图像的视觉效果，还为网络增加了结构相似性损失^[43]，其作为常用的图像质量评价方法，考虑了图像的亮度、对比度和结构等方面的信息，更加贴近人类视觉系统的感知机制。它能够捕捉图像的结构特性，对于保留图像细节和纹理等重要信息具有较好的效果。结构相似性指标的计算公式如下所示。

$$SSIM = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (3.4)$$

其中， μ_x 、 σ_x^2 分别为图像 x 像素的平均值和方差； μ_y 、 σ_y^2 分别为图像 y 像素的平均值和方差； σ_{xy} 是图像 x 、 y 的协方差； C_1 、 C_2 为常数。

对于结构相似性指标来说，其取值范围为 $[0,1]$ ，并且由生成图像的质量决定其值的大小即图片质量越好结构相似性指标越高，所以如果要将其作为损失函数来约束生成图像的质量，则需要其值与图像质量成反比，故需要用 1 减去 SSIM，可得结构相似性损失如下公式所示。

$$\mathcal{L}_{ssim} = 1 - SSIM(Y, G(x)) \quad (3.5)$$

其中， Y 表示真实的 SR 图， $G(x)$ 表示由网络生成的 SR 图。

3) 层次融合损失 (Hierarchical Fusion Loss, HFLoss)

在计算集视觉领域，实现高保真的超分辨率 (SR) 重建一直是一个核心挑战。上述 Charbonnier^[43]损失和 SSIM 损失通常关注于像素级精度或特征级相似性。然而，这些方法有时忽略了视觉感知的层次性，不同尺度的细节共同决定了重建图像的整体质量。受到人类视觉系统跨尺度信息整合能力的启发，本文引入了层次融合损失 (Hierarchical Fusion Loss, HFLoss)，这是一种新颖的损失函数，旨在通过同时考虑多个分辨率级别的特征对应关系来优化 SR 重建。

本文的方法通过从图像生成模块的最后三层提取特征来实施，其中每一层代表不同的分辨率级别。提取的每层特征随后通过各自的 ToRGB 模块转换成对应分辨率的图像。对于每个这样的分辨率层，本文将相应的超分辨率 (SR) 图像下采样，以匹配该层分辨率的图像尺寸。然后，计算不同层级的输出与对应下采样 SR 图像之间的差异，以确定特定的损失分量。这些损失分量旨在捕捉像素级的差异，采用 Charbonnier^[43]损失，以及保持结构的相似性，使用结构相似性 (SSIM) 损失，从而确保重建图像在细节和整体结构上的完整性。总损失是这些分量的加权和，其权重为可调参数，可以在训练过程中进行

优化。此方法不仅促进了不同分辨率层级之间的信息融合，而且通过细粒度的损失调节，进一步提升了超分辨率重建的质量和效率。其公式如下所示。

$$\mathcal{L}_{hf} = \sum_{i=1}^N a_i \cdot \mathcal{L}_s(y_i, \hat{y}_i) + \beta_i \cdot \mathcal{L}_{ssim}(y_i, \hat{y}_i) \quad (3.6)$$

其中， N 是分辨率层的数量， y_i 和 $\hat{y}_i$ 分别是第 i 层 SR 下采样图和网络预测结果， a_i 和 β_i 是可调的权重参数，分别控制像素级损失和 SSIM 损失在第 i 层的贡献。具体设计方案图如图 3.16 所示。




图 3.16 HFLoss 设计方案图

为了深入评估层次融合损失（HFLoss）对于本课题中超分辨率重建网络重建性能的影响，本研究进一步做了一系列消融实验。通过在保持网络架构和训练配置不变的情况下，比较采用 HFLoss 与未采用 HFLoss 时模型的表现差异，本文旨在精确量化 HFLoss 对提升模型性能的具体作用。这一实验设计允许本文探索 HFLoss 在促进多分辨率特征的有效融合及图像质量提升方面的机制，明确其在超分辨率重建任务中带来的潜在优势。具体实验结果如图 3.17 和图 3.18 所示。




图 3.17 是否使用 HFLoss 实测图对比结果




图 3.18 是否使用 HFLoss 的指标图

图 3.17 对比了使用 HFLoss 与未使用 HFLoss 条件下，超分辨率重建网络的输出结果。在这里，LR 表示输入网络的低分辨率图像在经过等比例放大后得到的图像，N-HF 表示未采用 HFLoss 进行训练的重建网络输出结果，而 HF 则代表使用 HFLoss 训练的网络输出。实验结果清楚地展示了，通过引入 HFLoss，重建得到的图像在整体亮度和颜色方面更接近于原始的低分辨率图像，同时在星星和星云的分布上也展现出更高的相似度。相比之下，未采用 HFLoss 的重建结果在亮度上普遍偏暗，星云的分布也呈现出较为明显的差异。在图 3.18 中，红色曲线和蓝色曲线分别代表了采用和未采用 HFLoss 时的性能指标曲线。通过对训练过程中验证集指标的分析，我们观察到使用 HFLoss 的情况下，PSNR 最高达到 30.036dB，SSIM 最高为 0.832。而在未采用 HFLoss 的情况下，PSNR 和 SSIM 的最高值分别为 29.92dB 和 0.8285。这一对比结果明确表明，采用 HFLoss 能够有效地引导模型更加关注于不同尺度的特征表达，从而显著提升了重建图像的整体保真度，包括细节的精确再现和整体视觉一致性。通过这种多尺度的处理策略，不仅增强了模型对细腻纹理和边缘的重建能力，而且有效地保持了图像的自然观感和感知质量，有效地缩小了基于像素的精度与基于感知的相关性之间的差距。

综上本课题拟使用的损失函数包括三部分：Charbonnier 损失函数 $\mathcal{L}_s$ 、结构相似性损失 $\mathcal{L}_{ssim}$ 和层次融合损失（HFLoss）。故整体的损失函数如下公式所示。

$$Loss = \mathcal{L}_s + \mathcal{L}_{ssim} + \mathcal{L}_{hf} \quad (3.7)$$

3.3.3 优化器选择

对于深度学习任务来说，优化器也是模型训练中不可缺少的一部分，其主要作用是通过调整模型的权重和偏置，最小化损失函数，从而提高模型在训练数据上的性能并促使其在未见过的数据上更好的泛化。优化器的任务主要是寻找损失函数的最小值，采用梯度下降等优化算法更新模型的参数，使其朝着最优方向调整。常用的优化器包括随机梯度下降（SGD^[44]）、动量法（Momentum^[45]）、Adagrad^[46]、RMSprop^[47]、Adam^[48]等。

SGD^[44]是最基本的优化算法，通过计算损失函数关于参数的梯度，并按梯度的反方向调整参数，实现模型参数的更新，其具有简单直观的优点，但可能受到局部最小值和

学习率的影响。其参数更新公式为

$$\theta_{t+1} = \theta_t - \alpha \nabla J(\theta_t) \quad (3.8)$$

其中, θ_t 是参数, α 是学习率, $\nabla J(\theta_t)$ 是损失函数关于参数的梯度。

动量法基于 SGD^[44] 引入了动量项, 使得更新方向不仅取决于当前梯度, 还考虑了历史梯度的影响, 这有助于加速收敛并减小震荡, 特别是在存在平坦时表现更为优越。其参数更新公式为

$$v_{t+1} = \beta v_t + (1 - \beta) \nabla J(\theta_t) \quad (3.9)$$

$$\theta_{t+1} = \theta_t - \alpha v_{t+1} \quad (3.10)$$

其中, v_t 是动量, β 是动量系数, 其余符号与 SGD 相同。

Adagrad^[46] 是一个自调节学习率的优化算法, 通过参数的梯度变化来调整学习率, 为常见参数分配较低的学习率而给予罕见参数较高的学习率。然而, 这种方法可能会因为学习率减少过快而导致训练过程过早结束。其参数更新公式为

$$G_{t+1} = G_t + (\nabla J(\theta_t))^2 \quad (3.11)$$

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{G_{t+1} + \epsilon}} \nabla J(\theta_t) \quad (3.12)$$

其中, G_t 是梯度平方的积累, ϵ 是平滑项, 其余符号与 SGD 相同。

RMSprop^[47] 也是自适应学习率的一种算法, 但相对于 Adagrad^[46], 它引入了衰减系数来限制历史梯度对学习率的影响, 这样一来就对学习率的调整相对平缓, 有助于克服 Adagrad^[46] 学习率过度衰减的问题。其参数更新公式为

$$G_{t+1} = \beta G_t + (1 - \beta) (\nabla J(\theta_t))^2 \quad (3.13)$$

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{G_{t+1} + \epsilon}} \nabla J(\theta_t) \quad (3.14)$$

其中, β 是衰减系数, 其余符号与 Adagrad^[46] 相同。

本课题选择使用 Adam^[48] 优化器, 它是一种动量法和 RMSprop^[47] 相结合的优化算法, 其主要优势在于能够自适应地调整学习率和学习参数, 以适应训练过程中的变化。Adam^[48] 优化器采用了一阶动量和二阶动量的结合方式, 这两者共同影响梯度下降的速率, 从而有效地控制梯度更新。通过自适应地调整学习率和参数更新步长, Adam^[48] 优化器能够提高模型的收敛速度和稳定性, 减少手动调整参数的工作量。由于其在深度学习领域的广泛应用和良好表现, 本课题决定使用 Adam^[48] 优化器来训练模型。其参数更新公式为

$$m_{t+1} = \beta_1 m_t + (1 - \beta_1) \nabla J(\theta_t) \quad (3.15)$$

$$v_{t+1} = \beta_2 v_t + (1 - \beta_2) (\nabla J(\theta_t))^2 \quad (3.16)$$

$$\hat{m}_{t+1} = \frac{m_{t+1}}{1 - \beta_1^{t+1}} \quad (3.17)$$

$$\hat{v}_{t+1} = \frac{v_{t+1}}{1 - \beta_2^{t+1}} \quad (3.18)$$

$$\theta_{t+1} = \theta_t - \frac{\alpha}{\sqrt{\hat{v}_{t+1} + \epsilon}} \hat{m}_{t+1} \quad (3.19)$$

其中, m_t 和 v_t 分别是梯度和梯度平方的指数移动平均, $\hat{m}_{t+1}$ 和 $\hat{v}_{t+1}$ 是偏差修正, 避免初始时动量和 RMSprop^[47] 的估计偏向于零, β_1 和 β_2 是衰减系数, 其余符号与 Adagrad^[46] 相同。

3.3.4 训练过程分析

通过对以上训练过程中的关键组件设计完成后, 便可以开始模型的正式训练。本文的模型在拥有四张 NVIDIA Tesla V100(32G) 的 NVIDIA DGX 上进行训练, 并使用 (Compute Unified Device Architecture) CUDA 技术进行计算加速。在训练过程中, 模型对训练数据的拟合情况如图 3.19 所示。从图中可以看出在网络刚开始训练时, 网络尚未学习到图像特征信息, 同时权重也未更新, 所以保存的结果图像为乱码。随着训练的进行, 到达第 10 个 epoch 时网络已经根据图像特点学习到具有拟合能力的权重; 而在第 20 个 epoch 时, 从结果可以看出网络生成的结果图像已经和原图几乎无差别, 说明网络已经趋于收敛。这表明本课题设计的网络结构和训练方式在天文图像超分辨率重建任务中有出色的学习和拟合能力, 能够有效完成模拟建模的重建过程。




图 3.19 训练过程图

3.4 模型验证

在本研究中,为验证所提出的深度学习模型在大视场天文图像超分辨率重建任务中的有效性,进行了一系列对比实验。本文选取了该领域中 EDSR^[49]、WDSR^[50]、SRGAN^[51]、RUNet^[52]和 Swin2SR^[53]等五篇经典论文中的方法进行对比,以全面评估模型在主观评价(定性)和客观评价(定量)两方面的性能。主观评价方面,通过观察模型在不同输入图像上的重建效果,我们能够直观地了解模型的细节保留能力、纹理生成能力以及对天文结构的准确还原程度。通过客观评价方面的对比实验,本文将采用 PSNR 和 SSIM 经典的评价指标,以客观地衡量不同方法在提高图像分辨率方面的性能。通过这一系列的对比实验,本文旨在深入探讨所提出模型的优越性,并对其在大视场天文图像超分辨率重建中的实际应用价值进行充分论证。这些实验证据将有助于确认模型的可靠性、稳定性,并为未来在天文学领域中的广泛应用提供坚实的基础。具体对比情况如下内容介绍。

3.4.1 主观评价

图像超分辨率重建任务的终极目标在于通过重建网络的处理,将退化后的低分辨率图像转化为更为清晰、细节更为明晰的高分辨率图像。为了全面评估本课题提出的重建网络,在测试阶段本文采用了与训练集相同制作方式但不包含其中的测试集,同时引入真实的天文图像数据集进行验证。本文通过对测试结果的视觉效果与输入网络的低分辨率图像所对应的高分辨率图像进行对比,以评估重建效果的保真度和对细节的重建能力。这样的评估方法能够更全面地衡量重建网络在不同数据集上的表现,并验证其在处理真实天文图像时的实际重建能力。具体的评估结果展示在图 3.20 和图 3.21 中。通过这些定量和定性的评估,我们能够更加深入地了解所提出模型在真实场景中的性能,为其在实际天文图像处理中的应用提供有力的支持。

图 3.20 中 Original 为韦伯官网下载的原图,红框为原图中裁剪出的高分辨率图像即为 Ground-Truth, LR(x4)为和训练集相同制作方式但不包含的 LR 图像等比放大的结果。通过对测试结果的分析,可以观察到网络在对低分辨率图像进行重建后,生成的高分辨率图像在视觉上具有较高的保真度,与原始高分辨率图像相比较为接近。EDSR^[49]、WDSR^[50]和 SRGAN^[51]的超分效果未能使整体细节更加清晰,仍然呈现出与输入的低分辨率图像相似的模糊效果。而 RUNet^[52]和 Swin2SR^[53]虽然在整体清晰度上表现尚可,但在图像内部的细节结构方面与对应的真实高分辨率图存在较大差异,其重建后的图像相较于真实图像内容不完整。相较之下,通过对测试集的验证,本文的网络在保持竞争力的同时,取得了令人满意的结果。这进一步验证了本文提出的模型在天文图像超分辨率重建任务的优越性和泛化能力。




图 3.20 仿真数据集测试结果




图 3.21 真实图像测试结果

图 3.21 中 Original 为未经模型训练的图片，其左下角绿框内的图像是从 Original 中裁剪出的将要输入网络的低分辨率图像。从测试结果可以看出，EDSR^[49]生成的超分辨率图像与原图比较为模糊，并且生成图中的噪声并不能很好的去除，Swin2SR^[53]虽然比 EDSR^[49]的生成图像略微清晰且较好的去除了原图中的噪声，但是其将星云中较小的恒星当成噪声除去，使重建后的图像不够完整，而本文的网络生成的超分辨率图像在将图像分辨率扩大的同时，不仅有效的去除了原图中的噪声还将星云中较小的恒星也都保存了下来，同时也保证了图像灰度值的正确表达，具有更加真实的纹理和更加清晰的视觉效果，说明本课题的模型具有较强的泛化能力和实际应用能力。

3.4.2 客观评价

为了更全面、客观地评价本研究提出的模型在大视场天文图像超分辨率重建任务中的效果，本文将使用经典的评价指标 PSNR 和 SSIM 进行定量的测试。其中 PSNR 代表图像的最大可能信号强度与噪声能量的平均值之间的比例，用于评估生成图像与原始图像之间的质量差异，其单位是分贝 (dB)。SSIM 评估生成图像与真实图像的相似度，主要通过分析图像的明亮度、对比度以及结构这三个核心属性来实现。通过客观指标的分析，我们将能够更深入地理解模型在提高图像分辨率方面的优越性，并与其他经典的方法进行有力的数据比较，为模型在实际应用中的性能提供更加量化的依据。具体测试结果如表 3.1 所示。

表 3.1 超分方法比较

名称	PSNR(dB)	SSIM
EDSR ^[49]	28.067	0.755
WDSR ^[50]	28.063	0.755
SRGAN ^[51]	27.278	0.722
RUNet ^[52]	27.051	0.629
Swin2SR ^[53]	23.877	0.659
Ours	30.036	0.832

通过对表 3.1 中的定量评估结果的深入分析，我们可以明确地观察到，在面对大视场天文图像的超分辨率重建任务时，传统超分辨率网络面临着对网络泛化能力的局限性，无法有效实现对这一特殊类别图像的良好重建效果。具体而言，本文所提出的网络结构在天文图像测试数据集上在 PSNR 方面相对第二名领先了 1.969dB，在 SSIM 方面更是领先了 0.077。这些定量结果表明了本文所提出的模型在应对大视场天文图像超分辨率重建任务中的显著性能优势，相较于传统方法在图像质量提升方面更具优越性。

3.4.3 模型泛化能力验证

为了更加彻底地验证本文模型的泛化能力，本文将其应用于处理除了使用韦伯望远镜拍摄的图像制作的训练集之外的数据集，包括斯皮策望远镜和哈勃望远镜拍摄的图像。通过这一进一步的实验证明，本文旨在展示模型对于不同望远镜数据源的强大适应性，从而证实其在处理多样性数据时的卓越泛化性能。具体测试结果如图 3.22 和 3.23 所示。

在图 3.22 和图 3.23 中，最左边展示的是原始图像，而绿色框内则为通过红框从原图中裁剪出的输入网络的低分辨率图像。从上图的结果可以明显看出，尽管本文的网络是在韦伯望远镜图像上进行训练的，但它仍然能够有效处理来自其他望远镜拍摄的图像。这进一步验证了本文模型的强大泛化能力，使其在处理不同望远镜拍摄的图像时表现出色。通过这样的综合展示，本文强调了模型在不同数据源上的适用性和鲁棒性。




图 3.22 斯皮策望远镜拍摄图像测试结果




图 3.23 哈勃望远镜拍摄图像测试结果

3.5 模型局限性分析

本课题中使用的训练数据的模糊核是 5×5 大小，高斯噪声的方差是 $5e-5$ 。为了测试本文模型的局限性，本文进行了以下实验。我们使用和训练集相同的数据制作方式生成一组模糊核大小范围为 5×5 到 51×51 大小的测试数据，并添加了方差为 $5e-5$ 到 $5e-3$ 之间的高斯噪声。并且在使用这组测试数据测试了本文的模型，具体测试结果如图 3.24 和表 3.2 所示。

表 3.2 不同方差的高斯噪声的影响

高斯噪声	5e-3		5e-4		5e-5	
指标类型	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
超分结果	25.233	0.548	28.799	0.769	30.036	0.832




图 3.24 不同模糊核大小的影响

通过图 3.24 和表 3.2 结果的观察, 本文发现, 当模糊核的大小从 5×5 增加到 51×51 时, 尽管在模糊尺寸从 5×5 到 7×7 时, 指标略微下降, 但总体上对超分辨率重建的影响不大。此外, 当高斯噪声的方差从 $5e-5$ 增加到 $5e-4$ 时, 即使指标有所下降, 但仍在正常范围内, 表明模型能够产生稳定的结果。这些结果强调了所提出的模型在处理具有正常模糊水平和噪声水平的图像时的有效性, 这也在之前在真实图像上的实验证实中得到了验证。然而, 当噪声的方差增加超过 $5e-3$ 时, 模型的有效性显著降低。因此, 在实际应用中, 如果待处理图像的噪声水平过高, 建议使用具有相同噪声水平的训练数据重新训练模型。这一综合分析为模型在不同条件下的鲁棒性提供了实际应用的指导建议。

3.6 本章小结

在本章节中, 本文全面探讨了针对大视场天文图像的超分辨率重建网络模型的设计、训练、验证过程及其局限性。首先, 考虑到大视场天文图像的独特特征, 本文巧妙地设计了一个基于自编码器架构的渐进式生成网络。该网络模型的每个组成部分均基于深入的设计理念, 通过与其他设计方案的对比实验, 本文最终确定了最优的模型设计方案。在模型训练阶段, 我们专注于学习率衰减策略、损失函数设计以及优化器的选择。通过比较不同的损失函数、自定义的层次融合损失 (HFLoss)、学习率衰减策略和优化器选择, 本文精心设计出了最适合本项目的训练策略, 这一策略有效支持了模型在训练过程中的高效收敛。进一步地, 本文采用了主观和客观的方法对模型进行了全面评价, 确保了对模型性能的综合检验。实验结果证明了该模型在处理具有正常模糊和噪声水平的天文图像上的卓越性能, 并展示了其在处理不同望远镜拍摄图像上的良好泛化能力。最后,

本文讨论了模型的应用范围，进一步充分验证了其在其他波段天文图像上的泛化能力。这一全面的讨论不仅为读者提供了深入理解模型设计与性能表现之间联系的机会，同时也指出了未来模型改进和拓展的可能方向，为天文图像超分辨率重建领域的进一步研究奠定了基础。

4 集成 PGSRNet 的嵌入式天文图像超分辨率重建系统

在前文中，深入探讨了针对大视场天文图像的超分辨率重建算法。为了实际应用于天文望远镜系统并验证算法的有效性，本章节详细介绍了集成 PGSRNet 的嵌入式天文图像超分辨率重建系统的设计与实施方案。该系统基于 NVIDIA JETSON TX2 开发板，融合了 PGSRNet 算法、GPS 模块、温湿度采集模块、WiFi 模块及二维舵机模块等关键技术组件，旨在与实际的望远镜系统无缝对接，实现对望远镜拍摄的天文图像进行实时的超分辨率重建^[55]。系统设计核心理念在于利用预设接口连接望远镜系统来捕获天文图像，并借助本研究开发的超分辨率重建算法对图像进行处理，以提升图像清晰度和细节展现。NVIDIA JETSON TX2 不仅承担了重建算法的实时处理任务，还有效协调各模块工作，通过集成的 WIFI 模块实现远程数据传输和控制，极大增强了系统的灵活性。此外，引入的二维舵机模块使得系统能够调整望远镜的观测方向，扩大观测范围。同时，系统还整合了 GPS 和温湿度采集模块，为天文观测提供实时的地理位置和环境信息支持。在硬件设计的基础上，本文利用 PyQt5 框架开发了上位机界面，该界面通过 NVIDIA JETSON TX2 AI 控制板与望远镜通信，不仅实时显示捕获的图像，还将处理后的图像展示给用户，PyQt5 的运用使得界面设计直观且用户友好，极大地提升了用户体验。

总体而言，这一集成 PGSRNet 的嵌入式天文图像超分辨率重建系统的设计将理论与实际应用相结合，为天文图像的超分辨率重建提供了一套全面而先进的解决方案。通过该系统，本文能够实时验证并展示在实际天文观测场景中，超分辨率重建算法的可行性和效果，为未来天文学研究提供了有力的工具和支持^[56]。

4.1 需求分析

4.1.1 系统功能需求分析

该嵌入式超分辨率重建系统的设计旨在实现一系列关键功能，以对接天文望远镜系统。首先，通过天文望远镜实时采集高质量的天文图像，并将采集到的图像传输至主控板，为系统提供了可靠的输入数据。主控板模块作为核心控制单元，在作为重建算法运行载体的同时，又协调各个硬件模块的工作，确保整个系统具有稳定性和高效性。为了增加系统的灵活性，实现远程控制和数据传输，引入了远程通信模块（WIFI 模块）。该模块将主控板接收到的图像发送至上位机，实现与上位机的远程通信，同时为用户远程操作舵机提供了便捷的通道。用户可以通过上位机的按钮远程操控二维舵机来实现望拍摄方向的灵活调整，从而拓展了系统的观测范围，使其能够适应不同的天文观测场景。与此同时，系统还引入了 GPS 模块，将望远镜的观测位置实时上传至上位机，方便了解当前观测的地理位置，为天文学研究提供更多的元数据支持。然而，系统的核心处理部

分是超分辨率重建算法，已在前文中详细介绍并构建完成。该算法负责对捕捉到的图像进行实时处理，以提高所拍摄图像的分辨率，便于细节信息的观察。而上位机通过与主控板通信，实时接收和显示捕捉到的图像，用户还可以通过上位机界面控制摄像头的拍摄角度，并将拍摄后的图像通过重建算法进行处理后展示给用户。通过该界面，用户能够方便地监控系统状态、图像处理效果，以及轻松地控制系统的运行。整体而言，这一系统的设计充分考虑了各个模块之间的紧密协作，为实际天文学研究提供了一套强大而先进的工具和支持。引入 GPS 模块的位置信息功能更进一步提升了系统的综合性能，使其在科研领域具备更广泛的应用前景。其可划分为两部分，具体如下：

1) AI 控制板端

- (1) 连接天文望远镜系统拍摄天文图像，并传输至上位机。
- (2) 作为重建算法的运行载体，实时处理天文图像的超分辨率重建。
- (3) 实时采集观测望远镜的位置信息，并将采集的数据转换为经纬度后上传。
- (4) 实时上报采集环境的温湿度信息。
- (5) 实时接收上位机的控制指令。

2) 上位机端

- (1) 实时接收图像，并通过界面展示给用户。
- (2) 具有拍摄以及二维舵机的方向控制按钮，增加系统的灵活性。
- (3) 具有选择本地图片和望远镜采集图像的选项，给用户的多维数据的处理。
- (4) 可选选项。通过 WiFi 实现与 AI 控制板端建立远程连接。

4.1.2 系统性能需求分析

1) 可扩展性

在硬件方面，系统选择的 NVIDIA JETSON TX2 AI 控制板，具有较高的计算性能和稳定性，为未来的重建算法优化提供了坚实基础。硬件模块的标准接口和模块化组件的设计，使得系统能够方便地与望远镜系统进行连接，以满足在面对未来需求的变化时能够轻松地进行升级和扩展。

在软件层面，超分辨率重建算法的模块化设计以及良好的接口规范，使得系统能够灵活适应未来更先进的图像处理算法，算法替换和升级可以通过相对简单的软件更新实现，为后续研究提供了可持续性的支持。

2) 可使用性

上位机界面采用 PyQt5 框架，提供直观友好的图形用户界面，用户能够轻松上手进行系统操作。引入选择本地图像和望远镜拍摄图像的功能，增加了系统的灵活性和适应性，为用户提供了更多选择。通过 WiFi 模块增加了远程连接的可选项，为远程操作提供了高度便捷性。

3) 准确性

大视场天文图像超分辨率重建算法是系统的核心，负责对捕捉到的图像进行实时处理，提高图像分辨率。算法的准确性和效果直接影响系统在天文观测中的应用效果，需要在设计和调优算法时重点考虑在提升分辨率的同时保留更多的细节信息，高度还原原始图像的内容，而算法的准确性已经在第三章进行了详细的验证，证实了算法的优越性和准确性。

4) 健壮性

选用 NVIDIA JETSON TX2 作为 AI 控制板，赋予算法强大算力，与望远镜及硬件模块的协调搭配，提升了系统稳定性，在外部干扰和各种环境下保持正常运作。系统设计还考虑到恶劣环境下的远程操控，确保即便无法现场作业，也能提供可靠服务。

4.1.3 系统运行环境分析

1) 硬件环境

- (1) 核心 AI 板：NVIDIA JETSON TX2
- (2) 采集节点：GPS 模块、RDS5160 双轴舵机模块、温湿度采集模块。
- (3) 网关节点：ESP8266WiFi 模块。
- (4) 客户端：显示屏或高性能计算机。

2) 软件环境

- (1) 采集节点以及网关节点：C 语言、Keil、CubeMx
- (2) 客户端上位机：Pytorch 框架、Python 语言、VSCode、Designer 设计器。

4.1.4 系统可行性分析

由于开发系统是针对用户的真实使用的，所以每一个系统都会受到技术、经济、操作等资源的限制。因此，在设计智能超分辨率重建系统之前，需要对该系统的各个模块的可行性进行分析，在确保系统各个模块都可以正常进行时，才能保证系统最终的完整实现。以下从技术、经济、操作三个方面进行了分析。

1) 技术可行性

(1) 硬件和软件兼容性。NVIDIA JETSON TX2 AI 控制板的双核 Denver 和四核 ARM Cortex-A57 的 CPU 以及 NVIDIA Pascal 架构的 GPU，为系统提供了充足的计算资源，确保了对复杂算法的高效执行。硬件模块以及望远镜之间通过标准接口实现紧密的继承、且商家均提供了开发手册，易于二次开发，确保了各个组件的无缝协作。而超分辨率重建算法经过多次优化，能够对天文图像进行有效的处理。

(2) 实时性和稳定性。主控板内核的实时性能使得系统在瞬时需求变化的情况下快速做出响应，同时其强大的算力，为超分辨率重建算法提供了实时性的保障，使其在处理大规模图像数据时具有强大的高效性。在长时间运行测试中，系统性能表现出色，各

硬件模块在不同天文观测条件下均保持可靠运行。

2) 经济可行性

(1) 成本估算。系统的主要成本集中在 NVIDIA JETSON TX2 AI 控制板上, 考虑到其高性能, 性价比非常优越。其他硬件模块均选择经济型选项, 确保整体预算合理。核心算法的编码独立完成, 未产生额外成本, 有效控制了研发费用。上位机开发使用免费工具和 Designer 设计器, 无需额外费用, 减轻了软件开发的经济压力, 显示了系统在经济层面的实用性。

(2) 效益评估。超分辨率重建算法的应用显著提升了系统的效益。与望远镜系统相连后, 用户可以实时查看拍摄和重建后的图像。加入的远程操控功能进一步增强了系统的灵活性和效率, 为天文观测带来了实质的增值效益。

3) 操作可行性

系统专注于优化用户体验, 提供了直观且友好的上位机界面。用户能够通过简单的操作流程访问系统功能, 轻松连接望远镜或远程操控舵机调整望远镜方向。这样的设计不仅降低了用户的上手难度, 还增强了系统的操作性。为了进一步辅助用户, 提供了详细的使用手册, 使用户能更全面地理解和利用系统功能, 增强了系统的可操作性。

4.2 系统总体设计

4.2.1 系统逻辑架构设计

在嵌入式天文图像超分辨率重建系统的逻辑架构设计中, 关键在于明确不同模块之间的功能关系和数据流动方式。这种设计强调了模块化、可扩展性和高效的数据管理。系统逻辑架构图如图 4.1 所示。




图 4.1 系统逻辑结构图

1) 模块化和解耦

系统中的每个模块（如望远镜预留接口、定位和通讯、方向控制和上位机处理）都设计为相对独立的单元, 每个模块仅负责特定的功能。这种解耦的设计使得系统的维护

和升级变得更加容易，同时也提高了系统的稳定性和可靠性。

2) 数据流和控制流

在逻辑架构中，数据流和控制流的设计至关重要。例如。图像数据从对接的望远镜系统流向上位机处理模块或者 AI 控制板进行超分辨率处理，而控制命令可能从上位机流向 AI 控制板或者方向控制模块。这种管理策略确保了数据和控制指令能够在系统内部高效流转。

3) 模块间协作

尽管每个模块相对独立，但它们通过明确定义的接口相互协作，共同实现系统的整体功能。例如方向控制模块的调整直接影响望远镜的图像捕获，进而影响上位机处理模块中的超分辨率处理效果。

4.2.2 系统功能模块设计

在本研究中，我们开发的嵌入式天文图像超分辨率重建系统旨在提高天文图像的质量和精度。系统被划分为两个主要功能模块：AI 控制板端（硬件端）和上位机端（软件端），每个模块都在整个观测和处理流程中发挥着关键作用。系统功能模块图如图 4.2 所示。




图 4.2 系统功能模块图

1) AI 控制板端

AI 控制板端主要负责连接望远镜系统，捕获原始图像，并收集与观测地点相关的环境数据。在设计上，我们特别重视预留兼容望远镜系统的对接端口，并确保以精确且高效的方式采集天文数据。其主要特点和功能包括：

(1) 预留高兼容性接口：本系统设计旨在接入天文望远镜系统，实现天文图像的采集及实时重建。系统配备了 WiFi 无线传输、HDMI 等标准图像传输接口，以及为连接专业级别更高望远镜而设的高带宽和低延迟的 Ethernet 接口和 PCIe 高速传输接口。

(2) 重建算法推理：为确保系统能够及时处理望远镜系统采集的天文图像，我们将重建算法嵌入到 AI 控制板中，实现对现场拍摄天文图像的即时处理。

(3) 精确的环境监测：为提升观测数据分析的精度，观测端配备了环境监测模块，能实时捕获并记录温度、湿度和位置等关键参数。这些环境数据对于分析在特定观测条件下获取的图像具有重要价值。

(4) 灵活的方向控制：考虑到天文观测的多样性，可将接入的天文望远镜装配在可精确控制的机械结构上，以实现多角度观测。这种设计使得系统能够覆盖更广的天空区域，增加观测的范围和深度。

2) 上位机端

上位机端致力于图像数据的处理与用户交互，确保图像数据不仅得到有效处理，而且用户访问和控制方便。其核心特性包括：

(1) 选择图像来源：用户可根据自己的需要选择本地图像或者通过调用望远镜系统拍摄的图像来进行超分辨率重建。

(2) 用户友好的交互界面：通过一个直观的用户界面，天文研究人员和爱好者可以轻松访问和分析处理后的图像。此外，该界面还提供了对 AI 控制端的远程控制功能，允许用户调整观测方向。

(3) 数据传输和远程通信：通过高效的无线通信模块，用户可选择远程控制功能，进行实时图像数据传输和远程控制指令的下发。这一功能对于提高实时观测和远程操作的灵活性极为关键。

4.2.3 系统总体流程设计

本系统的总体流程设计旨在确保从天文望远镜系统的对接到最终的图像处理和用户交互之间的高效和无缝连接。系统的工作流程可划分为几个关键阶段，每个阶段都由专门的模块负责，确保数据流和控制命令的顺畅传递。具体流程如图 4.3 所示。




图 4.3 系统功能流程图

该系统的工作流程首先从连接望远镜系统开始，确保连接成功后，便启动望远镜来捕获清晰的天文图像。在图像捕获的同时，系统的 GPS 模块和温湿度采集模块也会记录下观测地点的精确位置和环境的温湿度数据。这些捕获的图像及位置数据接着被 NVIDIA JETSON TX2 AI 控制板接收，进行数据格式化等初步处理。处理后的数据，根据用户是否选择了远程连接，通过有线或无线连接被传输到上位机端。这一实时数据传输机制保证了观测数据能够迅速送达上位机端，供即时处理。一旦数据到达上位机，用户便可以通过点击处理按钮来下发指令给 AI 控制板，启动图像的超分辨率重建过程，并实时在界面上展示重建结果。此外，用户还可以发送控制指令来远程调整望远镜的拍摄角度，或通过点击本地文件按钮，选择本地的图片进行处理。这样，整个系统通过 AI 控制板这一枢纽，实现了数据的实时同步，并顺畅完成了整个观测系统的工作流程。

4.3 AI 控制板端的设计与实现

本章节重点介绍嵌入式天文图像超分辨率重建系统的硬件组成部分，展现了通过一套精心设计的硬件架构，如何实现与望远镜系统的高度兼容性以及高效的天文图像捕获与重建算法的集成处理。系统的硬件设计整合了望远镜对接、高效的算法推理能力、精确的环境监测，以及高速的数据传输和远程操作功能，保障了观测数据的高质量、系统操作的灵活性与实时性。图 4.4 展示了硬件的物理连接示意图。



图 4.4 系统硬件物理连接图

4.3.1 对接望远镜系统的设计与实现

在对接望远镜系统的设计中，我们专注于多兼容的接口以及通过 DIY 适配的方式衔接方向控制。为此，我们选择预留 WiFi 无线传输、HDMI、PCIe 以及 Ethernet 接口作为望远镜的对接口，同时选用 RDS5160 双轴舵机来实现对望远镜的灵活控制。

1) 选型原因

(1) WiFi无线传输、HDMI、PCIe 以及 Ethernet 接口。WiFi无线传输与大多数天文望远镜兼容，能有效减少物理干扰，同时降低成本，便于系统的灵活升级。HDMI 接口专注于高清视频和音频信号的传输，常用于连接图像采集设备以提供高清晰度图像。PCIe 接口以其高速传输特性，特别适用于专业级别较高的望远镜，确保数据传输的高效率。Ethernet接口能够提供高带宽和低延迟的连接，能够确保数据传输的速度和稳定性，从而支持高速的数据分析和处理。

(2) RDS5160 双轴舵机。其是一款高性能的数字伺服舵机，以出色的大扭矩特性著称，操作速度为 $0.17 \text{ 秒}/60^\circ$ ，尺寸紧凑、响应迅速且兼容性好，可通过 PWM 信号进行精确控制，非常适合多角度的天文观测。

2) 作用

通过预设接口连接并将望远镜安装在舵机上，本文的系统可以实现多角度和全方位的图像采集。这种配置赋予了系统与各种望远镜设备的高度兼容性，并能灵活调整观测范围，从而覆盖更广阔的观测区域。这不仅增强了系统的适用性，还使其能够捕捉到更加丰富和细致的天文图像。

3) 核心编码

由于预留的用于对接望远镜系统的有线接口为板载接口，与系统 AI 控制板是以物理电路进行连接，同时接口的硬件驱动也由板载系统完成，所以不需要我们再进行单独编码来实现相应的功能，而无线传输的相关编码会在后续小节进行介绍。

RDS5160 舵机操作依赖于其内部的参考电路设计，这个电路产生一个周期为 20ms、脉宽为 1.5ms 的基准信号。舵机使用一个比较器来分析外来信号与这一基准信号的差异，进而决定旋转的角度和范围。在本文的系统中，我们使用 TIM3CH2（定时器 3 通道 2）的 PB5 引脚输出控制信号，这需要总周期为 20ms 的时基脉冲。通过 Rds5160_Init()函数设置定时器的总计数值和分频系数，然后用 SetAngle()函数调整比较值，从而改变舵机的转动角度。其核心代码的流程图如图 4.5 所示。




图 4.5 RDS5160 双轴舵机核心代码流程图

4.3.2 位置与环境检测的设计与实现

为了给望远镜提供更准确、更丰富的观测数据，本文在该模块中选用了 GT-U7 GPS 模块，来为系统提供精准的观测位置，同时还加入了 DHT11 温湿度采集传感器，实时的为系统提供直接影响图像质量的环境信息。

1) 选型原因

(1) GT-U7 GPS 模块。GT-U7 GPS 模块以其高灵敏度和低功耗特性著称，其小型化设计和卓越的追踪灵敏度使其能够在传统 GPS 模块难以定位的环境下，如狭窄的城市街道和密集的丛林中，实现高精度定位。这些特点使 GT-U7 非常适合于天文图像观测，在恶劣和复杂的环境中仍能保持精确的地理定位。

(2) DHT11 温湿度模块。DHT11 是一个高效能的综合型温湿度传感器，它提供经过校准的数字信号输出。该传感器融合了尖端的数字信号采集与温湿度测量技术，确保了其出众的稳定性和可靠性。这款传感器以其低成本、快速响应和强大的抗干扰能力而突出，能在复杂环境中准确测量相对湿度和温度。其包含的电容式湿度感测元件和 NTC 温度感测元件使其在环境监测应用中表现出色，尤其适合复杂和变化多端的观测环境。

2) 作用

系统通过融入 GPS 模块和温湿度采集模块，从而实现在采集图像的同时，将图像的采集位置以及周围环境温湿度进行实时上报，为后期天文学研究提供更多元的数据支持，同时也为图像的采集选择更加合适的地理位置和环境。

3) 核心编码

由于 GT-U7 GPS 模块已经内置了经纬度数据采集的功能，因此我们仅需配置 UART3 串口来接收这些数据。UART3 的配置涉及设置 PB10 (TX) 和 PB11 (RX) 引脚，这两个引脚需与 GPS 模块的相应引脚相反连接以确保正确的数据通信。接收到的 GPS 数据中包含了大量非关键信息，为了提取我们所需的经纬度数据，系统通过 NMEA_GPRMC_Analysis() 函数解析并过滤原始 GPS 数据。这一过程确保我们有效地获取精确的位置信息，同时避免了不必要的数据处理负担。其核心代码流程图如图 4.6 所示。

DHT11 温湿度传感器与 AI 控制板的交互过程始于控制板向传感器发送一个至少持续 18 毫秒的低电平信号。此后，控制板将信号拉高并维持 30 毫秒，以此来初始化传感器的数据传输。在这个阶段，控制板设置 GPIO 引脚为输入模式，以便接收来自 DHT11 的响应信号。一旦接收到响应，DHT11 将先拉低电平 80 毫秒，随后拉高 80 毫秒，标志着数据传输的开始。数据传输阶段，AI 控制板通过配置 PB1 引脚作为 GPIO 数据接口，既向 DHT11 传送控制电平，又读取由其发出的数据。这些数据通过控制板上的 DHT11_ReadData() 函数进行读取和解析，从而获取实时的温度和湿度信息。其核心代码流程图如图 4.7 所示。




图 4.6 GPS 模块核心编码流程图




图 4.7 DHT11 温湿度采集模块核心代码流程图

4.3.3 重建算法 PGSRNet 集成与远程控制的设计与实现

在此模块中，本文成功将本研究的算法移植至 NVIDIA JETSON TX2 AI 控制板，实现了天文图像的现场重建。此外，系统还整合了 ESP8266 WiFi 模块，为用户提供了远程控制的便利选项。

1) 选型原因

(1) NVIDIA JETSON TX2 AI 控制板。它搭载了 NVIDIA Pascal 架构的 GPU，拥有 256 个 CUDA 核心，以及一个双核 Denver CPU 和四核 ARM Cortex-A57 CPU，提供卓越的计算能力。TX2 支持多种高级计算功能，包括深度学习、机器视觉和高速图像处理。同时它还支持多种接口，如 Ethernet、HDMI 和 PCIe，为开发者提供灵活性。此外，它兼容 NVIDIA JetPack SDK，为 AI 应用开发提供强大的支持。

(2) ESP8266 WiFi 模块。该模块实现了高效的串口到 WiFi 转换，内置 TCP/IP 协议栈，简化了串口设备的网络数据传输配置。支持 LVTTTL 级别的串行通信，与 3.3V 及 5V 的微控制器系统兼容，便于集成。它提供了多种工作模式，如从串口到 WiFi 的 STA 和 AP 转换，以及针对串口到 WiFi 数据传输进行了优化。

2) 作用

重建算法的移植是整个系统的核心，通过将算法移植到 NVIDIA JETSON TX2 AI 控制板上，其强大的计算能力，使算法的推理计算更加顺畅，也使算法在实际应用中更加便捷，同时 NVIDIA JETSON TX2 AI 控制板起到了协调各个硬件模块的关键作用。而远程控制则是为用户提供的的一个可选项，用户可选择远程控制功能，从而实现数据的无线

上报。同时，该模块还能远程接收上位机的控制指令，并将这些指令通过 AI 控制板有效地分发到相应的外围设备进行操作。

3) 核心编码

算法移植过程主要包括在 AI 控制板上构建适应本文重建算法的推理环境，并对源代码进行裁剪以实现高效的算法推理。由于此过程涉及繁多的环境配置细节，本文不对其进行详细说明。

对于 ESP8266 WiFi 模块，其内置的 WiFi 协议栈大大简化了编码工作，主要聚焦于串口通信的实现。在这一过程中，我们无需深入到 WiFi 协议层面，而是通过串口实现数据的发送和接收。网络连接的建立是通过发送 AT 指令实现的，这一操作由 ESP8266_SetSAP()函数完成。一旦网络连接建立，本文便使用 ESP8266_SendData()和 ESP8266_ReceiveData()函数，通过在 AI 控制板上配置为 UART2 的 PA2 (TX) 和 PA3 (RX) 引脚进行数据的传输和接收。关键代码流程图如图 4.8 所示。




图 4.8 ESP8266 WIFI 模块核心代码流程图

4.4 上位机端的设计与实现

本章节详细阐述了上位机软件的设计与实施，特别强调了其功能展示、算法调用，以及与硬件的互动。在此部分，本文设计了一个直观的用户界面，确保用户可以轻松访问系统的全部功能。用户可以通过上位机实时监控观测环境和位置，远程操控舵机调整望远镜角度，捕获图像，并使用集成的算法进行处理和展示。整体界面如图 4.9 所示。



图 4.9 上位机整体界面展示

4.4.1 图像采集与信息监控的设计与实现

1) 设计与实现

在此系统中，上位机利用串口或无线方式与 AI 控制板通信。串口连接通过 serial.Serial()函数建立，用 read()函数读取数据。无线 WiFi 连接则通过创建 socket.socket()对象并使用 connect()方法连接到 WiFi 模块的 IP 地址和端口实现。连接成功后，使用 socket.recv()函数接收数据。接收到的图像数据通过 show_cv_img()函数转为 RGB 格式，并通过 QLabel 显示。对于温湿度和 GPS 数据，通过 QLCDNumber 控件的 display()方法实时展示，保证了信息更新的及时性和用户界面的交互性。核心代码流程图如图 4.10 所示。




图 4.10 图像采集与信息监控核心代码流程图

2) 界面展示

在该界面中,环境监测区域负责展示接收到的温度、湿度以及地理位置信息,包括经度和纬度数据。而 LR 区域则用于展示从天文望远镜接收到的图像,或展示本地即将重建的图像。



图 4.11 图像采集与信息监控界面

4.4.2 重建算法集成与结果展示的设计与实现

1) 设计与实现

本章节重点介绍如何将第三章节开发的网络的推理嵌入上位机,实现对拍摄图像的实时处理。第三章已详细完成了算法的核心编码和测试,考虑到代码量较大,这里不再详述。关键在于算法如何集成到上位机中。本文为重建算法设置了 `val()` 函数接口,用于输入待处理图像并返回处理结果。通过 `lr_to_sr()` 函数调用此接口,将处理后的图像结果展示出来。核心代码流程图如图 4.12 所示。




图 4.12 重建算法集成与结果展示核心代码流程图

2) 界面展示

在这个界面上，LR 区展示了待重建的低分辨率图像，而 SR 区则展示了经过重建处理后的高分辨率图像。这种布局便于用户对比分析原始图像与通过先进技术增强后的结果，从而直观地看到图像质量的显著提升。



图 4.13 重建结果展示

4.4.3 下发操作指令的设计与实现

1) 设计与实现

系统启动后默认为有线连接，若用户选择了远程连接则建立 WiFi 无线连接。有线连接则是通过调用 `write()` 函数给已经建立连接的串口发送数据。而无线连接是通过 `socket` 的 `send()` 函数向 AI 控制板发送控制指令，如开始拍摄、断开连接以及舵机方向控制，这些操作通过界面上的按钮实现。按钮点击事件与相应功能通过 `clicked.connect()` 方法绑定实现。系统还提供图像来源选择，用户可选择本地图像或望远镜采集图像进行处理，增强了系统的灵活性和用户体验。核心代码流程图如图 4.14 所示。




图 4.14 下发打开相机指令的核心代码

2) 界面展示

在该界面中，功能区为用户提供了一系列的操作选项，以便于他们充分利用系统的多样化功能。这包括了选择图像来源，实现远程连接，启动拍摄，以及断开连接等关键操作。另外，舵机控制区专门用于精确调整舵机的方向，这项功能至关重要，因为它允许用户细致地操控望远镜的拍摄角度，从而精确捕捉所需的天体图像。




图 4.15 下发操作指令界面

4.5 本章小结

本章节展示了嵌入式天文图像超分辨率重建系统的成功设计与实现，目的是与实际望远镜系统对接并验证网络模型在实际环境中的效果。该系统基于 NVIDIA JETSON TX2 AI 控制板，配备多个高兼容性接口以连接望远镜系统，并整合了诸如 GPS、温湿度采集、WIFI 和二维舵机等模块。系统支持有线连接至 AI 控制板，同时提供远程通信选项，以及与望远镜系统的集成，实现天文图像的实时采集和超分辨率重建。它还分析了影响观测的环境信息和地理位置。系统的图像源选择功能增强了其灵活性和实用性，充分证明了深度学习在天文图像处理领域的巨大应用潜力。

5 总结与展望

5.1 总结

在天文观测中，由于望远镜口径限制和传输过程中的各种干扰，常常导致图像质量下降，分辨率减弱，严重影响了对观测目标的识别和分析。面对因望远镜口径小而导致的低分辨率问题，虽然通过增大望远镜口径可以获取更高分辨率的图像，但这样做成本高昂，且维护困难。因此，利用图像后处理技术进行天文图像的超分辨率重建显得尤为重要。然而，传统的超分辨率重建算法在处理大视场天文图像时，通常效率低下，且容易导致图像内容的丢失。为解决这些问题，本文提出了一种基于自编码器结构的超分辨率重建算法。该算法旨在提高处理效率，同时减少图像内容的损失。为了验证这一算法的实际应用性能，本文还设计并实现了一套智能的超分辨率重建系统，希望通过这种方式为天文学的图像分析提供更加精确和高效的工具。具体工作如下：

（1）构建天文图像数据集。在本研究中，鉴于深度学习模型训练对大量数据的依赖，以及天文图像超分辨率重建作为一个新兴研究领域所面临的数据集缺乏问题，本文采取了创新的数据准备策略。首先，本文从韦伯官方获取原始天文图像，然后通过数据增强技术扩展这些源数据，以生成高清晰度样本（SR）。接着，对这些源数据进行高斯模糊处理，通过双三次插值方法进行下采样，并加入高斯及泊松噪声，最终构建了一套大规模的低分辨率与高分辨率图像对（LR-SR）数据集。这一数据集的建立为深度学习模型的有效训练提供了充足的数据支持。

（2）构建了基于自编码器结构的大视场天文图像超分辨率重建网络。为了解决传统超分辨率重建算法在大视场天文图像上处理效率低、图像内容不完整等问题。本文构建了一套基于自编码器结构的重建网络，其主要有特征提取模块、特征矫正模块以及图像生成模块组成。特征提取模块通过提取低分辨率图像中的浅层特征和深层特征，有效捕获细节和全局信息。特征矫正模块采用了移动卷积以及层归一化等先进的技术，来优化表达错误的特征。在图像生成阶段，本文利用渐进式增长的策略，结合深层和校正后的浅层特征，逐步生成高质量的高分辨率图像。该方法不仅提高了图像的细节丰富度，还增强了其真实感，展现了卷积神经网络在天文图像处理方面的强大潜力。此外，本文与目前主流的超分辨率重建算法进行了对比实验，实现了大视场天文图像方向的 SOTA 结果。在主观评价方面，本文的网络在提升分辨率的同时不仅去除了图像中的噪声还将星云中较小的恒星都保存了下来，同时也保证了图像灰度值的正确表达。在客观指标方面，本文的网络比其他方法中最优的结果在 PSNR 上领先了 1.969dB，在 SSIM 上更是领先了 0.077。最后本文还在其他望远镜的图像数据上证实了本文模型的泛化能力以及局限性。

(3) 设计实现了一套集成 PGSRNet 的嵌入式天文图像超分辨率重建系统。为了对接实际天文望远镜系统, 以及展示本研究中提出的重建算法在现实世界中的应用效果, 本文开发了一套先进的嵌入式天文图像超分辨率重建系统。该系统以 NVIDIA JETSON TX2 AI 控制板为核心, 通过与实际望远镜的有效对接, 同时集成了 PGSRNet 算法、GPS 模块、温湿度采集模块、WiFi 模块以及二维舵机模块, 实现了对天文图像的实时处理以及对观测环境的监控。此外, 本文还利用 PyQt5 框架开发了一个功能丰富的上位机应用程序。这个应用程序不仅可以远程操控硬件设备, 捕捉天文图像, 还能实时对处理后的图像进行展示。通过这套系统, 本文将理论研究与实际应用紧密结合, 为天文望远镜拍摄的天文图像提供了一整套全面且高效的后处理方案。这不仅验证了本文的超分辨率重建算法的有效性, 也为天文学领域的图像处理提供了新的视角和工具。

5.2 展望

本研究成功开发了一种针对大视场天文图像的超分辨率重建网络模型, 该模型在重建方面取得了显著突破。然而, 由于网络结构的设计限制, 目前的模型在训练过程中仅能处理特定倍率的图像对, 这在一定程度上限制了其灵活性和应用范围。为了解决这一问题, 本文计划对网络模型的训练机制进行进一步优化。本文将引入倍率参数, 使得网络能够在单次训练中处理不同倍率的图像对。这样的改进将大幅拓展网络的应用领域, 并实现多倍率图像重建的目标。此外, 本文还计划扩大训练数据集的类型和范围, 目的是训练出一个更为强大的大型模型。这个升级后的模型将能更好地适应不同拍摄设备捕获的图像, 从而提高模型的通用性和有效性。通过这些改进, 我们期望将本文的超分辨率重建网络模型推向一个新的高度, 为天文图像的处理提供更加强大和灵活的工具。

参考文献

- [1] Li W, Liu Z, Deng H. A Self-Attention Based SRGAN for Super-Resolution of Astronomical Image[C]//2022 IEEE 8th International Conference on Computer and Communications (ICCC). IEEE, 2022: 1977-1981.
- [2] Zhang L, Wu X. An edge-guided image interpolation algorithm via directional filtering and data fusion[J]. IEEE transactions on Image Processing, 2006, 15(8): 2226-2238.
- [3] Rasti P, Demirel H, Anbarjafari G. Improved iterative back projection for video super-resolution[C]//2014 22nd Signal Processing and Communications Applications Conference (SIU). IEEE, 2014: 552-555.
- [4] Blu T, Thévenaz P, Unser M. Linear interpolation revitalized[J]. IEEE Transactions on Image Processing, 2004, 13(5): 710-719.
- [5] Tekalp A M, Ozkan M K, Sezan M I. High-resolution image reconstruction from lower-resolution image sequences and space-varying image restoration[C]//[Proceedings] ICASSP-92: 1992 IEEE International Conference on Acoustics, Speech, and Signal Processing. IEEE, 1992, 3: 169-172.
- [6] Dong C, Loy C C, He K, et al. Image super-resolution using deep convolutional networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 38(2): 295-307.
- [7] Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [8] Shi Y, Han L, Han L, et al. A latent encoder coupled generative adversarial network (le-gan) for efficient hyperspectral image super-resolution[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-19.
- [9] Conde M V, Choi U J, Burchi M, et al. Swin2SR: Swinv2 transformer for compressed image super-resolution and restoration[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 669-687.
- [10] Liang J, Cao J, Sun G, et al. Swinir: Image restoration using swin transformer[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 1833-1844.
- [11] Yang F, Yang H, Fu J, et al. Learning texture transformer network for image super-resolution[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 5791-5800.
- [12] Hu X, Naiel M A, Wong A, et al. RUNet: A robust UNet architecture for image super-resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019: 0-0.

- [13] Rivadeneira R E, Sappa A D, Vintimilla B X, et al. A novel domain transfer-based approach for unsupervised thermal image super-resolution[J]. *Sensors*, 2022, 22(6): 2254.
- [14] Chua L O. CNN: A paradigm for complexity[M]. World Scientific, 1998.
- [15] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [16] Glorot X, Bordes A, Bengio Y. Deep sparse rectifier neural networks[C]//Proceedings of the fourteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings, 2011: 315-323.
- [17] Maas A L, Hannun A Y, Ng A Y. Rectifier nonlinearities improve neural network acoustic models[C]//Proc. icml. 2013, 30(1): 3.
- [18] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1026-1034.
- [19] Hendrycks D, Gimpel K. Gaussian error linear units (gelus)[J]. *arXiv preprint arXiv:1606.08415*, 2016.
- [20] Sun M, Raju A, Tucker G, et al. Max-pooling loss training of long short-term memory networks for small-footprint keyword spotting[C]//2016 IEEE Spoken Language Technology Workshop (SLT). IEEE, 2016: 474-480.
- [21] Gholamalinezhad H, Khosravi H. Pooling methods in deep neural networks, a review[J]. *arXiv preprint arXiv:2009.07485*, 2020.
- [22] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.
- [23] Wu Y, He K. Group normalization[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [24] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. *arXiv preprint arXiv:1607.06450*, 2016.
- [25] Huang X, Belongie S. Arbitrary style transfer in real-time with adaptive instance normalization[C]//Proceedings of the IEEE international conference on computer vision. 2017: 1501-1510.
- [26] Young I T, Van Vliet L J. Recursive implementation of the Gaussian filter[J]. *Signal processing*, 1995, 44(2): 139-151.
- [27] Rivolta C. Airy disk diffraction pattern: comparison of some values of $f/\text{no.}$ and obscuration ratio[J]. *Applied optics*, 1986, 25(14): 2404-2408.
- [28] Mattingly D. Modern tests of Lorentz invariance[J]. *Living Reviews in relativity*, 2005, 8(1): 1-84.
- [29] Amer A, Dubois E. Fast and reliable structure-oriented video noise estimation[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2005, 15(1): 113-118.

- [30] Foi A, Alenius S, Katkovnik V, et al. Noise measurement for raw-data of digital imaging sensors by automatic segmentation of nonuniform targets[J]. IEEE Sensors Journal, 2007, 7(10): 1456-1461.
- [31] Zhang L, Zhang L, Mou X, et al. A comprehensive evaluation of full reference image quality assessment algorithms[C]//2012 19th IEEE International Conference on Image Processing. IEEE, 2012: 1477-1480.
- [32] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [33] Young I T, Van Vliet L J. Recursive implementation of the Gaussian filter[J]. Signal processing, 1995, 44(2): 139-151.
- [34] Wang X, Yu K, Wu S, et al. Esrgan: Enhanced super-resolution generative adversarial networks[C]//Proceedings of the European conference on computer vision (ECCV) workshops. 2018: 0-0.
- [35] Chen L, Chu X, Zhang X, et al. Simple baselines for image restoration[C]//Computer Vision—ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part VII. Cham: Springer Nature Switzerland, 2022: 17-33.
- [36] Han K, Xiao A, Wu E, et al. Transformer in transformer[J]. Advances in Neural Information Processing Systems, 2021, 34: 15908-15919.
- [37] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [38] Karras T, Laine S, Aittala M, et al. Analyzing and improving the image quality of stylegan[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 8110-8119.
- [39] Zhou B, Khosla A, Lapedriza A, et al. Learning deep features for discriminative localization[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2921-2929.
- [40] Loshchilov I, Hutter F. Sgdr: Stochastic gradient descent with warm restarts[J]. arXiv preprint arXiv:1608.03983, 2016.
- [41] Lai W S, Huang J B, Ahuja N, et al. Fast and accurate image super-resolution with deep laplacian pyramid networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 41(11): 2599-2613.
- [42] Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14. Springer International Publishing, 2016: 694-711.
- [43] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [44] Ruder S. An overview of gradient descent optimization algorithms[J]. arXiv preprint arXiv:1609.04747, 2016.

- [45] He K, Fan H, Wu Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 9729-9738.
- [46] Zeiler M D. Adadelta: an adaptive learning rate method[J]. arXiv preprint arXiv:1212.5701, 2012.
- [47] Wilson A C, Roelofs R, Stern M, et al. The marginal value of adaptive gradient methods in machine learning[J]. Advances in neural information processing systems, 2017, 30.
- [48] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [49] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 136-144.
- [50] Yu J, Fan Y, Yang J, et al. Wide activation for efficient and accurate image super-resolution[J]. arXiv preprint arXiv:1808.08718, 2018.
- [51] Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [52] Hu X, Naiel M A, Wong A, et al. RUNet: A robust UNet architecture for image super-resolution[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019.
- [53] Conde M V, Choi U J, Burchi M, et al. Swin2SR: Swinv2 transformer for compressed image super-resolution and restoration[J]. arXiv preprint arXiv:2209.11345, 2022.
- [54] 敖东彪. 基于深度学习的图像超分辨率算法研究与应用[D].电子科技大学,2022.DOI:10.27005/d.cnki.gdzku.2022.002270.
- [55] 温少华.基于 ARM+FPGA 的超分辨率重建系统设计与实现[D].西安电子科技大学,2017.
- [56] 陈继成.基于 DM6446 的超分辨率图像重建系统的设计与实现[D].哈尔滨工业大学,2014.