

深度学习在星图质心测量中的应用

熊琰^{1,2}, 齐静雅^{1,2}, 孟小迪^{1,2}, 武延鹏^{1,2,*}

1. 北京控制工程研究所 空间光电测量与感知实验室, 北京 100190

2. 中国空间技术研究院, 北京 100094

摘要:星敏传感器在轨拍摄星图时,光斑质心测量精度与计算效率是其关键性能指标。研究旨在提出一种基于深度学习的质心测量方法(Deep Learning-based Centroid Measurement, DLCM),以解决传统质心测量方法在精度和计算效率方面的不足,尤其在噪声干扰和复杂星图条件下的表现。DLCM方法采用卷积神经网络(CNN)来自动提取星图中的复杂特征,并在网络的输出层使用多个全连接层进行质心位置的回归预测。为了训练神经网络,仿真模拟了在不同噪声水平下的高斯光斑,并通过大量的训练数据优化网络结构。DLCM方法能够自适应不同噪声和图像变化,而无须手动调整参数或根据图像特性进行预处理。实验结果表明,DLCM方法在 3σ 内可以实现0.05像素的星图质心测量精度,并展现出较好的鲁棒性和泛化能力,此外,DLCM方法在计算效率上也具备显著优势。实验结果验证了DLCM在星图质心测量中的应用潜力,具有较好的精度和高效性。该方法为未来高精度星敏传感器及其他光电指向测量设备的研发提供了有效的技术支持。

关键词:深度学习;星图;质心测量算法;卷积神经网络;星敏传感器

中图分类号:V488.2

文献标识码:A

Application of deep learning in centroid measurement of star images

XIONG Yan^{1,2}, QI Jingya^{1,2,*}, MENG Xiaodi^{1,2}, WU Yanpeng^{1,2,*}

1. Space Optoelectronic Measurement and Perception Lab, Beijing Institute of Control Engineering, Beijing 100190, China

2. China Academy of Space Technology, Beijing 100094, China

Abstract: The centroid measurement accuracy and computational efficiency of star spots in star charts are key performance indicators for star sensors in space. This study aims to develop a deep learning-based centroid measurement method (Deep Learning-based Centroid Measurement, DLCM) to address the limitations of traditional centroid measurement methods in terms of accuracy and computational efficiency, particularly under noisy conditions and complex star charts. The DLCM method utilizes convolutional neural networks (CNN) to automatically extract complex features from star charts, and employs multiple fully connected layers in the output layer of the network to predict the centroid position through regression. To train the neural network, Gaussian spots under various noise levels are simulated, and the network structure is optimized using a large volume of training data. The DLCM method adapts to varying noise levels and image conditions without requiring manual parameter adjustments or preprocessing based on image characteristics. Experimental results demonstrate that the DLCM method achieves a centroid measurement

收稿日期:2024-09-24;修回日期:2025-05-21;录用日期:2025-05-30

基金项目:民用航天基金项目(D020502);国家自然科学基金青年科学基金项目(52405247)

*通信作者. E-mail: wuyanpeng@gmail.com

引用格式:熊琰,齐静雅,孟小迪,等.深度学习在星图质心测量中的应用[J].中国空间科学技术(中英文),2025,45(6):99-110.
XIONG Y, QI J Y, MENG X D, et al. Application of deep learning in centroid measurement of star images[J]. Chinese Space Science and Technology, 2025, 45(6): 99-110 (in Chinese).

accuracy of 0.05 pixels within a 3σ range, with excellent robustness and generalization capabilities. Furthermore, DLCM shows significant advantages in computational efficiency. The experimental results validate the potential application of DLCM in star chart centroid measurement, showcasing its high accuracy and efficiency. This method provides effective technical support for the development of future high-precision star sensors and other electro-optical pointing measurement devices.

Keywords: deep learning; star images; centroid measurement algorithm; convolutional neural network; star sensors

0 引言

星敏感器^[1]是一种重要的光电指向测量设备,主要用于测量航天器的姿态、位置和速度等信息。在星敏感器的功能中,星图质心测量是一项关键任务,它通过拍摄星空图像并进行星图分析、星图匹配和星图识别等过程,来确定航天器的姿态。为了实现对轨道上拍摄的星图光斑质心的高精度测量,研究人员提出了多种不同的质心测量算法。

目前,常见的星图质心测量方法包括一阶质心法(First Moment Centroiding, FMC)、二阶质心法(Second Moment Centroiding, SMC)和高斯拟合法(Gaussian Fitting, GF)等。一阶质心法通过计算星图中像素的平均值来获取质心位置,具有计算简单和易于实现的优势,其质心测量精度在信噪比较高的情况下可以达到0.1像素左右。然而,当信噪比较低时,质心提取精度会明显下降^[2]。二阶质心法通过计算星图中像素的加权平均值来获取质心位置,相较于一阶质心法具有更高的准确性,在良好信噪比条件下可达到0.07像素的精度,但当光斑位于星图边缘时,质心提取精度会显著下降^[3]。高斯拟合法通过拟合星图中像素的概率分布来获取质心位置,具有鲁棒性好和抗干扰能力强的优势,通常可以实现0.049像素的精度,然而由于其较高的计算复杂度、计算时间长和对计算资源的高需求,目前尚未在轨应用^[4]。此外,还有一些研究人员通过对星图进行预处理来消除噪声干扰和其他复杂因素的影响,从而提高质心测量的精度^[5]。尽管现有方法在特定条件下表现良好,但它们也存在一些局限性和挑战,例如信噪比低、光斑位置偏离中心和复杂背景等,均会导致星图质心测量的误差增大。此外,由于星图通常是在航天器上拍摄的,其分辨率受到航天器载荷和成

本的限制,因此星图的尺寸相对较小,而且星点之间的距离较远,导致星图中的特征信息相对较少,这为星图质心的测量提出了挑战。

近年来,深度学习技术在星图质心测量领域得到了广泛关注。深度学习技术^[6-9]以其强大的特征提取能力而著称,通过学习大量数据的特征信息,能够自动提取星图中的质心信息,相较于传统方法,深度学习技术具备更好的鲁棒性和适应性,从而能够显著提升质心提取的精度和鲁棒性。目前,现有的基于深度学习的星图质心测量方法通常采用卷积神经网络^[10]或循环神经网络(RNN)^[11]等结构,通过多层次的特征提取和组合,实现对星点的质心位置的准确预测。例如,Zapevalin等人提出了一种基于CNN的星图质心测量方法,该方法使用CNN提取星图中的空间结构信息,并通过多个全连接层回归预测质心位置^[12]。实验结果表明,该方法在不同信噪比和星点位置条件下都具有较高的准确性。Li等人^[13]提出了一种用于计算自适应光学(AO)系统中Shack-Hartmann波前传感器(SHWFS)质心的方法,该研究探索了在极端情况下,例如高噪声、低信号强度或低光照条件下,使用人工神经网络来提高Shack-Hartmann波前传感器的质心计算性能,实现了在计算环境下精确的波前测量。方波浪等人^[14]提出了一种基于物理信息神经网络的质心定位方法,该方法利用U-Net神经网络预处理光斑图像,对于畸变的高斯光斑和Sinc光斑的质心计算,可达亚像素级别。此外,还有一些学者使用生成对抗网络(GAN)^[15]来生成虚拟星图数据,以增加训练数据的多样性和数量,提高模型的泛化能力。同时,还有一些研究专注于优化网络结构和损失函数^[16],以进一步提高模型的性能和鲁棒性。

尽管深度学习方法在星图质心测量中取得了一定的成功,但仍然存在一些挑战和改进的空间。例如,深度学习模型需要大量的标注数据进行训练,然而在星图质心测量领域,获取大规模

的标注数据可能会面临标注数据的获取成本高昂以及专业人员稀缺等诸多困难。对于基于大型预训练模型的微调^[12,14,17],虽然这种方法已经取得了一定的成功,但仍然存在一些限制。首先,现有的大型预训练模型通常是在其特定领域进行训练与优化,这些大型预训练模型往往难以完全满足星图质心测量的特定需求。其次,通过微调这些模型,可能会影响模型的泛化能力和可解释性。此外,对于航天在轨应用而言,计算资源可能也不足以支持现有大型预训练模型的计算需求。因此,如何进一步优化和改进深度学习方法,以提高质心测量的精度并降低计算复杂度,进而更好地适应航天应用的特殊需求,仍然是一个值得深入研究的问题,这对于推动星图质心测量算法的发展具有重要意义。

为了克服上述这些问题,本文提出了一种基于深度学习的质心测量方法,称为 Deep Learning-based Centroid Measurement (DLCM)。该方法利用卷积神经网络来识别星图的复杂特征,并通过多个全连接层在网络结构的输出部分进行质心位置的回归预测。通过仿真模拟了不同噪声水平下的高斯光斑来训练神经网络,经过充分的训练,DLCM 在 3σ 内可以达到 0.05 像素的星图质心测量精度,并且表现出较好的鲁棒性和泛化能力。相对于传统的一阶质心法、二阶质心法,DLCM 不需要根据噪声水平调整参数,在精度和计算效率方面均具有显著优势。相对于高斯拟合法,虽然 DLCM 的质心测量误差的标准差略有 7.78% 的差距,但其计算效率更高、计算复杂度更低,且具备在轨应用的可行性。本研究旨在验证深度学习技术在星图质心测量中的可行性与潜在优势,并为天文学和航天领域提供更准确和可靠的星图质心数据,推动星敏感器等相关领域的发展和应用。

1 数据与方法

1.1 数据采集与预处理

为了进行神经网络训练,首先需要构建训练数据集。本研究使用的数据集是通过理想高斯拟合来生成的仿真星图。理想高斯拟合是一种常用的方法,用于模拟天文图像中的星点。

首先,通过设置星点的高斯半径大小、质心位置、星点能量大小、背景噪声大小等,仿真生成星光经过星敏光学系统后形成理想点扩散函数(Point Spread Function, PSF)^[18]。假设 u 方向和 v 方向高斯半径分别为 $\text{sig } u$ 和 $\text{sig } v$,其中, sig 表示高斯函数的标准差,代表星点在对应方向上的扩散程度。更大的 sig 值意味着星点在该方向上更加模糊。仿真生成两组 1σ 分别为 $1000 \cdot \text{sig } u$ 和 $1000 \cdot \text{sig } v$ 的高斯曲线,这里的 1000 表示高斯曲线在生成过程中被缩放以模拟实际星图中像素的精细度。然后,将两组曲线相乘,形成二维曲面,即为 PSF 分布,如图 1 所示。




图1 PSF 分布规则
Fig. 1 PSF distribution rules

在仿真生成的星图中,质心位置是指星点的

中心位置,它表示星光最强的区域的几何中心。而像素格是指数字图像中的基本单元,每个像素格代表图像中的一个小方块区域。通过调整高斯半径、星点能量和背景噪声的大小,可以生成具有不同特征的星点,以此来模拟不同条件下的天文观测图像。这些仿真图像为神经网络的训练提供了丰富的数据支持。

假设星点在 u 方向和 v 方向上的质心位置分别为 x 和 y ,PSF 分布可以表示为:

$$\text{PSF}(x, y) = G(x; \sigma_u) \cdot G(y; \sigma_v)$$

式中: G 表示一维高斯分布函数, σ 为高斯分布的标准差。

假设星点在 u 方向和 v 方向上的质心位置分别为 x 和 y ,将 PSF 图像的中心位置对正星点在像素格上的质心位置 (x, y) ,每个像素格内应包含的 1000×1000 个 PSF 数据点,将每个像素格内的 PSF 数据点相加即可得出像素值,最后形成 iPSF 图像,如图 2 所示。




图 2 iPSF 图像组成
Fig. 2 iPSF image composition

根据设置星点能量大小,按照下式仿真形成总能量为 E 的星图:

$$I(x, y) = \frac{I_0(x, y)}{\sum I_0} \cdot E$$

式中: $I(x, y)$ 表示最终的星图; $I_0(x, y)$ 表示 iPSF 图像; $\sum I_0$ 表示所有像素值的总和。

最后,为了增加数据的真实性,根据设置的背景噪声大小,本研究在星图中添加了高斯分布

的背景噪声 $N(x, y)$ 。将星图和背景噪声相加,得到最终的带有背景噪声的星图:

$$I(x, y) = I(x, y) + N(x, y)$$

生成的数据集以 .raw 文件的形式保存在指定文件夹中。每个 .raw 文件包含一个星图的数据。每个星图由一个 24×24 像素的灰度图像表示,其中每个像素的值表示该位置的亮度。

1.2 基于回归的深度学习方

基于回归的深度学习方^[19]是一种用于解决回归问题的强大工具。它利用深度神经网络模型来学习输入特征与连续值输出之间的复杂非线性关系。深度神经网络通常由多个隐藏层组成,其中包括卷积层、池化层和全连接层等。

深度神经网络的原理是通过反向传播算法和优化方法(如梯度下降)来训练模型,使其能够自动地学习到最优的权重和偏置参数。基于回归的深度学习模型可以表示为:

$$\hat{y} = F(X; \theta)$$

式中: $\hat{y}$ 表示模型的预测输出; f 表示深度神经网络的映射函数; X 是输入特征; θ 表示模型的参数。

基于回归的深度学习方具有以下优势。

1) 拟合能力:深度神经网络的拟合能力确实强大,它们可以适应不同规模和复杂度的数据集。无论是处理简单的线性关系还是复杂的非线性关系,深度神经网络都能够通过多个隐藏层的组合来捕捉数据中的模式。这种灵活性使得它们在各种回归问题中都表现出色,从简单的函数拟合到复杂的现实世界数据预测。

2) 特征学习:深度神经网络的一个重要优势是它们能够自动地学习输入数据中的有用特征表示,无需手动设计特征。通过多个卷积层和池化层,模型可以逐渐提取出数据中的高级特征,从而提高回归预测的准确性。这种特征学习不仅减轻了特征工程的负担,还使得模型能够更好地理解和利用数据,从而提高了模型的性能和泛化能力。

3) 泛化能力:深度学习模型在足够大且具有代表性的数据集上训练后,通常具有较强的泛化能力。为了验证模型的泛化能力,常见的方法包括交叉验证、验证集评估等。例如,在图像回归

问题中,模型在训练过程中可能会遇到各种各样的图像,但只有当模型在不同类型的图像上都表现出色时,才能说明它具有较强的泛化能力。这使得模型对于输入数据的变化和噪声具有较强的鲁棒性,在面对未见过的数据时也能够做出准确的预测。

不同类型的基于回归的深度学习方法在具体任务和数据集上可能会有不同的优劣势。例如,卷积神经网络在处理图像数据时表现出色,能够通过卷积和池化操作来提取空间特征。在CNN中,主要的组成部分是卷积层和池化层。卷积层通过卷积操作对输入数据进行特征提取,池化层则通过降采样操作减少特征图的维度。卷积操作的公式如下:

$$Y^{(C)} = \sum_{i=1}^N X^{(C)} \cdot W_i^{(C)} + b$$

式中: $Y^{(C)}$ 是卷积层的输出特征图; $X^{(C)}$ 是输入特征; $W^{(C)}$ 是卷积核(权重)。通过滑动卷积核在输入数据上进行卷积操作,可以得到输出特征图。

池化操作的公式如下:

$$Y^{(p)} = \text{pooling}(X^{(p)})$$

式中: $Y^{(p)}$ 是池化层的输出特征图; $X^{(p)}$ 是输入数据。池化操作通常是取输入数据中的最大值或平均值作为输出特征图的元素。

而全连接神经网络(FC)是一种常见的神经网络结构,其中每个神经元都与前一层的所有神经元相连接。全连接神经网络能够更好地整合特征信息,并进行回归预测。

全连接神经网络的公式如下:

$$Y^{(f)} = f(X^{(f)}W^{(f)} + B^{(f)})$$

式中: $Y^{(f)}$ 是全连接神经网络的输出; $X^{(f)}$ 是输

入特征; $W^{(f)}$ 是权重参数; $B^{(f)}$ 是偏置参数; f 是映射函数。

通过将卷积神经网络的输出连接到全连接神经网络,可以实现特征学习和整合。卷积神经网络提取输入数据中的局部特征,而全连接神经网络通过参数化的权重和偏置对特征进行整合和映射,从而实现更高级别的特征表示和模式识别。

本文将通过使用卷积神经网络来提取星图的局部特征,并使用全连接神经网络整合星图的特征进行回归预测,进而充分利用两者的优势,实现星图质心高精度智能测量。

2 基于 DLCCM 的模型构建与训练

2.1 模型架构

本研究提出了一种基于深度学习的质心测量方法,即一种融合卷积神经网络(CNN)和全连接神经网络的深度学习模型,旨在解决星图质心提取任务。该模型的设计旨在充分利用CNN在图像特征提取方面的优势,并结合全连接神经网络的能力来映射提取的特征到输出类别,进而实现对星图质心的快速高精度提取。

如图3所示,该深度学习模型首先包含了一系列卷积层(Conv₁等),用于从星图图像中提取特征。这些卷积层采用了不同大小的滤波器,并通过卷积操作来捕捉图像中的局部特征。同时,为了保持特征图的大小不变,采用了填充技术。通过多个卷积层的堆叠,模型能够逐渐提取出更加抽象和高级的特征。




图3 神经网络结构

Fig. 3 Neural network architecture

在卷积层之后,引入了全连接神经网络(fc_1 等),通过连接所有神经元来建立特征与类别之间的关系,将提取的特征映射到输出类别。这样的设计使得模型能够学习到更复杂的特征组合,并提高对输入图像的理解能力。

此外,全连接神经网络还具备非线性建模能力,通过引入非线性激活函数,如 ReLU、sigmoid 等,可以对输入数据进行更灵活和复杂的建模。这使得模型能够处理非线性关系,提高对输入数据的表达能力。

最后,全连接神经网络的参数学习能力也在该模型中发挥作用。通过反向传播算法,全连接层的权重和偏置可以进行学习和调整,以最小化损失函数。通过不断迭代和优化,全连接层能够不断改进模型的性能,提高星图质心提取任务的准确性和鲁棒性。

为了训练该深度学习模型,使用了适当的优化算法和损失函数。常见的优化算法如 Adam 被广泛采用,用于调整网络中的权重和偏置,以最小化损失函数。损失函数的选择通常取决于任务的性质,例如在星图质心提取任务中,本文使用了 Huber 回归损失函数来度量星图质心预测位置与真实位置之间的差异。

因此,融合了卷积神经网络和全连接神经网络的深度学习模型在解决星图质心提取任务中,充分利用了 CNN 在图像特征提取方面的优势,并结合了全连接神经网络的特征组合能力、非线性建模能力和参数学习能力,从而能够准确地提取星图中的质心位置,并为相关应用提供了有效的解决方案。

2.2 模型训练过程

本节详细介绍了基于深度学习的质心测量方法(DLCM)的模型训练过程。该过程包括数据准备、模型构建、损失函数定义、参数初始化、模型训练、模型评估与调优等步骤。

(1)数据准备

首先,需要准备用于训练的星图数据集,包括星图图像和对应的质心位置标签。数据集应

具有足够的样本数量和多样性,以覆盖各种星图特征和模式。

(2)模型构建

DLCM 采用卷积神经网络(CNN)和全连接神经网络构建模型。CNN 用于提取星图图像的特征,全连接层将这些特征映射到质心位置的输出类别。模型的架构可以根据具体任务进行设计和调整,如 LeNet^[20]、AlexNet^[21]、VGG^[22]、ResNet^[23]等。

(3)损失函数定义

为了训练模型,需要定义一个损失函数来衡量模型输出与真实质心位置标签之间的差异。常见的损失函数包括均方误差(MSE)和交叉熵损失函数等。选择适当的损失函数有助于模型更好地拟合数据并提高训练效果。

(4)参数初始化

在训练之前,对模型的参数进行初始化。常见的初始化方法包括随机初始化和预训练模型的加载。适当的参数初始化方法可以加速模型的收敛和提高训练效率。

(5)模型训练

使用准备好的数据集,将星图图像输入模型,并计算损失函数。通过反向传播算法更新模型的参数,以最小化损失函数。训练过程通常采用批量梯度下降法(Batch Gradient Descent)^[24]或随机梯度下降法(Stochastic Gradient Descent)^[25]等优化算法。通过迭代和优化,模型逐渐学习到星图质心的特征和模式。

(6)模型评估与调优

在训练过程中,使用验证数据集对模型进行评估,以了解模型的性能和泛化能力,然后根据评估结果,对模型进行调优,如调整模型的超参数、增加训练数据集的样本数量、进行数据增强等。通过不断调优和改进,模型的性能和泛化能力可以得到提升。

通过以上步骤,可以构建和训练一个准确和可靠的 DLCM 模型,用于解决星图质心提取任务。模型训练过程中的数据准备、模型构建、损失函数定义、参数初始化、模型训练、模型评估与调优等步骤将确保模型的性能和泛化能力。

3 实验设计与结果分析

3.1 实验设计

在本实验中,为了确保与在轨星图保持一致性,首先统计了某型号星敏感器在轨拍摄的大量星图的实测数据,详细数据见表 1。然后,基于这些星图参数,经过拉丁超立方抽样,利用 Python 进行星图数值仿真,分别生成了训练数据集(16 万张)、验证数据集(2 万张)和测试数据集(2 万张),每张星图均由 24×24 像素的 raw 格式理想高斯星图组成。这些数据集确保了星点的高斯半径、星点质心位置、背景噪声以及平均信噪比等涵盖了表 1 所统计数据的整个范围。每张星图都包含了质心位置和高斯半径大小等标签信息,从而更好地模拟了真实星图的多样性和复杂性。具体的星图数值仿真过程和步骤可参考第 1 节的 1.1 小节。

表 1 星图统计数据 Table 1 Star image statistics		
Parameters	Acronym	Data range/ pixel
Gaussian radius	R_u, R_v	0.5-1.5
Centroid position	C_u, C_v	7-20
Window background noise	N	2-2.5
Average signal-to-noise ratio	S/N	7-35

为了更好地展示实验对象的特征,本文提供了一些仿真星图的示例图像,如图 4 及表 2 所示。




图 4 仿真星图
Fig. 4 Simulated star images

表 2 星图参数 Table 2 Star image parameters						
Case No.	Gaussian radius/pixel		Centroid position/pixel		Noise	Average signal-to-noise ratio
	R_u	R_v	C_u	C_v	N	S/N
1	0.955	1.067	9.874	17.375	2.420	35.181
2	1.447	1.193	15.227	11.483	2.307	19.469
3	1.334	0.814	14.749	15.104	2.456	25.161
4	0.521	0.625	10.012	14.509	2.256	27.577
5	0.768	1.242	12.466	16.020	2.082	46.778
6	0.865	1.410	9.526	19.755	2.036	14.620
7	1.004	1.345	18.996	13.963	2.113	44.081
8	1.213	0.526	19.336	10.694	2.208	32.589
9	1.158	0.718	19.132	16.874	2.368	11.552
10	0.654	0.926	17.659	14.273	2.175	38.871

3.2 实验实施

3.2.1 训练数据量对模型性能的影响分析

在本实验中,选取了不同大小的训练数据集,包括 1 000、5 000、10 000、50 000、100 000 和

160 000 张 24×24 像素的星图,这些星图涵盖了各种不同位置、模糊程度和噪声水平,以确保实验的全面性和可靠性。

在训练过程中,采用了 Z-Score 归一化方法对输入数据进行归一化处理,以消除不同数据范围的影响,确保模型的稳定性和可靠性。同时,

使用第 2.1 节所述的基于 DLCM 的神经网络模型通过 PyTorch 深度学习框架进行训练,相关超参数如表 3 所示。最佳超参数的选择通常基于先前的研究经验、实验结果以及对当前任务和数据集的理解,然后通过多次迭代计算和优化得到,推荐使用 Optuna^[26] 进行超参数优化,该库支持并行化和分布式计算,提供了多种优化算法,包括基于贝叶斯优化的 Tree-structured Parzen Estimator (TPE)等,能够实现超参数自动化搜索,显著提升优化效率。

表 3 神经网络模型超参数	
Table 3 Neural network hyperparameters	
Hyperparameters	Value
Optimizer	Adam
MaxEpochs	1 000
InitialLearnRate	0.001 090 8
MiniBatchSize	256
LearnRateDropFactor	0.25
LearnRateDropPeriod	56
ValidationFrequency	96
Loss function	Huber

在不同大小的训练数据集下(分别为 1 000、5 000、10 000、50 000、100 000 和 160 000 张 24×24 像素的星图),分别训练了对应的模型,共获得了 6 个模型。随后,使用相同的测试数据集(2 万张星图)对这些模型的星图质心预测性能(包括 u 和 v 方向)进行了测试评估,并记录了相应的模型预测误差的平均值和标准差。具体的测试结果与对比分析如图 5 所示。

实验结果显示,随着训练数据量的增加,模型的性能逐渐提高。这表明了数据量对模型性能的重要性,更多的数据有助于模型学习更准确的模式和特征。当训练数据量达到 5 万张星图时,模型的性能已经接近传统方法。这表明即使在相对较少的训练数据情况下,基于深度学习的模型也能取得可观的性能。进一步增加训练数据量至 16 万张星图时,模型的性能已经超越传统方法,但是提升效果不明显。这可能意味着模型已经对数据集中的主要模式和特征学习得差不多了,进一步增加数据量对性能的改善效果不




图 5 预测误差的平均值与标准差随训练数据量变化曲线

Fig. 5 Curve of the mean and standard deviation of prediction error as a function of training data volume

大。由此可以判断,适当的训练数据量可以提高模型性能,但过多的训练数据并不一定能带来显著的性能提升。这表明了在资源有限的情况下,选择合适的数据量是重要的,避免了不必要的数据收集和处理成本

此外,当训练数据量达到 16 万时,所得模型对训练集和测试集分别进行评估测试,对应的模型预测误差概率分布如图 6 所示,训练集与测试集两条曲线拟合效果很好,表明模型对训练集和测试集的拟合效果相当,无欠拟合及过拟合的潜在风险。




图 6 误差概率分布

Fig. 6 Error probability distribution

3.2.2 归一化方法对模型性能的影响分析

从第 3.2.1 小节可以看出,当训练数据量为 16 万时,模型预测效果最佳,因此,在本节进行归一化方法对模型性能的影响分析时,训练数据量设置为 16 万张 24×24 像素的星图,这些星图

涵盖了各种不同位置、模糊程度和噪声水平,以确保实验的全面性和可靠性。归一化方法采用了 Min-Max 归一化和 Z-Score 归一化两种方法,其中,在 Min-Max 归一化中,对比分析分别将输入数据归一化到 $[0,1]$ 和 $[-1,1]$ 范围后,训练所得模型的性能差异。使用第 2.1 小节所述的基于 DLCM 的神经网络模型通过 PyTorch

深度学习框架进行训练,相关的超参数与第 3.2.1 小节保持一致,共获得 3 个模型。

随后,使用相同的测试数据集(2 万张星图)对这些模型的星图质心预测性能(包括 u 和 v 方向)进行了测试评估,并记录了相应的模型预测误差的平均值和标准差。具体的测试结果与对比分析如表 4 所示。

表 4 不同归一化方法对比分析
Table 4 Comparative analysis of different normalization method

Parameters	Mean of prediction error/pixel		Standard deviation of prediction error/pixel	
	u	v	u	v
Min-Max $[0,1]$	0.000 74	0.000 74	0.041 2	0.041 0
Min-Max $[-1,1]$	0.000 65	0.000 66	0.040 1	0.039 8
Z-Score	0.001 3	0.001 5	0.019 0	0.019 1

实验结果显示,最大最小值归一化方法对模型性能的提升效果并不明显,这可能是因为该方法无法很好地处理数据分布的不均匀性,导致模型在训练过程中无法充分利用数据的特征。Z-Score 归一化方法对模型性能的提升效果明显, 3σ 内标准差相较于最大最小值归一化方法,性能提升了近一倍。这可能是因为 Z-Score 归一化方法能够更好地将数据集集中在均值附近,使得模型更容易学习到数据的特征和规律。在星图质心提取任务中,选择适当的归一化方法对模型的性能提升具有显著影响。因此,在实际应用中,应根据具体任务和数据特征选择合适的归一化方法,以提高模型的性能和稳定性。

3.2.3 信噪比大小对模型性能的影响分析

为了更全面地评估基于 DLCM 的神经网络模型在不同信噪比下对星图质心预测的性能,本研究将该模型与传统的一阶质心法、二阶质心法和高斯拟合法进行了对比分析。

本研究所使用的训练数据集包含 16 万张 24×24 像素的星图,这些星图涵盖了各种不同位置、模糊程度和噪声水平,以确保实验的全面性和可靠性。在读取所有星图数据后,本研究对其进行了 Z-Score 归一化处理,然后使用第 2.1 小节所述的基于 DLCM 的神经网络模型通过 PyTorch 深度学习框架进行训练,相关的超参数与第 3.2.1 小节保持一致通过训练,通过迭代训

练与优化,获得最优的模型。

本研究将这个最优模型与传统的一阶质心法、二阶质心法和高斯拟合法进行了对比测试。测试使用的是相同的测试数据集(2 万张星图)。如图 7 所示,对比分析了不同星图质心测量方法的预测误差随信噪比的变化。




图 7 信噪比大小对模型性能的影响分析
Fig. 7 Analysis of the impact of signal-to-noise ratio on model performance

实验结果显示,本文所提出的基于 DLCM 的神经网络模型、传统的一阶质心法、二阶质心法及高斯拟合法对信噪比低的星图质心测量精度较低,这可能是因为低信噪比条件下,星图中

的信号与噪声之间的差异不够明显,导致模型难以准确捕捉质心位置。相反,对于信噪比高的星图,信号与噪声之间的差异更为明显,因此模型的预测精度更高。在各种质心测量方法中,高斯拟合法的预测误差标准差最小,这可能是因为高斯拟合法能够更好地拟合星图中的数据分布。而本文所提出的基于 DLCM 的神经网络模型的预测误差标准差仅次于高斯拟合法,相对于一阶质心法、二阶质心法,具有更好的性能,这表明了深度学习模型在质心预测任务上的潜力和优势。

3.2.4 与传统星图质心测量方法的对比分析

从第 3.2.1 小节可以看出,当训练数据量达到 16 万时,模型性能达到最佳状态。而从第 3.2.2 小节可以得知,采用 Z-Score 归一化方法时,模型性能表现最佳。因此,在本节的分析中,将采用训练数据量为 16 万张 24×24 像素的星图,使用 Z-Score 归一化方法进行数据预处理,然后使用第 2.1 小节所述的基于 DLCM 的神经网络模型通过 PyTorch 深度学习框架进行训练,相关的超参数与第 3.2.1 小节保持一致通过训练,通过迭代训练与优化,获得最优的模型。

为了验证不同质心测量方法的性能差异,本研究选择了一阶质心法、二阶质心法和高斯拟合法作为对照组,使用相同的测试数据集(2 万张星图)对这些模型的星图质心预测性能(包括 u 和 v 方向)进行了测试评估,不同星图质心测量方法在 3σ 内测量误差的标准差,以及对相同的测试数据集(2 万张星图)进行质心测量所耗费总时间如表 5 所示。

表 5 不同星图质心测量方法预测误差与计算时间
Table 5 Prediction error and computation time of different star centroid measurement methods

Methods	Standard deviation of model prediction error within 3σ /pixel		Computation time/s
	u	v	
DLCM	$[-0.0528, 0.0552]$	$[-0.0528, 0.0552]$	3.39
FMC	$[-0.0993, 0.0972]$	$[-0.0996, 0.0975]$	14.93
SMC	$[-0.0633, 0.0615]$	$[-0.0635, 0.0614]$	14.45
GF	$[-0.0509, 0.0490]$	$[-0.0510, 0.0489]$	32.37

实验结果显示与一阶质心法和二阶质心法相比,基于 DLCM 的神经网络模型在测试集星图质心提取方面的平均误差达到了 0.0015 像素,标准差为 0.0191 像素, 3σ 内可以达到 0.05 像素的星图质心测量精度,处理 2 万张星图耗时仅 3.39 s,计算精度与效率均有明显的提升。本文所提出的基于 DLCM 的神经网络模型的 3σ 内测量误差的标准差仅次于高斯拟合法,略有 7.78% 的差距,但高斯拟合法计算复杂度高且效率低,关键难以实现在轨应用。基于 DLCM 的神经网络模型计算效率更高、计算复杂度更低、体积小,且具备在轨应用的可行性,在性能上又显著优于传统的一阶质心法和二阶质心法。

4 结论

针对星敏感器在轨拍摄的星图光斑质心测量精度和计算效率的挑战,本研究提出了一种基于深度学习的质心测量方法(Deep Learning-based Centroid Measurement, DLCM)。DLCM 采用卷积神经网络来识别星图复杂特征,并在网络结构的输出部分设置多个全连接层用于回归预测质心位置。通过仿真实验验证了该方法的可行性,并通过与传统星图质心测量方法对比分析,结果表明:深度学习模型通过大规模训练数据的学习,可以对不同状态下的星图都有较好的预测精度,具有较好的鲁棒性。相比传统方法,深度学习模型能够更好地处理信噪比较低、星点位置靠近边缘等复杂情况,提高预测的稳定性和准确性,即深度学习技术在星图质心提取方面具有较高的预测精度,能够更准确地估计星图质心的位置。此外,进一步增加训练数据量以及优化超参数、归一化方法等,深度学习模型的预测精度可以得到进一步提升。

未来的研究将重点探究在理想高斯星图下训练的深度学习模型对真实光学系统在轨拍摄的带有畸变和噪声的星图质心测量的预测性能。此外,研究还将评估各类大模型在星图质心测量中的适用性,为进一步改进星图质心提取任务的方法和方法的工程应用提供指导。

参考文献(References)

- [1] 梁斌,朱海龙,张涛,等.星敏感器技术研究现状及发展趋势[J].中国光学(中英文),2016,9(1):16-29.
LIANG B, ZHU H L, ZHANG T, et al. Research status and development tendency of star tracker technique[J]. Chinese Optics, 2016, 9(1): 16-29(in Chinese).
- [2] 张艳艳,郝晓龙,陈洁玮.加门限的一阶矩光斑质心探测方法[J].光学技术,2015(1):59-63.
ZHANG Y Y, HAO X L, CHEN J W. First moment spot centroid detection with a threshold to compute the centroid [J]. Optical Technology, 2015 (1): 59-63 (in Chinese).
- [3] 师亚萍,刘缠牢.提高夏克-哈特曼波前传感器光斑质心的定位精度[J].Laser & Optoelectronics Progress, 2017, 54(8):175-181.
SHI Y P, LIU C L. Positioning accuracy improvement of spot centroid for Shack-Hartmann wave front sensor[J]. Laser & Optoelectronics Progress, 2017, 54(8): 175-181 (in Chinese).
- [4] 王敏,赵金宇,陈涛.基于各向异性高斯曲面拟合的星点质心提取算法[J].光学学报,2017,37(5):226-235.
WANG M, ZHAO J Y, CHEN T. Center extraction method for stargmap targets based on anisotropic gaussian surface fitting [J]. Acta Optica Sinica, 2017, 37(5): 226-235(in Chinese).
- [5] 张俊,郝云彩,刘达.迭代加权质心法机理及多星定位误差特性研究[J].光学学报,2015,35(2):23-33.
ZHANG J, HAO Y C, LIU D. Investigation on themechanism and positioning error of multi-star spots extraction of iteratively weighted center of gravity algorithm[J]. Acta Optica Sinica, 2015, 35(2): 23-33 (in Chinese).
- [6] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [7] 王瑞琳,王立,贺盈波,等.空间点目标神经形态学探测方法[J].中国空间科学技术(中英文),2024,44(3):98-110.
WANG R L, WANG L, HE Y B, et al. Space point object neuromorphological detection method[J]. Chinese Space Science and Technology, 2024, 44 (3): 98-110 (in Chinese).
- [8] 周驰,李智,徐灿.基于深度神经网络的空间目标结构识别[J].中国空间科学技术,2019,39(1):32-39.
ZHOU C, LI Z, XU C. Research on spatial target structure recognition based on deep neural network [J]. Chinese Space Science and Technology, 2019, 39 (1): 32-39 (in Chinese).
- [9] 秦健凯,李鹏.基于双滤波器的高精度目标跟踪估计方法[J].中国空间科学技术,2021,41(5):116-124.
QIN J K, LI P. High-accuracy target tracking estimation based on dual Kalman filter[J]. Chinese Space Science and Technology, 2021, 41(5): 116-124(in Chinese).
- [10] 周飞燕,金林鹏,董军.卷积神经网络研究综述[J].计算机学报,2017,40(6):1229-1251.
ZHOU F Y, JIN L P, DONG J. Review of convolutional neural network[J]. Chinese Journal of Computers, 2017, 40(6): 1229-1251(in Chinese).
- [11] 刘建伟,宋志妍.循环神经网络研究综述[J].控制与决策,2022,37(11):2753-2768.
LIU J W, SONG Z Y. Overview of recurrent neural networks[J]. Control and Decision, 2022, 37(11): 2753-2768(in Chinese).
- [12] ZAPEVALIN P R, NOVOSELOV A, ZHAROV V E. Artificial neural network for star tracker centroid computation[J]. Advances in Space Research, 2023, 71(9):3917-3925.
- [13] LI Z Q, LI X. Centroid computation for Shack-Hartmann wavefront sensor in extreme situations based on artificial neural networks [J]. Optics Express, 2018, 26 (24): 31675-31692.
- [14] 方波浪,王建国,冯国斌.基于物理信息神经网络的光斑质心计算[J].物理学报,2022,71:200601.
FANG B L, WANG J G, FENG G B. Calculation of spot centroid based on physical informed neural networks [J]. Acta Physica Sinica, 2022, 71: 200601(in Chinese).
- [15] 张光华,王福豹,段渭军.基于GAN的天文图像生成研究[J].西北工业大学学报,2019,37(2):315-322.
ZHANG G H, WANG F B, DUAN W J. Study on star-galaxy image generation method based on GAN [J]. Journal of Northwestern Polytechnical University, 2019, 37(2): 315-322(in Chinese).
- [16] 徐亮,符冉迪,金炜,等.基于多尺度特征损失函数的图像超分辨率重建[J].光电工程,2019,46(11):1-9.
XU L, FU R D, JIN W, et al. Image super-resolution reconstruction based on multi-scale feature loss function [J]. Opto-Electronic Engineering, 2019, 46 (11): 1-9 (in Chinese).
- [17] ODUSAMI M, MASKELIŪNAS R, DAMAŠEVIČIUS R, et al. Analysis of features of Alzheimer's disease: detection of early stage from functional brain changes in magnetic resonance images using a finetuned ResNet18 network[J]. Diagnostics, 2021, 11(6):1071.
- [18] 杨利红,赵变红,张星祥,等.点扩散函数高斯拟合估计与遥感图像恢复[J].中国光学,2012,5(2):181-188.
YANG L H, ZHAO B H, ZHANG X X, et al. Gaussian fitted estimation of point spread function and remote sensing image restoration [J]. Chinese Optics, 2012, 5 (2): 181-188(in Chinese).
- [19] QIU X, ZHANG L, REN Y, et al. Ensemble deep learning for regression and time series forecasting[C]// Proc. of 2014 IEEE Symposium on Computational

- Intelligence in Ensemble Learning (CIEL). Orlando: IEEE, 2014: 1-6.
- [20] LECUN Y, JACKEL L D, BOTTOU L, et al. Learning algorithms for classification: a comparison on handwritten digit recognition[J]. Neural Networks: The Statistical Mechanics Perspective, 1995, 261(276): 2.
- [21] YUAN Z W, ZHANG J. Feature extraction and image retrieval based on AlexNet [C] // Eighth International Conference on Digital Image Processing (ICDIP 2016). Chengdu: SPIE, 2016: 65-69.
- [22] TAMMINA S. Transfer learning using vgg-16 with deep convolutional neural network for classifying images[J]. International Journal of Scientific and Research Publications(IJSRP), 2019, 9(10): 143-150.
- [23] WU Z F, SHEN C, HENGEL A. Wider or deeper: revisiting the resnet model for visual recognition[J]. Pattern Recognition, 2019, 90: 119-133.
- [24] KHIRIRAT S, FEYZMAHDAVIAN H R, JOHANSSON M. Mini-batch gradient descent: Faster convergence under data sparsity[C] // Proc. of 2017 IEEE 56th Annual Conference on Decision and Control(CDC). Melbourne: IEEE, 2017: 2880-2887.
- [25] BOTTOU L. Stochastic gradient descent tricks[M] // Neural Networks: Tricks of the Trade: 2nd Ed. Berlin: Springer Berlin Heidelberg, 2012: 421-436.
- [26] AKIBA T, SANO S, YANASE T, et al. Optuna: a next-generation hyperparameter optimization framework[C] // Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. Toronto: Association for Computing Machinery, 2019: 2623-2631.

作者简介:

熊琰(1992—), 男, 博士后, 研究方向为空间光电测量技术, xiongyan_academic@163.com。

武延鹏(1977—), 研究员, 研究方向为空间导航敏感器总体技术, wuyanpeng@gmail.com。

(编辑:高珍)