

分类号

密 级

太原理工大学

硕 士 学 位 论 文

题 目 深度学习用于天文图像空间碎片和恒星的分类

英文并列题目 Classification of Space Debris and Stars in Astronomic
Images Based on Deep Learning

研究生姓名：刘丹枫

学 号：2015520195

专 业：电子与通信工程

研 究 方 向：深度学习

导 师 姓 名：刘建霞

职 称：教授

论文提交日期 2018/05

学位授予单位：太原理工大学

地 址：山西·太原

太 原 理 工 大 学

深度学习用于天文图像空间碎片和恒星的分类

摘 要

随着太空探索的持续发展，航天器源源不断的被发往太空，退役的航天器以及航天器之间撞击直接导致了太空中空间碎片的数量的爆炸性增长。数量剧增的空间碎片反过来对太空探索也造成了严重的安全威胁，因此带动了相关空间碎片的研究。目前关于探测空间碎片的主要途径有雷达探测和望远镜观测，其中本文讨论的属于望远镜观测范畴。

目前，被广泛使用的识别空间碎片的软件是 SExtractor，原理是通过对望远镜观测到的天文图像进行图像处理，通过星象和空间碎片相对于望远镜运动速度的差异来对星象和空间碎片进行分类。

深度学习起源于机器学习中的神经网络，因其具有模仿人脑的结构而作为通往人工智能的重要的探索之一。其中，深度学习中的卷积神经网络作为一款性能优异的分类器也是图像处理重要的手段之一，本文探讨了用卷积神经网络通过望远镜的观测图像进行空间碎片的识别的可行性以及正确率，本文的工作如下：

(1) 本文在 caffe 的框架下搭建卷积神经网络进行空间碎片的识别实验并和 SExtractor 的正确率进行比较。其中，关于卷积神经网络的学习率参数，本文提出了用皮尔森检验筛选学习率的方法。

(2) 由于天文图像的特殊性，本文在之后对卷积神经网络的噪声的耐

受力进行了评估。通过试验验证了卷积神经网络的鲁棒性后，针对天文图像，提出了简单的图象处理以提高图像信噪比的方法并进行实验验证。

关键词：空间碎片，深度学习，卷积神经网络，皮尔森检验，信噪比

CLASSIFICATION OF SPACE DEBRIS AND STARS IN ASTRONOMIC IMAGES BASED ON DEEP LEARNING

ABSTRACT

With the continuous development of space exploration and spacecraft are continuously sent to space, the collision between spacecraft directly leading an explosive increase in the number of space debris. The increase in the number of space debris poses a serious security threat to space exploration in turn, which led to the study of relevant issues in space debris. At present, radar detection and telescope observations are the main ways to detect space debris. This article is about telescope observation.

Currently, the widely used software for identifying space debris is SExtractor. Its principle is to process the astronomical images observed by the telescope and classify the stars and space debris by the difference in the movement speeds of the stars and space debris.

Deep learning originated in neural networks in machine learning, and it has as one of the most important explorations into artificial intelligence because its structure simulates the human brain. Among them, the convolutional neural network in deep learning as an excellent classifier is also one of the important

methods of image processing. This paper discusses the feasibility and correctness of the recognition of space debris by the convolutional neural network through the observation images of the telescope. The rate of this article is as follows:

(1) In this paper, a convolutional neural network is constructed under the framework of caffe for space debris recognition experiments and compared with the accuracy of SExtractor. Among them, regarding the learning rate parameter of convolutional neural network, this paper proposes a method of screening learning rate by Pearson test.

(2) Due to the particularity of astronomical images, this paper evaluates the noise tolerance of convolutional neural networks. After verifying the robustness of convolutional neural network through experiments, a simple image processing method is proposed to improve image signal-to-noise ratio for astronomical images and experimental verification is performed.

KEY WORDS: space debris, deep learning, convolutional neural network, Pearson test, SNR

目录

第一章 绪论	1
1.1 课题背景以及研究的意义	1
1.2 研究现状与不足	2
1.3 目前主流应用软件的介绍	3
1.4 论文的主要工作及安排	4
第二章 空间碎片及预警	7
2.1 空间碎片研究现状及其危害	7
2.2 空间碎片预警以及国际关于碎片预警现状	10
第三章 深度学习及卷积神经网络	13
3.1 神经网络	13
3.1.1 神经元	13
3.1.2 前馈以及反馈神经网络	16
3.1.3 反向传播神经网络	20
3.1.4 神经网络的学习规则	21
3.1.5 神经网络目前的不足	22
3.2 深度学习概述	24
3.2.1 递归神经网络	24
3.2.2 卷积神经网络	25
3.3 卷积神经网络 (CNN)	27
3.3.1 卷积神经网络基本模型	27
3.3.2 稀疏连接和权值共享	29
3.3.3 CNN 的应用	30
3.3.4 目前几种主流框架的介绍	31
3.4 本章小结	32
第四章 基于 CNN 的空间碎片识别	33
4.1 数据来源以及处理	33

4.2 卷积神经网络的基本构建.....	36
4.3 学习参数的选取方法.....	39
4.3.1 目前研究采用的选取方法.....	39
4.3.2 基于皮尔森检验的筛选方法.....	39
4.4 结果及讨论.....	40
第五章 CNN 对信噪比耐受性的评估	45
5.1 对于 CNN 削弱噪声的理论推导	45
5.2 实验配置和结果.....	46
5.3 本章小结.....	48
第六章 总结与展望.....	49
参考文献.....	50

第一章 绪论

1.1 课题背景以及研究的意义

1957 年,从苏维埃社会主义共和国联盟发射人造卫星到太空运行之后,人类正式迈进了探索太空的时代。从此,太空中运行的航天器数量与日俱增,太空逐渐紧凑的空间导致发生空间碰撞的事故概率增大,一连串的航天器碰撞事故致使空间环境污染愈来愈严重以及近地目标数量急剧上升。太空垃圾主要指的是空间碎片,地球轨道上或重返大气层的无功能人造物体。

近些年来,一系列太空中的航天器意外事故引起了国际社会对于空间环境的重视。1973 年,Delta 运载火箭爆炸;1993 年成立机构间空间碎片协调委员会(Inter-Agency Space Debris Coordination Committee, IADC)^[1];2007 年 1 月,中国利用动能 ASAT 击中了一颗退役气象卫星“FYIC”;同年 2 月,俄罗斯的“Breeze-M”火箭在太空的近地轨道面发生爆炸;2008 年 2 月,美国海军用一枚导弹摧毁了“USA 193”号大型侦察卫星;2009 年 2 月,美国铱星公司的“Iridium 33”卫星与俄罗斯的“Cosmos 2251”军用通信卫星发生碰撞事故^[2]。这些事故导致太空垃圾也就是太空碎片的数量在近一些年的急剧增加,太空碎片时时威胁着发射卫星的安全,促使国际社会加大对于此项课题的研究力度。

目前已探知的空间碎片根据 MASTER-2009(欧空局建立的一种空间碎片模型)标准,来源有 8 种,包括失去功能的卫星、任务相关碎片、解体碎片、NaK 液滴、固体火箭发动机喷射物、航天器表面溅射物、WestFord 铜针、太阳帆板碎片等^[3]。目前,美军利用地面雷达持续追中的有 2 万多个比棒球大的空间碎片。根据空间碎片的体积分类,目前太空中现有的三种空间碎片:直径大于 10 厘米的大空间碎片有 2 万多个;大于 0.1 厘米小于 10 厘米的危险空间碎片则有 13 亿 5 千万多个;还有难以估计数量的小于 0.1 厘米的小空间碎片。

关于空间碎片的研究主要有几类:空间碎片观测、空间碎片预警、空间碎片防护、空间碎片减缓、空间碎片环境建模等^[4]。空间碎片探测指使用地面的大型探测雷达或是望远镜对空间碎片进行甄别观测以及追踪,获取的天文图像并进行分析追踪。空间碎片预警就是在监视航天器运行过程中,一旦发现航天器有被空间碎片撞击的危险,就做出

相应对策, ISS 的主动轨道机动属于空间碎片预警。空间碎片防护,是指在航天器舱壁加装防护板,起到对航天器保护的作用,工程上是在航天器舱壁外放置防护屏。空间碎片减缓是指主动减少空间碎片。前几年中国发射航天器在太空进行修复卫星就可视为是未来用在空间碎片减缓的用机器捕捉的手段之一^{[5][6]}。本文研究的重点是在空间碎片的观测上来探测识别空间碎片。

1.2 研究现状与不足

目前关于空间碎片探测,国际上投入了相当大的人力物力。据美国航空航天局(NASA)估计 5 毫米大小级别的空间碎片已经可以对飞行器造成损害了。目前关于空间碎片的防治,NASA 主要应用的包括 ORDEM 3.0, Meter Class Autonomous Telescope (MCAT), DebrisSat, Debris Resistive/Acoustic Grid Orbital Navy Sensor (DRAGONS)。其中 ORDEM 3.0 是 NASA 目前最先进的空间碎片模拟模型;MCAT 是和美国空军合作的 1.3 米望远镜(2015 年启用)可探测最小分米级别的空间碎片;DebrisSat 是 NASA 标准的解体模型,其设计模拟的是一个 60 厘米 50 千克级别的卫星解体;DRAGONS 旨在提供小于 1mm 的空间碎片的信息。通过这一套系统综合的努力,NASA 成功在 STS-128 第二次飞行检查中发现载荷仓散热器的氟利昂冷却圈上的许多小碎片,这使得其避免丧失过半的冷却能力从而导致的严重后果。这已经是世界范围上在空间碎片防治上所取得的不小的进展,可见我们在空间碎片的防治上仍需很大的努力。




图 1-1 1970 年、1990 年和 2010 年的空间碎片的分布图。

Figure 1-1 Distribution of space debris in 1970, 1990 and 2010

现在在检测太空间碎片上,我们已经取得了阶段性的成功,虽然国际组织持续监控着的数以万计的大空间碎片,但仍有未知数量的空间碎片在近地太空中高速的飞行着,这对于卫星,航天飞机等时时刻刻存在着危险,可能导致卫星等的损毁甚至爆炸,这是

直接导致空间碎片数量的爆发性增长的恶性循环。

1.3 目前主流应用软件的介绍

SExtractor (Software for source extraction) 是一款把一张天文图像中的物体建立一个目录的软件同时它也是运行在 Linux 环境下的开放免费软件^[9], 虽然它是主要做大视场下的星系级别的目标搜寻, 但是它也在适度密集的天体图像提取目标上有良好表现。在目前我们的天文台仍旧是用 SExtractor 提取分类星象和空间碎片。

SExtractor 主要针对市 FITS 格式的天文图像进行处理, 最大可用 32 位的电脑处理 65000*65000 的图像或是 64 位机器处理 2G*2G 的图像。不仅如此, SExtractor 对于图像中重叠物体的检测也有很高的鲁棒性, 早在 90 年代时该软件的定位是寻找精准的测量和探测之间的平衡点顺便加快处理速度, 然而今天软件的进化已经远远超过这个目标, 可以看做一种快捷方便没有大的纰漏的工具。

SExtractor 处理图片的过程可以分为两个步骤: 第一步过程中, 首先建立一个天空背景的背景模型, 然后建立一组全局统计结果, 第二步的时候, 先从图片抽去第一步中建立的背景模型, 然后快速的用阈值过滤整幅图, 这样被探测的目标就被提取出来了, 探后用形态学上的方法区分目标并标上标签。




图 1-2 SExtractor 软件流程图

Figure 1-2 The schematic diagram of SExtractor

1.4 论文的主要工作及安排

本文针对目前空间碎片的识别提出了一种基于卷积神经网络的机器学习的算法进行空间碎片的识别工作，并针对卷积神经网络的参数选择提出了基于皮尔森检验的筛选方

法，以及卷积神经网络对噪声的耐受力做了一定的研究。

第一章 绪论。对本文所做的工作的背景做了简要的介绍，针对目前空间碎片的研究现状做了详细的描述。

第二章 空间碎片。本章对于空间碎片的危害以及目前国际主要机构的研究现状做了详细的阐述。本文所做内容为地基望远镜用于空间碎片预警的内容。

第三章 深度学习以及卷积神经网络。本章对于神经网络从简到繁做了详细的讲解，卷积神经网络作为目前神经网络里面广为知名的一种，其综合了前馈神经网络和反馈神经网络。另外，本章也对深度学习里面的另一种递归神经网络略作介绍。

第四章 基于 CNN 的空间碎片识别。本章着重讲解了在实际工作中针对数据集搭建卷积神经网络的各个参数的选取，并且提出了基于皮尔森检验的筛选学习率的方法。

第五章 CNN 对信噪比耐受性的评估。针对本文所用的数据的特殊性，本章所做的工作重点是用不同的信噪比的数据做对比试验，评估 CNN 卷积网络对噪声的耐受力，以及针对这种情况所采用的缓解措施。

第六章 总结与展望。本章对全文的工作做了总结，并提出了课题继续研究下去的发展前景。

第二章 空间碎片及预警

2.1 空间碎片研究现状及其危害

空间碎片是失去功能的卫星、解体碎片、NaK 液滴、固体火箭发动机喷射物、航天器表面溅射物、WestFord 铜针、太阳帆板碎片等漂浮在近地轨道上的太空垃圾的总称。随着国际各国开始对太空战的重视越来越深，太空武器的实验导致近些年来太空碎片的数量呈现爆炸式的增长。




图 2-1 空间碎片数量分布图

Figure 2-1 Distribution of space debris' number

图 2-1 是美国 NASA 统计的空间碎片数量曲线图，从图中可以很明显的看到空间碎片的数量在近五十年来呈现数量级的增长，不可忽略的是这个统计报告并没有统计微小的空间碎片，所以可预见的是空间碎片的实际数量要远远大于图上的数字。这也说明现在空间碎片的情势不容乐观，治理空间碎片污染的问题已经迫在眉睫。

表 2-1 1987 到 1991 年苏联中国和美国发生的爆炸事故。

Table 2-1 Explosion accidents from 1987 to 1991 in USA, China and the Soviet Union

名称	爆 炸 日 期 (年,月,日)	分离高度 (km)	远 地 高 度 (km)	近地高度 (km)	倾角	统计的碎片 数量
Cosmos 1813	1987, 1, 28	390	417	359	73	190
Cosmos 1866	1987, 7,26	243	361	167	67	9
Cosmos 1769	1987, 9,21	333	444	310	65	4
Cosmos 1646	1987, 11,20	406	434	401	65	25
Cosmos 1823	1987,12,17	1485	1523	1477	74	43
Cosmos 2030	1990, 7,28	150	220	150	67	0
Cosmos 2031	1990, 8, 31	270	370	250	57	8
长征四号 三级火箭	1990,10,4	900	900	890	99	75
Cosmos 2101	1990, 11, 30	210	290	200	65	3
USA 68	1990,12,1	850	850	610	99	25
SL-12 推 进剂箱	1991,2,4	18500	18800	330	52	0
SL-8 二 级火箭	1991,3,5	1560	1750	1470	74	52
德尔它二 级火箭	1991,5,1	1088	1102	1093	99	13

在人类探索太空的近些年，有不少航天事故是空间碎片引起的。1975 年 7 月，美国的探测卫星被空间碎片撞毁。1978 年，苏联的核动力侦察卫星也被空间碎片撞毁并落于加拿大。1983 年，美国挑战者号航天飞机被空间碎片撞击并穿透。1993 年发现哈勃空间望远镜大概有 120 个孔是被高速碎片撞击形成。1991 年发射的发现号和亚特兰蒂斯号航天飞机都是在发射前几个小时接到指令，预测会与苏联飞船的空间碎片相撞，因而晚发射几分钟或是临时调整方向。否则后果将是机毁人亡。

空间碎片对于航天器的损害主要有以下几个方面：

(1) 空间碎片会损害航天器表面的涂装及减少表面光滑度。这主要是个体小的空间碎片造成或是大的空间碎片摩擦导致的且由于肉眼几乎不可见的空间碎片数量庞大弥漫在空间轨道中导致发生这个事件的概率尤其高，称为“沙蚀”，这种程度的损害会导致航天器热控失衡。

(2) 撞击航天器。这是最常见的对航天器的损害，通常会损坏航天器表面材料甚至对内部器件造成损坏。对于空间卫星，由于其面积大部分是太阳能电池板，所以空间碎片更容易损伤其太阳能电池的供电线路并导致其断路。



图 2-2 空间碎片撞击图

Figure 2-2 Fragmentation Debris

(3) 等离子云效应。太空中的空间碎片撞击航天器也有极大的可能使材料直接气化从而形成了等离子云。等离子云在引力作用下很可能渗入航天器里面对航天器内部的电路造成损坏。

(4) 动量传递。根据动量守恒定理,当大型空间碎片撞击航天器或是极多的小型空间碎片撞击航天器之后很可能对航天器的运行轨迹产生影响。如果致使航天器脱离其在轨道,就极有可能致使其坠毁或是脱离地球引力的束缚。

(5) 引起航天器爆炸。航天器表面若是被撞极有可能导致其表面强度降低甚至破裂,当撞击部位是航天器的应力集中的部位或是高压容器,则会导致航天器的爆炸。

2.2 空间碎片预警以及国际关于碎片预警现状

针对空间碎片各个国家都努力进行研究,目前比较成熟的预警工程主要有三个:美国 NASA 研制的 OMEM 系列,欧空局(ESA)的日地空间流星体和碎片参考模式 MASTER 系列以及俄罗斯的 SDPA 系列。

预警工程的工作是通过概率的方法预测空间碎片和航天器的碰撞概率,当碰撞概率大于一定阈值时候报警。NASA 在航天飞机上装有雷达会在航天飞机发射后实时监测周围空间碎片状况并进行风险评估进而预警。主要的判定方法使用的是 Box 区域判定法和碰撞概率计算。随着时代发展,现在大量的使用相控阵雷达可以大大提高空间碎片的检测效率,美国空军电子系统中心提出研发使用 S 波段雷达的太空篱笆议案,可以精确的追踪最小半径仅厘米级别的碎片。

1995 年 6 月中华人民共和国正式加入机构间空间碎片协调委员会。2000 年,中国国家航天局实质化启动了空间碎片的研究工作“空间碎片行动计划”。中国已经初步的建成了空间碎片防护能力,包括一整套空间碎片防护的实验验证系统。

空间碎片的预警可以分成两部分,包括地面观测和太空观测,其中地面观测又可以分为雷达观测和望远镜观测。

(1) 雷达观测。属于全天候观测,利用地面的大型雷达探测并追踪空间碎片。雷达用的碗状机械控制天线的脉冲雷达,还有电子控制的相控阵天线的相控阵雷达。通过雷达测量,可以了解到空间碎片的轨道要素,空间碎片的运行姿态,空间碎片的体积以及形状,空间碎片的材质。

(2) 望远镜观测。光学观测不属于全天候观测,望远镜观测只适用于少云的夜晚的天光背景下观测空间碎片^[8]。对于观测时长,近地的空间碎片整夜仅有两小时左右的时间适合观测,远地的空间碎片则可以整夜观测,另外望远镜观测也受限于天空天气状况。望远镜观测的好处就是不必额外制造器械,仅仅使用已有的天文观测望远镜就可以实现

所有的要求。本文所采用的方法正是属于望远镜观测的范畴。

太空观测是雷达安装在航天器上进行观测的手段。同地面观测相比，太空观测准确度更高，观测距离更近，观测的物体尺寸更小。太空观测由于本身太空的真空环境使其具有更好的效率，使用高频段雷达可以观测更小的空间碎片并且可以帮助地面观测到的空间碎片数据进行纠正和检验。

第三章 深度学习及卷积神经网络

3.1 神经网络

3.1.1 神经元

随着近几年人工智能以及深度学习在工业应用上的大力发展，关于深度学习的研究也变得热门起来。1943 年，自从神经学和控制论研究者 Warren McCulloch 和逻辑学家 Walter Pitts 基于数学和阈值逻辑算法创造了第一种神经网络模型以来，神经网络历经多次的发展和改进，现在的深度学习指的就是深层复杂网络结构的神经网络，其中尤其指的是卷积神经网络和递归神经网络。

为了了解神经网络的运行原理，我们首先要介绍一下组成神经网络的最基本的成分，就是神经元。顾名思义，机器学习里面所说的神经元的灵感是来源于人类大脑的神经细胞^[7]，之所以被称为人工智能也是这个原因，人们一代又一代人的努力，就是希望复制上帝的工作，创造出可以和人类比拟的智慧，称之为人工智能。所以在创造人工智能的时候，也就是参考人类神经细胞的功能和形状创造出的神经网络的神经元，这也有赖于医学的进一步发展，神经元的结构如下图：




图 3-1 神经元结构图

Figure 3-1 Structure of nerve cell




图 3-2 机器学习中的神经元结构图

Figure 3-2 Structure of nerve cell in machine learning

如图 3-1 及图 3-2 所示，神经元的结构和人类神经元细胞相似^[10]，神经元输入通过神经元内部运算输出神经元，经此往复从而达到提取输入信息的目的。假设输入是 x_j ， w_{kj} 是神经元的权重，神经元的公式为：

$$y_k = \varphi\left(\sum_{j=1}^m w_{kj}x_j - v_k\right) \quad (3-1)$$

神经元通过训练权重来筛选输入中的有效信息，权重越大也就意味着对应这个权重的输入是对整体输入而言较为重要的信息，而相反的话则意味着这个输入冗余度较高了。 v_k 作为阈值起的作用就是筛选不同神经元的重要度，它本身对于神经元的兴奋起着一种抑制的作用。神经元细胞里的非线性函数 $\varphi()$ 也有着很重要的作用，也可以称为作用函数或是激发函数（Activation Function）可以把这种非线性函数视为一种数学上的映射，从一个特征平面映射到另一个特征平面，不同的非线性函数有着不同的特征^[11]。这里我们列举几种：

Sigmoid 函数具有良好部分线性，在其范围内近乎线性的作用神经元的输出，在超过函数范围的会对其输出产生极大的抑制。其公式为：

$$S(x) = \frac{1}{1+e^{-x}} \quad (3-2)$$




图 3-3 Sigmoid 函数图

Figure 3-3 Sigmoid function

主要是因为它的一些缺点：当输入超过单位范围的时候，这些神经元的激活函数的梯度是趋近于 0 的，所以，如果神经元前面输出很大的话，大部分细胞可能都会处在饱和的状态同时其梯度值趋近于 0，这会导致网络变的很难学习。Sigmoid 函数的输出不是 0 均值的，后一层的神细胞将用上层输出的非 0 均值的信号作为输入。产生的一个结果就是：如果神经细胞的输入是正值的话，其计算的梯度永远不会为负^[12]。

Tanh 函数是 sigmoid 的变形：

$$\tanh(x) = \frac{\sinh(x)}{\cosh(x)} \quad (3-3)$$




图 3-4 Tanh 函数图

Figure 3-4 Tanh function

相比于 sigmoid 函数，改进的 tanh 函数是 0 均值的，避免产生梯度不为负的情况。近年来，Relu 变的越来越受欢迎。它的数学表达式如下：

$$\text{ReLU}(x) = \begin{cases} x & \text{if } x > 0 \\ 0 & \text{if } x \leq 0 \end{cases} \quad (3-4)$$




图 3-5 ReLU 函数图

Figure 3-5 ReLU function

从图 3-5 可以看出, 输入信号为负时, 输出都是 0, 输入为正的情况下, 输出等于输入。ReLU 函数的优点是得到的随机梯度下降的收敛速度会快很多^[13]。相比于 sigmoid/tanh, ReLU 函数只需要一个阈值就可以得到激活值, 而不用去算一大堆复杂的运算。ReLU 函数的缺点是网络训练阶段很脆弱, 容易死机。当一个 ReLU 神经元的输入数据很大时, 学习过参数之后, 这个神经元对输入信号的兴奋状态会呈现明显的抑制效果, 这个神经元就死亡了, 也就是它的梯度永远是 0, 不再兴奋。在学习率很大的情况下, 网络中的将近一半的神经元都会停止激活, 破坏原有网络的结构, 所以 ReLU 函数硬性需要神经网络具有较小的学习率。

以上介绍的是一维输入下的神经元结构, 在本文实际应用中, 神经网络是对二维图像进行处理, 所以本文所用的卷积神经网络中的神经元的权重矩阵具有二维的结构。

3.1.2 前馈以及反馈神经网络

上节我们讨论了神经网络中的最基本的神经元的结构和功能, 那么这节我们将讨论一下由神经元所构成的神经网络的结构。

总体来说神经网络的拓扑结构可以分为层次连接型和全连接型两种, 其中层次型网络又包括前馈型网络和反馈型网络。层次型网络就是网络结构可以大体分为几层, 层层相连, 而全连接型网络就是网络中的所有神经元两两互连, 相对于层次型网络, 在相同个数的神经元的前提下, 全连接型网络具有更高的复杂度。下图为简单的几种网络结构示意图:




图 3-6 层次型网络

Figure 3-6 hierarchical network




图 3-7 全连接型网络

Figure 3-7 fully-connected network

本文我们着重讨论一下层次型网络，对于层次型网络，经过几十年的发展，产生了很多不同的分支，这里我们首先介绍一下在层次型网络中相对简单也是诞生时间最长的前馈神经网络。

前馈型神经网络，是由心理学家 Frank Rosenblatt 在 1958 年发明出来的。Frank Rosenblatt 首先创造出的单层神经网络也可以称为单层感知机^[14]，就是类似于生物眼镜或是感知器官的功能，是接受外界信息处理信息的第一层。在单层感知器的基础之上发展出了多层感知器，其分为输入层，输出层和隐藏层，每一层都包含若干个神经元。其结构如图：




图 3-8 前馈型网络

Figure 3-8 Forward network

反馈型神经网络是在前馈型神经网络的基础上加上另网络的输出反馈回网络的输入的一种神经网络，前馈和反馈都是指的网络结构上的差别。其结构如下：




图 3-9 反馈型网络

Figure 3-9 Backward network

现在前馈型神经网络以及反馈型神经网络都算是有监督的学习网络。有师学习，是指在训练神经网络的时候的数据有标签的^[15]，类似于一个老师教课，用经过分类的数据让神经网络学习分类。相对应的神经网络还有另一类就是无师学习神经网络，也就是无监督神经网络。其意义就是不给数据加标签，让神经网络自己识别数据的差别进而分类。当用无监督神经网络的时候，通常数据在多维空间的离散分布是非均匀的，理论上来说，无监督神经网络就是一种多维空间数据映射到特征空间的函数。

虽然目前有监督学习是神经网络乃至深度学习的主流，但未来还应该是属于无监督

神经网络的。因为只有无监督神经网络才能在未来处理数据量的爆炸性增长。目前国际上主流看法都是数据量越大，训练的网络的精确率就越高^[16]。显然，目前数据量凭借人工标记标签还勉强可以，但随着网络的发展，人工标记标签肯定会被机器标记标签也就是无监督网络所取代。

无监督网络目前主要应用是对大型数据的聚类分析，其比较具有代表意义的是自组织映射神经网络（SOM）和适应性共振理论网络（ART）^[17]。

自组织映射神经网络是一种竞争型神经网络^[18]，它的灵感来源也与大脑神经网络的研究有关。生物神经学的研究表明，当一个神经元兴奋的时候会产生一种物质抑制周围的神经元兴奋，这就与自组织映射神经网络原理不谋而合。首先，自组织网络是由两层组成，一层输入层，一层竞争层，层间有互联。显然，其竞争关系是由层间互联来实现的，这也是自组织竞争网络和其他有监督型网络的区别。其网络结构如图：




图 3-10 自组织映射网络

Figure 3-10 SOM network

对应这特殊的无监督网络，其竞争学习规则也与其他网络有所区别。竞争学习规则（Winner Take All）^[19]即每一时刻只有一个神经元可以兴奋即是胜者，而选取胜者的规则很简单。归一化网络的输入向量和权重参数向量，选取和输入向量最相似的神元元的权值为胜者，胜者有权进行参数的更新学习。

3.1.3 反向传播神经网络

和前向传播神经网络相对应的是反向传播神经网络，其传播方向是从后向前的。Rumelhart, McClelland 于 1985 年提出了 BP 网络的误差反向后传 BP(Back Propagation) 学习算法^[20]。其网络结构如图：




图 3-11 反向传播网络示意图

Figure 3-11 Back propagation network

如图 3-11 所示，输入层相当于外界的刺激，是刺激的来源并且将刺激传递给神经元，中间部分，表现神经元相互之间传递刺激相当于人脑里面即隐藏层。最后，信息流过神经元经过多次相互传递后对外界的输出为输出层。其结构和前向传播网络并无较大区别，其主要区别在于反向传播网络的运作流程主要是分两步：首先，前向传播过程中，不对网络进行学习，而是直接按照既有的权重生成结果。其次，就是反向传播过程，利用前向传播的结果计算误差，再利用误差去反向逐层修正权重。这两个步骤就构成了反向传播神经网络的学习过程。

在反向传播网络之中，最为重要的就是反向传播修改权重的学习过程，也是显而易见的调整权重最终达到输出和标准相近。

(1) 计算正向输出和标准输出的平方差：

$$E = \frac{1}{2}(t - y)^2 \quad (3-5)$$

E: 平方误差。

t: 正向传播的标准输出。

y: 正向传播过程的实际输出。

(2) 每个神经元的输出为:

$$O_j = \varphi(\text{net}_j) = \varphi\left(\sum_{k=1}^n \omega_{kj} O_k\right) \quad (3-6)$$

O_j : 神经元j的输出。

ω_{kj} : 神经元k与神经元j之间的连接权重。

O_k : 神经元k的输出。

φ : 表示激活函数。

(3) 计算平方差对权重的微分:

$$\frac{\partial E}{\partial \omega_{kj}} = \frac{\partial E}{\partial O_j} \frac{\partial O_j}{\partial \omega_{kj}} \quad (3-7)$$

(4) 更新权重:

$$\Delta \omega_{kj} = -\alpha \frac{\partial E}{\partial \omega_{kj}} \quad (3-8)$$

α : 学习率。

反馈型神经网络也就是 BP 网络也是卷积神经网络的一部分，卷积神经网络可以看做是神经元是卷积核的层与层不全相连的一种 BP 神经网络。

3.1.4 神经网络的学习规则

对于神经网络而言，神经网络之所以被称为人工智能的先驱，是因为具有学习的特征。神经网络的学习分为有监督学习，无监督学习，半监督学习^[21]等。

(1) Hebbian 学习规则，由心理学家 Hebb 最早提出的突触修正的假说^[22]。这个假设根据生物上神经元突触前膜与后膜同时具有正电的时候会增强该突触的传导性提出了当两个神经元同时兴奋时应加强连接。改规则主要用于纯前馈无监督型网络，其典型应用是训练线性联想器的权矩阵。

(2) 感知器 (Perception) 学习规则，由美国 Frank Rosenblatt 在 1958 年提出^[23]。感知器学习规则的权重修改量等于期望输出和实际输出之差。

$$\Delta \omega_{ij} = \eta [d_j - \text{sgn}(W_j^t X)] x_i \quad (3-9)$$

其中 η 为学习率， d_j 是期望输出， x_i 是输入，

$$\text{sgn}(W_j^t X) = \begin{cases} 1, & W_j^t X \geq 0 \\ -1, & W_j^t X < 0 \end{cases} \quad (3-10)$$

(3) δ (Delta) 学习规则, 由认知心理学家 McClelland 和 Rumelhart 在 1986 年提出^[24]。与感知器学习规则类似, Delta 学习规则就是连续性的感知器学习规则。

(4) Widrow-Hoff 学习规则, 也称为最小均方规则。

$$\Delta\omega_{ij} = \eta[d_j - W_j^t X]x_i \quad (3-11)$$

(5) 相关 (Correlation) 学习规则, 权值的初始化为 0。

$$\Delta\omega_{ij} = \eta d_j x_i \quad (3-12)$$

(6) Winner-Take-all 学习规则, 属于无导师学习规则, 它的学习规则是每层仅有一个可以兴奋的神经元, 其他神经元是 loser 不具有更新权重的权利, 用于竞争型神经网络, 一般作为聚类使用。

3.1.5 神经网络目前的不足

作为第一次人类创造人工智能的尝试, 神经网络不可避免的也存在着很多的缺点。本文着重讨论比较重要的几个方面。

Hessian 矩阵的 H 病态问题^[25]。一般情况下函数具有多维输入的时候, 它的二阶导数矩阵就是 Hessian 矩阵, 通过对函数二阶导数的检测, 并用 Hessian 的特征值分解来判断一个临界点是局部极大值, 局部极小值, 亦或是鞍点。判断依据如下: 当 Hessian 是正定的时候, 显然此临界点是局部极小值点; 相反, 当 Hessian 是负定的时候, 此临界点就是局部极大值点了; 最复杂的是当 Hessian 特征值中有正也有负的时候, 该点可能是一个横截面的极大值也可能是另一个横截面的极小值。然而梯度下降的方法在多维数据中就会显示出其病态, 当某个方向上倒数增加的速度很快而另一个方向增加的慢的时候, 我们希望的是沿着长期为负的方向走, 然而梯度下降法会沿着下降最快的方向走, 这种情况在多维数据的时候很常见。这种状况也直接导致进行神经网络训练学习的时候选取步长参数的时候的最优化的方法是选取足够小的步长以免步子太大越过最优解, 也就导致了学习步数将变得过长。




图 3-12 鞍点图

Figure 3-12 Saddle point

局部极小值问题也是神经网络甚至深度学习一直面临的优化难题^[26]。对于神经网络，通常有很多个甚至无穷多个局部极小值，也由于神经网络函数的模型不具备可辨识性（model identifiability）也可以称其为权重空间的对称性，例如，把同一层的两个神经元对换或是若干同一层神经元交换位置对于整体神经网络而言差别并不大，都可以是等价的，对于同一神经元，输入权重乘以一个系数然后在输出时除以这个系数所得的结果完全一样没有影响。这些都意味着神经网络的代价函数具有极其多个局部极小值。

当处理高维数据的时候，不可避免的会产生鞍点问题。鞍点就是微分方程中，沿着某一方向是稳定的，另一条方向是不稳定的奇点，在矩阵中，在所在行中是最大值，在所在列中是最小值的点。通过定义可以了解到，在某一方向上鞍点是局部极小值而另一方向上是局部极大值的点。2014 年 Dauphin 等人证明在神经网络中有很多损失函数具有多个鞍点^[27]。鞍点梯度为零，在使用牛顿方法的时候很容易就走到一个鞍点走不出去了。但是当使用梯度函数的时候就不存在这个问题，因为 Goodfellow 等人通过可视化证明了梯度下降方法可以顺利逃过鞍点。

另一个问题也是常见的问题，当多层神经网络存在斜率较大的地方，这也是很多非

线性函数普遍存在的，当某个地方斜率近乎无穷大的时候，梯度下降算法往往会产生很大的步长，导致学习训练过程中错过最优解或是加长学习过程。梯度消失与梯度爆炸是神经网络很常见的问题。当目标函数的梯度是急性下降的时候会使得梯度在转折处无限大，从而产生梯度爆炸如图：




图 3-13 梯度爆炸示意图

Figure 3-13 The explosion of gradient

当目标函数出现平滑的过渡的时候，梯度值会有为 0 的时候，这时候就产生了所谓的梯度消失的现象。另外神经网络还存在很多瑕疵，像是有噪声的情况，优化算法的性能限制等等。

3.2 深度学习概述

3.2.1 递归神经网络

递归神经网络（recurrent neural network）也称作 RNN，循环神经网络。在深度学习里面通常作为一种处理序列数据的神经网络来和卷积神经网络进行区分^[28]。序列数据可以理解为数据以时间间隔有序的输入进网络里面，而卷积神经网络通常是处理图片等多维数据的。形象化解释，卷积神经网络处理空间域的数据，而循环神经网络则是处理时间域上的数据。循环神经网络是有记忆的网络，不仅可以识别个案，更能分析出所输入的信息的逻辑序列富含的内容，信息间存在着复杂的时间上的关联性且所输入的信息序

列不具备固定的长度。输出有赖于当前的输入和其所存储的记忆，循环神经网络是可以理解语言的，通过训练可以理解文字的意义。两句话里面字完全一样，但变换文字的顺序就会产生完全不同的意思，循环神经网络是可以区分这两句话的。它的网络结构如下




图 3-14 递归神经网络示意图

Figure 3-14 recurrent neural network

每个单元做的事情都是一样的，所以可以简化为左边的版本，一个单元结构的重复运算。

$$a_h^t = \sum_i \omega_{ih} x_i^t + \sum_{h'} \omega_{h'h} b_{h'}^{t-1} \quad (3-13)$$

$$b_h^t = f(a_h^t)$$

其中 x^t 表示 t 时刻的输入， a^t 表示 t 时刻的隐层的输入， b^t 表示 t 时刻的网络输出。可以把 s_t 当作隐状态，记忆了之前时间点上的信息。 o_t 是由当前时间以及之前所有的记忆得到的。 s_t 并不能捕捉之前所有时间点的信息，和卷积神经网络一样，这里的网络中每个 cell 都共享了一组参数 (U, V, W): $U \in \mathbb{R}^{I \times H}, W \in \mathbb{R}^{H \times H}, V \in \mathbb{R}^{H \times K}$ ，这样就能极大的降低计算量。

3.2.2 卷积神经网络

作为深度学习中应用最广泛的一类网络，卷积神经网络指的是至少在网络中应用一层卷积神经元的神经网络。卷积神经网络也是通过三个重要的思想来改进机器学习的，这三个分别是：稀疏交互，权值共享，等等^[30]。

自从 1998 年 LeCun 创造出经典的 LeNet 卷积神经网络模型以来，其在人工智能领域的地位与日俱增。2006 年 Hinton 先生在 Science 发表的论文《通过神经网络减少数据

维度》(Reducing the dimensionality of data with neural networks)几乎可以看做是深度学习崛起的标志,文中指出多隐层神经网络拥有良好的学习目标特征的能力,并且逐层初始化权重可以减缓其训练的繁复。这也就指出当时人工智能的出路之一就是卷积神经网络^[33]。2012年以来可以说是深度学习飞速发展的黄金时段,2012年的ImageNet大赛上Hinton用卷积神经网络以卓越的成绩赢得第一。2014年卷积神经网络成功应用在人脸识别上并取得很好的成果,DeepFace和DeepID就是两个成功的模型。2016年众所周知的阿尔法狗机器人在围棋领域横扫人类顶尖国手,使得深度学习人工智能成为目前计算机行业发展的主流力量。

理解卷积神经网络之前我们首先了解一下卷积运算的概念:表征函数 $f(x)$ 与经过翻转和平移的 $g(x)$ 的乘积函数所围成的曲边梯形的面积。卷积又可以细分为连续卷积和离散卷积,假设 $f(x)$, $g(x)$ 是 $\mathbb{R}$ 上的两个可积函数:

$$\int_{-\infty}^{\infty} f(\tau) g(x-\tau) d\tau \quad (3-14)$$

上式为卷积运算在连续函数上的公式,在卷积神经网络中采用的是离散卷积,对于函数 $f(x)$ 和 $g(x)$ 定义在整数 $\mathbb{Z}$ 上:

$$\begin{aligned} (f * g)[n] &\stackrel{\text{def}}{=} \sum_{m=-\infty}^{\infty} f[m] g[n-m] \\ &= \sum_{m=-\infty}^{\infty} f[n-m] g[m] \end{aligned} \quad (3-15)$$

卷积运算符合下列性质:交换律,结合律,分配率,数乘结合律以及微分定理。卷积的核心就是函数间时域的卷积等于频域的相乘。

池化层(Pooling layer)是卷积神经网络的基本组成成分,卷积层搭配池化层可以有效的提取信息并保证信息流失量不大。

Softmax层是卷积神经网络里面相对灵活的一层,softmax本身是一个线性函数亦称为归一化指数函数,可以作为某一层的激活函数也可以作为单独的一层来看。

$$\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad (3-16)$$

向量经过Softmax函数后,所有元素会在(0,1)之间且全部元素之和为1。Softmax作用于最后的全连接层的时候会有效的最后区分信息的手段。

全连接层(Fullyconnect layer)一般作为神经网络最后输出的部分。在卷积神经网络前部的卷积层和池化层进行筛选提取信息之后,全连接层可以说是充当分类的角色,最后全连接层的输出就是分辨不同的类别^[47]。

3.3 卷积神经网络（CNN）

3.3.1 卷积神经网络基本模型

目前卷积神经网络在图像应用上有几个著名的可行模型：LeNet, AlexNet, GoogleNet, VGG, Deep Residual Learning。

LeNet 可以说是卷积神经网络里元老级别的网络模型，它是由 LeCun 一手创造，在 90 年代盛极一时，尤其是在手写数字的辨认上取得了卓越的成果。LeNet 以其简洁的构造，可靠性强启发了后来诸多的神经网络开发者^[34]。

AlexNet 是在著名的 ImageNet 比赛 2012 年的冠军 Alex Krizhevsky 一手设计的。AlexNet 网络模型证明了卷积神经网络在复杂模型下有效性，

不同于 LeNet，AlexNet 里面用卷积层，池化层和标准化层为一组计算单元。GoogleNet 和 VGG 是 2014 年的 ImageNet 比赛上崭露头角的。相比于前两个网络，GoogleNet 网络更深，也可以理解是网络层数更加多^[36]。上文我们提到了理论上增加网络的深度是一个提高网络正确率可行的方法，但是同时也增加了大量的参数需要训练，也增加了网络产生过拟合的可能性。为了应对这个状况，GoogleNet 也采用了稀疏网络，这样也大大减轻了需要学习的参数量。其网络结构如下：

表 3-1 GoogleNet 结构

Table 3-1 structure of GoogleNet

type	Patch size/stride	Output size	depth
Convolution	7×7/2	112× 112 × 64	1
Max pool	3×3/2	56× 56 × 64	0
Convolution	3×3/1	56×56× 192	2
Max pool	3×3/2	28× 28 × 192	0
Inception(3a)		28× 28 × 256	2
Inception(3b)		28× 28 × 480	2
Max pool	3×3/2	14×14×480	0
Inception(4a)		14×14×512	2
Inception(4b)		14×14×512	2
Inception(4c)		14×14×512	2
Inception(4d)		14×14×528	2
Inception(4e)		14×14×832	2
Max pool	3×3/2	7×7×832	0
Inception(5a)		7×7×832	2
Inception(5b)		7×7×1024	2
Avg pool	7×7/11	1×1×1024	0
Dropout		1×1×1024	0
Linear		1×1×1000	1
Softmax		1×1×1000	0

其中 GoogleNet 首创的 inception 结构:




图 3-15 inception 结构图

Figure 3-15 Structure of inception

VGG 是从 AlexNet 发展而来的网络，相比于原来的网络，VGG 拥有更深的层次，但收敛的迭代次数却减少了。VGG 使用了很多小尺寸的卷积核代替的大卷积核提取特征，经过[45]论文证明了，小而深的网络和大而浅的网络可以起到等价的作用，并且小而深的网络需要训练的参数还减少了。

Deep Residual Learning 也叫深度残差网络，来源是 2016 年 CVPR 的一篇最佳论文，《Deep Residual Learning for Image Recognition》。Deep Residual Learning 以其 152 层架构毫无疑问的成为在神经网络里面深度最深的网络之一，与此同时，其错误率低到 3.6% 已经成为目前为止最好的框架了^[35]。

3.3.2 稀疏连接和权值共享

稀疏连接^[37]是卷积神经网络用来控制更新权重的重要组成部分，其核心就是一个稀疏矩阵。稀疏连接是卷积神经网络的层与层之间不在是全连接，而是部分连接，也就是说上层神经元和下层几个和其相关的几个神经元或是邻近的神经元相连接。下图展示了层间全连接和层间部分连接的区别。




图 3-16 稀疏连接示意图

Figure 3-16 Partially connected

卷积神经网络采用稀疏连接是可以减少其网络规模，也是卷积神经网络有别于传统反馈型神经网络。稀疏连接会使下层的神经元可以被上层有限的神经元传递信息，假如把卷积神经网络整体看做一个提取有效信息的过程，每个卷积核对应一个特征面，稀疏连接就是筛选不同特征簇的筛子。

这里说的卷积神经网络的权值共享^[38]也是卷积神经网络减少训练参数的技巧之一。简单的说就是卷积核可以看做一个小的局部特征检测，那么这个局部特征检测不仅适用于局部图像也同时适用于整幅图像。权值共享原则允许卷积神经网络使用较小的卷积核替代和图像等大小的卷积核，极大的减少权值的数量。




图 3-17 局部连接示意图

Figure 3-17 Sparse connectivity

3.3.3 CNN 的应用

卷积神经网络在图像处理中的应用最为流传的就是经典的手写数字识别，人脸识别了。最经典的手写数字识别就是用的 LeNet^[39]，其在水写数字识别领域里做到了近乎

极致，不仅是效率极高而且兼顾了准确率也是极高。

2016 年是深度学习发展最为迅猛的一年，深度学习被应用于各个领域：百度公司开发的用深度学习进行写诗；Latent Predictor Networks for Code Generation 通过深度学习能够根据输入的文字要求自动生成代码；图像修补，用深度学习网络修补缺失的图像（引用 Context Encoders:Feature Learning by Inpainting）；西安交大研发的用深度学习网络识别伪随机数；图像变换，通过深度学习网络把图像风格化等等。

3.3.4 目前几种主流框架的介绍

Torch 是一款基于 Lua 语言的深度学习的平台，支持把计算拆分多步，更加具有计算上的灵活性。Torch 主要研发团队来自 Facebook，拥有与 caffe 平台相近似的用层来定义网络。它包含了大量的机器学习，计算机视觉等等相关的库，虽然没有使用主流深度学习都依赖的 Python 语言而是使用的 Lua，但它的计算性能反而比其他框架更为优良。

Tensorflow 是 Google 公司主持研发的深度学习平台，其主要理念就是把深度学习网络具象为流动的向量图，在网络的可视性上做的很好。支持多种语言，由于 Google 公司的大力投入，该平台在 Github 上备受追捧，使用的人数是众多平台里最多的。最重要的是作为深度学习的平台，TensorFlow 的分布式性能也是目前所有平台里较好的。

Theano 由蒙特利尔大学 Lisa Lab 团队开发制作，是一款高性能的符号计算深度学习库。其优点如下：集成了 Numpy，API 接口学习成本低；计算的稳定性较为优良；可以动态生成 C 以及 CUDA 代码编译为高效的机器代码。

Caffe（Convolutional Architecture for Fast Feature Embedding）创始人是加州大学伯克利校区的贾扬清教授，贾教授也是 Tensorflow 的创作者之一，目前由伯克利视觉学中心（Berkeley Vision and Learning Center, BVLC）维护。Caffe 作为被广泛使用的深度学习的框架之一，其优点也是很多：对于开始接触深度学习的研究者来说上手较为容易，网络结构都已封装为配置文件，虽然减少其灵活性，但用起来较为方便；训练速度快，caffe 框架搭建的网络可以胜任大规模数据集的训练。在计算机视觉领域中，caffe 框架被广泛用于图片分类，人脸识别，目标追踪等。

表 3-2 深度学习框架对比

Table 3-2 Comparison of Deep learning frameworks

框架	机构	支持语言
TensorFlow	Google	Python/C++/Go/...
Caffe	BVLC	Python/C++
Keras	Fchollet	Python
CNTK	Microsoft	C++
MXNet	DMLC	Python/C++/R/
Torch7	Facebook	Lua
Theano	U.Montreal	Python
Deeplearning4J	Deeplearning4J	Java/Scala
Leaf	AutumnAI	Rust
Lasagne	Lasagne	Python
Neon	NervanaSystems	Python

3.4 本章小结

本章着重讲述的是卷积神经网络的原理，卷积神经网络起源于从机器学习里发展而来的神经网络，综合了 BP 反馈式神经网络等结构，用二维的卷积核代替原有神经元的一维结构而诞生出来的。

深度学习今年来发展十分迅速，作为深度学习两大部分：卷积神经网络和递归神经网络，进展也是十分快的。卷积神经网络以其处理图像上的优越性，被不断地改进着，从最开始的 LeNet 五层结构到现在的 152 层的深度残差网络。深度学习的深度指的就是网络的层数，层数越多，网络越深。可以预见，不久之后，越来越深的网络将越来越多。

第四章 基于 CNN 的空间碎片识别

4.1 数据来源以及处理

本文使用的是南京紫金山天文台提供的数据。数据分为两组，分别是两个口径不同的望远镜的拍的天文图像。在望远镜一段时间拍摄的天文图像中，可能会有空间碎片存在，本文主要的工作就是识别区分图像中的空间碎片与星象。

星象和空间碎片在相对于望远镜的运动速度不同^{[31][32]}，这给了我们区分空间碎片和星象最直接的特征区别，下图左边两幅均是空间碎片的图像，右边则为星象图像。




图 4-1 星象和空间碎片图像

Figure 4-1 Stars and space debris

在传统方法提取识别分类星象和空间碎片的时候，对于区分星象和空间碎片仍有一部分缺陷，其中，当星象的图像由于 CCD 相机的问题或是其他噪声干扰，会使图像产生误分类的现象^[40]。




图 4-2 四种会导致误分类的情况

Figure 4-2 Four situations that can lead to misclassification

图 4-2 左上为两空间目标距离过近导致的误分类，右上是一个完整的目标被 CCD 相机内部原因造成被误分成两个目标，左下和右上一样也属于被误分成两部分，左下呈明显的蝌蚪状，右下也属于两目标距离过近。

当采用 SExtractor 分类时，SExtractor 会提取出目标的在图像中的中心的坐标，星等以及长宽比等等，分类时所依据的就是长宽比进行分类^[41]。上图的四种状况都会导致误分类，其中左下的蝌蚪形目标最常见，会使软件测算的长宽比趋近于另一类导致误分类。

在本文中，天文台提供的观测数据为 .fits 格式^{[48][49][50]}的天文图像数据集，fits (Flexible Image Transport System) 是国际天文学会(IAU)1982 年确定的世界各天文台之间用于数据传输、交换的统一标准格式，描述了数据的定义和数据编码的一般方法，提供了图象的单值转换，精度包括符号在内可以达到 32 位。对一维、二维、三维、甚至多维的数据类型都提供了合适的转换。fits 格式图像根据所用望远镜的不同每张通常大

小在 15M 到 40M 之间。Fits 图像中不仅仅存储了整个图像各个像素的灰度值，还保留有一部分望远镜以及拍摄信息，例如拍摄时间，曝光时长等等。正常处理的灰度图像的灰度值通常在 0 到 255 之间，而天文图像则得益于 CCD 相机灰度值的细分可以达到 0 到 60000 多的程度。




图 4-3 fit 文件的格式

Figure 4-3 Format of fit file

文件头的五个文件说明是：SIMPLE, BITPIX, NAXIS, NAXIS 和 END。其中 SIMPLE 是逻辑变量,指明文件是否符合基本的 FITS 标准。BITPIX 整数变量,指明用于表示每一个象元值的位数。NAXIS 整数变量,指明图象里坐标轴数。NAXIS1 整数变量,指明在数组内沿最快变化轴的象元数。NAXIS2 整数变量,指明在数组内沿次快变化轴的象元数。

本文接下来的工作需要读取 FITS 文件并转化为灰度值矩阵方便进入神经网络并处理。卷积神经网络的输入包括图像的四维矩阵和相应标签。在本文里我们选用基于 caffe 架构的卷积神经网络搭建平台，要求规范输入的训练样本为四维数据集，其中前两个维度用于存储样本图片，第三个维度存储 1 和 3 表示图像是灰度图像还是彩色图像，若是彩色图像则用 1 到 3 分别表示彩色图像的红绿蓝三个通道，第四个维度用于存储序列，即样本编号。关于输入的训练样本集的标签，需要和原有的样本集一一对应。

对于天文图像来说，数据集还存在另一个常见问题，就是不平衡数据集^[42]。本文所做的卷积神经网络需要的训练数据集应尽量保持各个分类相平衡的数据集，不平衡数据集会导致网络训练过程产生过拟合现象或是欠拟合现象。

在本文所用的数据集中存在很严重的不平衡数据集现象，用于训练卷积神经网络的两类样本集分别是星象的样本和空间碎片的样本的比例大约是 1000:1。为了达到抑制不

平衡数据集，本文采用的放回抽取的策略。

首先，两个样本池中分别放有所有的样本，然后从两个样本池分别有放回的抽取同样数量的样本，最后把所有样本打乱顺序放入训练集中。

有放回的抽取不可避免的会造成弱势数据重复增多，但打乱所有数据顺序则可以抑制过拟合问题，目前机器学习大部分训练采用的也是打乱训练数据集的策略。

4.2 卷积神经网络的基本构建

本节将详细讲述如何构建一个可以用于训练学习特定数据的卷积神经网络。构建卷积神经网络首先是选择适合的网络结构，我们在 3.3.1 里详细讲述了不同的网络结构的基本形态以及优劣作为选择网络结构的参考，另外一个更重要的参考依据是针对特定数据搭建的网络结构应该满足最基本的深度以及有限训练时长的要求。在本文中，我们所采用的是最成熟的 LeNet 网络的调整版。

之所以选择 LeNet 网络有以下几个原因：首先，针对我们所用的天文数据而言，需要一个结构相对简单可靠的网络。天文数据的规模通常是普通数据的几十倍之多，一张天文图片每个像素灰度值可以达到普通图像的 240 倍，这也就意味着如果网络过于复杂将导致处理时间过长的问题。通常天文台对于拍摄下来的天文图片是不予以保存的，基本都是实时观察，挑一些时段的图片进行保存。这就更是要求网络在处理图片的速度应该越快越好。而 LeNet 网络历经几十年的验证，可靠性很高并且也支持简单的网络结构。其次，本文用于训练的网络图片实际上是经过剪裁的天文图像，大小限制在 30×30 以下，那么根据所需处理的图片的大小也不应选择更为复杂的网络结构。另外，更为复杂的网络结构也意味着更多的权重需要学习训练，更加意味着足够大量的训练样本是其网络的刚性需求，然而这一点上对于我们所应用的天文图像较为困难。困难之处在于虽然我们拥有一个特征的训练样本，但是对于关键的空间碎片的样本并不多，望远镜在进行巡天拍摄的时候，空间碎片的移动速度相对于恒星在图片里非常快，这就致使即使选取大量的天文图片，但其中关于空间碎片的图片的数量仍旧十分的稀少。再有一点就是目标特征的复杂度也限制的选取网络的复杂度^[46]。简单点理解就是假如只分辨简单的几何图形的网络其结构将十分简单，甚至可能一层神经网络就可以。可以理解的是天文台拍摄的天文图片虽然理论上应该是简单的几何图形，区分的难度不是很大，但是由于一些硬件的噪声和太空目标的点扩散效应，简单的神经网络并不能胜任，所以我们就选取

了稍微复杂可靠一些的 LeNet 卷积神经网络。在原有 LeNet 网络结构的基础上我们做了一点点改进，以下是我们设计的网络结构：




图 4-4 本文的卷积神经网络结构图

Figure 4-4 Structure of designed convolutional neural network

本文里在搭建卷积神经网络的时候，首先用 LeNet 试验发现 LeNet 完全可以胜任这个工作，准确率已经在 90%以上，远高于原有的 SExtractor 软件。

从 3.3.1 节我们了解到了 LeNet 的基本结构，那么在这一节我们将详细讲述关于卷积神经网络的卷积层的卷积核大小及个数如何选取。我们在第三章讨论过了卷积运算的过程，那么我们就不难推导出卷积层的输入输出图像大小，这里我们默认输入输出图像为长宽相等的图像。当卷积核滑过图像边缘的时候，通常为了避免卷积核无法卷积图像边缘的像素会采用填充边缘的方法（padding），填充法就是在图像边缘填充宽度自定义的四条边。关于卷积层还有一个重要的参数就是步长（stride），我们先看卷积层定义的输入输出之间的关系公式：

$$\text{output} = \left(\frac{\text{input} - \text{kernelsize} + 2 \times \text{padding}}{\text{stride}} \right) + 1 \quad (4-1)$$

从上面公式可以了解到填充和步长都对输出图像大小有着影响。当我们构建卷积层的时候，不可避免的要选择这些参数的大小，其中一个重要的准则就是必须输出图像大小是个整数，这就要求分子必须整除分母。另外一个重要的必须考虑的就是后面的网络大小。在构建前面两层网络的时候，通常会忽略后面的网络，前一层的输出也就是后一层的输入，这也就导致后面的网络在搭建的时候往往选不到恰当的参数。所以，当构建卷积层神经网络的时候，主要参数的选取要考虑到本层的输出要为整数，后面几层的参数选取。构建网络之前首先分析数据大小以及复杂程度，分析网络的深度和宽度。

池化层（Pooling layer）可以被理解为特殊的卷积层。池化层有两种不同的种类，一种平均池化，一种最大池化。两个各有优势，平均池化能更好的保存原图像多有的信息，而最大池化则具有更好的抗噪声性能。

平均池化就是取矩阵所有数的平均数。可以理解为一个所有元素都相同的卷积核，其卷积核如下：

$$P_{m \times m} = \begin{bmatrix} \frac{1}{m^2} & \cdots & \frac{1}{m^2} \\ \vdots & \ddots & \vdots \\ \frac{1}{m^2} & \cdots & \frac{1}{m^2} \end{bmatrix} \quad (4-2)$$

最大池化则是不同于普通的卷积核，它是选取矩阵里面的最大数，相比于平均池化，最大池化拥有的最大的优点就是其对于噪声的抗性相对较高一些。平均池化明显的会把噪声信息全部保留下来，而最大池化显然只会保留最大值上的噪声信息，显然比平均池化更具有鲁棒性[8]。这样的分析为我们提供一个选择池化层的选择方案：当输入的信息显然的信噪比不高的前提下，最大池化是一个更加适合的选择，而当图像信噪比很高并且有用的信息量比较集中的时候，显然平均池化是个更加明智的决策。然而最大池化也有其不足点就是随着噪声的消减，其也会减去一部分有用的信息。




图 4-5 卷积神经网络训练成功后各个层的特征图（数据集一）

Figure 4-5 Feature maps of layers flowing trained convolutional neural network (No.1 data sets)




图 4-6 卷积神经网络训练成功后各个层的特征图（数据集二）

Figure 4-6 Feature maps of layers flowing trained convolutional neural network (No.2 data sets)

上层是一组数据分别的星象和空间碎片通过各个层产生的特征图像，左起第一张是

原图。下层是另一组数据集的空间碎片和星象通过卷积神经网络各个层产生的特征图。

从图 4-5 图 4-6 可以粗略看出卷积神经网络提取图像特征信息的过程。卷积神经网络的最后一层是全连接层，无法画出特征图像。

4.3 学习参数的选取方法

4.3.1 目前研究采用的选取方法

在搭建好神经网络之后仍有一些参数需要确定才能开始训练网络，这些参数包括学习率，训练批次数等等。其中最为重要的就是选取一个合适的学习率。学习率可以理解为一种学习的步长。在梯度下降中，学习就是沿着梯度反方向一步一步走到局部极值的过程。倘若学习率过大，则步长过大很容易错过最优解。若是学习率太小，又会导致学习时间过长，效率低下。那么如何选取学习率就成了神经网络里面备受关注的话题之一了。

2015 年 Leslie N. Smith 在其论文里提出了一种选择学习率的方法，就是从一个最低的学习率开始训练网络，依次指数提高学习率，然后画出损失图，可以有效地选取最优学习率。（Cyclical Learning Rates for Training Neural Networks）这是一个可行的方法，但仍有一定的不确定性。我们所搭建的神经网络的权重一开始是随机产生的，就像一幅地图，出生的位置是随机的，但目的地却是唯一的，这样单次的成功并不意味着这个学习率就是最好的，随机性导致的不确定性使得我们要考虑寻找一个更加稳定的学习率参数。本文选用的是皮尔森检验的筛选学习率参数的方法。

4.3.2 基于皮尔森检验的筛选方法

在最开始的试验中，我们采用逐步下降的学习率来训练我们的卷积神经网络模型，但都没有取得良好的结果。于是，改变策略采用固定的学习率，固定的学习率有这样几个好处，首先在学习率足够低的情况下具有更高的概率收敛到局部最优解。其次是每次训练的时间较为稳定，不会有剧烈的波动。虽然固定的学习率在机器学习中很少被使用到，但是本文处理数据的特殊性，恰巧适用这种方法。

虽然现在大量的搭建神经网络的文章使用的也是固定的学习率，但是目前并没有明确的计算公式，大都是根据经验来定学习率参数。在本文里，我们使用皮尔森检验法来

筛选可用的学习率。由于最初的参数是随机的，所以即使同一学习率也会出现有的时候可以训练成功，有的时候训练失败。对此，我们使用皮尔森检测的目的就是筛选成功概率最高的学习率。首先假设：

H_0 ：每次试验训练的成功收敛的概率大于等于 0.8。

皮尔森检测公式为：

$$\chi^2 = \sum_{i=1}^k \frac{\left(\frac{n_i - p_i}{\frac{p_i}{n}}\right)^2}{\frac{p_i}{n}} \quad (4-3)$$

其中 $k = 2$, $p_1 = 0.8$, $n = 5$, $p_2 = 0.2$, 经查表得 $\chi_{0.05}^2(1) = 3.84$, 带入公式里面计算得当 n_i 大于等于 2.25 的时候才能满足 $\chi^2 < \chi_{0.05}^2(1)$ 。所以，我们可以得出结论，只有当 5 次实验中成功 3 次及以上才能确定该学习率满足 H_0 条件，即每次试验训练的成功收敛概率大于等于 0.8。

经过皮尔森检测的结果，我们在寻找合适的学习率的原则就是训练五次，成功收敛三次即是合格。之后把经筛选出的合格的学习率再每一组挑选训练时成功收敛的 20 组结果来计算最后的分类正确率，取正确率高的一组为最后选取的学习率参数。

4.4 结果及讨论

本章主要叙述了所用的特殊的数据格式以及对此所搭建的卷积神经网络的结构，卷积神经网络各个参数如何选取。在经过训练后成功收敛的卷积神经网络可以用与之前训练数据来源相同的另一组数据进行测试。下面是分别两组测试数据集的各个学习率的准确率统计图：




图 4-7 数据集一在不同学习率下的 NPV 曲线

Figure 4-7 No.1 data sets' NPV curve in different learning rate




图 4-8 数据集二在不同学习率下的 NPV 曲线

Figure 4-8 No.2 data sets' NPV curve in different learning rate

上两图分别是两组数据集的 NPV (negative predictive value) 曲线图:

$$NPV = \frac{\text{successfully predicted negative samples}}{\text{total negative samples}} \quad (4-4)$$

在本章的试验中, 阴性样本 (negative sample) 为星象, 阳性样本 (positive sample) 为空间碎片。NPV 等于用在一次测试中预测正确的星象样本除以星象样本的总数, 代表了星象样本测试的准确率。上图四种颜色的曲线分别代表了通过皮尔森检验筛选出的四个学习率分别训练的同样网络最后测试的多组数据的准确率。可以明显看出准确率很高基本都在 99% 以上, 这和星象数据样本量很大有一定的关系。星象数据量远大于空间碎片的数据量, 导致训练集中星象样本集的不重复率远大于空间碎片样本集, 这也是 NPV 如此高的原因之一。




图 4-9 数据集一在不同学习率下的 PPV 曲线

Figure 4-9 No.1 data sets' PPV curve in different learning rate




图 4-10 数据集二在不同学习率下的 PPV 曲线

Figure 4-10 No.2 data sets' PPV curve in different learning rate

上图是两组数据集的 PPV (positive predictive value) :

$$PPV = \frac{\text{successfully predicted positive samples}}{\text{total positive samples}} \quad (4-5)$$

上图显示大体上空间碎片的分类的准确率高于 91%，下面是和 SExtractor 软件对比图：




图 4-11 卷积神经网络和 SExtractor 准确率对比图

Figure 4-11 Accuracy comparison between Convolutional Neural Network and SExtractor

图 4-11 横坐标轴为作为阈值的长短比，在 4.1 节中介绍了 SExtractor 用于分类时采用的一般是提取的目标的长短比，当长短比越接近 1 的时候也就是目标越接近圆形。由于一些原因会使 SExtractor 提取目标中心坐标时产生偏差，进而让 SExtractor 在算长短比的时候产生误差。上图显示当选长短比为 1.2 作为阈值的时候，即长短比低于 1.2 的目标会划为空间碎片其他的划为星象，有最大的准确率接近 80%，而本文所用的卷积神经网络会使准确率提升到接近 99%。上图所用的准确率包括星象和空间碎片的综合准确率。

第五章 CNN 对信噪比耐受性的评估

从神经网络创建以来，神经网络对信噪比的鲁棒性一直就不算是研究的重点之一。原因之一就是目前用于神经网络的训练的数据集信噪比很高，并不存在信噪比会影响神经网络准确性。第二，卷积神经网络从理论推导来说，它的很多功能（最大池化，分批训练，正则化数据等等）都具有减弱噪声的作用。然而天文图像具有它的特殊性，天文图像的信噪比相对于普通图像较低，天文图像的主要内容具有简单的几何形体，更容易产生过拟合的问题。天文图像的噪声来源主要有：硬件噪声，星象的点扩散现象^{[43][44]}。硬件噪声指的就是 CCD 相机拍摄过程中产生的噪声。现代天文望远镜一般使用的大型光学望远镜后面的负责采集图片的单元就是 CCD 相机了，天文学级的 CCD 相机因为做工优良，所以在热噪声方面干扰很小，它的硬件噪声主要集中在散粒噪声，光子噪声和暗电流噪声等等。

散粒噪声是目前 CCD 相机的主要噪声来源，由载流子的突然出现和消失产生的，与电流的大小相关。当图像呈现低亮度低反差时，散粒噪声可能会成为图像中的主要噪声。

光子噪声，比较容易理解，光子具有波粒二象性，当其发射和被相机接收时会展现其粒子性，因此会有一定的随机性，这个噪声是 CCD 相机无法避免的噪声。

暗电流噪声生成的原因是其 CCD 相机内部的热运动形成的微弱的电流。因其即使在毫无光照的条件下仍然会存在，所以称之为暗电流。其又可以细分为扩散暗电流和表面暗电流两种。

5.1 对于 CNN 削弱噪声的理论推导

由于本文所使用的数据的特殊性，即数据具有较低的信噪比，那么研究噪声对神经网络的影响就是做这个课题必须的环节了。首先，我们先从理论上推导噪声是否会在神经网络传播过程中收到极大的抑制甚至是消失。下面是加入噪声后各个网络层的输入输出。这里我们采用的信噪比计算公式为：

$$SNR = \frac{\mu_{sig} - \mu_{bkg}}{\sqrt{\frac{\sum_{i=1}^n \sum_{j=1}^n \left(x_i^j - \frac{\sum_{i=1}^n x_i^j}{n} \right)^2}{n^2}}} \quad (5-1)$$

其中 μ_{sig} 是信号的平均灰度值， μ_{bkg} 是背景的平均灰度值， n 是图像的行数， x_i^j 是第

i 行 j 列的灰度值。

(1) 卷积层对噪声的影响, 其中 $X_{n \times n}$ 是原始信息矩阵, $A_{n \times n}$ 是噪声矩阵, $W_{m \times m}$ 是卷积核:

$$(X_{n \times n} + A_{n \times n}) \otimes W_{m \times m} = X_{n \times n} \otimes W_{m \times m} + A_{n \times n} \otimes W_{m \times m} \quad (5-2)$$

由上面公式可以看出, 卷积层并没有抑制噪声功率的功能, 即通过卷积层之后噪声功率并未明显减弱。

(2) 池化层对噪声的影响, 分为平均池化和最大池化, 显然平均池化类似于上面的卷积层, 并且显然平均池化甚至不能减少一点噪声的功率, 下面我们讨论最大池化:

$$(X_{n \times n} + A_{n \times n}) \otimes P_{m \times m} = X_{n \times n} \otimes P_{m \times m} + A_{n \times n} \otimes P_{m \times m} \quad (5-3)$$

$$P_{m \times m} = \begin{bmatrix} \frac{1}{m^2} & \cdots & \frac{1}{m^2} \\ \vdots & \ddots & \vdots \\ \frac{1}{m^2} & \cdots & \frac{1}{m^2} \end{bmatrix}$$

$$\text{Max}(X_{n \times n} + A_{n \times n}) \geq \text{Max}(X_{n \times n}) \quad (5-4)$$

最大池化层是具有一定的抗噪声能力的, 从公式 (5-4) 可以看出来, 最大池化仅仅保留了局部像素最大值的噪声信号, 如此就削减了局部区域内其他像素点的噪声信号, 但相对的也放大了单个点的噪声信号。

对于全连接层, 可以看作为卷积核是一个点的特殊的卷积层, 因此全连接层也并不具备减弱噪声的能力。从上面理论推导可以了解到, 本文所设计的卷积神经网络在理论上不具备抗噪声的性能, 而由于本文所用的数据集的特殊性, 抗噪声能力显然是很重要的指标之一。下一小节将讲述用不同信噪比的图像测试的网络的抗噪声性能的评估以及改进方法。

5.2 实验配置和结果

我们设计实验采用的对比试验方法, 我们预计用不同信噪比的数据对我们设计的卷积神经网络进行测试。

首先, 我们用软件生成不同信噪比的图片, 信噪比分别从 1.2 到 6.2, 然后分别进行学习训练。实验结果表明, 6dB 可以作为一个分水岭, 信噪比低于 6dB 的数据集无法完成训练过程, 即无法使卷积神经网络收敛。纵坐标的 TPR (true positive rate) 是用预测正确的空间碎片的数量除以预测正确的空间碎片的数量与被误判为空间碎片的数量之

和。

本次有三个对比试验，把数据分为大于 6db 的和小于 6db 的两部分，分别是高信噪比数据集和低信噪比数据集。

首先，用低信噪比数据集作为训练集，用全部两部分数据集为测试集。经过十次实验，低信噪比数据集作为训练集无法使卷积神经网络收敛，也就是无法达到学习的目的。

其次，第二个实验是用高低两个数据集共同作为训练集，并且两部分也共同作为测试集，效果和上一个实验相同。可以得出结论，当训练数据中混有一定数量的过低信噪比的图片的时候，会使网络“迷惑”无法达到训练学习的目的，即卷积神经网络无法通过训练学习来提取训练集中的有效特征。

最后，用高信噪比数据集作为训练数据，全部数据集作为测试数据，得出的结果如下图：




图 5-1 不同信噪比下的卷积神经网络的正确率

Figure 5-1 TPR of Convolutional Neural Network in different SNR

从图 5-1 中明显看出在信噪比小于 6db 的时候卷积神经网络无法完成工作。基于的数据可以判断本文所用的卷积神经网络对于输入图像的要求是其信噪比高于或等于 6db。

那么关于数据集信噪比研究的最后一个问题就是，低信噪比 < 6db 的数据是否可以通过图像预处理的方式提高其信噪比到 6db 以上。

关于这个问题，本文使用了简单的图像预处理，整幅图像减去图像的整体平均灰度值这个方法，经过测试，实验证明了该方法对于此种天文图像具有可行性。低信噪比数据集经过图像预处理均可达到要求即信噪比大于等于 6db。

5.3 本章小结

本章着重研究了上一章节搭建的卷积神经网络对于训练测试数据集的信噪比上的鲁棒性。首先，第一小节从理论上推导出在卷积神经网络的训练阶段和测试阶段噪声并不会被消除，噪声会对最后的分类产生影响。然后在第二小节中，通过对比试验，测试出低信噪比的图像会令卷积神经网络“致盲”。卷积神经网络的工作原理和人眼的工作原理是可以进行类比的，人眼进行识别时也是具有一定的识别区间的，当信噪比低的时候，人眼所具有的识别率可能不会高于神经网络。最后，本章提出了一种可行的针对本文搭建的卷积神经网络识别低信噪比图像的方法，即训练和测试用的数据集在进入卷积神经网络之前先进行一步数据的预处理。对于本文所针对的天文图像，图像预处理完全可以使数据集里面的低信噪比数据的信噪比提升到满足卷积神经网络的要求。

第六章 总结与展望

从上世纪以来，太空垃圾与日俱增，妨碍了正常的太空行为。在这种背景下，对于空间碎片的研究逐渐加强。越来越多的研究指向通过望远镜拍摄的天文图象探测空间碎片，但天文图象相对于普通相片具有一定的特殊性，其低信噪比以及引力透镜等作用下产生的点扩散现象都是望远镜探测的难点。近几十年的研究表明，神经网络相对于传统的复杂非线性图像处理方式具有了更优越的性能以及可靠性。很多的天文观测上常用的开源图像处理的软件是 **SExtractor**，本文通过实验等方法探究了在天文图像处理的领域卷积神经网络相对该款软件是否具有优势。

本文主要的研究工作以及思路如下：

(1) 对 **SExtractor** 软件工作原理进行了分析和推导，总体来看，该软件处理图像分为两步：第一步，寻找天光背景并去除背景；第二步，对剩下的图像进行图像处理，并采用简单的神经网络进行分类提取坐标。

(2) 研究并探讨了深度学习中的卷积神经网络，对卷积神经网络的起源与发展做了详细的介绍及解释。

(3) 实验使用的是来自紫金山天文台的观测图像，搭建卷积神经网络进行训练和验证。针对卷积神经网络的参数选择，提出了基于皮尔森检测的筛选学习率的方法。

(4) 针对本文搭建的卷积神经网络对噪声的耐受力，设计了对比试验，验证了所搭建的卷积神经网络所能接受的信噪比的阈值，并提出了用图像预处理的方法改进这种状况。

深度学习作为人工智能道路上的一次重要的探索，其在各个领域都展示了优异的性能，本文的实验室其在天文图像处理的一次尝试。相信随着深度学习的发展，在天文图像处理领域会有越来越卓越的效果。

参考文献

- [1] Walls R, Gaylor D, Reddy V, et al. Assessing the IADC Space Debris Mitigation Guidelines: A Case for Ontology-based Data Management[C]// Advanced Maui Optical and Space Surveillance Technologies Conference. Advanced Maui Optical and Space Surveillance Technologies Conference, 2016.
- [2] 马楠, 贵先洲. 国外空间碎片清除计划[J]. 国际太空, 2013(2):64-69.
- [3] 王国语. 空间碎片国际机制发展趋势分析[J]. 航天器环境工程, 2015, 32(2):147-152.
- [4] 陈蓉, 申麟, 高朝辉, 等. 空间碎片减缓技术发展研究[J]. 科技创新导报, 2014(28):4-5.
- [5] 孙荣煜. 空间碎片光学观测中若干问题研究[J]. 天文学报, 2015, 56(1):89-90.
- [6] 刘林, 杨健, 王建华. 近地轨道空间碎片清除策略分析[J]. 装备学院学报, 2013, 24(2):70-73.
- [7] Geirhos, R., Janssen, D.H., Schutt, H.H., Rauber, J., Bethge, M., Wichmann, F.A., Comparing deep neural networks against humans: object recognition when the signal gets weaker. 2017. arXiv preprint arXiv:1706.06969 .
- [8] Abraham, S., Aniyan, A., Kembhavi etc, Detection of bars in galaxies using a deep convolutional neural network. 2017. arXiv preprint arXiv:1711.04573 .
- [9] Bertin, E., Arnouts, S., SExtractor: Software for source extraction. Astronomy and Astrophysics Supplement Series 1996. 117, 393-404.
- [10] 尹宝才, 王文通, 王立春. 深度学习研究综述[J]. 北京工业大学学报, 2015(1):48-59.
- [11] 孙志远, 鲁成祥, 史忠植, 等. 深度学习研究与进展[J]. 计算机科学, 2016, 43(2):1-8.
- [12] Cohen, N., Sharir, O., Levine, Y., Tamari, R., Yakira, D., Shashua, A., Analysis and design of convolutional networks via hierarchical tensor decompositions. 2017. arXiv preprint arXiv:1705.02302 .
- [13] 陈先昌. 基于卷积神经网络的深度学习算法与应用研究[D]. 浙江工商大学, 2014.
- [14] Gieseke, F., Bloemen, S., van den Bogaard, C., Heskes, T., Kindler, J., Scalzo, R.A., Ribeiro, V.A., van Roestel, J., Groot, P.J., Yuan, F., et al., Convolutional neural networks for

- transient candidate vetting in large-scale surveys. *Monthly Notices of the Royal Astronomical Society* 2017.472, 3101-3114.
- [15] Gupta, H., Jin, K.H., Nguyen, H.Q., McCann, M.T., Unser, M., Cnnbased projected gradient descent for consistent image reconstruction. 2017.arXiv preprint arXiv:1709.01809 .
- [16] 焦李成, 杨淑媛, 刘芳,等. 神经网络七十年:回顾与展望[J]. 计算机学报, 2016, 39(8):1697-1716.
- [17] Hon, M., Stello, D., Yu, J., Deep learning classication in asteroseismology. *Monthly Notices of the Royal Astronomical Society* . 2017.
- [18] Isobe, S., Asami, A., Asher, D., Hashimoto, N., Nakano, S.i., Nishiyama, K., Ohshima, Y., Terazono, J., Umehara, H., Urata, T., et al., A new 1 m telescope for space debris survey observations. *Advances in Space Research* 2004. 34, 917-920.
- [19] Ji, P., Zhang, T., Li, H., Salzmann, M., Reid, I., Deep subspace clustering network, in: *Advances in Neural Information Processing Systems*, 2017. pp. 23-32
- [20] Karpathy, A., Johnson, J., Fei-Fei, L., Visualizing and understanding recurrent networks. 2015.arXiv preprint arXiv:1506.02078 .
- [21] Khalifa, N.E.M., Taha, M.H.N., Hassanien, A.E., Selim, I., Deep galaxy: Classication of galaxies based on deep convolutional neural networks. 2017. arXiv preprint arXiv:1709.02245 .
- [22] 马锐. 人工神经网络原理[M]. 机械工业出版社, 2014.
- [23] Koenderink, J., Valsecchi, M., van Doorn, A., Wagemans, J., Gegenfurtner, K., Eidolons: Novel stimuli for vision research. *Journal of Vision* 2017. 17, 7-7.
- [24] Kuo, C.C.J., Understanding convolutional neural networks with a mathe370 matical model. *Journal of Visual Communication and Image Representation* 2016. 41, 406-413.
- [25] Laas-Bourez, M., Coward, D., Klotz, A., Boer, M., A robotic telescope network for space debris identication and tracking. *Advances in Space Research* 2011. 47, 402-410.
- [26] Lin, H.W., Chen, Y.T., Wang, J.H., Wang, S.Y., Yoshida, F., Ip, W.H., Miyazaki, S., Terai, T., Machine learning based real bogus system for hsc-ssp moving object detecting pipeline. 2017. arXiv preprint arXiv:1704.06413 .

- [27] Linares, R., Furfaro, R., Space object classification using deep convolutional neural networks, in: Information Fusion (FUSION), 2016 19th International Conference on, IEEE. 2016. pp. 1140-1146.
- [28] 卢宏涛, 张秦川. 深度卷积神经网络在计算机视觉中的应用研究综述[J]. 数据采集与处理, 2016, 31(1):1-17.
- [29] 陈先昌. 基于卷积神经网络的深度学习算法与应用研究[D]. 浙江工商大学, 2014.
- [30] 李彦冬, 郝宗波, 雷航. 卷积神经网络研究综述[J]. 计算机应用, 2016, 36(9):2508-2515.
- [31] Montojo, F., Fors, O., Muinos, J., Nunez, J., Lopez-Morcillo, R., Baena, R., Boloix, J., Lopez-Moratalla, T., Merino, M., The fabra-roa telescope at montsec (tfrm): A fully robotic wide-eld telescope for space surveillance and tracking. 2011. arXiv preprint arXiv:1109.5918 .
- [32] Morii, M., Ikeda, S., Tominaga, N., Tanaka, M., Morokuma, T., Ishiguro, K., Yamato, J., Ueda, N., Suzuki, N., Yasuda, N., et al., Machine-learning selection of optical transients in the subaru/hyper supprime-cam survey. Publications of the Astronomical Society of Japan 68. 2016.
- [33] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6):1229-1251.
- [34] Nguyen, A., Yosinski, J., Clune, J., Deep neural networks are easily fooled: High condence predictions for unrecognizable images, in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015. pp. 427-436.
- [35] 盛银. 递归神经网络的稳定性分析[D]. 华中科技大学, 2015.
- [36] Qayyum, A., Anwar, S.M., Majid, M., Awais, M., Alnowami, M., Medical image analysis using convolutional neural networks: A review. 2017. arXiv preprint arXiv:1709.02250 .
- [37] Ronen, R., Why & when deep learning works: Looking inside deep learnings. 2017. arXiv preprint arXiv:1705.03921 .
- [38] Shwartz-Ziv, R., Tishby, N., Opening the black box of deep neural net-works via information. 2017. arXiv preprint arXiv:1703.00810 .
- [39] 吕国豪, 罗四维, 黄雅平,等. 基于卷积神经网络的正则化方法[J]. 计算机研究与发

- 展, 2014, 51(9):1891-1900.
- [40] Sun, R., Zhao, C., Zhang, X., Improving the precision of astrometry for space debris. The Astronomical Journal, 2014.147, 58.
- [41] Sun, R.y., Zhan, J.w., Zhao, C.y., Zhang, X.x., Algorithms and applications for detecting faint space debris in geo. Acta Astronautica, 2015. 110, 9-17.
- [42] Sun, R.Y., Zhao, C.Y., A new source extraction algorithm for optical space debris observation. Research in Astronomy and Astrophysics 2013. 13, 604.
- [43] Sun, R.Y., Zhao, C.Y., Lu, Y., An improved astrometric calibration technique for space debris observation. Research in Astronomy and Astrophysics, 2016. 16, 029.
- [44] Sun, R.Y., Zhao, C.Y., Zhang, Y.P., An innovative image reconstruction method for high-precision astrometry. Publications of the Astronomical Society of Japan 65. 2013.
- [45] Szegedy, C., Vanhoucke, V., Ioe, S., Shlens, J., Wojna, Z., Rethinking the inception architecture for computer vision, in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016. pp. 2818-2826.
- [46] Zeiler, M.D., Fergus, R., Visualizing and understanding convolutional networks, in: European conference on computer vision, Springer. 2014. pp. 818-833.
- [47] 常亮, 邓小明, 周明全, 等. 图像理解中的卷积神经网络[J]. 自动化学报, 2016, 42(9):1300-1312.
- [48] 邱立杰, 彭青玉, 张艳. FITS 图像三维显示和坐标转换[J]. 微计算机信息, 2011, 27(3):172-174.
- [49] 吴光节. CCD 光谱的 IRAF 和 FITS 格式转换[J]. 天文研究与技术, 1993(4):53-58.
- [50] 崔辰州, 李文, 于策, 等. FITS 数据文件的检索和访问[J]. 天文研究与技术:国家天文台台刊, 2008, 5(2):116-123.